

**PERAMALAN CURAH HUJAN DENGAN
PEMBOBOTAN DERET WAKTU
BERBASIS SPATIO TEMPORAL**

***RAINFALL FORECASTING USING TIME
SERIES WEIGHTING BASED ON
SPATIAL TEMPORAL***

Tugas Akhir

Diajukan untuk memenuhi salah satu syarat memperoleh
gelar sarjana dari program studi Sarjana Sains Data
Direktorat Kampus Surabaya
Universitas Telkom

CALISTA GHEA ARDHANI
NIM 1206220010



**PROGRAM STUDI SARJANA SAINS DATA
DIREKTORAT KAMPUS SURABAYA
UNIVERSITAS TELKOM
SURABAYA
2025**

LEMBAR PENGESAHAN

TUGAS AKHIR

PERAMALAN CURAH HUJAN DENGAN PEMBOBOTAN DERET WAKTU BERBASIS SPATIO TEMPORAL

Telah disetujui dan disahkan untuk memenuhi syarat memperoleh
gelar pada Program Studi Sarjana Sains Data
Direktorat Kampus Surabaya, Universitas Telkom

CALISTA GHEA ARDHANI

NIM: 1206220010

Surabaya, 1 Desember 2025

Menyetujui

Regita Putri Permata S.Stat., M.Stat.
NIP: 22960008

(Pembimbing 1)

Rifdatun Ni'mah S.Si., M.Si.
NIP: 22900008

(Pembimbing 2)

Dosen Penguji Satu
NIP: Dosen Penguji Satu

(Penguji 1)

Dosen Penguji Dua
NIP: Dosen Penguji Dua

(Penguji 2)

Ketua Program Studi Sarjana
Sains Data

Moh. Hamim Zajuli Al Faroby, S.Si., M.Mat.
NIP: 23950023

Lembar Pernyataan Orisinalitas



Nama : CALISTA GHEA ARDHANI
NIM : 1206220010
Alamat : Jl. Residen Sudirman No 68K
No. Telp : 081213770725
Email : calistaghea@student.telkomuniversity.ac.id

Menyatakan bahwa Tugas Akhir ini merupakan karya orisinal saya sendiri. Atas pernyataan ini, saya siap menanggung risiko atau sanksi yang dijatuhkan kepada saya apabila kemudian ditemukan adanya pelanggaran terhadap kejujuran akademik atau etika keilmuan dalam karya ini, atau ditemukan bukti yang menunjukkan ketidakaslian karya ini.

Surabaya, 1 Desember 2025

CALISTA GHEA ARDHANI

ABSTRAK

Curah hujan merupakan salah satu parameter meteorologis penting yang memengaruhi berbagai sektor, seperti pertanian, infrastruktur, dan mitigasi bencana. Di kota metropolitan seperti Surabaya, prediksi curah hujan yang akurat sangat diperlukan untuk mendukung perencanaan kota dan pengurangan risiko bencana hidrometeorologi. Namun, karakteristik curah hujan bersifat kompleks karena dipengaruhi oleh faktor ruang (spasial) dan waktu (temporal) secara bersamaan. Oleh karena itu, diperlukan pendekatan pemodelan yang tidak hanya mempertimbangkan aspek deret waktu, tetapi juga keterkaitan antar lokasi geografis. Penelitian ini bertujuan untuk membangun model prediksi curah hujan bulanan menggunakan pendekatan spasio-temporal, dengan mempertimbangkan keterkaitan pola curah hujan antar wilayah dan waktu. Model yang digunakan adalah STARMA (Space-Time Autoregressive Moving Average). Tiga skema pembobotan dibandingkan dalam penelitian ini, yaitu bobot seragam, bobot berdasarkan jarak, dan bobot berbasis korelasi silang. Model STARMA dengan pembobotan adaptif ini diharapkan dapat menjadi dasar dalam pengembangan sistem peringatan dini serta kebijakan mitigasi dan adaptasi terhadap perubahan iklim secara lebih tepat sasaran. Data curah hujan diperoleh dari citra satelit NASA POWER untuk wilayah Surabaya selama tahun 2015 - 2024.

Kata Kunci: Prediksi Curah Hujan, Spatial Weight Matrix, STARMA, Surabaya.

Abstract

Rainfall is one of the key meteorological parameters that influences various sectors such as agriculture, infrastructure, and disaster mitigation. In metropolitan cities like Surabaya, accurate rainfall prediction is crucial to support urban planning and reduce the risk of hydrometeorological disasters. However, rainfall patterns are complex, as they are simultaneously influenced by spatial and temporal factors. Therefore, a modeling approach that considers both time series aspects and the interrelationship between geographical locations is required. This study aims to develop a daily rainfall prediction model using a spatio-temporal approach, taking into account the spatial and temporal patterns of rainfall across regions. The model employed is the STARMA (Space-Time Autoregressive Moving Average) model. Three weighting schemes are compared in this study: uniform weights, distance-based weights, and cross-correlation-based weights. The STARMA model with adaptive weighting is expected to serve as a foundation for the development of early warning systems as well as for more targeted climate change mitigation and adaptation policies. Rainfall data were obtained from NASA POWER satellite imagery for the Surabaya region covering the years 2015 - 2024.

Keywords: Rainfall Prediction, Spatial Weight Matrix, STARMA, Surabaya.

Kata Pengantar

Puji syukur saya panjatkan kepada Tuhan Yang Maha Esa atas segala rahmat-Nya sehingga skripsi berjudul "Peramalan Curah Hujan dengan Pembobotan Deret Waktu Berbasis Spasio-Temporal" ini dapat diselesaikan dengan baik. Skripsi ini disusun sebagai salah satu syarat kelulusan pada Program Studi Sains Data Universitas Telkom Kampus Surabaya.

Penelitian ini bertujuan untuk memprediksi curah hujan secara lebih akurat menggunakan model STARMA berbasis spasio-temporal. Diharapkan hasilnya dapat bermanfaat bagi sistem peringatan dini dan kebijakan mitigasi bencana.

Saya mengucapkan terima kasih kepada dosen pembimbing, seluruh pengajar, keluarga, serta teman-teman yang telah memberikan dukungan dan bantuan selama proses penyusunan skripsi ini. Kritik dan saran sangat saya harapkan demi penyempurnaan di masa mendatang.

Surabaya, 1 Desember 2025
CALISTA GHEA ARDHANI

Daftar Isi

Lembar Persetujuan	i
Lembar Pernyataan Orisinalitas	ii
Abstrak	iii
<i>Abstract</i>	iv
Kata Pengantar	v
Daftar Isi	vi
Daftar Tabel	viii
Daftar Gambar	ix
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	4
1.3 Tujuan Penelitian	5
1.4 Batasan dan Asumsi Penelitian	5
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	6
II Landasan Teori	8
2.1 Penelitian Terkait	8
2.2 Peramalan	12
2.3 Menguji Kestasioneran Data	13
2.4 ARIMA Model	14
2.5 Model STARMA (<i>Space-Time Autoregressive Moving Average</i>)	16
2.6 Spatial Weight Matrix (SWM)	21
2.6.1 Konsep Dasar Spatial Weight Matrix	21

2.6.2	Bentuk Umum Matriks SWM	22
2.6.3	Jenis-jenis Pembobotan	22
2.6.4	Peran SWM dalam Model STARMA	24
III	Metodologi Penelitian	25
3.1	Metode Penelitian	25
3.2	Sumber Data	26
3.2.1	Data Sekunder	26
3.3	Pra-pemrosesan Data	27
3.4	Analisis Eksploratif Pola Spasio-Temporal Curah Hujan	28
3.5	Pengecekan Kestasioneran Data	28
3.6	Pembentukan <i>Spatial Weight Matrix</i>	28
3.7	Pembangunan Model ARIMA	28
3.8	Pembangunan Model STARMA	29
3.9	Evaluasi	29
3.10	Harapan Hasil Peramalan	29
IV	Hasil dan Pembahasan	30
4.1	Eksplorasi Data	30
4.1.1	Statistika Deskriptif	30
4.1.2	Pola Curah Hujan Kelima Wilayah di Surabaya	31
4.1.3	Karakteristik dengan BoxPlot	34
4.1.4	Analisis Temporal Curah Hujan	35
4.1.5	Analisis Korelasi Spatio Temporal	36
4.2	ARIMA	36
4.2.1	Stasioner Data	36
4.2.2	Estimasi Parameter	40
4.2.3	Model Fitting	41
4.2.4	Hasil Forecasting ARIMA	42
4.3	STARIMA	46
4.3.1	Stasioner Data	46
4.3.2	Bobot Seragam	49
4.3.3	Bobot Invers Jarak	58
4.3.4	Bobot Lokasi Normalisasi Korelasi Silang	66
4.4	Hasil Peramalan	75
V	Kesimpulan dan Saran	77
5.1	Kesimpulan	77
5.2	Saran	77
	Daftar Pustaka	79
	Lampiran	82

Daftar Tabel

3.1	Data Curah Hujan Bulanan Berdasarkan Wilayah	26
4.1	Statistika Deskriptif	30
4.2	Tabel Korelasi Setiap Wilayah	36
4.3	Nilai Lambda Semua Wilayah	37
4.4	Hasil Uji ADF	38
4.5	Perbandingan RMSE Tanpa Transformasi dan Dengan Transformasi Box-Cox	40
4.6	Estimasi Parameter ARIMA	41
4.7	Hasil Model Fitting ARIMA	42
4.8	Nilai Lambda Semua Wilayah	47
4.9	Hasil Uji ADF	48
4.10	Estimasi Parameter	52
4.11	Hasil Model Fitting STARIMA	53
4.12	Estimasi Parameter	61
4.13	Hasil Model Fitting STARIMA	61
4.14	Estimasi Parameter	69
4.15	Hasil Model Fitting STARIMA	70
4.16	Perbandingan RMSE ARIMA dan STARIMA per Wilayah . . .	76

Daftar Gambar

3.1	Diagram Alur Metodologi Penelitian	25
3.2	Data NASA Wilayah Surabaya	26
4.1	Pola Curah Hujan Wilayah Barat	31
4.2	Pola Curah Hujan Wilayah Selatan	32
4.3	Pola Curah Hujan Wilayah Tengah	32
4.4	Pola Curah Hujan Wilayah Timur	33
4.5	Pola Curah Hujan Wilayah Utara	33
4.6	Boxplot Kelima Wilayah di Surabaya	34
4.7	Seasonal Decompose Semua Wilayah	35
4.8	Plot ACF dan PACF Wilayah Barat (Sebelum)	39
4.9	Plot ACF dan PACF Wilayah Barat (Sesudah)	39
4.10	Hasil Forecasting Wilayah Barat	42
4.11	Hasil Forecasting Wilayah Selatan	43
4.12	Hasil Forecasting Wilayah Tengah	44
4.13	Hasil Forecasting Wilayah Timur	45
4.14	Hasil Forecasting Wilayah Utara	46
4.15	Hasil Grafik Curah Hujan Setelah Transformasi dan Differencing	48
4.16	STACF dan STPACF SLAG 0	49
4.17	STACF dan STPACF SLAG 1	50
4.18	Hasil Peramalan Wilayah Barat	54
4.19	Hasil Peramalan Wilayah Selatan	55
4.20	Hasil Peramalan Wilayah Tengah	56
4.21	Hasil Peramalan Wilayah Timur	57
4.22	Hasil Peramalan Wilayah Utara	58
4.23	STACF dan STPACF SLAG 0	59
4.24	STACF dan STPACF SLAG 1	60
4.25	Hasil Peramalan Wilayah Barat	62
4.26	Hasil Peramalan Wilayah Selatan	63
4.27	Hasil Peramalan Wilayah Tengah	64
4.28	Hasil Peramalan Wilayah Timur	65
4.29	Hasil Peramalan Wilayah Utara	66

4.30 STACF dan STPACF SLAG 0	67
4.31 STACF dan STPACF SLAG 1	68
4.32 Hasil Peramalan Wilayah Barat	71
4.33 Hasil Peramalan Wilayah Selatan	72
4.34 Hasil Peramalan Wilayah Tengah	73
4.35 Hasil Peramalan Wilayah Timur	74
4.36 Hasil Peramalan Wilayah Utara	75

Bab I

Pendahuluan

1.1 Latar Belakang

Surabaya merupakan salah satu kota metropolitan di Indonesia yang memiliki kepadatan aktivitas ekonomi, sosial, dan infrastruktur yang tinggi. (Saesarin 2020). Terletak di wilayah timur Pulau Jawa, Surabaya berada pada zona iklim tropis basah yang ditandai dengan adanya dua musim, yaitu musim penghujan dan musim kemarau. Kondisi iklim ini menjadikan curah hujan sebagai salah satu elemen penting dalam tata kelola perkotaan. Tingginya intensitas curah hujan dalam waktu singkat di Surabaya dapat menyebabkan genangan atau banjir yang berpotensi mengganggu aktivitas masyarakat dan merusak infrastruktur. (Febriana 2019)

Curah hujan sendiri merupakan salah satu parameter meteorologi yang paling krusial dalam berbagai sektor, seperti pertanian, pengelolaan sumber daya air, mitigasi bencana, serta perencanaan pembangunan wilayah. Curah hujan menunjukkan banyaknya air hujan yang turun dalam suatu wilayah selama periode waktu tertentu. Dalam konteks kota seperti Surabaya, pemahaman terhadap curah hujan sangat penting untuk menunjang kebijakan adaptif dan strategi mitigasi terhadap dampak bencana hidrometeorologi. (Azka et al. 2018)

Dalam beberapa tahun terakhir terjadi ketidakpastian musim yang dipengaruhi oleh perubahan iklim global, termasuk pergeseran waktu dan intensitas musim penghujan maupun kemarau. Hal ini menjadikan upaya untuk memahami karakteristik curah hujan sebagai langkah penting dalam menghadapi tantangan perubahan iklim (Sofia et al. 2018). Salah satu karakteristik penting curah hujan adalah variabilitasnya, baik secara temporal (waktu) maupun spasial (lokasi geografis), yang mencerminkan fluktuasi jumlah serta distribusi hujan.

Untuk mendukung perencanaan dan pengambilan kebijakan yang adaptif, diperlukan model prediksi curah hujan yang akurat. Pemodelan ini bertujuan untuk melihat dan menganalisis pola hujan yang akan terjadi di masa mendatang. Penelitian ini menggunakan data curah hujan berbasis satelit dari NASA

untuk menganalisis dinamika curah hujan dan meramalkan pola curah hujan di wilayah Surabaya. Diharapkan hasil dari peramalan ini dapat digunakan sebagai dasar perencanaan kebijakan perkotaan yang tanggap terhadap risiko bencana dan perubahan iklim.

Forecasting atau peramalan adalah proses membuat prediksi mengenai kejadian di masa depan dengan menggunakan data historis dan pengetahuan saat ini. Tujuannya adalah memberikan dasar yang kuat bagi pengambilan keputusan dalam berbagai bidang. Peramalan tidak selalu harus menghasilkan satu nilai pasti, dalam praktiknya dapat berupa nilai tunggal *point forecast*, interval prediksi, distribusi probabilitas atau kemungkinan terjadinya sesuatu. Proses peramalan melibatkan pengamatan pola masa lampau seperti tren, musiman, atau siklus, yang kemudian dianalisis menggunakan berbagai metode statistik atau teknik pembelajaran mesin (Petrooulos et al. 2021). Terdapat dua jenis metode peramalan yang terdiri dari kualitatif dan kuantitatif. Metode kualitatif mengandalkan pendapat ahli dan bersifat subjektif, biasanya digunakan saat data historis sulit diperoleh. Sebaliknya, metode kuantitatif menggunakan prinsip statistik, lebih objektif, dan mencakup berbagai pendekatan salah satunya yaitu *time series* yang menganalisis pola data berurutan berdasarkan waktu untuk menghasilkan prediksi masa depan (Ruchjana 2019).

Namun, metode peramalan konvensional *time series* murni hanya mempertimbangkan aspek temporal tanpa mengikutsertakan faktor spasial, sehingga kurang optimal dalam menganalisis fenomena seperti curah hujan yang dipengaruhi oleh kondisi geografis wilayah. Itu dibuktikan dalam penelitian yang berjudul "*Enhanced Spatio Temporal Modeling for Rainfall Forecasting: A High Resolution Grid Analysis*" yang menjelaskan bahwa model konvensional seperti ARIMA hanya menangkap aspek temporal dan linier. Tanpa mempertimbangkan korelasi spasial antar lokasi, model model tersebut sering kali gagal memberikan prediksi curah hujan yang akurat terutama ketika diterapkan pada wilayah dengan variasi geografis yang kompleks. Sebaliknya, pendekatan spatio temporal berbasis grid resolusi tinggi merupakan salah satu pendekatan yang relevan dalam konteks iklim dan meteorologi (Alam et al. 2024).

Model spasio-temporal merupakan suatu pendekatan yang menggambarkan fenomena alam dengan mempertimbangkan aspek lokasi (spasial) dan waktu (temporal) (Utami 2017). Dalam proses analisisnya, model ini memperhitungkan adanya ketergantungan antar lokasi pengamatan serta hubungan korelatif yang mungkin muncul dari keterlambatan waktu (lag). Data yang diamati berdasarkan waktu biasanya tidak bersifat independen, melainkan saling berkorelasi dan membentuk pola deret waktu. Model spasio-temporal pertama kali dikembangkan oleh Bilonick dan Nicholas pada tahun 1983, melalui penelitian curah hujan menggunakan tiga pendekatan. Pendekatan pertama berfokus pada aspek temporal dengan mengabaikan pengaruh spasial, yang kedua menekankan pengaruh spasial tanpa mempertimbangkan aspek waktu,

dan yang ketiga menggabungkan keduanya dalam satu analisis (Islami et al. 2021).

Pendekatan spasio-temporal memungkinkan identifikasi kemiripan pola curah hujan antar wilayah dengan memperhatikan hubungan geografis antar lokasi, baik yang berdekatan maupun berjauhan. Salah satu alat penting dalam pendekatan ini adalah *Spatial Weight Matrix*. *Spatial Weight Matrix* merupakan matriks yang merepresentasikan kekuatan hubungan spasial antara suatu lokasi dengan lokasi lainnya (Mukhaiyar et al. 2024). Nilai dalam matriks ini menunjukkan seberapa besar pengaruh satu lokasi terhadap lokasi lain berdasarkan kedekatan geografis, jarak, atau karakteristik spasial tertentu.

Dalam pengembangannya, *Spatial Weight Matrix* dapat dibentuk dalam dua dimensi (menggunakan koordinat horizontal) maupun tiga dimensi (menggabungkan perbedaan ketinggian). Pendekatan tiga dimensi ini menjadi penting ketika fenomena yang diteliti, seperti curah hujan atau muka air tanah, dipengaruhi oleh topografi atau elevasi wilayah. Matrix ini bisa dibentuk dengan berbagai metode seperti bobot berbasis inverse distance, bobot seragam, hingga yang dimodifikasi untuk memasukkan faktor ketinggian (Mukhaiyar et al. 2024).

Dengan menggunakan *Spatial Weight Matrix* yang tepat, model spatio-temporal seperti STARMA (*Space Time Autoregressive Moving Average*) mampu menangkap keterikatan spasial dan temporal secara simultan (Sharma et al. 2025). Model ini mengakomodasi efek pengaruh wilayah sekitar terhadap suatu lokasi, serta mempertimbangkan dinamika temporal yang mempengaruhi dari waktu ke waktu. STARMA menggunakan bobot dan mengintegrasikannya dengan temporal lag untuk menghasilkan prediksi yang lebih akurat terhadap fenomena spasio-temporal seperti curah hujan.

Penggunaan pendekatan spasio-temporal seperti STARMA menjadi semakin relevan di tengah kondisi perubahan iklim yang menyebabkan curah hujan menjadi lebih ekstrem, tidak teratur, dan tidak menentu di berbagai wilayah Indonesia. Oleh karena itu, perancangan model prediksi curah hujan berbasis spasio-temporal tidak hanya memiliki kontribusi dalam pengembangan ilmu, tetapi juga sangat krusial untuk mendukung sistem peringatan dini, kebijakan mitigasi bencana, dan pengelolaan sumber daya air secara berkelanjutan.

Dalam mendukung kebutuhan tersebut, model spasio-temporal seperti STARMA telah dikembangkan dan digunakan untuk menangani fenomena yang melibatkan keterkaitan ruang dan waktu secara simultan. Konsep dasar dari model ini berakar pada penelitian awal oleh Cliff dan Ord pada tahun 1975 melalui pengembangan model STAR (*Space-Time Autoregressive*) serta model lanjutannya, yaitu STARMA (*Space-Time Autoregressive Moving Average*) (Laily 2020). Model STARMA menggabungkan pengaruh lag waktu sebelumnya baik dalam komponen autoregresif maupun *moving average*, yang berlaku tidak hanya secara temporal tetapi juga secara spasial. Model ini digunakan

untuk memodelkan data yang menunjukkan adanya autokorelasi spasial, yaitu keterkaitan antara nilai-nilai di lokasi yang berbeda dalam suatu sistem spasio-temporal (Rathod et al. 2018).

Berbagai pendekatan telah digunakan dalam peramalan curah hujan, mulai dari model *time series* konvensional seperti ARIMA yang menangani pola linier, hingga metode pembelajaran mesin seperti ANN, SVR, dan LSTM untuk menangani pola non-linier. Model *hybrid machine learning* menjadi alternatif menjanjikan karena mampu meningkatkan akurasi prediksi melalui kombinasi teknik dekomposisi sinyal dan algoritma optimasi, meskipun keberhasilannya sangat bergantung pada arsitektur dan pemrosesan data yang tepat (Latif et al. 2022).

Penelitian di Andhra Pradesh menggabungkan ARIMA, LSTM, XGBoost, dan Prophet dalam model ensemble menggunakan weighted averaging, menghasilkan prediksi yang lebih akurat dibandingkan model individu, dengan kontribusi besar dari ARIMA dan LSTM (Kumar et al. 2023). Di Indonesia, penelitian menggunakan algoritma *clustering* berbasis DTW menunjukkan bahwa klasifikasi iklim tidak hanya berdasarkan rata-rata, tetapi juga mempertimbangkan pola spasio-temporal (Suryana et al. 2023). Penelitian lain membandingkan beberapa algoritma *machine learning* dan menemukan bahwa *Random Forest Regressor* paling akurat dalam memprediksi curah hujan berdasarkan atribut suhu, kelembapan, dan tekanan udara (Jagtap & Karande 2019).

Namun, model konvensional dan *machine learning* sering kurang efektif untuk data spasio-temporal karena kompleksitas polanya. Untuk itu, model STARMA dirancang khusus menangani data tersebut dan terbukti efektif dalam berbagai studi klimatologis. Contohnya, model hibrida STARMA-ANN-SVM digunakan untuk memprediksi curah hujan tahunan di Bengal Barat (Saha et al. 2020). Di Indonesia, model GSTAR juga telah diterapkan pada data curah hujan di Jawa Tengah dengan hasil yang menunjukkan pengaruh spasial yang signifikan. Sementara itu, pengembangan model STARMA II yang menggabungkan STARMA dan TDNN berhasil meningkatkan akurasi prediksi hasil panen padi dengan menggunakan matriks spasial berbasis KNN dan korelasi Pearson untuk menggambarkan *Spatio Temporal Similarity* antar wilayah (Badu-Apraku et al. 2021).

Dengan melihat studi-studi terdahulu terbukti bahwa penggunaan model STARMA dan variannya mampu memberikan hasil prediksi yang lebih akurat pada data yang memiliki ketergantungan ruang dan waktu, khususnya dalam dominan meteorologi dan iklim.

1.2 Perumusan Masalah

Berikut rumusan masalah yang pada penelitian ini yaitu:

1. Bagaimana pola curah hujan di wilayah Surabaya dalam dimensi spasial temporal?

2. Bagaimana efektifitas pembobotan spatio temporal dalam memprediksi model curah hujan?
3. Bagaimana hasil peramalan berdasarkan pembobotan spasio temporal dalam memprediksi curah hujan?

1.3 Tujuan Penelitian

Berikut adalah tujuan yang ingin dicapai pada penulisan proposal/TA.

1. Untuk menganalisis pola penyebaran curah hujan di Surabaya dari waktu ke waktu dan antar lokasi dalam wilayah tersebut.
2. Untuk mendapatkan model curah hujan yang efektif dalam menangkap keterkaitan spatial dan temporal dalam data curah hujan Surabaya.
3. Untuk mengidentifikasi hasil peramalan curah hujan dengan pembobotan spasio temporal.

1.4 Batasan dan Asumsi Penelitian

Hipotesis dari tulisan ini adalah

1. Data penelitian ini diambil dari data NASA yang dianggap sudah melalui proses validasi dan tidak mengandung kesalahan pencatatan yang signifikan ada di wilayah Surabaya
2. Data curah hujan yang digunakan adalah data bulanan selama 2015 sampai 2024
3. Model Spasio temporal yang digunakan adalah STARMA yang dianggap mampu merepresentasikan spatial dan temporal dalam curah hujan tanpa penggabungan model hybrid atau *machine learning*
4. Data NASA berupa tangkapan satelit di wilayah Surabaya didasarkan pada koordinat geografis (longitude dan latitude).

1.5 Manfaat Penelitian

Kontribusi dari tulisan ini adalah

1. Memberikan kontribusi dalam pengembangan ilmu statistik dan klimatologi, khususnya dalam pemodelan *spasio-temporal* data cuaca menggunakan metode STARMA.
2. Menambah referensi penelitian yang mengintegrasikan pendekatan statistik spasial dan deret waktu dalam konteks prediksi cuaca di Surabaya.
3. Menyediakan informasi komparatif mengenai hasil peramalan dari berbagai skema pembobotan, seperti bobot seragam, inverse jarak, korelasi silang untuk meningkatkan akurasi model STARMA.

1.6 Sistematika Penulisan

Berikut adalah gambaran singkat mengenai uraian secara singkat lingkup isi dari setiap Bab yang ada di dalam Buku Tugas Akhir ini:

1. Pendahuluan

Bab ini menjelaskan latar belakang pentingnya peramalan curah hujan di Surabaya sebagai kota metropolitan yang rawan banjir dan dipengaruhi dinamika iklim tropis basah. Bab ini menyoroti kompleksitas curah hujan yang dipengaruhi oleh factor spasial dan temporal, sehingga model time series biasas seperti ARIMA kurang memadai. Dijelaskan juga perkembangan model spasio-temporal seperti STARIMA yang dapat menangkap ketergantungan antar lokasi dan antar waktu. Berdasarkan fenomena dan studi terdahulu, dirumuskan tiga masalah utama pola spasio temporal curah hujan, efektif pembobotan SWM, serta hasil peramalan. Bab ini juga memuat tujuan penelitian, batasan data NASA (2015 hingga 2024), asumsi, manfaat penelitian, serta rencana dan jadwal kegiatan penelitian.

2. Kajian Pustaka

Bab ini berisi teori dan penelitian terdahulu yang relevan dengan pemodelan curah hujan spasio temporal. Disajikan berbagai studi menggunakan ARIMA, STARMA, model hibrida, fuzzy STARMA, dan pembobotan spasial adaptif. Bab ini menjelaskan konsep dasar peramalan, jenis metode, RMSE sebagai evaluasi, serta kestasioneran data dengan uji ADF. Selanjutnya dibahas teori ARIMA, identifikasi orde dengan ACF/PACF, estimasi parameter, dan diagnostik model. Bagian inti menjelaskan model STARMA: struktur matematisnya, STACF/STPACF untuk identifikasi orde spasial-temporal, estimasi parameter AR dan MA, uji signifikansi, serta peran penting Spatial Weight Matrix. Jenis pembobotan SWM (seragam, invers jarak, korelasi silang) dijelaskan lengkap sebagai dasar model utama.

3. Metodologi

Bab ini menyajikan langkah-langkah penelitian secara sistematis. Dimulai dengan alur metode penelitian, kemudian dijelaskan sumber data curah hujan satelit NASA POWER untuk lima wilayah Surabaya tahun 2015–2024. Tahapan pra-pemrosesan mencakup pembersihan data, transformasi Box-Cox, dan differencing. Analisis eksploratif mencakup visualisasi pola spasial dan temporal. Setelah itu dilakukan uji kestasioneran, pembentukan tiga jenis Spatial Weight Matrix, serta pembangunan model baseline ARIMA. Setelah ARIMA, dibangun model STARMA dengan tiga jenis bobot: seragam, invers jarak, dan korelasi silang. Bab

ini ditutup dengan penjelasan teknik evaluasi menggunakan RMSE serta tujuan akhir peramalan.

4. Hasil dan Pembahasan

Bab ini menyajikan hasil implementasi seluruh langkah penelitian. Pertama dilakukan eksplorasi data curah hujan untuk lima wilayah Surabaya, termasuk statistik deskriptif, pola musiman, dan korelasi antar wilayah. Selanjutnya hasil ARIMA ditampilkan: uji stasioner, estimasi parameter, fitting model, dan grafik peramalan untuk tiap wilayah. Bagian terbesar membahas STARMA. Setiap jenis bobot (seragam, invers jarak, korelasi silang) dianalisis dari:

- a. Hasil Stationeritas
- b. Hasil STACF dan STPACF
- c. Estimasi parameter
- d. Fitting model
- e. Grafik hasil peramalan tiap wilayah

Setiap bobot dibandingkan performanya. Bab ini menunjukkan bahwa pembobotan tertentu memberikan RMSE paling rendah dan model STARMA lebih unggul dibanding ARIMA.

5. Kesimpulan dan Saran

Bab ini merangkum temuan utama penelitian:

- a. Pola curah hujan di Surabaya memiliki variasi spasio-temporal kuat.
- b. Pembobotan spasial memengaruhi performa STARMA secara signifikan.
- c. Model STARMA tertentu menghasilkan prediksi terbaik berdasarkan RMSE.

Saran diberikan untuk pengembangan selanjutnya, seperti penggunaan resolusi data lebih tinggi, model hybrid, atau pembobotan spasial adaptif untuk meningkatkan akurasi.

Bab II

Landasan Teori

Pada bab ini, dipaparkan mengenai penelitian-penelitian terdahulu yang berkaitan dengan topik penelitian. Selain itu, ditunjukkan beberapa teori-teori yang menjadi landasan penyelesaian masalah yang dikemukakan pada penelitian ini.

2.1 Penelitian Terkait

Pada sub bab ini, dipaparkan mengenai penelitian-penelitian yang berkaitan dengan topik penelitian.

1. Penelitian yang dilakukan oleh (Fuad et al. 2021) yaitu memodelkan dan memprediksi penyebaran kasus COVID-19 di tiga kota wilayah Mekkah yaitu Jeddah, Makkah dan Taif dengan memanfaatkan pendekatan statistik ARIMA dan STARIMA (Space Time ARIMA). Penelitian ini bertujuan untuk membandingkan performa kedua model tersebut serta menilai pengaruh hubungan spasial antar wilayah terhadap Akurasi Prediksi. Dalam studinya, penulis menggunakan data 31 Mei hingga 11 Oktober 2020. Analisis awal menunjukkan bahwa data belum stasioner sehingga dilakukan transformasi log dan diferensiasi pertama. Model ARIMA dibangun secara terpisah untuk setiap kota Menggunakan pendekatan Box Jenkins, sedangkan model STARIMA dikembangkan secara simultan dengan mempertimbangkan hubungan spasial antar lokasi melalui spatial weight matrix, yang merepresentasikan keterhubungan antar kota.

Hasil penelitian menunjukkan bahwa model STARIMA mampu menangkap autokorelasi ruang waktu dengan lebih baik dibandingkan ARIMA univariat. Model terbaik yang diperoleh adalah STARIMA $(1_0, 1, 1_1)$ yang menunjukkan nilai MAE, MSE, dan RMSE lebih rendah dibandingkan model ARIMA diketioga kota. Temuan ini menegaskan bahwa mempertimbangkan hubungan spasial (misalnya kedekatan geografis atau mobilitas penduduk antar kota) dapat secara signifikan meningkatkan Akurasi Peramalan penyebaran COVID-19.

Penelitian ini menyimpulkan bahwa pendekatan spasial temporal seperti STARIMA lebih unggul dan direkomendasikan untuk data epidemiologi yang memiliki pola penyebaran antar wilayah. Studi ini juga membuka peluang untuk penggunaan model spasial temporal yang lebih kompleks seperti Bayesian spatial temporal models atau spatial panel models untuk analisis lanjutan.

2. Dalam penelitian yang berjudul “*Enhanced Spatio-Temporal Modeling for Rainfall Forecasting: A High-Resolution Grid Analysis*” Curah hujan sangat penting bagi pertanian, terutama di negara seperti India. Karena bersifat spasio-temporal, peramalan curah hujan menjadi kompleks dan tidak cocok jika hanya menggunakan model deret waktu atau machine learning konvensional. Diperlukan pendekatan yang mampu menangani pola *non-linear*, *non-stasioner*, dan *non-normal*. Model STARMA efektif dalam menangkap ketergantungan spasial dan temporal sekaligus, dibantu oleh Spatial Weight Matrix (SWM) untuk mengintegrasikan pengaruh lokasi sekitar. Studi ini menggunakan data curah hujan tahunan selama 50 tahun (1970–2019) dari 119 lokasi di West Bengal, India, yang dibagi menjadi data pelatihan dan pengujian. Hasilnya menunjukkan bahwa model STARMA mampu meningkatkan akurasi peramalan, yang bermanfaat untuk perencanaan dan pengelolaan pertanian di wilayah rentan terhadap perubahan iklim (Alam et al. 2024)
3. Dalam penelitian yang berjudul “*An improved Space-Time Autoregressive Moving Average (STARMA) model for Modelling and Forecasting of Spatio-Temporal time-series data*” menjelaskan bahwa Model *Box-Jenkins* univariat tidak mampu menangani ketergantungan spasial yang sering muncul dalam fenomena iklim. Untuk mengatasi hal ini, digunakan model STARMA (*Space-Time Autoregressive Moving Average*) yang memasukkan hubungan spasial dan temporal secara simultan melalui matriks bobot spasial. Dalam penelitian ini, digunakan matriks bobot spasial seragam orde dua dan bobot berdasarkan jarak terbalik yang dihitung menggunakan jarak lingkaran besar (*great circle distance*) dari koordinat lintang dan bujur. Metode ini diuji pada data simulasi dan data nyata berupa suhu maksimum bulanan di sembilan distrik Karnataka Utara. Hasilnya menunjukkan bahwa model STARMA yang diusulkan memberikan performa yang lebih baik dibandingkan ARIMA univariat dan STARMA orde spasial pertama dalam pemodelan dan peramalan deret waktu spasio-temporal (Rathod et al. 2018)
4. Penelitian ini berhasil mengembangkan dan menguji model prediksi hasil panen padi berbasis pendekatan two-stage yang dinamakan STARMA II (*Spatio-Temporal Autoregressive Moving Average with Time Delay Ne-*

ural Network). Model ini menggabungkan keunggulan model STARMA yang menangkap ketergantungan spasial dan temporal secara linear dengan kemampuan model *Time Delay Neural Network* (TDNN) dalam mempelajari hubungan non-linear dari data time series.

Dalam implementasinya, pengaruh spasial antar distrik dimodelkan menggunakan *Spatial Weight Matrix* (SWM) yang dibangun berdasarkan gabungan metode *K-Nearest Neighbors* (KNN) dan koefisien korelasi Pearson. Matriks ini berfungsi untuk merepresentasikan kemiripan spatio-temporal antar wilayah secara kuantitatif, yang kemudian digunakan dalam tahap pelatihan model untuk menangkap pola hubungan antar wilayah dalam konteks produksi padi.

Hasil evaluasi model menunjukkan bahwa STARMA II memberikan akurasi prediksi yang lebih tinggi dan konsisten dibandingkan dengan:

- Model ARIMA yang hanya mempertimbangkan aspek temporal (waktu), dan
- Model STARMA klasik yang hanya menangkap hubungan linier antar ruang dan waktu.

Kinerja model diukur melalui metrik evaluasi seperti *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan *Coefficient of Determination* (R^2), di mana STARMA II unggul secara signifikan dalam semua indikator.

Dengan demikian, pendekatan two-stage hybrid model seperti STARMA II terbukti lebih efektif dalam memodelkan dinamika kompleks produksi padi yang dipengaruhi oleh faktor spasial dan temporal, serta memiliki potensi besar untuk diterapkan dalam sistem peringatan dini, perencanaan pertanian, dan pengambilan kebijakan berbasis data (Badu-Apraku et al. 2021)

5. Penelitian yang dilakukan oleh Saha, Singh, Ray, Rathod, dan Dhyani (2022) bertujuan untuk meningkatkan akurasi peramalan suhu dengan mengembangkan model baru yang disebut *Fuzzy Rule-Based Weighted Space-Time Autoregressive Moving Average* (STARMA). Model ini merupakan pengembangan dari STARMA konvensional, dengan mengintegrasikan sistem inferensi fuzzy (FIS) untuk menghitung bobot spasial antar lokasi. Pendekatan ini dirancang untuk mengatasi keterbatasan dari matriks bobot spasial konvensional yang tidak mampu menangkap dinamika dan heterogenitas spasial secara optimal. Dalam penelitian ini, data suhu maksimum bulanan digunakan dari tujuh distrik di negara bagian West Bengal, India, untuk mengembangkan model, serta dari sembilan distrik di Karnataka untuk validasi. Hasil penelitian menunjukkan bahwa

model fuzzy STARMA memberikan hasil yang lebih akurat dibandingkan dengan model STARMA konvensional dan model ARIMA. Hal ini dibuktikan dengan nilai *Mean Absolute Percentage Error* (MAPE) yang lebih rendah, yaitu 1,78% untuk model fuzzy STARMA, dibandingkan dengan 2,09% untuk STARMA biasa, dan 4,39% untuk ARIMA. Dengan demikian, penelitian ini menyimpulkan bahwa penggunaan sistem inferensi fuzzy dalam peramalan spasial-temporal memberikan peningkatan performa yang signifikan. Model ini sangat berpotensi untuk digunakan dalam aplikasi yang berkaitan dengan perencanaan iklim dan sektor pertanian, khususnya di wilayah yang memiliki karakteristik spasial yang kompleks seperti India (Saha et al. 2022)

6. Penelitian yang dilakukan oleh Kumar, Sarkar, Dhakre, dan Bhattacharya (2023) bertujuan untuk meningkatkan akurasi peramalan suhu bulanan dengan mengembangkan pendekatan pemodelan hibrida yang menggabungkan model *Space-Time Autoregressive Moving Average* (STARMA) dan *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH). Studi ini difokuskan pada peramalan suhu maksimum bulanan dan rentang suhu di delapan lokasi di negara bagian Bihar, India. Model STARMA digunakan untuk menangkap pola spasial dan temporal dalam data, dengan matriks bobot spasial yang dikonstruksi berdasarkan jarak antar lokasi. Setelah penerapan STARMA, residual model dianalisis lebih lanjut menggunakan uji BDS dan ARCH-LM, yang menunjukkan adanya karakteristik nonlinier dan heteroskedastisitas. Untuk menangani fenomena ini, model GARCH diterapkan pada residual STARMA, membentuk pendekatan hibrida STARMA-GARCH. Hasil penelitian menunjukkan bahwa model STARMA-GARCH (khususnya konfigurasi STARMA(1,1,0,0)-GARCH(0,1)) memberikan performa yang lebih baik dibandingkan model STARMA murni, dengan nilai kesalahan prediksi (MAPE) yang lebih rendah di semua lokasi. Uji diagnostik tambahan seperti uji Ljung-Box Q juga menunjukkan bahwa residual dari model hibrida tidak memiliki autokorelasi, menandakan bahwa model tersebut telah dikalibrasi dengan baik. Kesimpulan dari penelitian ini adalah bahwa pendekatan pemodelan hibrida ini sangat efektif dalam menangkap dinamika kompleks suhu bulanan dan dapat menjadi alat yang andal untuk mendukung pengambilan keputusan di sektor-sektor yang sensitif terhadap iklim seperti pertanian dan pengelolaan sumber daya alam (Kumar et al. n.d.)

Berbagai penelitian sebelumnya telah banyak mengembangkan model peramalan spasio-temporal menggunakan pendekatan STARMA dan variannya dengan integrasi matriks bobot spasial. Meskipun model STARMA efektif dalam menangkap ketergantungan linier spasial dan temporal,

model ini masih memiliki keterbatasan dalam mengakomodasi pola non-linear dan heterogenitas spasial yang kompleks, terutama dalam konteks data curah hujan. Selain itu, konstruksi matriks bobot spasial yang digunakan sebagian besar masih bersifat statis dan umum, seperti berdasarkan jarak geografis atau metode *K-Nearest Neighbors*, sehingga kurang mampu menangkap dinamika hubungan spasial-temporal secara adaptif. Selanjutnya, belum banyak penelitian yang secara eksplisit memanfaatkan pembobotan deret waktu berbasis kemiripan spasio-temporal yang menggabungkan aspek spasial dan temporal secara simultan dan kuantitatif, khususnya untuk peramalan curah hujan dengan skala spasial dan temporal yang rinci. Selain itu, kompleksitas model yang tinggi pada beberapa pendekatan hibrida seperti *neural network* dan *fuzzy inference* juga menimbulkan tantangan terkait efisiensi komputasi pada data berukuran besar. Oleh karena itu, penelitian ini berupaya mengisi gap tersebut dengan mengembangkan model peramalan curah hujan yang menggunakan pembobotan seragam, pembobotan invers jarak, dan pembobotan korelasi silang yang adaptif. Pendekatan ini diharapkan dapat meningkatkan akurasi peramalan curah hujan sekaligus mendukung pengambilan keputusan di bidang pertanian dan mitigasi risiko bencana iklim.

2.2 Peramalan

Peramalan deret waktu (*time series forecasting*) merupakan komponen kunci yang digunakan dalam berbagai bidang untuk memprediksi kejadian di masa depan dan mengidentifikasi tren. Metode peramalan terbagi menjadi dua yaitu kualitatif (berbasis opini ahli) dan kuantitatif (berbasis analisis statistik dan matematis), dengan deret waktu sebagai salah satu pendekatan kuantitatif yang umum digunakan karena menganalisis data berurutan berdasarkan waktu (Petropoulos et al. 2021). Model-model peramalan telah berkembang secara bertahap seiring waktu. Pada awalnya, metode prediksi deret waktu mengandalkan prosedur statistik murni seperti analisis regresi dan metode ARIMA (Putra et al. 2019). Metode statistik ini bekerja dengan baik untuk data dengan hubungan linier. Untuk data non linier, model kecerdasan buatan terutama jaringan saraf telah digunakan (Marino et al. 2016). Baru baru ini, metode hibrida yang menggabungkan metode statistik dengan pendekatan deep learning telah dikembangkan untuk menghasilkan prediksi yang lebih akurat (Jagtap & Karande 2019). Bahkan model konvensional seperti ARIMA sering kali gagal memberikan prediksi curah hujan yang akurat ketika diterapkan pada wilayah dengan variasi geografis yang kompleks sehingga memerlukan model alternatif. Maka dari itu, dalam konteks penelitian ini menggunakan model yang efektif ketika berhadapan dengan data spatio temporal. Untuk mengetahui model itu efektif atau tidaknya dalam penelitian ini menggunakan

evaluasi RMSE. Berikut adalah rumus umum untuk menghitung RMSE.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (2.1)$$

Persamaan (2.1) menunjukkan rumus *Root Mean Square Error* (RMSE). Keterangan:

- y_t : nilai aktual pada waktu ke- t
- $\hat{y}_t$: nilai prediksi pada waktu ke- t
- n : jumlah total data atau observasi yang diprediksi

Nilai-nilai seperti RMSE merupakan ukuran tingkat kesalahan prediksi. Semakin rendah nilai-nilai ini, maka semakin akurat model dalam memprediksi data.

2.3 Menguji Kestasioneran Data

Kestasioneran dalam data deret waktu merupakan salah satu asumsi utama dalam analisis deret waktu. Suatu deret dianggap stasioner apabila nilai rata-rata dan variansinya tidak berubah seiring waktu (Ilmi et al. 2023). Artinya, data tersebut cenderung stabil dan berfluktuasi di sekitar nilai tengah yang tetap. Untuk menilai apakah data stasioner dalam hal rata-rata, dapat dilakukan secara visual dengan membuat plot antara nilai observasi dan waktu. Jika grafik menunjukkan pola fluktuasi yang konsisten di sekitar garis lurus dengan penyebaran yang relatif seragam, maka data dapat dianggap stasioner. Selain pendekatan visual, pengujian kestasioneran rata-rata juga dapat dilakukan menggunakan metode statistik seperti uji *Augmented Dickey-Fuller* (ADF).

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t \quad (2.2)$$

Keterangan:

- Δy_t : Diferensiasi orde pertama, yaitu $y_t - y_{t-1}$, digunakan untuk mengubah data menjadi stasioner.
- α : Konstanta (intersep) dalam model regresi.
- βt : Tren waktu (opsional), mencerminkan arah pergerakan jangka panjang dalam data.
- γy_{t-1} : Komponen autoregresif (lag 1), digunakan untuk menguji keberadaan akar unit (unit root).

- $\sum_{i=1}^p \delta_i \Delta y_{t-i}$: Lag dari perubahan y hingga lag ke- p , untuk mengatasi autokorelasi serial dalam residual.
- ε_t : Error term (white noise), mewakili gangguan acak yang tidak berkorelasi satu sama lain.

2.4 ARIMA Model

Autoregressive Integrated Moving Average (ARIMA) merupakan salah satu model deret waktu konvensional yang banyak digunakan, terutama sejak diperkenalkan oleh Box dan Jenkins (1970). Model ini membentuk pola deret waktu berdasarkan nilai masa lalu (lag) dan error acak (white noise) (Rathod et al. 2017). ARIMA terdiri dari tiga komponen utama, yaitu: Autoregressive (AR), Integrated (I), dan Moving Average (MA). Komponen AR merepresentasikan pengaruh nilai sebelumnya, I berfungsi menjadikan data stasioner melalui proses differencing, sedangkan MA mencerminkan pengaruh kesalahan masa lalu. Secara umum, model ini dinotasikan sebagai ARIMA (p, d, q), di mana p adalah orde AR, d adalah tingkat differencing, dan q adalah orde MA.

Persamaan umum model ARIMA adalah sebagai berikut:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q} \quad (2.3)$$

Keterangan:

- y_t : Nilai deret waktu pada waktu ke- t ,
- ϕ_i : Parameter model AR (*autoregresif*),
- θ_j : Parameter model MA (*moving average*),
- ε_t : Error acak (*white noise*) pada waktu ke- t ,
- B : Operator backshift, yaitu $B^k y_t = y_{t-k}$.

Langkah langkah dalam membangun model ARIMA yaitu:

1. Identifikasi dan Estimasi Model Setelah data dibuat stasioner, langkah selanjutnya adalah menentukan orde model ARIMA, yaitu nilai p (*Autoregressive*) dan q (*Moving Average*). Nilai p ditentukan dengan melihat pola pemotongan (*Cut-off*) pada grafik *Partial Autocorrelation Function* (PACF), sedangkan nilai q ditentukan dari pola pada *Autocorrelation Function* (ACF). Rumus ACF:

$$ACF(k) = \frac{\sum_{t=1}^{T-k} (e_t - \bar{e})(e_{t+k} - \bar{e})}{\sum_{t=1}^{T-k} (e_t - \bar{e})^2} \quad (2.4)$$

Keterangan:

- $ACF(k)$ = Korelasi antara residu pada lag ke- k
- k = Lag yang diinginkan
- e_t = Residu pada waktu ke- t
- $\bar{e}$ = Rata-rata dari semua residu
- T = Jumlah observasi dalam deret waktu

Rumus PACF:

$$\phi_{11} = \rho_1 \quad (2.5)$$

Keterangan: Di mana ρ_1 adalah nilai ACF pada lag ke-1. Estimasi Parameter Model: Latih model ARIMA dengan orde (p, d, q) yang telah ditentukan menggunakan data pelatihan. Parameter-parameter model diestimasi menggunakan metode *Maximum Likelihood Estimation* (MLE)

2. Diagnostik Model Analisis Residu: Periksa residu model (kesalahan prediksi) untuk memastikan mereka mendekati *white noise* (tidak ada autokorelasi, rata-rata nol, varians konstan). Gunakan uji *Ljung-Box* dan plot ACF/PACF residu. Rumus *Ljung-Box*:

$$Q = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k} \quad (2.6)$$

Keterangan:

- Q : Statistik uji Ljung-Box.
- n : Jumlah observasi (ukuran sampel) dalam deret waktu.
- h : Jumlah lag yang diuji (batas atas jumlah autokorelasi yang dihitung). Nilai h dapat ditentukan sesuai kebutuhan; secara umum digunakan nilai $h = 10, 15, 20$, atau 25 .
- $\hat{\rho}_k$: Estimasi koefisien autokorelasi sampel (SACF) dari residu pada lag ke- k .

Evaluasi Akurasi: Jika anda memiliki data pengujian, bandingkan prediksi model pada data pengujian dengan nilai aktualnya menggunakan metrik seperti RMSE.

3. Peramalan Lakukan Peramalan ke Depan: Gunakan model ARIMA yang telah tervalidasi untuk membuat prediksi nilai di masa depan.

2.5 Model STARMA (*Space-Time Autoregressive Moving Average*)

1. Identifikasi Orde Model (p, q, λ, μ)

Ini adalah bagian paling menantang dalam membangun model STARMA. Mirip dengan ACF dan PACF di ARIMA, STARMA menggunakan STACF (*Space-Time Autocorrelation Function*): Mengukur korelasi antara observasi pada lokasi i dan waktu t dengan observasi pada lokasi j dan waktu $t - k$, mempertimbangkan struktur spasial.

Rumus STACF:

$$\hat{\rho}_{10}(s) = \frac{\sum_{i=1}^N \sum_{t=1}^{T-s} L^{(1)}z_i(t) \cdot L^{(0)}z_i(t+s)}{\left[\sum_{i=1}^N \sum_{t=1}^T (L^{(1)}z_i(t))^2 \cdot \sum_{i=1}^N \sum_{t=1}^T (L^{(0)}z_i(t))^2 \right]^{1/2}} \quad (2.7)$$

Keterangan:

- $\hat{\rho}_{10}(s)$: Estimasi koefisien *Space-Time Autocorrelation Function* (STACF) pada lag spasial 1 dan lag temporal s
- N : Jumlah total lokasi spasial (misalnya jumlah stasiun, kota, area, dll.)
- T : Jumlah total periode waktu (observasi temporal) untuk setiap lokasi
- $z_i(t)$: Nilai observasi dari deret waktu pada lokasi ke- i dan waktu ke- t
- $L^{(1)}z_i(t)$: Operator *lag spasial orde 1* (spatial shift operator) yang menunjukkan pengaruh lokasi sekitar terhadap lokasi i pada waktu t
- $L^{(0)}z_i(t)$: Nilai asli dari $z_i(t)$ tanpa pergeseran spasial (orde 0), yaitu nilai pada lokasi itu sendiri

STPACF (*Space-Time Partial Autocorrelation Function*): Mirip dengan PACF tetapi mempertimbangkan dimensi ruang dan waktu.

Rumus STPACF:

$$\hat{\gamma}_{ho}(s) = \sum_{j=1}^k \sum_{l=0}^{\lambda} \hat{\phi}_{jl} \hat{\gamma}_{hl}(s-j) \quad (2.8)$$

Keterangan:

- $\hat{\gamma}_{ho}(s)$: Ini adalah estimasi koefisien Space-Time Partial Autocorrelation Function (STPACF).

- $\sum_{j=1}^k$: Ini adalah penjumlahan untuk lag temporal j , dari 1 hingga k .
- $\sum_{l=0}^{\lambda}$: Ini adalah penjumlahan untuk lag spasial l , dari 0 hingga λ .
- $\hat{\phi}_{jl}$: Ini adalah koefisien model Space-Time Autoregressive (STAR) yang diestimasi.
- $\hat{\gamma}_{hl}(s-j)$: Ini adalah estimasi koefisien STPACF sebelumnya pada lag spasial l dan lag temporal $s-j$.

Identifikasi orde melibatkan penentuan:

- Orde *Autoregressive* (p): Jumlah *lag* temporal dari komponen AR
- Orde *Moving Average* (q): Jumlah *lag* temporal dari komponen MA
- Orde *Spasial Autoregressive* (λ): Jumlah *lag* spasial dari komponen AR. Ini menunjukkan berapa lapis tetangga yang memengaruhi nilai saat ini
- Orde Spasial *Moving Average* (μ): Jumlah *lag* spasial dari komponen MA

2. Estimasi Parameter

Setelah orde (p, q, λ, μ) dan matriks bobot spasial ditentukan, parameter model STARMA diestimasi. Estimasi parameter STARMA menggunakan Maximum Likelihood Estimation Langkah-langkah estimasi Maximum Likelihood Estimation:

- a) Membangun model ST-AR (Spatiotemporal Autoregressive)
 - i) Rumus umum

$$\mathbf{Z}_t = \sum_{k=1}^p \sum_{l=0}^{\lambda_k} \phi_{kl} W^l \mathbf{Z}_{t-k} + \mathbf{e}_t \quad (2.9)$$

Keterangan:

- $\mathbf{Z}_t$: Vektor data variabel dependen di semua lokasi pada waktu t .
- p : Orde lag temporal (berapa periode waktu ke belakang data mempengaruhi).
- λ_k : Orde lag spasial untuk lag temporal k (seberapa jauh pengaruh tetangga).
- ϕ_{kl} : Koefisien (parameter) yang menunjukkan pengaruh variabel pada lag temporal k dan lag spasial l .

- W^l : Matriks bobot spasial orde l (W^0 adalah diri sendiri, W^1 tetangga terdekat, dst.).
- $\mathbf{Z}_{t-k}$: Vektor data variabel dependen di semua lokasi pada waktu $t - k$.
- $\mathbf{e}_t$: Vektor istilah gangguan (error term) pada waktu t .

Kemudian dilakukan penurunan terhadap semua parameter, selanjutnya dibentuk matriks dengan memilih

$$\hat{\phi} = \begin{bmatrix} \phi_{10} \\ \phi_{11} \\ \phi_{12} \\ \vdots \\ \phi_{p\lambda} \end{bmatrix} \quad \text{dan} \quad \mathbf{X} = [\mathbf{Z}_{t-1} \quad W\mathbf{Z}_{t-1} \quad W^2\mathbf{Z}_{t-1} \quad \cdots \quad W^\lambda\mathbf{Z}_{t-p}] \quad (2.10)$$

ii) Estimasi Parameter

$$\hat{\phi} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Z} \quad (2.11)$$

Keterangan:

- $\hat{\phi}$: Nilai-nilai koefisien (parameter) yang diestimasi oleh model.
- $\mathbf{X}$: Matriks yang berisi semua data variabel penjelas (independen).
- $\mathbf{X}'$: Transpose dari matriks $\mathbf{X}$.
- $(\mathbf{X}'\mathbf{X})^{-1}$: Kebalikan (invers) dari hasil perkalian matriks $\mathbf{X}'$ dengan $\mathbf{X}$.
- $\mathbf{Z}$: Vektor data variabel yang dijelaskan (dependen).

iii) Uji Signifikansi

Dalam uji signifikansi menggunakan uji t

$$t = \frac{(\hat{\phi}_2 + \hat{\phi}_3) - (\phi_2 + \phi_3)}{\text{se}(\hat{\phi}_2 + \hat{\phi}_3)} = \frac{(\hat{\phi}_2 + \hat{\phi}_3) - 1}{\sqrt{\text{var}(\hat{\phi}_2) + \text{var}(\hat{\phi}_3) + 2 \text{cov}(\hat{\phi}_2, \hat{\phi}_3)}} \quad (2.12)$$

Keterangan:

- t : Nilai statistik uji- t yang dihitung.
- $(\hat{\phi}_2 + \hat{\phi}_3)$: Penjumlahan dari estimasi koefisien untuk variabel kedua ($\hat{\phi}_2$) dan ketiga ($\hat{\phi}_3$) dari model regresi.
- $(\phi_2 + \phi_3)$: Nilai hipotesis dari penjumlahan koefisien yang sebenarnya. Dalam baris kedua rumus, nilai 1 menunjukkan bahwa hipotesis yang diuji adalah apakah $\phi_2 + \phi_3 = 1$.

- $se(\hat{\phi}_2 + \hat{\phi}_3)$: Standard error dari penjumlahan estimasi koefisien, yang mengukur presisi dari estimasi tersebut.
- $var(\hat{\phi}_2)$: Variansi dari estimasi koefisien $\hat{\phi}_2$.
- $var(\hat{\phi}_3)$: Variansi dari estimasi koefisien $\hat{\phi}_3$.
- $cov(\hat{\phi}_2, \hat{\phi}_3)$: Kovariansi antara estimasi koefisien $\hat{\phi}_2$ dan $\hat{\phi}_3$.

Hipotesa Parameter

$$H_0 : \phi_j = 0 \quad (\text{parameter tidak signifikan}) \quad (2.13)$$

$$H_1 : \phi_j \neq 0 \quad (\text{parameter signifikan}) \quad (2.14)$$

Pengambilan keputusan

- Jika p-value < 0.05 maka tolak H_0
- Jika p-value > 0.05 maka gagal tolak H_0

Melihat hasil uji dari output regresi yang ada python dimana disitu tercantum nilai p-value. Untuk melihat apakah residual model ST-AR masih menunjukkan pola autokorelatif maka dilakukan uji multivariat box pierce. Jika ternyata masih ada maka itu dianggap model belum selesai dan bisa dilanjutkan ke ST-MA

b) Membangun ST-MA (Spatiotemporal Moving Average)

i) Rumus umum

$$\mathbf{Z}_t = \mathbf{e}_t - \sum_{k=1}^q \sum_{l=0}^{\lambda_k} \theta_{kl} W^l \mathbf{e}_{t-k} \quad (2.15)$$

Keterangan:

- $\mathbf{Z}_t$: Vektor data variabel dependen di semua lokasi pada waktu t .
- $\mathbf{e}_t$: Vektor istilah gangguan (error term) pada waktu t . Ini adalah "kejutan" atau error pada waktu saat ini.
- $\sum_{k=1}^q$: Penjumlahan untuk orde temporal moving average, di mana q adalah orde MA temporal maksimum.
- $\sum_{l=0}^{\lambda_k}$: Penjumlahan untuk orde spasial moving average, di mana λ_k adalah orde spasial maksimum untuk lag temporal k .
- θ_{kl} : Koefisien (parameter) moving average spatio-temporal yang akan diestimasi.
- W^l : Matriks bobot spasial orde ke- l (W^0 adalah diri sendiri, W^1 tetangga terdekat, dan seterusnya).

- $\mathbf{e}_{t-k}$: Vektor istilah gangguan (error term) dari waktu $t-k$, yaitu "kejutan" masa lalu dari lokasi itu sendiri dan tetangganya.

Kemudian dilakukan penurunan terhadap semua parameter, selanjutnya dibentuk matriks dengan memilih

$$\hat{\boldsymbol{\theta}} = \begin{bmatrix} \theta_{10} \\ \theta_{11} \\ \theta_{12} \\ \vdots \\ \theta_{p\lambda} \end{bmatrix} \quad \text{dan} \quad \hat{\mathbf{e}} = [\mathbf{e}_{t-1} \quad W\mathbf{e}_{t-1} \quad W^2\mathbf{e}_{t-1} \quad \cdots \quad W^\lambda\mathbf{e}_{t-p}] \quad (2.16)$$

ii) Estimasi parameter

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{e} \quad (2.17)$$

Keterangan:

- $\hat{\boldsymbol{\theta}}$: Vektor koefisien yang diestimasi (hasil akhir yang ingin kita cari).
- $\mathbf{X}$: Matriks berisi data variabel penjelas (independen).
- $\mathbf{X}'$: Transpose dari matriks $\mathbf{X}$.
- $(\mathbf{X}'\mathbf{X})^{-1}$: Invers dari hasil perkalian $\mathbf{X}'$ dengan $\mathbf{X}$.
- $\mathbf{e}$: Vektor berisi data variabel yang dijelaskan (dependen).

iii) Uji signifikansi

Dalam uji signifikansi menggunakan uji t

$$t = \frac{(\hat{\theta}_2 + \hat{\theta}_3) - (\theta_2 + \theta_3)}{\text{se}(\hat{\theta}_2 + \hat{\theta}_3)} = \frac{(\hat{\theta}_2 + \hat{\theta}_3) - 1}{\sqrt{\text{var}(\hat{\theta}_2) + \text{var}(\hat{\theta}_3) + 2 \text{cov}(\hat{\theta}_2, \hat{\theta}_3)}} \quad (2.18)$$

Keterangan:

- t : Nilai statistik uji- t yang dihitung.
- $(\hat{\theta}_2 + \hat{\theta}_3)$: Penjumlahan dari estimasi koefisien untuk variabel kedua ($\hat{\theta}_2$) dan ketiga ($\hat{\theta}_3$) dari model regresi.
- $(\theta_2 + \theta_3)$: Nilai hipotesis dari penjumlahan koefisien yang sebenarnya. Dalam baris kedua rumus, nilai 1 menunjukkan bahwa hipotesis yang diuji adalah apakah $\theta_2 + \theta_3 = 1$.
- $\text{se}(\hat{\theta}_2 + \hat{\theta}_3)$: Standard error dari penjumlahan estimasi koefisien, yang mengukur presisi dari estimasi tersebut.
- $\text{var}(\hat{\theta}_2)$: Variansi dari estimasi koefisien $\hat{\theta}_2$.
- $\text{var}(\hat{\theta}_3)$: Variansi dari estimasi koefisien $\hat{\theta}_3$.

- $\text{cov}(\hat{\theta}_2, \hat{\theta}_3)$: Kovariansi antara estimasi koefisien $\hat{\theta}_2$ dan $\hat{\theta}_3$.
Dalam uji signifikansi menggunakan hipotesis

$$H_0 : \theta_j = 0 \quad (\text{parameter tidak signifikan}) \quad (2.19)$$

$$H_1 : \theta_j \neq 0 \quad (\text{parameter signifikan}) \quad (2.20)$$

Pengambilan keputusan

- Jika p-value < 0.05 maka tolak H_0
- Jika p-value > 0.05 maka gagal tolak H_0

Melihat hasil uji dari output regresi yang ada python dimana disitu tercantum nilai p-value.

c) Model STARMA

Model STARMA secara umum dituliskan dalam bentuk matrix sebagai berikut:

$$Z(t) = \sum_{k=1}^p \sum_{l=0}^{L_k} \phi_{kl} W_l Z(t-k) + \sum_{k=1}^q \sum_{l=0}^{L_k} \theta_{kl} W_l \varepsilon(t-k) + \varepsilon(t) \quad (2.21)$$

Keterangan:

- $Z(t)$: vektor observasi pada waktu ke- t untuk semua lokasi
- p, q : orde *autoregressive* dan *moving average* dalam waktu
- L_k : orde spasial untuk lag waktu ke- k (misalnya tetangga orde ke-1, ke-2, dst.)
- ϕ_{kl}, θ_{kl} : parameter AR dan MA pada lag waktu ke- k dan lag spasial ke- l
- W_l : matriks bobot spasial orde ke- l
- $\varepsilon(t)$: vektor galat acak pada waktu ke- t , diasumsikan mengikuti distribusi normal identik dan independen (white noise)

3. Evaluasi Akurasi

Jika anda membagi data, evaluasi kinerja Peramalan model pada data pengujian menggunakan metrik akurasi seperti RMSE

Untuk menangkap hubungan antar lokasi, digunakan spatial weight matrix berukuran $N \times N$ yang menggambarkan sejauh mana keterkaitan antar lokasi.

2.6 Spatial Weight Matrix (SWM)

2.6.1 Konsep Dasar Spatial Weight Matrix

Matriks Bobot Spasial (SWM) merupakan matriks persegi berukuran $N \times N$, di mana N menyatakan jumlah total lokasi atau grid yang diamati. Setiap

elemen w_{ij} dalam matriks ini merepresentasikan besarnya pengaruh lokasi j terhadap lokasi i , dengan ketentuan sebagai berikut:

- $w_{ii} = 0$, yang berarti suatu lokasi tidak memberikan pengaruh terhadap dirinya sendiri.
- Jika terdapat keterkaitan spasial antara lokasi j dan i , maka $w_{ij} > 0$; jika tidak ada hubungan, maka $w_{ij} = 0$.

2.6.2 Bentuk Umum Matriks SWM

Secara umum, matriks bobot spasial dapat dituliskan dalam bentuk:

$$\mathbf{W} = \begin{bmatrix} 0 & w_{12} & w_{13} & \cdots & w_{1N} \\ w_{21} & 0 & w_{23} & \cdots & w_{2N} \\ w_{31} & w_{32} & 0 & \cdots & w_{3N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_{N1} & w_{N2} & w_{N3} & \cdots & 0 \end{bmatrix} \quad (2.22)$$

Dengan:

- w_{ij} menyatakan kekuatan hubungan dari lokasi j ke lokasi i
- Setiap baris menyatakan distribusi pengaruh dari semua lokasi terhadap satu lokasi tertentu.

2.6.3 Jenis-jenis Pembobotan

Berikut adalah beberapa metode populer dalam membentuk nilai w_{ij} dalam SWM:

- a) Bobot Lokasi Seragam (*Uniform Weight*) Mengasumsikan bahwa semua lokasi tetangga memiliki pengaruh yang sama besar terhadap lokasi target:

$$w_{ij} = \begin{cases} \frac{1}{n}, & i \neq j \\ 0, & i = j \end{cases} \quad (2.23)$$

dengan $n = N - 1$ sebagai jumlah lokasi tetangga. Bobot ini sederhana dan tidak memperhitungkan jarak geografis, namun tetap dapat menghasilkan model yang baik dalam kondisi tertentu.

- b) Bobot Inverse Jarak (*Inverse Distance Weight*) Menggunakan jarak antar lokasi sebagai dasar pembobotan. Lokasi yang lebih dekat memiliki bobot lebih besar:

$$d_{ij} = d_{ji} = ([x_i(u_i) - x_j(u_j)]^2 + [x_i(v_i) - x_j(v_j)]^2)^{1/2} \quad (2.24)$$

$$w_{ij} = w_{ji} = \frac{1}{d_{ij}} = \frac{1}{d_{ji}} \quad (2.25)$$

dan normalisasi bobot lokasi invers jarak dapat dihitung menggunakan rumus berikut:

$$w_{ij} = \begin{cases} \frac{w_{ij}}{\sum_{j=1}^m w_{ij}}, & i \neq j \\ 0, & i = j \end{cases} \quad (2.26)$$

Keterangan: x_i = lambang lokasi ke- i dengan $i = 1, 2, \dots, N$ u = koordinat lintang lokasi v = koordinat bujur lokasi d_{ij} = jarak antar lokasi ke- i terhadap lokasi lainnya (lokasi ke- j).

- c) Bobot Korelasi Silang (*Cross-Correlation Weight*) Didasarkan pada kemiripan pola waktu antar lokasi, dihitung dari korelasi silang pada lag tertentu:

$$\rho_{ij}(k) = \frac{\gamma_{ij}(k)}{\sigma_i \sigma_j} \quad (2.27)$$

Keterangan:

- $\rho_{ij}(k)$: korelasi silang antara lokasi ke- i dan ke- j pada lag waktu ke- k
- $\gamma_{ij}(k)$: kovarians silang antara lokasi ke- i dan ke- j pada lag waktu ke- k
- σ_i, σ_j : simpangan baku dari lokasi ke- i dan ke- j

di mana $\gamma_{ij}(k)$ merupakan kovarians silang antara pengamatan pada lokasi ke- i dan ke- j pada lag waktu k . σ_i dan σ_j merupakan simpangan baku dari pengamatan lokasi ke- i dan ke- j

$$r_{ij}(k) = \frac{\sum_{t=k+1}^n [z_i(t) - \bar{z}_i][z_j(t-k) - \bar{z}_j]}{(\sum_{t=1}^n [z_i(t) - \bar{z}_i]^2) (\sum_{t=1}^n [z_j(t) - \bar{z}_j]^2)} \quad (2.28)$$

Keterangan:

- $r_{ij}(k)$: penduga korelasi silang antara lokasi ke- i dan ke- j pada lag waktu ke- k
- $z_i(t)$: nilai pengamatan pada lokasi ke- i di waktu t
- $\bar{z}_i$: rata-rata nilai pengamatan pada lokasi ke- i
- n : banyaknya data

Untuk penentuan pembobot korelasi silang antar lokasi diperoleh sebagai berikut:

$$w_{ij} = \frac{r_{ij}(k)}{\sum_{j \neq i} |r_{ij}(k)|} \quad (2.29)$$

Keterangan:

- w_{ij} : bobot korelasi silang dari lokasi ke- j terhadap lokasi ke- i
- $r_{ij}(k)$: penduga korelasi silang seperti dijelaskan di atas

dan memenuhi $\sum_{i \neq j} |w_{ij}| = 1$. Pembobot korelasi silang ini tidak memerlukan aturan tertentu, seperti ketergantungan jarak dari lokasi.

2.6.4 Peran SWM dalam Model STARMA

Dalam model STARMA, SWM digunakan untuk mengintegrasikan pengaruh spasial antar lokasi ke dalam proses prediksi curah hujan. Setiap variasi bobot akan dimasukkan ke dalam model, lalu hasil peramalannya dibandingkan untuk menentukan pembobotan mana yang paling efektif dalam merepresentasikan hubungan spasio-temporal.


Bab III

Metodologi Penelitian

Pada bab ini, dijelaskan tentang tahapan-tahapan penelitian yang dilakukan untuk menyelesaikan masalah yang telah dikemukakan pada rumusan masalah. Ditunjukkan pula jadwal penelitian untuk masing-masing tahapan penelitian tersebut.

3.1 Metode Penelitian

Metode penelitian dapat dilihat pada Gambar 3.1.




Gambar 3.1: Diagram Alur Metodologi Penelitian

3.2 Sumber Data

Penelitian ini dilakukan menggunakan data sekunder secara daring tanpa melakukan pengambilan data di lapangan. Seluruh proses analisis dan pengolahan data dilakukan secara komputasi di lingkungan pengolahan data statistik.

Data utama yang digunakan dalam penelitian ini adalah data curah hujan bulanan berbasis satelit yang diperoleh dari NASA (*National Aeronautics and Space Administration*) melalui platform *POWER Data Access Viewer*. Data ini mencakup informasi spasial (koordinat grid wilayah) dan temporal (periode waktu pengamatan) yang diperlukan dalam pemodelan spasio temporal menggunakan STARMA.

Selain itu, informasi koordinat geografis yang merepresentasikan lokasi grid atau titik observasi juga digunakan untuk membangun *spatial weight matrix* yang merepresentasikan kedekatan spasial antar wilayah. Data pendukung ini diambil langsung dari metadata bawaan dataset NASA yang digunakan. Berikut merupakan gambar sumber data yang digunakan dalam penelitian ini:



Gambar 3.2: Data NASA Wilayah Surabaya

3.2.1 Data Sekunder

Tabel 3.1: Data Curah Hujan Bulanan Berdasarkan Wilayah

Wilayah	Latitude	Longitude	Date	Precipitation
Utara	-7.2	112.73	1/31/2015	13.89
Utara	-7.2	112.73	2/28/2015	11.93
Utara	-7.2	112.73	3/31/2015	9.38
⋮	⋮	⋮	⋮	⋮
Utara	-7.2	112.73	10/31/2024	1.12

Wilayah	Latitude	Longitude	Date	Precipitation
Utara	-7.2	112.73	11/30/2024	6.53
Utara	-7.2	112.73	12/31/2024	13.60
Barat	-7.24	112.61	1/31/2015	13.92
Barat	-7.24	112.61	2/28/2015	11.87
Barat	-7.24	112.61	3/31/2015	9.44
⋮	⋮	⋮	⋮	⋮
Barat	-7.24	112.61	10/31/2024	1.46
Barat	-7.24	112.61	11/30/2024	6.29
Barat	-7.24	112.61	12/31/2024	13.62
Timur	-7.31	112.84	1/31/2015	12.24
Timur	-7.31	112.84	2/28/2015	10.29
Timur	-7.31	112.84	3/31/2015	8.84
⋮	⋮	⋮	⋮	⋮
Timur	-7.31	112.84	10/31/2024	1.22
Timur	-7.31	112.84	11/30/2024	5.63
Timur	-7.31	112.84	12/31/2024	12.31
Selatan	-7.35	112.73	1/31/2015	14.30
Selatan	-7.35	112.73	2/28/2015	12.15
Selatan	-7.35	112.73	3/31/2015	11.21
⋮	⋮	⋮	⋮	⋮
Selatan	-7.35	112.73	10/31/2024	1.24
Selatan	-7.35	112.73	11/30/2024	6.63
Selatan	-7.35	112.73	12/31/2024	13.51
Tengah	-7.26	112.74	1/31/2015	14.25
Tengah	-7.26	112.74	2/28/2015	12.17
Tengah	-7.26	112.74	3/31/2015	11.19
⋮	⋮	⋮	⋮	⋮
Tengah	-7.26	112.74	10/31/2024	0.83
Tengah	-7.26	112.74	11/30/2024	6.66
Tengah	-7.26	112.74	12/31/2024	13.59

3.3 Pra-pemrosesan Data

Sebelum dilakukan pemodelan, data yang digunakan harus melalui tahapan pra-pemrosesan agar bersih, konsisten, dan siap untuk dianalisis secara spasio-temporal. Proses ini dimulai dengan pembersihan data dari nilai-nilai ekstrem atau tidak logis akibat gangguan akuisisi satelit. Jika terdapat nilai hilang, maka akan dilakukan *handling missing value*, atau penghapusan jika jumlahnya signifikan. Selanjutnya, dilakukan perhitungan statistika deskriptif.

3.4 Analisis Eksploratif Pola Spasio-Temporal Curah Hujan

Sebelum membentuk matriks pembobotan, dilakukan analisis eksploratif terhadap pola curah hujan di wilayah Surabaya. Analisis ini mencakup visualisasi boxplot untuk setiap grid guna mengidentifikasi distribusi curah hujan bulanan secara spasial, pembuatan heatmap temporal untuk memantau intensitas curah hujan sepanjang waktu, serta pemetaan spasial rata-rata curah hujan setiap lima tahun untuk melihat distribusi geografisnya. Tujuan dari analisis ini adalah untuk memahami dinamika dan variabilitas intensitas hujan serta mengidentifikasi grid yang memiliki pola hujan serupa.

3.5 Pengecekan Kestasioneran Data

Data yang ada di cek stasioneritas nya menggunakan uji *Augmented Dickey-Fuller* (ADF). Jika data tersebut tidak stasioner maka akan dilakukan differencing, namun apabila data nya sudah stasioner maka akan dilakukan perhitungan selanjutnya.

3.6 Pembentukan *Spatial Weight Matrix*

Berdasarkan matriks *similarity* yang telah diperoleh, kemudian disusun *Spatial Weight Matrix* (SWM) seperti pada matriks 2.22 sebagai komponen penting dalam model STARMA. SWM menunjukkan kekuatan pengaruh antar grid, dan tidak hanya mempertimbangkan kedekatan geografis, tetapi juga kemiripan spasio-temporal. Dalam penelitian ini, dibangun tiga variasi bobot sebagai pembanding, yaitu bobot seragam yang memberikan bobot sama untuk seluruh tetangga yang dapat dilihat pada persamaan 2.23, bobot invers jarak yang menggunakan jarak antar lokasi sebagai dasar pembobotan yang dapat dilihat pada persamaan 2.25, bobot berdasarkan korelasi silang antar grid yang dapat dilihat pada persamaan 2.27. Masing-masing variasi digunakan untuk mengukur efektivitas pembobotan spasial dalam meningkatkan performa prediksi model.

3.7 Pembangunan Model ARIMA

Setelah data stasioner, dilakukan identifikasi nilai parameter p dan q dengan mengamati pola ACF (untuk q) 2.4 dan PACF (untuk p) 2.5, atau dapat pula menggunakan metode otomatis seperti *auto_arima*. Model kemudian dibangun dan parameternya diestimasi menggunakan **Maximum Likelihood Estimation** (MLE). Setelah model dibentuk, dilakukan **analisis residu** untuk memastikan bahwa kesalahan model bersifat acak (*white noise*). Hal ini dapat diperiksa melalui plot ACF/PACF dari residu serta uji *Ljung-Box* 2.6. Diagnostik ini penting untuk memastikan bahwa model tidak melewatkan pola yang masih ada dalam data. Bila tersedia data uji, model dievaluasi menggu-

nakan metrik prediksi seperti **RMSE**.

3.8 Pembangunan Model STARMA

Model STARMA digunakan untuk menganalisis data yang memiliki ketergantungan spasial dan temporal secara simulta. Identifikasi orde model melibatkan empat parameter utama: p dan q (lag temporal AR dan MA) serta λ dan μ (lag spasial AR dan MA). Orde ini ditentukan menggunakan fungsi STACF 2.7 dan STPACF 2.8, yang merupakan perluasan dari ACF dan PACF dalam konteks spasial-temporal. Setelah orde ditentukan, parameter model diestimasi menggunakan **Maximum Likelihood Estimation (MLE)**. Diagnostik dilakukan melalui analisis residu untuk memastikan tidak ada autokorelasi spasial-temporal yang tersisa, serta evaluasi akurasi dilakukan dengan metrik seperti RMSE

3.9 Evaluasi

Model-model yang dibangun kemudian divalidasi dengan menggunakan data testing untuk mengukur performanya. Validasi dilakukan dengan membandingkan hasil prediksi dengan data aktual menggunakan metrik evaluasi *Root Mean Square Error* (RMSE) pada persamaan 2.1. Selain itu, dilakukan perbandingan performa antara model STARMA dengan dan tanpa pembobotan spasio-temporal untuk mengetahui sejauh mana pembobotan tersebut meningkatkan akurasi model.

3.10 Harapan Hasil Peramalan

Hasil akhir dari proses pemodelan STARMA divisualisasikan dalam bentuk grafik yang membandingkan nilai prediksi dengan data aktual curah hujan. Visualisasi dilakukan pada lima titik observasi yang mewakili bagian-bagian wilayah Surabaya, yaitu Surabaya Barat, Timur, Utara, Selatan, dan Pusat. Hasil prediksi ini menjadi dasar untuk mengevaluasi sejauh mana model mampu merepresentasikan dinamika spasio-temporal curah hujan di Surabaya secara akurat.

Bab IV

Hasil dan Pembahasan

4.1 Eksplorasi Data

4.1.1 Statistika Deskriptif

Sebelum melakukan proses pemodelan dengan metode ARIMA dan STARIMA, langkah pertama yang dilakukan adalah melakukan eksplorasi data yaitu dengan statistika deskriptif. Tujuannya untuk memahami karakteristik dasar data seperti tren, musiman, serta variabilitas yang terjadi. Melalui analisa deskriptif, diperoleh gambaran umum mengenai perilaku data yang akan dimodelkan.

Tabel 4.1: Statistika Deskriptif

Statistik	Barat	Selatan	Tengah	Timur	Utara
Count	3653.000000	3653.000000	3653.000000	3653.000000	3653.000000
Mean	5.843041	5.920063	5.919724	5.206096	5.842067
Min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.090000	0.000000	0.020000	0.000000	0.120000
50%	1.650000	0.780000	1.370000	0.600000	2.010000
75%	7.520000	6.560000	7.630000	6.400000	8.030000
Max	308.380000	366.490000	318.680000	195.030000	249.460000
Std	11.013619	13.287137	11.868456	10.058238	10.116447

Tabel 4.1 menyajikan hasil analisis statistika deskriptif curah hujan pada lima wilayah Kota Surabaya, yaitu Barat, Selatan, Tengah, Timur, dan Utara. Berdasarkan tabel tersebut, jumlah data pengamatan pada masing-masing wilayah adalah 120 observasi, yang menunjukkan bahwa seluruh wilayah memiliki panjang deret waktu yang sama sepanjang periode penelitian.

Secara umum, nilai rata-rata (mean) curah hujan di kelima wilayah berkisar antara 5,20 hingga 5,92 mm, yang menunjukkan bahwa intensitas curah hujan harian di Kota Surabaya relatif seragam antar wilayah. Wilayah Tengah (5,92 mm) memiliki rata-rata curah hujan tertinggi, diikuti oleh Selatan (5,92 mm) dan Barat (5,84 mm), sedangkan wilayah Timur (5,21 mm) mencatat rata-rata

terendah.

Nilai minimum pada seluruh wilayah adalah 0 mm, yang menandakan adanya hari-hari tanpa hujan selama periode pengamatan. Sementara itu, nilai maksimum menunjukkan variasi yang cukup tinggi, di mana curah hujan ekstrem tertinggi tercatat di wilayah Selatan (366,49 mm), diikuti oleh Tengah (318,68 mm) dan Barat (308,38 mm). Hal ini menunjukkan bahwa wilayah bagian selatan Surabaya cenderung mengalami intensitas hujan ekstrem lebih besar dibandingkan wilayah lainnya.


Berdasarkan nilai median (50%), sebagian besar wilayah memiliki nilai tengah curah hujan antara 0,6 hingga 2,0 mm, yang berarti sebagian besar hari dalam periode pengamatan memiliki curah hujan rendah hingga sedang. Nilai kuartil atas (75%) menunjukkan bahwa 75% data memiliki curah hujan di bawah 7–8 mm, sedangkan sisanya mewakili kejadian hujan intensitas tinggi.

Nilai simpangan baku (standar deviasi) berkisar antara 10,05 hingga 13,28, yang mengindikasikan adanya variasi curah hujan yang cukup besar antar waktu. Wilayah Selatan memiliki standar deviasi tertinggi (13,29), yang menandakan fluktuasi curah hujan paling tinggi, sedangkan wilayah Timur menunjukkan variasi paling rendah (10,06).

Secara keseluruhan, analisis deskriptif ini menunjukkan bahwa curah hujan di lima wilayah Kota Surabaya memiliki pola sebaran yang relatif serupa, namun dengan tingkat variabilitas dan intensitas ekstrem yang berbeda antar wilayah. Temuan ini mendukung perlunya analisis spasio-temporal lanjutan menggunakan model STARIMA untuk menangkap hubungan dinamis antar wilayah dan antar waktu.

4.1.2 Pola Curah Hujan Kelima Wilayah di Surabaya


Data yang digunakan adalah data curah hujan hasil dari pengamatan satelit NASA POWER pada lima titik wilayah di Kota Surabaya yaitu Utara, Selatan, Timur, Tengah dan Barat selama periode 1 Januari 2015 hingga 31 Desember 2024. Data curah hujan nya memiliki satuan mm/hari dan kemudian dilakukan agregasi menjadi rata-rata bulanan agar dapat menggambarkan tren musiman jangka panjang.



Gambar 4.1: Pola Curah Hujan Wilayah Barat


Curah hujan bulanan di Wilayah Barat selama periode 2015 - 2024 mem-

perlihatkan pola musiman yang sangat jelas, dengan peningkatan intensitas hujan yang konsisten terjadi pada bulan Desember hingga Maret serta kondisi curah hujan rendah hingga mendekati nol pada bulan Juni hingga September. Puncak hujan tahunan umumnya berada pada kisaran 12–18 mm/hari, disertai beberapa kejadian ekstrem yang mencapai lebih dari 20 mm/hari pada tahun-tahun seperti 2017, 2020, 2022, dan 2024. Dengan struktur musiman yang kuat dan variabilitas yang cukup signifikan, deret waktu pada wilayah ini sangat mendukung penerapan model STARIMA dalam mempelajari hubungan spasial-temporal serta memprediksi curah hujan dengan lebih akurat.



Gambar 4.2: Pola Curah Hujan Wilayah Selatan


Curah hujan bulanan di Wilayah Selatan selama periode 2015 - 2024 menunjukkan pola musiman yang sangat konsisten, ditandai dengan peningkatan intensitas hujan pada bulan Desember hingga Maret dan kondisi hampir tanpa hujan pada periode Juni hingga September. Puncak hujan tahunan umumnya berada pada kisaran 12–18 mm/hari, dengan beberapa kejadian ekstrem yang melebihi 20 mm/hari terutama pada awal 2016, 2021, dan 2024. Variabilitas intra-tahunan yang cukup tinggi serta fluktuasi intensitas yang tajam menggambarkan dinamika atmosfer yang aktif di wilayah ini, sekaligus menegaskan adanya komponen musiman yang kuat dan berulang. Pola temporal yang terstruktur ini mendukung penerapan model deret waktu spasial-temporal seperti STARIMA untuk memodelkan dan memprediksi curah hujan secara lebih akurat.



Gambar 4.3: Pola Curah Hujan Wilayah Tengah


Curah hujan bulanan di Wilayah Tengah selama periode 2015 - 2024 menunjukkan pola musiman yang sangat jelas, dengan intensitas hujan meningkat secara konsisten pada Desember hingga Maret dan menurun drastis pada Juni

hingga September. Variabilitas intra-tahunan tampak cukup tinggi, ditandai dengan fluktuasi tajam antara kondisi tanpa hujan hingga puncak 10–15 mm/hari, serta beberapa kejadian ekstrem seperti pada awal 2024 yang mencapai lebih dari 25 mm/hari. Pola yang stabil dan berulang ini mencerminkan dinamika monsun yang kuat serta pengaruh faktor atmosfer regional yang membentuk variasi hujan tahunan. Struktur temporal yang konsisten tersebut mendukung penerapan model STARIMA dalam memodelkan dan memprediksi curah hujan berbasis hubungan spasial-temporal antar wilayah di Surabaya.



Gambar 4.4: Pola Curah Hujan Wilayah Timur

Curah hujan bulanan di Wilayah Timur selama periode 2015 - 2024 memperlihatkan pola musiman yang konsisten, dengan intensitas hujan meningkat pada bulan Desember hingga Maret dan menurun drastis mendekati nol pada periode Juni hingga September. Puncak hujan tahunan berada pada kisaran 10–15 mm/hari, dengan beberapa kejadian ekstrem yang melampaui nilai tersebut, seperti pada awal tahun 2021, 2022, dan 2024. Fluktuasi intra-tahunan yang tajam dan variasi antar tahun menunjukkan dinamika atmosfer yang aktif di wilayah ini, dipengaruhi oleh siklus monsun dan fenomena cuaca regional. Pola temporal yang berulang dan stabil ini menunjukkan bahwa wilayah Timur memiliki struktur deret waktu yang kuat untuk dimodelkan melalui pendekatan STARIMA dalam analisis spasial-temporal curah hujan.




Gambar 4.5: Pola Curah Hujan Wilayah Utara

Curah hujan bulanan di Wilayah Utara selama periode 2015 - 2024 menunjukkan pola musiman yang sangat konsisten, dengan peningkatan intensitas pada bulan Desember hingga Maret dan curah hujan yang hampir nol pada periode Juni hingga September. Puncak hujan tahunan berada pada kisaran 10–15 mm/hari, disertai beberapa kejadian ekstrem yang melebihi 20

mm/hari, terutama pada awal tahun 2020, 2022, dan 2024. Fluktuasi yang tajam antar musim menggambarkan dinamika atmosfer regional yang aktif dan dipengaruhi oleh siklus monsun serta fenomena cuaca skala besar seperti MJO dan ENSO. Pola temporal yang stabil dan berulang ini menunjukkan bahwa Wilayah Utara memiliki struktur deret waktu yang kuat dan cocok dimodelkan menggunakan pendekatan STARIMA untuk analisis dan peramalan spasial-temporal curah hujan.

4.1.3 Karakteristik dengan BoxPlot

Sebelum masuk ke analisis lebih lanjut, diperlukan pemahaman mengenai pola dasar distribusi curah hujan di setiap wilayah. Oleh karena itu, boxplot digunakan untuk menampilkan gambaran awal mengenai sebaran dan karakteristik data curah hujan bulanan.




Gambar 4.6: Boxplot Kelima Wilayah di Surabaya

Gambar 4.6 menampilkan boxplot distribusi curah hujan bulanan untuk lima wilayah di Kota Surabaya, yaitu Timur, Barat, Selatan, Utara, dan Tengah. Secara umum, kelima wilayah menunjukkan pola distribusi yang relatif serupa dengan median curah hujan berada di rata-rata 5 mm/hari, menandakan bahwa sebagian besar nilai curah hujan bulanan terkonsentrasi pada tingkat menengah. Rentang interkuartil (IQR) di seluruh wilayah menunjukkan variasi yang moderat, menggambarkan tingkat sebaran data yang cukup stabil antarwilayah. Meskipun demikian, terlihat adanya beberapa outlier pada Wilayah Barat, Selatan, dan Tengah dengan nilai di atas 25 mm/hari yang

menandakan adanya kejadian hujan ekstrem pada periode tertentu. Sementara itu, nilai minimum di setiap wilayah mendekati nol, menunjukkan periode kering yang umum terjadi selama musim kemarau. Tidak terdapat perbedaan yang signifikan antarwilayah dalam hal median maupun rentang variasi, yang mengindikasikan bahwa pola distribusi curah hujan bulanan di Surabaya relatif homogen secara spasial, meskipun dengan sedikit perbedaan amplitudo akibat pengaruh lokal seperti topografi dan kedekatan terhadap kawasan pesisir.

4.1.4 Analisis Temporal Curah Hujan

Analisis temporal dilakukan untuk mengidentifikasi pola perubahan curah hujan dari waktu ke waktu. Berdasarkan grafik deret waktu bulanan yang dibuat untuk masing – masing wilayah terlihat bahwa pola curah hujan Surabaya cenderung musiman dan berulang setiap tahun.



Gambar 4.7: Seasonal Decompose Semua Wilayah

Berdasarkan hasil dekomposisi pada gambar 4.7 tersebut dapat dijelaskan bahwa:

a. Komponen Tren:

Pola tren menunjukkan adanya fluktuasi jangka panjang yang cenderung meningkat secara perlahan hingga pertengahan periode pengamatan, kemudian relatif stabil. Hal ini mengindikasikan bahwa selama 2015-2024, curah hujan di seluruh wilayah Surabaya mengalami kecenderungan peningkatan moderat yang mungkin dipengaruhi oleh faktor klimatologis regional.

b. Komponen Musiman:

Pola musiman menunjukkan fluktuasi yang berulang secara konsisten setiap tahun, dengan puncak curah hujan umumnya terjadi pada Desember

– Februari dan minimum pada Juli – September. Pola ini menggambarkan dengan jelas siklus tahunan curah hujan di semua wilayah Surabaya yang mengikuti pola iklim monsun tropis.

c. **Komponen Residual:**

Komponen residual menunjukkan penyebaran acak disekitar nol yang menandakan bahwa sebagian besar variasi curah hujan telah berhasil dijelaskan oleh komponen tren dan musiman. Tidak terlihat adanya pola sistematis yang menonjol pada residu, sehingga model dekomposisi dianggap cukup baik dalam memisahkan variasi utama pada data

4.1.5 Analisis Korelasi Spatio Temporal

Analisis korelasi spasio-temporal dilakukan untuk mengidentifikasi tingkat keterhubungan pola curah hujan antar wilayah Surabaya. Nilai korelasi yang ditampilkan pada tabel berikut memberikan gambaran mengenai seberapa kuat kesamaan pola hujan secara ruang dan waktu.

Tabel 4.2: Tabel Korelasi Setiap Wilayah

Wilayah	Barat	Selatan	Tengah	Timur	Utara
Barat	1.000000	0.994376	0.993769	0.983211	0.999738
Selatan	0.994376	1.000000	0.999631	0.975665	0.994562
Tengah	0.993769	0.999631	1.000000	0.975762	0.994531
Timur	0.983211	0.975665	0.975762	1.000000	0.983363
Utara	0.999738	0.994562	0.994531	0.983363	1.000000

Tabel 4.2 merupakan tabel yang menunjukkan bahwa kelima wilayah di Surabaya ini memiliki nilai korelasi yang besar antara 0.975 hingga 0.999. Korelasi ini menunjukkan hubungan positif yang sangat kuat artinya peningkatan curah hujan di satu wilayah cenderung diikuti oleh peningkatan di wilayah lain pada waktu yang sama. Hal ini menandakan bahwa curah hujan di Surabaya bersifat homogen secara spasial karena semua wilayah mengalami kondisi meteorologis yang hampir sama.

4.2 ARIMA

4.2.1 Stasioner Data

Setelah dilakukan analisis dekomposisi untuk mengidentifikasi pola tren dan musiman, langkah selanjutnya adalah menguji tingkat kestasioneran data pada masing - masing wilayah. Uji stasioneritas dilakukan untuk memastikan bahwa deret waktu curah hujan telah memenuhi asumsi dasar analisis time series, yaitu nilai rata - rata dan varians yang relatif konstan terhadap waktu. Data yang tidak stasioner dapat menyebabkan estimasi parameter model

menjadi bias dan tidak stabil, sehingga perlu dilakukan transformasi atau differencing sebelum proses pemodelan. Oleh karena itu, pada tahap ini dilakukan pengujian kestasioneran data curah hujan di kelima wilayah Kota Surabaya guna menentukan apakah proses differencing diperlukan untuk menjadikan data stasioner secara statistik.

- a. Kestasioneran terhadap varians Kesationeran data curah hujan terhadap varians dapat dilihat dari transformasi lambda (λ) yang dihasilkan dari plot BoxCox. Jika nilai (λ) mendekati satu maka dapat disimpulkan bahwa data telah stasioner dan sebaliknya. Untuk membuat plot BoxCox data yang digunakan harus bernilai positif.

Tabel 4.3: Nilai Lambda Semua Wilayah

Wilayah	Nilai Lambda
Barat	0.3779
Selatan	0.3476
Tengah	0.3461
Timur	0.3596
Utara	0.3783

Berdasarkan tabel 4.3 nilai λ untuk seluruh wilayah berada pada rentang 0.34 - 0.38, yang menunjukkan bahwa data belum stasioner terhadap varians. Karena itu, diperlukan transformasi Box-Cox agar varians data lebih stabil dan sesuai dengan asumsi pemodelan time series. Transformasi ini membantu meningkatkan kinerja model dengan mengurangi bias akibat varians yang tidak stabil. Setelah transformasi diterapkan, stasioneritas mean diperiksa kembali melalui uji ADF dan analisis ACF/PACF. Jika pola tren atau musiman masih terlihat, maka perlu dilakukan differencing agar data benar - benar stasioner sebelum proses pemodelan.

- b. Kestasioneran terhadap rata - rata

Setelah data stasioner terhadap varians, selanjutnya dilakukan pengujian kestasioneran terhadap rata - rata. Pengujian ini dapat dilakukan dengan Menggunakan *Augmented Dickey-Fuller Unit Root Test*, berikut adalah hipotesisnya:

H_0 : $\phi \geq 0$ (data tidak stasioner terhadap rata-rata)

H_1 : $\phi < 0$ (data stasioner terhadap rata-rata)

Hasil pengujian *Augmented Dickey-Fuller Unit Root* untuk masing-masing lokasi terangkum pada tabel di bawah ini.


Tabel 4.4: Hasil Uji ADF

Wilayah	t-statistik	Nilai-p
Barat	-3.287547	0.015444
Selatan	-3.280075	0.015793
Tengah	-3.254672	0.017030
Timur	-3.347334	0.012891
Utara	-3.270636	0.016243

Tabel 4.4 itu menunjukkan bahwa data curah hujan kelima wilayah Surabaya sudah stasioner sepenuhnya. Berdasarkan hasil tersebut, dapat dilihat bahwa semua wilayah memiliki nilai p-value < 0.05 yang artinya sudah memenuhi syarat untuk melakukan pemodelan ARIMA.


c. Plot ACF dan PACF

Setelah dilakukan transformasi Box-Cox untuk menstabilkan varians dan proses differencing orde pertama untuk menghilangkan tren serta menjadikan data stasioner dalam mean, tahap selanjutnya adalah melakukan analisis fungsi autokorelasi (ACF) dan fungsi autokorelasi parsial (PACF). Analisis ini bertujuan untuk mengidentifikasi struktur keterkaitan temporal antar-observasi dalam deret waktu dan menentukan orde awal model ARIMA, yaitu nilai p (autoregressive) dan q (moving average). Plot ACF digunakan untuk mengamati pola korelasi antar lag waktu guna memperkirakan komponen MA, sedangkan plot PACF digunakan untuk mendeteksi lag signifikan yang mewakili komponen AR. Melalui analisis visual terhadap kedua plot tersebut, dapat diperoleh indikasi awal mengenai bentuk model ARIMA yang paling sesuai dengan karakteristik data curah hujan setelah proses transformasi dan differencing dilakukan. Berikut merupakan hasil plot ACF dan PACF:



Gambar 4.8: Plot ACF dan PACF Wilayah Barat (Sebelum)

Berdasarkan Gambar 4.8 pada plot ACF sebelum transformasi pola autokorelasi menunjukkan penurunan yang lambat dan masih signifikan hingga lag yang tinggi. Hal ini mengindikasikan bahwa data belum stasioner secara temporal karena masih terdapat pengaruh tren dan musiman yang kuat. Nilai autokorelasi positif yang menurun secara perlahan pada ACF memperlihatkan adanya long-term persistence, sedangkan pola PACF yang juga menunjukkan beberapa lag signifikan mengonfirmasi keberadaan komponen autoregresif (AR) dan musiman yang belum tereliminasi sehingga perlu dilakukan differencing dan juga transformasi BoxCox.



Gambar 4.9: Plot ACF dan PACF Wilayah Barat (Sesudah)

Berdasarkan Gambar 4.9 setelah dilakukan transformasi BoxCox dan differencing musiman, pola ACF dan PACF mengalami perubahan signifikan. ACF menunjukkan penurunan cepat di sekitar lag ke-1 hingga lag ke-2 dan kemudian berfluktuasi di sekitar nol, sedangkan PACF menampilkan cut-off yang jelas setelah lag pertama. Kondisi ini menandakan bahwa proses transformasi dan differencing berhasil menghilangkan tren dan menjadikan data stasioner dalam mean dan varians. Untuk plot ACF dan PACF lainnya dapat dilihat di Lampiran 4

d. Transformasi vs Tanpa Transformasi

Untuk memastikan bahwa proses transformasi BoxCox memberikan dampak yang signifikan terhadap stabilitas data dan akurasi prediksi, dilakukan evaluasi komprehensif terhadap kinerja model SARIMA pada lima wilayah. Evaluasi dilakukan dengan membandingkan nilai Root Mean Squared Error (RMSE) antara model yang dibangun tanpa transformasi BoxCox dan model yang menerapkan transformasi tersebut. Perbandingan kuantitatif atas seluruh konfigurasi model disajikan pada tabel dibawah ini

Tabel 4.5: Perbandingan RMSE Tanpa Transformasi dan Dengan Transformasi Box-Cox

Wilayah	Model	Tanpa Transformasi	Transformasi
Barat	$(1,1,0) \times (0,1,0)_{12}$	11.208	3.332
Selatan	$(1,1,0) \times (0,1,0)_{12}$	14.580	4.474
Tengah	$(1,1,0) \times (1,1,0)_{12}$	11.620	4.553
Timur	$(1,1,0) \times (0,1,0)_{12}$	5.206	3.185
Utara	$(1,1,0) \times (0,1,0)_{12}$	11.559	3.353

Berdasarkan Tabel 4.5 yang merupakan evaluasi kinerja berbagai konfigurasi model SARIMA untuk masing - masing wilayah dengan membandingkan nilai RMSE sebelum dan sesudah penerapan transformasi BoxCox. Hasilnya menunjukkan bahwa hampir seluruh wilayah mengalami penurunan RMSE yang signifikan setelah transformasi diterapkan, mengindikasikan bahwa BoxCox mampu menstabilkan varians, meningkatkan kualitas pemodelan, dan menghasilkan performa prediksi yang lebih akurat dibandingkan model tanpa transformasi.

4.2.2 Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi menggunakan metode Maximum Likelihood, disajikan dalam table dibawah ini, bersama dengan standar error, nilai t , dan nilai p masing - masing:

Tabel 4.6: Estimasi Parameter ARIMA

Wilayah	Model	Statistik	AR Parameter			MA Parameter		
			Non Seasonal		Seasonal	Non Seasonal		Seasonal
			AR 1	AR 2	AR	MA 1	MA 2	MA
Barat	$(1,1,0) \times (0,1,0)_{12}$	Estimasi	-0.3800					
		SE	0.112					
		t-value	-3.403					
		p-value	0.001					
Selatan	$(1,1,0) \times (0,1,0)_{12}$	Estimasi	-0.412					
		SE	0.109					
		t-value	-3.825					
		p-value	0.000					
Tengah	$(1,1,0) \times (1,1,0)_{12}$	Estimasi	-0.3575	-0.4898				
		SE	0.137	0.116				
		t-value	-2.608	-4.210				
		p-value	0.009	0.000				
Timur	$(1,1,0) \times (0,1,0)_{12}$	Estimasi	-0.4077					
		SE	0.097					
		t-value	-0.4206					
		p-value	0.000					
Utara	$(1,1,0) \times (0,1,0)_{12}$	Estimasi	-0.3653					
		SE	0.112					
		t-value	-3.267					
		p-value	0.001 ***					

Berdasarkan Tabel 4.6 tersebut, dapat dilihat bahwa setiap wilayah memiliki model terbaik yang sama, yaitu SARIMA $(1, 1, 0) \times (1, 1, 0)_{12}$, dan seluruh parameter yang terbentuk pada masing - masing model menunjukkan nilai p-value < 0.05 , yang berarti seluruh parameter AR non-seasonal dan AR musiman signifikan secara statistik. Hal ini menegaskan bahwa komponen autoregressive, baik pada bagian non-musiman maupun musiman, memberikan kontribusi nyata dalam menjelaskan pola curah hujan bulanan di tiap wilayah. Selain itu, hasil diagnostik checking juga menunjukkan bahwa residual dari seluruh model telah memenuhi asumsi white noise, yang berarti tidak terdapat autokorelasi tersisa pada residual dan model sudah mampu menangkap pola yang ada pada data. Dengan demikian, model SARIMA yang diperoleh dapat dikatakan telah lolos uji kelayakan dan valid digunakan untuk proses peramalan pada masing - masing wilayah.

4.2.3 Model Fitting

Berdasarkan hasil analisis ACF dan PACF pada kelima wilayah terlihat bahwa pola autokorelasi menurun secara bertahap setelah lag ke-1 dan PACF menunjukkan cut-off pada lag pertama, baik untuk komponen non musiman maupun musiman. Pola tersebut mengindikasikan keberadaan komponen agresif (AR) dan moving average (MA) pada lag pertama, serta adanya pengaruh musiman dengan periode tahunan (seasonal periode = 12). Oleh karena itu, model yang sesuai untuk menggambarkan karakteristik data curah hujan di seluruh wilayah Kota Surabaya adalah sebagai berikut:


Tabel 4.7: Hasil Model Fitting ARIMA

Wilayah	Model	RMSE
Barat	$(1, 1, 0) \times (0, 1, 0)_{12}$	3.332
Selatan	$(1, 1, 0) \times (0, 1, 0)_{12}$	4.474
Tengah	$(1, 1, 0) \times (1, 1, 0)_{12}$	4.553
Timur	$(1, 1, 0) \times (0, 1, 0)_{12}$	3.185
Utara	$(1, 1, 0) \times (0, 1, 0)_{12}$	3.353

Dari Tabel 4.7 tersebut diketahui bahwa kelima wilayah menunjukkan model terbaik yang sama, yaitu SARIMA $(1, 1, 0) \times (1, 1, 0)_{12}$ dan $(1, 1, 0) \times (0, 1, 0)_{12}$, berdasarkan pola ACF dan PACF yang konsisten menunjukkan cut-off pada lag pertama serta adanya komponen musiman dengan periode 12 bulan. Meskipun model yang terpilih sama untuk sleuruh wilayah, nilai RMSE berbeda-beda, yang menunjukkan bahwa tingkat akurasi model bervariasi sesuai karakteristik curah hujan tiap wilayah. Wilayah Timur memiliki performa terbaik dengan RMSE terendah (3.185), sedangkan wilayah Tengah memiliki RMSE tertinggi (4.553), mengindikasikan bahwa ketepatan prediksi pada wilayah tersebut lebih rendah dibanding wilayah lainnya.

4.2.4 Hasil Forecasting ARIMA


Berikut merupakan hasil forecasting ARIMA menggunakan model yang ada pada Tabel 4.7:



Gambar 4.10: Hasil Forecasting Wilayah Barat

Berdasarkan Gambar 4.10 model SARIMA $(1, 1, 0) \times (0, 1, 0)_{12}$ pada wilayah Barat menunjukkan kemampuan yang terbatas dalam menangkap dina-


mika curah hujan. Meskipun pada beberapa bulan seperti Januari - Mei serta November - Desember model masih mampu mengikuti arah naik - turun data aktual, prediksi yang dihasilkan cenderung terlalu halus dan memiliki amplitudo yang jauh lebih kecil. Hal ini menyebabkan underestimation yang kuat pada puncak musim hujan awal tahun dan overestimation pada akhir tahun. Kinerja model semakin buruk pada periode Juni - Oktober, ketika curah hujan aktual berada pada titik minimum. Pada periode ini, model tidak hanya memberikan nilai yang jauh lebih tinggi dari aktual, tetap juga sering bergerak berlawanan arah dengan pola sebenarnya. Akibatnya, model gagal merepresentasikan karakteristik musim kemarau. Secara keseluruhan, tingginya nilai RMSE (3.332) memperlihatkan bahwa model ini kurang responsif terhadap perubahan ekstrem dan tidak cukup akurat untuk menggambarkan pola curah hujan wilayah Barat.



Gambar 4.11: Hasil Forecasting Wilayah Selatan


Berdasarkan Gambar 4.11 model SARIMA $(1, 1, 0) \times (0, 1, 0)_{12}$ untuk wilayah Selatan menunjukkan kemampuan yang terbatas dalam menangkap pola naik - turun curah hujan yang sangat fluktuatif sepanjang tahun. Pada awal tahun (Januari - Maret), model masih mampu mengikuti arah kenaikan dengan cukup baik meskipun sempat tertinggal di Januari dan Februari. Namun, mulai April hingga Mei muncul ketidaktepatan magnitudo, dimana model mengunderestimate penurunan April dan kemudian overestimate kenaikan di Mei. Ketidaksesuaian semakin kuat pada periode Juni - Agustus ketika model tidak selaras dengan dinamika musim kemarau, prediksi sering bergerak berlawanan arah dengan aktual dan menunjukkan overestimation besar, terutama pada Agustus. Pada September - Oktober, model kembali tidak responsif karena gagal menangkap titik minimum dan arah pergerakan aktual. Meskipun pada November model cukup selaras, Desember kembali menunjukkan overestimate pada puncak hujan. Secara keseluruhan, model menghasilkan prediksi yang

terlalu halus, kurang mengikuti volatilitas data, serta menghasilkan error tinggi RMSE (4.474) sehingga kurang representatif untuk kondisi curah hujan wilayah Selatan.




Gambar 4.12: Hasil Forecasting Wilayah Tengah

Berdasarkan Gambar 4.12 model SARIMA $(1, 1, 0) \times (1, 1, 0)_{12}$ untuk wilayah Tengah menunjukkan bahwa prediksi yang dihasilkan cenderung jauh lebih halus dibandingkan pola aktual yang sangat fluktuatif. Pada awal tahun (Januari - Maret), model masih mampu mengikuti arah kenaikan meskipun consistently meng-underestimate puncaknya. Arah turun - naik hingga Mei juga masih dapat diikuti dengan cukup baik, bahkan Mei menjadi titik paling akurat. amun memasuki musim kemarau (Juni - Oktober), performa model menurun drastis, model gagal menangkap penurunan ekstrem, sering bergerak berlawanan arah dengan aktual, dan menghasilkan overestimation sangat besar terutama di Agustus. Pada bulan - bulan menjelang akhir tahun, model kembali mengikuti arah perubahan tetapi tetap tidak tepat dalam magnitudo, termasuk underestimation puncak hujan Desember. Secara keseluruhan, model tidak cukup responsif terhadap perubahan ekstrem, menghasilkan prediksi yang terlalu halus, serta memiliki tingkat error yang sangat tinggi RMSE (4.553), sehingga kurang representatif untuk menggambarkan dinamika curah hujan wilayah Tengah.



Gambar 4.13: Hasil Forecasting Wilayah Timur

Berdasarkan Gambar 4.13 model SARIMA $(1, 1, 0) \times (0, 1, 0)_{12}$ untuk wilayah Timur menghasilkan prediksi dengan pola yang jauh lebih halus dibandingkan fluktuasi aktual yang sangat tajam sepanjang tahun. Pada awal tahun, model mampu mengikuti arah kenaikan curah hujan, tetapi consistently meng-underestimate besarannya. Tren penurunan dan kenaikan hingga Mei juga diikuti dengan cukup baik meskipun amplitudo tetap lebih kecil dari aktual. Memasuki musim kemarau, ketidaksesuaian menjadi lebih jelas, model gagal menangkap kenaikan ringan di Juli, bahkan bergerak berlawanan arah pada Agustus dengan memberikan overestimation ekstrem ketika aktual justru menurun. Model juga tidak mampu mencapai titik rendah curah hujan di September. Menjelang akhir tahun, arah peningkatan kembali diikuti tetapi magnitudonya tetap jauh lebih kecil, termasuk underestimation puncak hujan Desember. Secara keseluruhan, model tidak cukup responsif terhadap ekstrem musiman, menghasilkan prediksi yang terlalu konservatif, dan memiliki error tinggi RMSE (3.185) sehingga kurang representatif untuk memodelkan pola curah hujan wilayah Timur.



Gambar 4.14: Hasil Forecasting Wilayah Utara

Berdasarkan Gambar 4.14 model SARIMA $(1, 1, 0) \times (0, 1, 0)_{12}$ untuk wilayah Utara menghasilkan pola prediksi yang lebih halus dibandingkan fluktuasi aktual yang sangat ekstrem. Pada awal tahun, model masih mampu mengikuti arah kenaikan dan penurunan, meskipun consistently meng-underestimate puncak hujan dan tidak sedalam aktual saat menurun. Menjelang Mei, model sempat sangat mendekati nilai aktual, tetapi memasuki musim kemarau (Juni - Oktober), performa model menurun drastis, beberapa kali bergerak berlawanan arah, sering memberikan overestimation besar terutama di Agustus, dan gagal mencapai nilai minimum aktual. Pada bulan - bulan menjelang akhir tahun, model kembali mengikuti arah kenaikan tetapi masih berbeda skala, termasuk sedikit overestimate pada puncak Desember. Secara keseluruhan, model tidak cukup responsif terhadap perubahan tajam, menghasilkan prediksi yang cenderung terlalu halus, dan memiliki error yang masih tinggi RMSE (3.353) sehingga kurang representatif untuk menggambarkan dinamika curah hujan wilayah Utara.

4.3 STARIMA

4.3.1 Stasioner Data

Setelah dilakukan analisis dekomposisi untuk mengidentifikasi pola tren dan musiman, langkah selanjutnya adalah menguji tingkat kestasioneran data pada masing - masing wilayah. Uji stasioneritas dilakukan untuk memastikan bahwa deret waktu curah hujan telah memenuhi asumsi dasar analisis time series, yaitu nilai rata - rata dan varians yang relatif konstan terhadap waktu. Data yang tidak stasioner dapat menyebabkan estimasi parameter model menjadi bias dan tidak stabil, sehingga perlu dilakukan transformasi atau differencing sebelum proses pemodelan. Oleh karena itu, pada tahap ini dilakukan pengujian kestasioneran data curah hujan di kelima wilayah Kota Surabaya gu-

na menentukan apakah proses differencing diperlukan untuk menjadikan data stasioner secara statistik.

A. Kestasioneran terhadap varians

Kestasioneran data curah hujan terhadap varians dapat dilihat dari transformasi lambda (λ) yang dihasilkan dari plot BoxCox. Jika nilai (λ) mendekati satu maka dapat disimpulkan bahwa data telah stasioner dan sebaliknya. Untuk membuat plot BoxCox data yang digunakan harus bernilai positif.

Tabel 4.8: Nilai Lambda Semua Wilayah

Wilayah	Lambda Sebelum	Lambda Sesudah
Barat	0.1962	1.119
Selatan	0.2009	1.140
Tengah	0.1847	1.146
Timur	0.1843	1.305
Utara	0.1894	1.127

Berdasarkan Tabel 4.8 itu nilai λ hasil transformasi BoxCox menunjukkan peningkatan yang signifikan pada seluruh wilayah setelah proses optimasi dilakukan. Kenaikan nilai λ yang mendekati 1 menandakan bahwa varians data curah hujan menjadi lebih stabil dan mendekati kondisi stasioner. Dengan demikian, transformasi BoxCox terbukti efektif sebagai langkah pra pemrosesan untuk menormalkan varians dan memastikan bahwa data memenuhi asumsi homoskedastisitas sebelum proses differencing dan pemodelan STARIMA dilakukan.

B. Kestasioneran terhadap rata - rata


Setelah data stasioner terhadap varians, selanjutnya dilakukan pengujian kestasioneran terhadap rata - rata. Pengujian ini dapat dilakukan dengan Menggunakan *Augmented Dickey-Fuller Unit Root Test*, berikut adalah hipotesisnya: $H_0 : \phi \geq 0$ (data tidak stasioner terhadap rata-rata) vs $H_1 : \phi < 0$ (data stasioner terhadap rata-rata) Hasil pengujian *Augmented Dickey-Fuller Unit Root* untuk masing-masing lokasi terangkum pada tabel dibawah ini:

Tabel 4.9: Hasil Uji ADF

Wilayah	<i>t-statistik</i>	Nilai-p
Barat	-8.314	0.01
Selatan	-8.111	0.01
Tengah	-8.107	0.01
Timur	-7.781	0.01
Utara	-8.313	0.01

Tabel 4.9 menunjukkan bahwa data curah hujan kelima wilayah Surabaya telah stasioner terhadap varians juga stasioner terhadap rata - rata sehingga tidak perlu di diferensiasi. Hal tersebut dapat diketahui dari nilai peluang yang dihasilkan oleh ke 5 wilayah Surabaya yaitu sebesar 0.01. Dengan tingkat kepercayaan 95% dapat disimpulkan bahwa kelima wilayah Surabaya telah stasioner terhadap varians juga stasioner terhadap rata-rata.

Berikut adalah grafik curah hujan kelima wilayah surabaya setelah dilakukan transformasi BoxCox dan differencing.



Gambar 4.15: Hasil Grafik Curah Hujan Setelah Transformasi dan Differencing

Berdasarkan Gambar 4.15 diatas pola curah hujan yang telah melalui proses differencing musiman, setelah transformasi BoxCox diterapkan.

Seluruh wilayah Barat, Selatan, Tengah, Timur, dan Utara menunjukkan fluktuasi yang lebih stabil serta tidak lagi memperlihatkan pola musiman yang berulang, menandakan bahwa komponen musiman berhasil dieliminasi. Pola residual yang berosilasi di sekitar nol mengindikasikan bahwa data telah berada dalam kondisi yang lebih mendekati stasioner, sehingga layak digunakan untuk pemodelan STARIMA pada tahap selanjutnya.


4.3.2 Bobot Seragam

Pada STARIMA ini setelah melakukan stasioner tes seperti pada poin 4.3.1 lalu membuat pembobotan yang mana disini menggunakan tiga pembobotan yaitu bobot lokasi seragam, bobot lokasi invers jarak, dan bobot lokasi normalisasi korelasi silang. Penggunaan ketiga bobot ini dilakukan untuk mendapatkan model STARIMA terbaik dengan bobot lokasi yang sesuai. Berikut merupakan matriks bobot lokasi seragam:

$$W = \begin{pmatrix} 0.00 & 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.00 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.00 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.00 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 & 0.00 \end{pmatrix} \quad (4.1)$$

A. Identifikasi

Setelah mendapatkan bobot, melakukan perhitungan STACF seperti pada Rumus 2.7 dan STPACF seperti pada Rumus 2.8. Perhitungan Perhitungan STACF dan STPACF ini digunakan untuk menentukan orde p , q nya karena data nya sudah di differencing. Berikut adalah plot STACF dan STPACF:




Gambar 4.16: STACF dan STPACF SLAG 0

Gambar 4.16 menunjukkan hasil analisis Spatio-Temporal Autocorrelation Function (STACF) dan Spatio-Temporal Partial Autocorrelation Function (STPACF) menggunakan bobot seragam. Kedua grafik ini digunakan untuk mengidentifikasi pola keterkaitan spasial dan temporal

pada data curah hujan antar wilayah di Kota Surabaya.

Berdasarkan plot STACF, pada beberapa temporal lag awal (khusus nya lag 1-3) menunjukkan autokorelasi positif yang cukup kuat, berada di atas batas kepercayaan 95%. Hal ini menandakan adanya ketergantungan temporal jangka pendek, di mana curah hujan pada periode ini masih dipengaruhi oleh periode sebelumnya. Setelah lag ke-5 autokorelasi mulai berfluktuasi disekitar nol dengan kecenderungan negatif cukup konsisten setelah lag ke-25 hingga lag ke-40. Hal ini menunjukkan adanya siklus musiman pada data curah hujan bulanan.

Sementara itu, plot STPACF yang signifikan pada lag 1 dengan amplitudo cukup tinggi (sekitar 0,4) menandakan adanya pengaruh langsung yang kuat dari satu periode sebelumnya terhadap periode saat ini. Nilai nilai berikutnya tampak menurun dan berfluktuasi di sekitar nol dengan beberapa titik yang masih melewati batas kepercayaan 95%. Hal ini menunjukkan adanya pengaruh remporal yang semakin lemah seiring bertambahnya lag. Nilai STPACF yang relatif acak setelah lag ke-5 mengindikasikan bahwa sebagian besar struktur autokorelasi telah tertangkap oleh komponen AR pada lag awal. Dengan kata lain, model STARIMA dapat menggunakan orde $p=1$ atau 2 sebagai kandidat awal untuk komponen AR. Secara keseluruhan, kombinasi pola pada STACF dan STPACF mendukung pemilihan model dengan struktur STARIMA(3,1,2), tergantung pada kekuatan korelasi spasial dan kestabilan residual yang akan dievaluasi pada tahap estimasi berikutnya.



Gambar 4.17: STACF dan STPACF SLAG 1

Gambar 4.17 menunjukkan hasil analisis Spatio-Temporal Autocorrelation Function (STACF) dan Spatio-Temporal Partial Autocorrelation Function (STPACF) menggunakan bobot seragam. Kedua grafik ini digunakan untuk mengidentifikasi pola keterkaitan spasial dan temporal pada data curah hujan antar wilayah di Kota Surabaya.

Berdasarkan plot STACF, pada beberapa temporal lag awal (khusus nya lag 1-3) menunjukkan autokorelasi positif yang cukup kuat, berada di atas batas kepercayaan 95%. Hal ini menandakan adanya pengaruh spa-

sial langsung antar wilayah yang berdekatan dimana curah hujan di satu wilayah pada waktu tertentu masih berkaitan erat dengan kondisi wilayah sekitarnya pada periode sebelumnya. Setelah lag ke-5 autokorelasi mulai berfluktuasi di sekitar nol dengan kecenderungan negatif cukup konsisten setelah lag ke-25 hingga lag ke-40. Hal ini menunjukkan adanya fase keterlambatan pengaruh spatio-temporal dimana efek keterkaitan spasial mulai melemah dan bergeser menjadi hubungan negatif akibat perbedaan siklus hujan antar wilayah.

Sementara itu, plot STPACF yang signifikan pada lag 1 menunjukkan hubungan langsung antar waktu yang kuat antara wilayah dan tetangganya yang berarti curah hujan di satu wilayah sangat dipengaruhi oleh kondisi wilayah sekitar pada satu periode sebelumnya. Beberapa nilai STPACF lainnya yang melewati batas kepercayaan pada lag 6, 10 dan 20 menunjukkan ada resonansi temporal tambahan, kemungkinan akibat siklus musiman yang berulang di beberapa wilayah. Setelah lag ke-25, nilai STPACF sebagian besar berfluktuasi di sekitar nol menandakan bahwa pengaruh langsung antar waktu di antara wilayah sudah sangat lemah dan sebagian besar ketergantungan sudah dijelaskan oleh lag awal.

Secara keseluruhan, kombinasi pola pada STACF dan STPACF mendukung pemilihan model dengan struktur STARIMA(3,1,2), tergantung pada kekuatan korelasi spasial dan kestabilan residual yang akan dievaluasi pada tahap estimasi berikutnya.

B. Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi (STARIMA (1,1,0), STARIMA (1,1,1), dan STARIMA (1,1,2)) menggunakan metode Maximum Likelihood, disajikan dalam Tabel 4.10, bersama dengan standar error, nilai t, dan nilai p masing-masing:

Tabel 4.10: Estimasi Parameter

Spatial Orde	Model	Statistik	AR Parameter			MA Parameter		
			ϕ_{10}	Φ_{20}	Φ_{30}	Θ_{10}	Θ_{20}	Θ_{30}
Lag 0	1,1,0	Estimasi	0.4812					
		SE	0.0435					
		t-value	11.1					
		p-value	< 0.000000000000002 ***					
	1,1,1	Estimasi	0.5747			-0.1557		
		SE	0.0685			0.0853		
		t-value	8.39			-1.83		
		p-value	0.000000000000056 ***	0.069				
	1,1,2	Estimasi	0.6760	-0.2765	-0.1313			
		SE	0.088	0.1082	0.076			
		t-value	7.62	2.56	1.71			
		p-value	0.0000000000014 ***	0.011 ***	0.087			
Lag 1	1,1,0	Estimasi	0.4890					
		SE	0.0437					
		t-value	11.2					
		p-value	< 0.000000000000002 ***					
	1,1,1	Estimasi	0.5711			-1.392		
		SE	0.0681			0.0855		
		t-value	8.38			-1.63		
		p-value	0.00000000000058 ***	0.10				
	1,1,2	Estimasi	0.679	-0.2783	-0.125			
		SE	0.114	0.143	0.102			
		t-value	5.94	-1.98	-1.23			
		p-value	0.00000057 ***	0.048	0.221			

Berdasarkan Tabel 4.10 hasil estimasi parameter dari tiga model STARIMA (1,1,0), (1,1,1), dan (1,1,2) pada lag spasial 0 dan lag spasial 1 yang diestimasi menggunakan metode Maximum Likelihood. Masing-masing parameter dilaporkan bersama standar error, nilai t, dan nilai p untuk menilai signifikansi statistik. Secara umum, model STARIMA (1,1,0) menunjukkan parameter autoregressive yang sangat signifikan dengan nilai p jauh di bawah ambang 0.05, sedangkan model (1,1,1) dan (1,1,2) memperlihatkan kombinasi parameter AR dan MA yang cenderung kurang stabil atau tidak seluruhnya signifikan. Berdasarkan keseluruhan pola signifikansi, konsistensi, dan stabilitas parameter, model STARIMA (1,1,0) menjadi konfigurasi yang paling unggul untuk bobot seragam.

C. Model terbaik

Untuk memilih model spasial terbaik dalam penelitian ini menggunakan evaluasi Root Mean Squared Error (RMSE) untuk membandingkan kinerja peramalan dari model - model STARIMA. Berdasarkan hasil pada Lampiran 14, berikut adalah tabel nya


Tabel 4.11: Hasil Model Fitting STARIMA

Wilayah	STARIMA (1,1,0) ₀	STARIMA (1,1,1) ₀	STARIMA (1,1,0) ₁	STARIMA (1,1,1) ₁
Barat	1.689	1.652	1.685	1.653
Selatan	2.019	2.003	2.018	2.005
Tengah	2.065	2.125	2.066	2.119
Timur	1.423	1.408	1.420	1.407
Utara	1.699	1.681	1.696	1.680
Rata-Rata	1.779	1.7738	1.777	1.7728

Berdasarkan Tabel 4.11, terlihat bahwa setiap konfigurasi model STARIMA menghasilkan nilai RMSE yang berbeda untuk masing-masing wilayah. Secara umum, nilai RMSE seluruh model berada pada kisaran 1.40 - 2.12, menunjukkan bahwa performa model cukup stabil di seluruh wilayah Surabaya. Jika dilihat dari nilai rata-rata RMSE di bagian bawah tabel, model STARIMA (1, 1, 1)₁ memiliki nilai rata-rata terkecil, yaitu 1.7728, sehingga dapat disimpulkan sebagai model dengan performa terbaik dibandingkan model lainnya. Nilai rata-rata RMSE yang lebih rendah menunjukkan bahwa model ini paling efektif dalam menangkap pola spasio-temporal curah hujan pada seluruh wilayah. Secara wilayah, model STARIMA (1, 1, 1)₁ memberikan hasil RMSE yang relatif kecil terutama pada wilayah Timur (1.407) dan Utara (1.680), yang menunjukkan bahwa kedua wilayah ini memiliki pola curah hujan yang lebih mudah diprediksi ketika mempertimbangkan hubungan spasial antar wilayah. Sementara itu, wilayah Tengah cenderung memiliki RMSE lebih tinggi pada semua model, yang mengindikasikan bahwa fluktuasi curah hujan di wilayah ini lebih kompleks atau dipengaruhi variabilitas spasial yang lebih besar. Jika dibandingkan dengan model lain seperti STARIMA (1, 1, 0)₀ atau STARIMA (1, 1, 1)₀, terlihat bahwa penambahan komponen spasial pada lag 1 memberikan peningkatan akurasi. Hal ini menunjukkan bahwa hubungan spasial antar wilayah memiliki peran signifikan dalam memodelkan curah hujan di Surabaya, sehingga model dengan komponen spasial yang lebih lengkap menjadi lebih representatif. Secara keseluruhan, analisis ini menegaskan bahwa model STARIMA yang mempertimbangkan baik hubungan temporal maupun spasial pada lag pertama mampu menghasilkan prediksi yang paling akurat. Oleh karena itu, STARIMA (1, 1, 1)₁ dipilih sebagai model spasial terbaik dalam penelitian ini.


D. Hasil Forecasting STARIMA

Berikut adalah hasil peramalan curah hujan di berbagai wilayah menggunakan bobot seragam:




Gambar 4.18: Hasil Peramalan Wilayah Barat

Berdasarkan Gambar 4.18 Hasil prediksi cuaca di wilayah barat menunjukkan error sebesar 1.652, yang menunjukkan bahwa tingkat kesalahan ini relatif kecil, artinya model memiliki kemampuan memprediksi yang cukup baik. Model mampu mengenali tren peningkatan curah hujan musiman di awal tahun dengan baik. Namun, pada bulan Mei hingga Agustus terjadi penurunan curah hujan, dan prediksi model sedikit lebih tinggi dibandingkan dengan data aktual. Mulai dari bulan September hingga Desember, tren kenaikan curah hujan kembali terdeteksi secara akurat. Hal ini menunjukkan bahwa model mampu mengikuti dinamika perubahan waktu dengan cukup tepat.




Gambar 4.19: Hasil Peramalan Wilayah Selatan

Berdasarkan Gambar 4.19 Model STARIMA dengan bobot seragam menghasilkan kesalahan sebesar 2.003. Hasil ini masih cukup baik karena model mampu menangkap tren umum curah hujan, meskipun terdapat sedikit perbedaan pada fase-fase ekstrem. Pada awal tahun, model mengikuti pola kenaikan curah hujan dengan baik, terutama hingga puncak bulan Maret. Namun, terlihat sedikit terlalu tinggi. Lalu, antara bulan Mei sampai Agustus terjadi penurunan curah hujan yang cukup signifikan, dan model berhasil menangkap tren tersebut. Di bulan September hingga Desember, tren curah hujan mulai meningkat kembali, model menunjukkan kemampuan adaptasi yang baik dalam mengikuti pola tersebut. Namun, menjelang bulan Desember, prediksi sedikit lebih tinggi dari data aktual, sehingga puncak curah hujan tidak sepenuhnya terwakili. Jadi, dari hasil peramalan ini sudah cukup memadai untuk menggambarkan pola curah hujan musiman, tetapi belum sepenuhnya menangkap variasi spasial spesifik.




Gambar 4.20: Hasil Peramalan Wilayah Tengah

Berdasarkan Gambar 4.20 Model STARIMA dengan bobot seragam menghasilkan nilai kesalahan sebesar 2.125. Model ini mampu mengikuti tren kenaikan curah hujan hingga mencapai puncaknya sekitar bulan Maret, dengan sedikit perbedaan nilai pada masa-masa ekstrem. Model cenderung sedikit mengestimasi nilai yang lebih tinggi di awal tahun, menunjukkan bahwa model merespon terhadap autokorelasi temporal yang kuat. Selanjutnya, dari bulan Mei sampai Agustus, curah hujan mengalami penurunan yang signifikan, dan model berhasil menangkap tren tersebut dengan baik. Sementara itu, dari bulan September sampai Desember, model kembali mengikuti tren kenaikan curah hujan yang terjadi menjelang akhir tahun.



Gambar 4.21: Hasil Peramalan Wilayah Timur

Berdasarkan Gambar 4.21 Model STARIMA dengan bobot seragam di wilayah Timur memberikan nilai kesalahan terkecil yaitu 1.408. Model ini mampu menggambarkan dengan tepat pola peningkatan curah hujan musiman hingga mencapai puncaknya sekitar bulan Maret. Setelah itu terjadi penurunan yang cukup signifikan mulai bulan Mei hingga Agustus. Model menunjukkan bahwa tren ini konsisten dan menghasilkan nilai prediksi yang lebih tinggi dibandingkan dengan nilai aktual. Pada bulan September hingga Desember, hasil prediksi menunjukkan kemiripan dengan data nyata, namun di bulan Desember terjadi under forecast pada puncaknya.



Gambar 4.22: Hasil Peramalan Wilayah Utara

Berdasarkan Gambar 4.22 Model STARIMA Menggunakan bobot seragam menunjukkan nilai error sebesar 1.681 yang berarti tingkat kesalahan prediksi relatif rendah dan model mampu mengikuti pola temporal curah hujan aktual dengan baik terutama dalam menangkap siklus musiman tahunan. Model ini merepresentasikan tren kenaikan curah hujan hingga puncak sekitar Maret. Garis prediksi cenderung sedikit lebih rendah dari data aktual pada puncak maksimum, namun pola kenaikan dan penurunan menunjukkan akurasi yang konsisten. Curah hujan pada bulan Mei sampai Agustus model sedikit over forecast, namun tetap mempertahankan bentuk tren yang realistis. Pada bulan September sampai Desember tren curah hujan kembali meningkat dan model mampu mengikuti arah kenaikan dengan cukup baik. Sedikit under forecast muncul di sekitar Desember, tetapi model tetap menunjukkan sinkronisasi temporal yang kuat dengan data aktual.

4.3.3 Bobot Invers Jarak


Perhitungan bobot lokasi inver jarak menggunakan jarak sebenarnya natar lokasi, perhitungan bobot ini diperoleh dari hasil invers jarak sebenarnya yang kemudian dinormalisasi. Perhitungan jarak antar wilayah dapat dilakukan sesuai dengan Persamaan 2.25 yaitu dengan menggunakan posisi longitude dan latitude dari kedua wilayah yang akan dihitung jaraknya. Posisi longitude dan latitude yang digunakan berupa jarak terluar atau terjauh dari masing masing wilayah Surabaya. Bobot lokasi invers jarak memberikan nilai koefisien yang kecil untuk jarak yang lebih jauh dan sebaliknya. Berikut merupakan matriks

bobot lokasi invers jarak:

$$W = \begin{pmatrix} 0.00 & 0.2380 & 0.2946 & 0.1612 & 0.3063 \\ 0.1896 & 0.00 & 0.3409 & 0.2637 & 0.2058 \\ 0.1727 & 0.2508 & 0.00 & 0.2031 & 0.3734 \\ 0.1482 & 0.3403 & 0.3186 & 0.00 & 0.2290 \\ 0.2112 & 0.1781 & 0.4910 & 0.1717 & 0.00 \end{pmatrix} \quad (4.2)$$

A. Identifikasi


Setelah mendapatkan bobot, melakukan perhitungan STACF seperti pada Rumus 2.7 dan STPACF seperti pada Rumus 2.8. Perhitungan Perhitungan STACF dan STPACF ini digunakan untuk menentukan orde p , q nya karena data nya sudah di differencing. Berikut adalah plot STACF dan STPACF:



Gambar 4.23: STACF dan STPACF SLAG 0

Berdasarkan Gambar 4.23 pada kondisi slag 0 dengan bobot invers jarak didapatkan nilai STACF pada lag ke-1 hingga lag ke-3 menunjukkan autokorelasi positif yang cukup kuat dan signifikan, melewati batas kepercayaan 95%. Hal ini menunjukkan bahwa curah hujan periode sekarang memiliki hubungan erat dengan periode satu hingga tiga bulan sebelumnya. Setelah lag ke-5 nilai autokorelasi berfluktuasi di sekitar nol, kemudian mengalami pola negatif yang semakin kuat setelah lag ke-25 hingga lag ke-40. Pola ini menunjukkan adanya pergeseran siklus temporal musiman.

Sedangkan pada nilai STPACF, menunjukkan puncak signifikan pada lag ke-1 dengan sekitar 0,4 menandakan adanya pengaruh langsung yang kuat dari periode satu bulan sebelumnya terhadap periode saat ini. Beberapa nilai STPACF pada lag ke-6, lag ke-12 dan lag ke-18 masih melampaui batas kepercayaan. Hal ini menunjukkan bahwa komponen musiman yang berulang secara periodik. Setelah lag ke-25, pola STPACF berfluktuasi di sekitar nol dan cenderung melemah, menunjukkan keterkaitan temporal langsung mulai hilang dan sebagian besar variasi sudah dapat dijelaskan oleh lag awal.



Gambar 4.24: STACF dan STPACF SLAG 1

pada kondisi slag 1 dengan bobot invers jarak didapatkan nilai STACF pada lag 1 hingga lag 3 menunjukkan autokorelasi positif yang signifikan dengan beberapa nilai berada di batas kepercayaan 95%. Hal ini menunjukkan bahwa curah hujan di suatu wilayah sangat dipengaruhi oleh curah hujan di wilayah lain yang berdekatan pada waktu sebelumnya. Setelah lag ke-5, nilai autokorelasi mulai berfluktuasi di sekitar nol dan kemudian menurun tajam menjadi negatif pada lag di atas 25, menunjukkan bahwa pengaruh spasial antar wilayah berkurang secara bertahap dan berubah arah menjadi berlawanan fase akibat siklus musiman. Sedangkan pada nilai STPACF, lag 1 masih menunjukkan pengaruh langsung yang kuat antara wilayah dan tetangga terdekatnya. Beberapa nilai signifikan juga muncul pada lag ke-10, lag ke-20 dan lag ke-28 yang dapat menunjukkan reasonasi temporal tambahan akibat kesamaan pola curah hujan antar wilayah yang memiliki jarak spasial tertentu namun masih berada dalam radius pengaruh spasial model. Setelah lag ke-25, nilai STPACF berfluktuasi di sekitar nol dan tidak lagi signifikan, menunjukkan bahwa pengaruh langsung antar wilayah berkurang secara substansi dan mayoritas ketergantungan spasio temporal telah dijelaskan oleh lag awal.

B. Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi (STARIMA (1,1,0), STARIMA (1,1,1), dan STARIMA (1,1,2)) menggunakan metode Maximum Likelihood, disajikan dalam Tabel 4.12, bersama dengan standar error, nilai t, dan nilai p masing-masing:

Tabel 4.12: Estimasi Parameter

Spatial Orde	Model	Statistik	AR Parameter			MA Parameter		
			ϕ_{10}	Φ_{20}	Φ_{30}	Θ_{10}	Θ_{20}	Θ_{30}
Lag 0	1,1,0	Estimasi	0.4812					
		SE	0.0435					
		t-value	11.1					
		p-value	< 0.000000000000002 ***					
	1,1,1	Estimasi	0.5747			-0.1557		
		SE	0.0685			0.0853		
		t-value	8.39			-1.83		
		p-value	0.0000000000000056 ***	0.069				
	1,1,2	Estimasi	0.6760	-0.2765	-0.1313			
		SE	0.088	0.1082	0.076			
		t-value	7.62	2.56	1.71			
		p-value	0.000000000000014 ***	0.011 ***	0.087			
Lag 1	1,1,0	Estimasi	0.4849					
		SE	0.0436					
		t-value	11.1					
		p-value	< 0.000000000000002 ***					
	1,1,1	Estimasi	0.5694			-0.1423		
		SE	0.0682			0.0855		
		t-value	8.34			1.66		
		p-value	0.0000000000000078 ***	0.097				
	1,1,2	Estimasi	0.6760	-0.2792	-0.1297			
		SE	0.1114	0.1385	0.0983			
		t-value	6.07	-2.02	-1.32			
		p-value	0.00000000026 ***	0.044	0.187			

C. Model Terbaik

Untuk memilih model spasial terbaik dalam penelitian ini menggunakan evaluasi Root Mean Squared Error (RMSE) untuk membandingkan kinerja peramalan dari model-model STARIMA. Berdasarkan hasil pada Lampiran 15, berikut adalah tabel nya:


Tabel 4.13: Hasil Model Fitting STARIMA

Wilayah	STARIMA (1,1,0) ₀	STARIMA (1,1,1) ₀	STARIMA (1,1,0) ₁	STARIMA (1,1,1) ₁
Barat	1.688	1.652	1.686	1.653
Selatan	2.020	2.005	2.020	2.005
Tengah	2.067	2.127	2.067	2.121
Timur	1.420	1.407	1.419	1.407
Utara	1.698	1.681	1.696	1.681
Rata-Rata	1.7786	1.7744	1.7776	1.7734

Berdasarkan hasil Tabel 4.13 diatas model STARIMA (1, 1, 1)₁ menunjukkan kinerja paling optimal secara agregat dengan nilai RMSE rata-rata 1.7734, yang merupakan nilai terendah dibandingkan tiga model lainnya. Hal ini menegaskan bahwa kombinasi komponen autoregressive


dan moving average baik pada lag spasial maupun temporal mampu menangkap dinamika curah hujan secara lebih presisi di seluruh wilayah pengamatan. Model ini secara konsisten memberikan performa yang lebih stabil lintas wilayah, sehingga direkomendasikan sebagai konfigurasi STARIMA terbaik untuk implementasi dalam penelitian ini.

- D. Hasil Forecasting STARIMA Berikut adalah hasil forecasting menggunakan model STARIMA(1,1,2)₁ dengan bobot invers jarak:




Gambar 4.25: Hasil Peramalan Wilayah Barat

Gambar 4.25 diatas merupakan hasil forecasting di wilayah Barat periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrem curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) dapat ditangkap dengan baik oleh model. Dengan nilai RMSE sebesar 1.653 menunjukkan bahwa error forecasting berada pada kategori rendah sehingga model dapat dikatakan memiliki akurasi yang cukup baik dalam memprediksi pola curah hujan di wilayah Barat.




Gambar 4.26: Hasil Peramalan Wilayah Selatan

Gambar 4.26 diatas merupakan hasil forecasting di wilayah Selatan periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) dapat ditangkap dengan baik oleh model. Dengan nilai RMSE sebesar 2.005 menunjukkan bahwa error forecasting berada pada kategori kecil sehingga model dapat dikatakan memiliki akurasi yang cukup baik dalam memprediksi pola curah hujan di wilayah Selatan.




Gambar 4.27: Hasil Peramalan Wilayah Tengah

Gambar 4.27 diatas merupakan hasil forecasting di wilayah Tengah periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) dapat ditangkap dengan baik oleh model. Dengan nilai RMSE sebesar 2.121 menunjukkan bahwa error forecasting berada pada kategori sedang sehingga model dapat dikatakan memiliki akurasi yang cukup baik dalam memprediksi pola curah hujan di wilayah Tengah. Dengan demikian, model STARIMA dapat dikatakan memiliki kinerja yang stabil meskipun akurasinya sedikit lebih tinggi daripada wilayah Barat dan Selatan.



Gambar 4.28: Hasil Peramalan Wilayah Timur

Gambar 4.28 diatas merupakan hasil forecasting di wilayah Timur periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) meskipun terdapat perbedaan data aktual dan hasil forecast tetapi itu tidak mempengaruhi pola keseluruhan. Dengan nilai RMSE sebesar 1,407 menunjukkan bahwa error forecasting berada pada kategori rendah sehingga model dapat dikatakan memiliki akurasi yang sangat baik dalam memprediksi pola curah hujan di wilayah Timur.



Gambar 4.29: Hasil Peramalan Wilayah Utara

Gambar 4.29 diatas merupakan hasil forecasting di wilayah Utara periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) meskipun terdapat perbedaan data aktual dan hasil forecast tetapi itu tidak mempengaruhi pola keseluruhan. Dengan nilai RMSE sebesar 1.681 menunjukkan bahwa error forecasting berada pada kategori rendah sehingga model dapat dikatakan memiliki akurasi yang sangat baik dalam memprediksi pola curah hujan di wilayah Utara.

4.3.4 Bobot Lokasi Normalisasi Korelasi Silang


Perhitungan bobot lokasi normalisasi korelasi silang dapat diselesaikan dengan menormalisasikan korelasi silang antar lokasi pada lag yang sesuai, penentuan lag berdasarkan orde struktur data deret waktu. Perhitungan bobot lokasi normalisasi korelasi silang sesuai dengan Persamaan 2.29 pada lag 1, karena order struktur deret waktu yang didapatkan pada studi kasus ini yaitu STARIMA (1,1,1). Berikut merupakan matriks bobot lokasi normalisasi

korelasi silang:

$$W = \begin{pmatrix} 0.00 & 0.2504 & 0.2503 & 0.2476 & 0.2518 \\ 0.2508 & 0.00 & 0.2522 & 0.2461 & 0.2509 \\ 0.2507 & 0.2522 & 0.00 & 0.2462 & 0.2509 \\ 0.2509 & 0.2490 & 0.2490 & 0.00 & 0.2510 \\ 0.2517 & 0.2504 & 0.2504 & 0.2476 & 0.00 \end{pmatrix} \quad (4.3)$$

A. Identifikasi

Setelah mendapatkan bobot, melakukan perhitungan STACF seperti pada Rumus 2.7 dan STPACF seperti pada Rumus 2.8. Perhitungan Perhitungan STACF dan STPACF ini digunakan untuk menentukan orde p , q nya karena data nya sudah di differencing. Berikut adalah plot STACF dan STPACF:




Gambar 4.30: STACF dan STPACF SLAG 0

Gambar 4.30 merupakan hasil STACF pada slag 0 dengan pembobotan korelasi silang. Terlihat bahwa nilai autokorelasi pada beberapa temporal lag awal (khususnya lag ke-1 hingga lag ke-3) menunjukan nilai positif yang cukup tinggi dan berada di atas batas kepercayaan 95% menunjukan adanya dependensi temporal yang kuat pada data curah hujan. Yang berarti nilai curah hujan pada waktu tertentu masih dipengaruhi oleh nilai-nilai curah hujan pada periode sebelumnya. Setelah lag ke-5 nilai autokorelasi mulai menurun dan berfluktuasi di sekitar nol dengan beberapa lag menunjukan nilai negatif signifikan terutama setelah lag ke-25. Pola ini menunjukan bahwa pengaruh temporal menurun seiring bertambahnya jeda waktu dan kemungkinan terdapat pola musiman pada data curah hujan.

Sedangkan nilai STPACF pada slag 0, nilai autokorelasi parsial yang signifikan hanya muncul pada beberapa lag awal (khususnya lag ke-1 dan lag ke-13) yang menunjukan bahwa komponen AR pada model kemungkinan kecil, dengan dominasi efek pada lag pendek. Setelah itu, nilai

STPACF berfluktuasi di sekitar nol dan tidak menunjukkan pola signifikan yang teratur. Hal ini menunjukkan bahwa setelah mempertimbangkan pengaruh lag terdekat, hubungan antar waktu berikut menjadi relatif lemah. Secara keseluruhan pola STACF dan STPACF dengan bobot korelasi silang slag 0 menunjukkan bahwa data curah hujan memiliki struktur ketergantungan temporal jangka pendek dengan efek spasial musiman (karena lag spasial = 0). Oleh karena itu, model STARIMA yang sesuai untuk kondisi ini kemungkinan akan memiliki order AR rendah, dengan komponen spasial yang lebih menonjol pada lag $i, 0$.



Gambar 4.31: STACF dan STPACF SLAG 1

Gambar 4.31 merupakan hasil STACF pada slag 1 dengan pembobotan korelasi silang. Pola autokorelasi pada beberapa temporal lag awal (khususnya lag ke-1 hingga lag ke-3) memiliki nilai positif yang cukup tinggi dan melampaui batas kepercayaan 95%. Hal ini menunjukkan bahwa terdapat keterkaitan kuat antar wilayah yang berdekatan secara spasial dalam waktu yang berdekatan. Setelah lag 5, nilai autokorelasi mulai menurun dan berganti menjadi negatif secara konsisten setelah lag ke-20, menandakan adanya pola musiman terbalik atau perubahan fase curah hujan antara periode. Pola negatif yang stabil hingga lag ke-40 menunjukkan bahwa pengaruh spasial antar wilayah cenderung bersifat jangka pendek dan melemah seiring meningkatnya jarak waktu. Sedangkan nilai STPACF pada slag 1 nilai autokorelasi parsial yang tinggi pada lag ke-1 menunjukkan bahwa hubungan AR dan spasial pada lag pendek sangat dominan. Di mana curah hujan di suatu wilayah dipengaruhi secara signifikan oleh curah hujan pada wilayah sekitar pada periode sebelumnya. Setelah lag ke-5, sebagian besar nilai STACF berfluktuasi di sekitar nol dengan hanya beberapa lonjakan kecil yang signifikan menunjukkan bahwa hubungan spatio temporal selanjutnya relatif lemah. Secara keseluruhan pola STACF dan STPACF dengan pembobotan korelasi silang slag 1 menunjukkan adanya keterkaitan spasial yang nyata antarwilayah berdekatan dalam waktu singkat dengan pengaruh yang semakin menurun pada periode lebih panjang. Hal ini memperkuat indikasi bahwa

model STARIMA yang digunakan perlu mempertimbangkan komponen spasial autoregressive dengan lag pendek (Slag 1) untuk menangkap dinamika curah hujan secara lebih akurat.

B. Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi (STARIMA (1,1,0), STARIMA (1,1,1), dan STARIMA (1,1,2)) menggunakan metode Maximum Likelihood, disajikan dalam Tabel 4.14, bersama dengan standar error, nilai t, dan nilai p masing-masing:

Tabel 4.14: Estimasi Parameter

Spatial Orde	Model	Statistik	AR Parameter			MA Parameter		
			ϕ_{10}	Φ_{20}	Φ_{30}	Θ_{10}	Θ_{20}	Θ_{30}
Lag 0	1,1,0	Estimasi	0.4812					
		SE	0.0435					
		t-value	11.1					
		p-value	< 0.0000000000000002					
	1,1,1	Estimasi	0.5747			-0.1557		
		SE	0.0685			0.0853		
		t-value	8.39			-1.83		
		p-value	0.0000000000000056	0.069				
	1,1,2	Estimasi	0.6760	-0.2765	-0.1313			
		SE	0.088	0.1082	0.076			
		t-value	7.62	2.56	1.71			
		p-value	0.00000000000014	0.011	0.087			
Lag 1	1,1,0	Estimasi	0.4890					
		SE	0.0437					
		t-value	11.2					
		p-value	< 0.0000000000000002					
	1,1,1	Estimasi	0.5712			-0.1392		
		SE	0.0681			0.0855		
		t-value	8.39			-1.63		
		p-value	0.000000000000057	0.10				
	1,1,2	Estimasi	0.6760	-0.2792	-0.1297			
		SE	0.1115	0.1440	0.1020			
		t-value	5.90	-1.97	-1.22			
		p-value	0.000000007	0.05	0.22			

Berdasarkan Tabel 4.14 diatas merupakan hasil estimasi parameter untuk model STARIMA dengan kombinasi orde (1,1,0), (1,1,1), dan (1,1,2) pada lag spasial 0 dan 1. Setiap parameter dilaporkan bersama standar error, nilai t, serta nilai p untuk mengukur signifikansi statistiknya. Secara umum, parameter autoregressive (ϕ) pada seluruh model menunjukkan signifikansi yang tinggi, khususnya pada lag 0 dan lag 1, yang mengindikasikan adanya ketergantungan temporal yang kuat dalam data. Sementara itu, parameter moving average (θ) pada model dengan orde lebih tinggi memperlihatkan variasi tingkat signifikansi, mencerminkan kompleksitas dinamika spasial-temporal yang diwakili oleh masing-masing

model.

C. Model Terbaik

Untuk memilih model spasial terbaik dalam penelitian ini menggunakan evaluasi Root Mean Squared Error (RMSE) untuk membandingkan kinerja peramalan dari model-model STARIMA. Berdasarkan hasil pada Lampiran 16, berikut adalah tabel nya:


Tabel 4.15: Hasil Model Fitting STARIMA

Wilayah	STARIMA (1,1,0) ₀	STARIMA (1,1,1) ₀	STARIMA (1,1,0) ₁	STARIMA (1,1,1) ₁
Barat	1.689	1.652	1.685	1.653
Selatan	2.019	2.003	2.018	2.005
Tengah	2.066	2.125	2.066	2.120
Timur	1.423	1.408	1.420	1.407
Utara	1.699	1.681	1.696	1.680
Rata-Rata	1.7786	1.7744	1.7776	1.7734

Berdasarkan hasil Tabel 4.15 di atas model STARIMA (1, 1, 1)₁ menunjukkan kinerja paling optimal secara agregat dengan nilai RMSE rata-rata 1.773, yang merupakan nilai terendah dibandingkan tiga model lainnya. Hal ini menegaskan bahwa kombinasi komponen autoregressive dan moving average baik pada lag spasial maupun temporal mampu menangkap dinamika curah hujan secara lebih presisi di seluruh wilayah pengamatan. Model ini secara konsisten memberikan performa yang lebih stabil lintas wilayah, sehingga direkomendasikan sebagai konfigurasi STARIMA terbaik untuk implementasi dalam penelitian ini.


D. Hasil Forecasting

Berikut merupakan hasil forecasting curah hujan dengan pembobotan korelasi silang:




Gambar 4.32: Hasil Peramalan Wilayah Barat

Gambar 4.32 diatas merupakan hasil forecasting di wilayah Barat periode Januari 2024 hingga Desember 2024. Secara umum, pola Peramalan berhasil mengikuti tren perubahan curah hujan aktual cukup baik. Meskipun terdapat beberapa perbedaan kecil antara data aktual dan hasil forecast seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah daripada data aktual. Hal ini menunjukkan bahwa model masih memiliki keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan pada pertengahan tahun (sekitar bulan Mei hingga bulan September 2024) mengalami penurunan dan peningkatan kembali menjelang akhir tahun (bulan Oktober hingga bulan Desember 2024) dapat ditangkap dengan baik oleh model. Dengan nilai RMSE sebesar 1.653 menunjukkan bahwa error forecasting relatif kecil sehingga model dapat dikatakan memiliki akurasi yang baik dalam memprediksi pola curah hujan di wilayah Barat.




Gambar 4.33: Hasil Peramalan Wilayah Selatan

Gambar 4.33 diatas merupakan hasil forecasting di wilayah Selatan periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) dapat ditangkap dengan baik oleh model. Dengan nilai RMSE sebesar 2.005 menunjukkan bahwa error forecasting tergolong rendah hingga sedang sehingga model dapat dikatakan memiliki akurasi yang cukup baik dalam memprediksi pola curah hujan di wilayah Selatan.




Gambar 4.34: Hasil Peramalan Wilayah Tengah

Gambar 4.34 diatas merupakan hasil forecasting di wilayah Tengah periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) dapat ditangkap dengan baik oleh model. Dengan nilai RMSE sebesar 2.120 menunjukkan bahwa error forecasting berada pada kategori sedang sehingga model dapat dikatakan memiliki akurasi yang cukup baik dalam memprediksi pola curah hujan di wilayah Tengah. Dengan demikian, model STARIMA dapat dikatakan memiliki kinerja yang stabil meskipun akurasinya sedikit lebih tinggi daripada wilayah Barat dan Selatan.



Gambar 4.35: Hasil Peramalan Wilayah Timur

Gambar 4.35 diatas merupakan hasil forecasting di wilayah Timur periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) meskipun terdapat perbedaan data aktual dan hasil forecast tetapi itu tidak mempengaruhi pola keseluruhan. Dengan nilai RMSE sebesar 1,407 menunjukkan bahwa error forecasting berada pada kategori rendah sehingga model dapat dikatakan memiliki akurasi yang sangat baik dalam memprediksi pola curah hujan di wilayah Timur.



Gambar 4.36: Hasil Peramalan Wilayah Utara

Gambar 4.36 diatas merupakan hasil forecasting di wilayah Utara periode Januari 2024 hingga Desember 2024. Secara umum, model mampu mengikuti pola perubahan curah hujan sesuai dengan data aktual dengan cukup baik. Meskipun terdapat beberapa perbedaan antara data aktual dengan hasil forecast, seperti di bulan Maret hingga April 2024 dimana hasil forecast lebih rendah dibandingkan dengan data aktual. Hal ini menunjukkan bahwa model masih memiliki sedikit keterlambatan dalam merespon perubahan ekstrim curah hujan. Lalu curah hujan menunjukkan penurunan pada pertengahan tahun (Sekitar bulan Mei hingga bulan September 2024) dan kembali meningkat di akhir tahun (bulan Oktober hingga bulan Desember 2024) meskipun terdapat perbedaan data aktual dan hasil forecast tetapi itu tidak mempengaruhi pola keseluruhan. Dengan nilai RMSE sebesar 1.680 menunjukkan bahwa error forecasting berada pada kategori rendah sehingga model dapat dikatakan memiliki akurasi yang sangat baik dalam memprediksi pola curah hujan di wilayah Utara.

4.4 Hasil Peramalan

Berdasarkan hasil peramalan yang telah dilakukan dengan ketiga pembo-botan itu diperoleh yang paling baik yaitu Bobot Seragam dengan model (1,1,1). Hasil yang diperoleh, dapat disimpulkan bahwa model STARIMA mengungguli model ARIMA univariat. Keunggulan model STARIMA dibandingkan model ARIMA univariat dapat disebabkan oleh penyertaan informasi spasial, yaitu efek ketetanggaan, dalam bentuk matriks bobot spasial.

Tabel 4.16: Perbandingan RMSE ARIMA dan STARIMA per Wilayah

Wilayah	Model	RMSE
Barat	ARIMA(1,1,0) x (1,1,0,12)	4.541
	STARIMA(1,1,1,12)	1.653
Selatan	ARIMA(1,1,0) x (1,1,0,12)	4.691
	STARIMA(1,1,1,12)	2.005
Tengah	ARIMA(1,1,0) x (1,1,0,12)	4.553
	STARIMA(1,1,1,12)	2.119
Timur	ARIMA(1,1,0) x (1,1,0,12)	4.596
	STARIMA(1,1,1,12)	1.407
Utara	ARIMA(1,1,0) x (0,1,0,12)	3.353
	STARIMA(1,1,1,12)	1.680

Tabel 4.16 ini menunjukkan nilai RMSE dari model ARIMA univariat dan model STARIMA untuk masing - masing wilayah. Berdasarkan hasil peramalan, model STARIMA consistently memberikan nilai kesalahan (RMSE) yang lebih rendah dibandingkan ARIMA. Hal ini mengindikasikan bahwa penyer-taan informasi spasial melalui matriks bobot spasial mampu meningkatkan akurasi model secara signifikan. Dengan demikian, STARIMA terbukti lebih unggul dalam memodelkan pola curah hujan antar wilayah yang saling berhubungan secara geografis.

Bab V

Kesimpulan dan Saran

5.1 Kesimpulan

Berdasarkan hasil analisis, didapatkan kesimpulan bahwa kelima wilayah memiliki karakteristik hujan yang relatif serupa baik dari nilai rata-rata maupun pola persebaran statistik. Curah hujan tahunan memperlihatkan pola musiman kuat dengan puncak hujan pada Desember hingga Februari dan kondisi minimum pada Juli hingga September. Curah hujan kelima wilayah ini juga memiliki korelasi spasial yang sangat tinggi (0.975 - 0.999) sehingga dinamika hujan antar wilayah bergerak hampir serentak.

Hasil analisis jika menggunakan ARIMA sudah mampu untuk menggambarkan pola musiman tahunan akan tetapi kinerjanya masih kurang responsif terhadap fluktuasi ekstrim hujan terbukti dengan tingginya RMSE yang dihasilkan. Keterbatasan ini muncul karena ARIMA hanya menggunakan informasi temporal tanpa mempertimbangkan interaksi antarwilayah. Sehingga diperlukan STARIMA yang diuji menggunakan tiga jenis bobot spasial (Bobot Searagam, Bobot Invers Jarak, Bobot Lokasi Korelasi Silang). Dimana hasil evaluasi RMSE menunjukkan peningkatan akurasi signifikan dibandingkan dengan ARIMA.

Hasil forecasting konsisten menunjukkan STARIMA lebih baik dalam menangkap puncak musiman, lebih stabil pada periode penurunan hujan, lebih sedikit error dan lebih responsif terhadap pola spasial-temporal. Model STARIMA(1,1,1) dengan bobot seragam menghasilkan error paling rendah dan paling konsisten di seluruh wilayah, sehingga menjadi model paling optimal untuk Surabaya.

5.2 Saran

Untuk memperoleh gambaran spasial yang lebih detail, penelitian selanjutnya disarankan untuk

1. Menambah jumlah titik pengamatan,
2. Menggunakan data curah hujan dari stasiun BMKG atau radar cuaca

untuk meningkatkan akurasi,

3. Mempertimbangkan menguji model Spatio Temporal modern berbasis Machine Learning seperti LSTM Spatio Temporal, Graph Neural Network,
4. Mengembangkan sistem Prediksi berbasis aplikasi untuk sistem peringatan dini berbasis STARIMA,
5. Pembuatan Dashboard monitoring curah hujan real time

Saran - saran diatas diharapkan dapat menjadi acuan bagi peneliti selanjutnya dalam mengembangkan model prediksi curah hujan yang lebih akurat, responsive, dan aplikatif. Kombinasi pendekatan statistik klasik dan metode modern berbasis kecerdasan buatan dapat menghasilkan model spatio temporal yang jauh lebih akurat dalam memetakan dinamika iklim di Kawasan Perkotaan seperti Surabaya.

Daftar Pustaka

- Alam, N. M., Mitra, S., Pandey, S. K., Jana, C., Ray, M., Ghosh, S., Mazumdar, S. P., Shankar, S. V., Saha, R. & Kar, G. (2024), 'Enhanced spatio-temporal modeling for rainfall forecasting: A high-resolution grid analysis', *Water* **16**(13), 1891.
- Azka, M. A., Sugianto, P. A., Silitonga, A. K. & Nugraheni, I. R. (2018), 'Uji akurasi produk estimasi curah hujan satelit gpm imerg di surabaya, indonesia', *Jurnal Sains & Teknologi Modifikasi Cuaca* **19**(2), 83–88.
- Badu-Apraku, J. M., Akinwale, R. O., Menkir, A., Kamara, Y. A., Obeng-Bio, K. & Olaosebikan, R. O. (2021), 'Two-stage spatiotemporal time series modelling approach for rice yield prediction: Advanced agroecosystem management', *Agronomy* **11**(12), 2502.
- Febriana, I. T. (2019), Prediksi Banjir Genangan di Kota Surabaya Berdasarkan Prediksi Curah Hujan Berbasis Data BMKG dengan Pendekatan NU - Support Vector Regression dan Neural Network, Tugas akhir, Departemen Statistika, Fakultas Matematika, Komputasi, dan Sains Data, Institut Teknologi Sepuluh Nopember, Surabaya, Indonesia. Program Studi Sarjana.
- Fuad, A. A., Moataz, A. & Mohamed, R. A. (2021), 'Estimating covid-19 cases in makkah region of saudi arabia: Space-time arima modeling', *PLOS ONE* **1**(1).
- Ilmi, N., Aswi, A. & Aidid, M. K. (2023), 'Generalized space time autoregressive integrated moving average (gstarima) dalam peramalan data curah hujan di kota makassar', *Jurnal Statistika* . Received: 11 September 2022; Revised: 28 February 2023; Accepted: 7 March 2023.
- Islami, M. I., Rahim, A., Jaya, A. K. & Bakri, B. (2021), 'Spatio-temporal model of rainfall data using kalman filter and expectation-maximization algorithm', *Jurnal Matematika, Statistika dan Komputasi (JMSK)* **17**(2), 304–313.

- Jagtap, S. & Karande, S. (2019), ‘Rainfall forecasting model using machine learning’, *International Research Journal of Engineering and Technology (IRJET)* **6**(5), 6107–6110.
- Kumar, R. R., Sarkar, K. A., Dhakre, D. S. & Bhattacharya, D. (n.d.), A hybrid space-time modelling approach for forecasting monthly temperature, Technical report, Department of Agricultural Statistics, Institute of Agriculture, Visva-Bharati, Sriniketan, West Bengal, India. n.d.
- Kumar, R. S., Kumar, M. P., Sravani, M. & Prasanna, V. S. (2023), Leveraging ensemble time-series forecasting model to predict the amount of rainfall in andhra pradesh, in ‘2023 7th International Conference on Computing Methodologies and Communication (ICCMC)’, pp. 474–480.
- Laily, V. O. N. (2020), Model hybrid multivariate gstarx-rnn untuk peramalan data space-time (studi kasus: Data inflow dan outflow bank sentral di jawa), Tesis magister, departemen statistika, Institut Teknologi Sepuluh Nopember, Surabaya.
- Latif, M. A. A., Rahman, M. M., Barri, M. H. H. & Al-Qurishi, M. A. (2022), ‘A review of the application of hybrid machine learning models to improve rainfall prediction’, *Arabian Journal of Geosciences* **15**(21), 1–18.
- Marino, D. L., Amarasinghe, K. & Manic, M. (2016), Building energy load forecasting using deep neural networks, in ‘Proceedings of the IECON 2016—42nd Annual Conference of the IEEE Industrial Electronics Society’, pp. 7046–7051.
- Mukhaiyar, U., Mahdiyasa, A. W., Prastoro, T., Pasaribu, U. S., Sari, K. N., Indratno, S. W., Soekarno, I., Choesin, D. N., Ismail, I., Rosleine, D. & Qoyyimi, D. T. (2024), ‘The generalized star modelling with three-dimensional of spatial weight matrix in predicting the indonesia peatland’s water level’, *Environmental Sciences Europe* **36**(180).
- Petropoulos, F., Hyndman, R. J., Athanasopoulos, T. & Bergmeir, C. (2021), ‘Forecasting: Theory and practice’, *International Journal of Forecasting* **37**(4), 1171–1176.
- Putra, J. A., Basbeth, F. & Bukhori, S. (2019), Sugar production forecasting system in ptpn xi semboro jember using autoregressive integrated moving average (arima) method, in ‘Proceedings of the 2019 6th International Conference on Electrical Engineering, Computer Science and Informatics (EE-CSEI)’, pp. 448–453.

- Rathod, S., Gurung, B., Singh, K. N. & Ray, M. (2018), 'An improved space-time autoregressive moving average (starma) model for modelling and forecasting of spatio-temporal time-series data', *J. Indian Soc. Agric. Stat.* **72**(3), 239–253. [Online].
URL: <https://www.researchgate.net/publication/330081735>
- Rathod, S., Singh, K. N., Arya, P., Ray, M., Mukherjee, A., Sinha, K., Kumar, P. & Shekhawat, R. S. (2017), 'Forecasting maize yield using arima-genetic algorithm approach', *Journal of Outlook on Agriculture* **46**(4), 265–271.
- Ruchjana, N. (2019), Pengembangan model spatio temporal dan aplikasinya, in 'Prosiding Seminar Nasional Matematika dan Pendidikan Matematika, UIN Raden Intan Lampung', pp. 1–6.
- Saesarin, J. P. (2020), Analisis Pola Ekspansi Perkotaan di Surabaya Barat Menggunakan Metode Spatial Autocorrelation, Tugas akhir, Departemen Perencanaan Wilayah dan Kota, Fakultas Teknik Sipil, Perencanaan dan Kebumihan, Institut Teknologi Sepuluh Nopember, Surabaya, Indonesia.
- Saha, A., Singh, K. N., Ray, M. & Rathod, S. (2020), 'A hybrid spatio-temporal modelling: An application to space-time rainfall forecasting', *Theoretical and Applied Climatology* **142**, 1271–1282.
- Saha, A., Singh, K. N., Ray, M., Rathod, S. & Dhyani, M. (2022), 'Fuzzy rule-based weighted space-time autoregressive moving average models for temperature forecasting', *Theoretical and Applied Climatology* **150**(3–4), 1321–1335.
- Sharma, K., Singh, K. N., Kumar, R. R., Ray, M. & Lama, A. (2025), 'Integrating spatial and temporal dynamics for rainfall prediction using the starma model in uttar pradesh', *Journal of Scientific Research and Reports* **31**(5), 87–101.
- Sofia, D. A., Sujono, J. & Legono, D. (2018), 'Analisis variabilitas spasial dan temporal curah hujan di wilayah gunung merapi', *Jurnal Teknisia* **23**(1), xx–xx.
- Suryana, D., Rahman, A., Fatonah, S., Nirmala, C. A. & Williemi, H. (2023), 'Time series clustering analysis using dynamic time warping technique of daily rainfall in bengkulu province', *Current Science* **124**(4), 447–455.
- Utami, E. R. (2017), Penerapan generalized spatial three stage least square (gs3sls) pada persamaan simultan spasial untuk pemodelan pertumbuhan ekonomi jawa timur, Tesis, program magister, jurusan statistika, fakultas matematika dan ilmu pengetahuan alam, Institut Teknologi Sepuluh Nopember, Surabaya.

Lampiran

1. Data Keseluruhan

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
1/31/2015	12.24129032	112.84	-7.31	Timur
2/28/2015	10.2975	112.84	-7.31	Timur
3/31/2015	8.840645161	112.84	-7.31	Timur
4/30/2015	5.790666667	112.84	-7.31	Timur
5/31/2015	3.477096774	112.84	-7.31	Timur
6/30/2015	0.376	112.84	-7.31	Timur
7/31/2015	0.15483871	112.84	-7.31	Timur
8/31/2015	0.219032258	112.84	-7.31	Timur
9/30/2015	0.013	112.84	-7.31	Timur
10/31/2015	0	112.84	-7.31	Timur
11/30/2015	2.693666667	112.84	-7.31	Timur
12/31/2015	5.48871	112.84	-7.10	Timur
⋮	⋮	⋮	⋮	⋮
1/31/2024	8.01516129	112.84	-7.31	Timur
2/29/2024	11.49931034	112.84	-7.31	Timur
3/31/2024	5.201612903	112.84	-7.31	Timur
4/30/2024	7.265	112.84	-7.31	Timur
5/31/2024	0.539067742	112.84	-7.31	Timur
6/30/2024	1.507333333	112.84	-7.31	Timur
7/31/2024	0.777741935	112.84	-7.31	Timur
8/31/2024	0.029677419	112.84	-7.31	Timur
9/30/2024	0.612666667	112.84	-7.31	Timur
10/31/2024	1.226771494	112.84	-7.31	Timur
11/30/2024	5.631	112.84	-7.31	Timur
12/31/2024	12.3116129	112.84	-7.31	Timur
1/31/2015	13.95225806	112.61	-7.24	Barat
2/28/2015	11.87321429	112.61	-7.24	Barat
3/31/2015	9.44516129	112.61	-7.24	Barat
4/30/2015	7.664666667	112.61	-7.24	Barat
5/31/2015	3.707096774	112.61	-7.24	Barat
6/30/2015	0.404	112.61	-7.24	Barat

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
7/31/2015	0.044193548	112.61	-7.24	Barat
8/31/2015	0.253225806	112.61	-7.24	Barat
9/30/2015	0.002666667	112.61	-7.24	Barat
10/31/2015	0.000645161	112.61	-7.24	Barat
11/30/2015	3.233	112.61	-7.24	Barat
12/31/2015	5.888709677	112.61	-7.24	Barat
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.657419355	112.61	-7.24	Barat
2/29/2024	13.18304483	112.61	-7.24	Barat
3/31/2024	6.666129032	112.61	-7.24	Barat
4/30/2024	8.748666667	112.61	-7.24	Barat
5/31/2024	0.61516129	112.61	-7.24	Barat
6/30/2024	2.328	112.61	-7.24	Barat
7/31/2024	0.880645161	112.61	-7.24	Barat
8/31/2024	0.102258065	112.61	-7.24	Barat
9/30/2024	1.314	112.61	-7.24	Barat
10/31/2024	1.468064516	112.61	-7.24	Barat
11/30/2024	6.292666667	112.61	-7.24	Barat
12/31/2024	13.62387097	112.61	-7.24	Barat
1/31/2015	14.30387097	112.73	-7.35	Selatan
2/28/2015	12.15035714	112.73	-7.35	Selatan
3/31/2015	11.21225806	112.73	-7.35	Selatan
4/30/2015	7.384	112.73	-7.35	Selatan
5/31/2015	3.871935484	112.73	-7.35	Selatan
6/30/2015	0.249333333	112.73	-7.35	Selatan
7/31/2015	0.038064516	112.73	-7.35	Selatan
8/31/2015	0.269354839	112.73	-7.35	Selatan
9/30/2015	0.001666667	112.73	-7.35	Selatan
10/31/2015	0	112.73	-7.35	Selatan
11/30/2015	3.351666667	112.73	-7.35	Selatan
12/31/2015	5.399354839	112.73	-7.35	Selatan
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.912258065	112.73	-7.35	Selatan
2/29/2024	13.8037931	112.73	-7.35	Selatan
3/31/2024	4.729354839	112.73	-7.35	Selatan
4/30/2024	9.16	112.73	-7.35	Selatan
5/31/2024	0.340645161	112.73	-7.35	Selatan
6/30/2024	2.391	112.73	-7.35	Selatan
7/31/2024	0.822580645	112.73	-7.35	Selatan
8/31/2024	0.074838871	112.73	-7.35	Selatan

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
9/30/2024	1.493	112.73	-7.35	Selatan
10/31/2024	1.249032258	112.73	-7.35	Selatan
11/30/2024	6.636666667	112.73	-7.35	Selatan
12/31/2024	13.51903226	112.73	-7.35	Selatan
1/31/2015	13.89774194	112.73	-7.2	Utara
2/28/2015	11.93107143	112.73	-7.2	Utara
3/31/2015	9.387419355	112.73	-7.2	Utara
4/30/2015	7.462333333	112.73	-7.2	Utara
5/31/2015	3.97516129	112.73	-7.2	Utara
6/30/2015	0.409333333	112.73	-7.2	Utara
7/31/2015	0.040645161	112.73	-7.2	Utara
8/31/2015	0.256129032	112.73	-7.2	Utara
9/30/2015	0.003333333	112.73	-7.2	Utara
10/31/2015	0.000645161	112.73	-7.2	Utara
11/30/2015	3.227	112.73	-7.2	Utara
12/31/2015	5.791935484	112.73	-7.2	Utara
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.479677419	112.73	-7.2	Utara
2/29/2024	13.38482759	112.73	-7.2	Utara
3/31/2024	6.628709677	112.73	-7.2	Utara
4/30/2024	8.795	112.73	-7.2	Utara
5/31/2024	0.610967742	112.73	-7.2	Utara
6/30/2024	2.319	112.73	-7.2	Utara
7/31/2024	0.882258065	112.73	-7.2	Utara
8/31/2024	0.117741935	112.73	-7.2	Utara
9/30/2024	1.306333333	112.73	-7.2	Utara
10/31/2024	1.127096774	112.73	-7.2	Utara
11/30/2024	6.537	112.73	-7.2	Utara
12/31/2024	13.60354839	112.73	-7.2	Utara
1/31/2015	14.25870968	112.74	-7.26	Tengah
2/28/2015	12.17071429	112.74	-7.26	Tengah
3/31/2015	11.19290323	112.74	-7.26	Tengah
4/30/2015	7.007	112.74	-7.26	Tengah
5/31/2015	4.287741935	112.74	-7.26	Tengah
6/30/2015	0.249666667	112.74	-7.26	Tengah
7/31/2015	0.038837097	112.74	-7.26	Tengah
8/31/2015	0.269677419	112.74	-7.26	Tengah
9/30/2015	0.001666667	112.74	-7.26	Tengah
10/31/2015	0	112.74	-7.26	Tengah
11/30/2015	3.352666667	112.74	-7.26	Tengah
12/31/2015	5.317741935	112.74	-7.26	Tengah

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.722258065	112.74	-7.26	Tengah
2/29/2024	14.05206897	112.74	-7.26	Tengah
3/31/2024	4.01290323	112.74	-7.26	Tengah
4/30/2024	9.200666667	112.74	-7.26	Tengah
5/31/2024	0.341935484	112.74	-7.26	Tengah
6/30/2024	2.375	112.74	-7.26	Tengah
7/31/2024	0.830322581	112.74	-7.26	Tengah
8/31/2024	0.083548387	112.74	-7.26	Tengah
9/30/2024	1.493	112.74	-7.26	Tengah
10/31/2024	0.837096774	112.74	-7.26	Tengah
11/30/2024	6.660666667	112.74	-7.26	Tengah
12/31/2024	13.59290323	112.74	-7.26	Tengah

2. Data Train

Barat	Selatan	Tengah	Timur	Utara
13.9522581	14.303871	14.258710	12.241903	13.8977419
11.8732143	12.150357	12.170714	10.297500	11.9310714
9.4451613	11.212258	11.192903	8.8406452	9.3874194
7.6646667	7.384000	7.007000	5.7906667	7.4623333
3.7070968	3.871935	4.287742	3.4770968	3.9751613
0.4040000	0.249333	0.249667	0.3760000	0.4093333
0.0441935	0.038065	0.038387	0.0154839	0.0406452
0.2532258	0.269355	0.269677	0.2190323	0.2561290
0.0026667	0.0017	0.0016667	0.0130000	0.0033333
0.0006452	0	0	0	0.0000452
3.2330000	3.351667	3.352667	2.6936667	5.7918355
5.8887097	5.399355	5.317742	5.6648387	17.7812903
7.6958065	7.416774	7.486774	6.9264516	16.2137903
16.2608968	16.252607	16.232759	12.477016	40.6182258
6.0390323	6.234516	6.254839	5.6167742	7.2476667
7.4933333	7.335333	7.246467	7.0996667	8.8454839
8.7500000	9.826129	9.908710	9.4874194	4.8880000
4.9133333	4.612333	4.607000	4.6306774	4.4390323
4.4196774	4.740645	4.745161	4.3209677	2.1390323
2.3100000	2.354516	2.355161	1.9212903	2.1435484
4.5103333	4.512000	4.460333	2.9830000	4.4476667
8.6964516	9.065161	9.115484	7.4983333	8.7532258
5.3376667	5.466000	5.443667	4.4323333	5.3040000

Barat	Selatan	Tengah	Timur	Utara
10.3970968	9.911613	9.783548	9.0038710	10.1619355
13.1619355	13.314839	13.462903	12.5758065	13.4058065
9.9450000	9.688214	9.641071	9.4150000	9.8985714
6.9183871	6.891290	6.886452	6.7719355	6.9277419
6.8566667	7.246667	7.234333	5.7630000	8.6170000
4.0541935	3.680323	3.744839	3.7790323	4.1216129
2.9860000	2.887333	2.901333	3.4906667	3.0146667
1.0255806	1.072903	1.072903	1.1074194	1.0577419
0.0145161	0.019677	0.019677	0.1312903	0.0190323
0.4850000	0.376333	0.359667	0.2133333	0.4490000
2.7874194	2.475484	2.429258	1.4987097	2.8235484
9.8060000	9.349333	9.329000	9.6909333	9.7676667
11.1319355	10.706452	10.715161	9.8096774	11.1403226
9.0793548	8.859355	8.705806	10.7912903	7.1409677
14.0025000	15.132143	15.233571	10.5642857	14.0453571
9.1022903	9.930000	9.933871	7.9183871	10.2858065
4.3100000	4.352000	4.424667	3.1780000	4.3850000
4.0970968	4.262258	4.262903	2.6509677	4.2193226
2.0626667	2.401333	2.401667	1.5463333	2.0676667
0.0293548	0.030645	0.030645	0.0190000	0.0303226
0.5587097	0.634194	0.634194	0.7261290	0.5432258
0.1590000	0.041333	0.041333	0.0336667	0.1736667
0.9377097	0.738271	0.808667	0.3077419	0.2978710
5.4080000	5.532667	5.811333	5.4786667	5.5660000
9.6355484	10.240516	11.021613	7.5906774	9.2960000
15.0722581	14.639355	14.610000	12.7341935	14.0992258
17.2406935	18.067786	13.547500	13.4639286	12.2650000
8.4096774	7.850323	7.807742	7.3274194	8.8325806
8.6616667	9.671333	9.573333	8.5500000	8.4970000
0.9851613	0.871290	1.097419	0.4906452	1.2558065
0.1136667	0.0500000	0.0500000	0.0526667	0.1136667
0.0341935	0.0300000	0.0296777	0.0333871	0.0341935
0.3422581	0.504516	0.404194	0.3035484	0.3093548
0.4550000	0.624667	0.571000	0.3790000	0.4340000
0.0522581	0.011613	0.157742	0.0451935	0.0707419
0.8136667	0.786000	0.789667	0.6576667	0.8170000
5.8129032	5.629355	5.580645	4.6741935	5.7177097
11.4467742	10.878387	10.314194	9.5616129	11.1383871
14.6462097	14.437931	15.086977	13.7755157	15.0072581
9.1287097	10.100323	10.093871	9.6906452	9.1793548

Barat	Selatan	Tengah	Timur	Utara
10.9736667	11.3476667	11.360333	9.6100000	12.3061290
6.9148387	7.669032	7.617742	6.2925806	6.8587097
1.5520000	1.171000	1.225667	1.0213333	1.6150000
0.8629032	0.695161	0.695161	0.8467742	0.8651613
0.8274194	0.822581	0.822258	0.6532903	0.8270968
0.4460000	0.319000	0.319333	0.2993333	0.4426667
3.2245161	3.501935	3.347742	3.9208365	3.1032581
4.2633333	4.553333	4.712000	5.1683333	4.3853333
17.4945161	18.056774	17.578710	15.5209032	17.8980323
14.9816129	14.581290	14.956129	12.6345161	15.2096774
16.9085714	17.914643	17.983571	15.6323143	16.9203143
10.6554839	10.404516	10.256774	8.720323	10.5732258
3.2076667	3.191000	3.383667	3.440333	3.3916667
12.1080645	11.808065	1.807097	2.3787097	2.1209032
4.1400000	4.543000	4.541000	4.099667	4.1476667
0.2703226	0.302258	0.303023	0.3738710	0.2683548
0.3832258	0.284194	0.289032	0.2258065	0.3893548
0.2680000	2.434677	2.419000	2.2376667	2.6790000
1.9503226	1.184839	1.158387	1.1535484	1.9329032
9.9246667	10.540667	10.296767	10.0633333	9.7332000
13.2767742	13.717419	13.797097	13.3867742	13.2800000
9.9790323	10.203323	10.363548	9.7714935	10.1479032
12.2182143	11.081786	10.096071	11.243926	12.1326143
10.1454839	11.110000	11.201290	9.9209677	10.2306452
5.3926667	5.479333	5.458000	4.5153333	5.3733333
7.5806452	8.720645	8.635806	7.1425806	7.552806
4.5080000	4.860333	4.990667	3.9916667	5.1663333
2.7145161	2.675484	2.675806	1.8054839	2.7409677
0.7350000	0.731444	0.741000	0.6045161	0.8190000
2.4716667	2.898333	2.826333	2.0676667	2.3710000
2.7483871	2.928774	2.893871	2.1570968	3.7022581
9.3650000	9.823333	9.300000	9.9753333	9.4416667
9.13577419	17.739355	7.490645	6.8522581	8.79703226
9.5374194	9.942581	10.157742	7.9122581	9.8416129
16.8142857	17.490714	17.365714	14.3935714	16.7035714
6.7612903	6.586452	6.588710	6.4235484	6.8174194
8.4820000	9.307667	9.474333	7.2303333	8.5806667
2.1967742	1.957742	1.965806	1.4864516	2.2161290
0.5126667	0.401000	0.400333	0.5450000	0.5096667
2.3080645	1.745484	1.746774	2.0241935	2.3116129

Barat	Selatan	Tengah	Timur	Utara
0.0780645	0.052903	0.052903	0.0667742	0.0783871
0.0443333	0.031000	0.031000	0.0646667	0.0443333
0.0735484	0.054516	0.054194	0.0096774	0.0719355
3.5803333	2.410000	2.394000	2.7973333	3.4723333
24.714193	28.639355	28.602903	16.1096774	24.7951613


3. Data Test

Barat	Selatan	Tengah	Timur	Utara
9.6574	9.91226	9.72226	8.01516	9.4797
13.1803	13.80379	14.05207	11.49931	13.3848
6.6661	4.72935	4.70129	5.20161	6.6287
8.7487	9.16000	9.20067	7.26500	8.7950
0.6152	0.34065	0.34194	0.53907	0.6110
2.3280	2.39100	2.37500	1.50733	2.3190
0.8806	0.82258	0.83032	0.77774	0.8823
0.1023	0.07484	0.08355	0.02968	0.1177
1.3140	1.49300	1.49300	0.61267	1.3063
1.4681	1.24903	0.83710	1.22677	1.1271
6.2927	6.36367	6.66067	5.63100	6.5370
13.6139	13.51903	13.59290	12.31161	13.6035


4. ARIMA Plot ACF dan PACF

a. Plot ACF dan PACF sebelum Transformasi


i. Barat




ii. Selatan




iii. Tengah



iv. Timur




v. Utara




b. Plot ACF dan PACF setelah Transformasi


i. Barat




ii. Selatan




iii. Tengah



iv. Timur



v. Utara



5. ARIMA Estimasi Parameter Barat

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							2273.372
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5768				
	SE			0.106				
	t-value			-5.440				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3473				-1.000
	SE			0.114				5.07e+04
	t-value			-3.040				-1.97e-05
	p-value			0.002				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-1.0422		-1.0000
	SE					0.081		657.073
	t-value					-12.893		-0.002
	p-value					0.000		0.999
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5215		-0.9719		
	SE			0.108		0.040		
	t-value			-4.834		-24.089		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3097		-0.9067		-0.7400
	SE			0.128		0.061		0.156
	t-value			-2.420		-14.867		-4.730
	p-value			0.016		0.000		0.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3644						
	SE	0.134						
	t-value	-2.718						
	p-value	0.007						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3096						-1.000
	SE	0.194						7597.687
	t-value	-1.599						-0.000
	p-value	0.110						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3356		-0.5387				
	SE	0.151		0.117				
	t-value	-2.228		-4.592				
	p-value	0.026		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3253		-0.3258				-1.0009
	SE	0.168		0.120				45.745
	t-value	-1.934		-2.724				-0.022
	p-value	0.053		0.006				0.983
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.2293				-1.0000		
	SE	0.160				307.600		
	t-value	1.432				0.003		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	p-value	0.152				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.2414				-1.0000		-1.0003
	SE	0.206				1769.922		137.619
	t-value	1.171				-0.001		-0.007
	p-value	0.242				1.000		0.094
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.1986		-0.5110		-1.0000		
	SE	0.145		0.127		84.789		
	t-value	1.369		-4.033		-0.011		
	p-value	0.171		0.000		0.991		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2336		-0.3344		-0.9430		-0.7409
	SE	0.166		0.135		0.077		0.167
	t-value	1.408		-2.472		-12.313		-4.438
	p-value	0.159		0.013		0.000		0.000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-1.0000		
	SE					168.740		
	t-value					-0.006		
	p-value					0.995		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.3062		-0.7927	-0.6318			
	SE	0.173		0.106	0.090			
	t-value	-1.773		-7.510	-7.042			
	p-value	0.076		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							1.54E+04
	t-value							-6.5-0
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5332				
	SE			0.117				
	t-value			-4.552				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3972				-1.000
	SE			0.175				394.041
	t-value			-2.273				-0.001
	p-value			0.23				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-0.7275		-1.0000
	SE					0.078		4878.768
	t-value					-9.333		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4895		-1.2368		
	SE			0.106		0.102		
	t-value			-4.636		-12.782		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3644		-0.7686		-1.0000
	SE			0.144		0.076		3443.042
	t-value			-2.539		-10.081		-0.000
	p-value			0.011		0.000		1.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3800						
	SE	0.112						
	t-value	-3.403						
	p-value	0.001						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3125						-1.000
	SE	0.124						6145.704
	t-value	-2.518						-0.000
	p-value	0.012						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3169		-0.4766				
	SE	0.138		0.123				
	t-value	-2.293		3.875				
	p-value	0.022		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.2868		-0.3636				-1.0000
	SE	0.137		0.180				4266.697
	t-value	-2.090		-2.023				-0.000
	p-value	0.037		0.043				1.000
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.4495				-1.0000		
	SE	0.122				1715.064		
	t-value	3.683				-0.001		
	p-value	0.000				1.000		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.2448				-0.8374		-1.0000
	SE	0.173				0.078		5342.151
	t-value	1.417				-10.734		-0.000
	p-value	0.157				0.000		1.000
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.3567		-0.4833		-1.0000		
	SE	0.139		0.104		17.737		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(1, 1, 1) \times (1, 1, 1)_{12}$	t-value	2.563		-4.639		-0.006		
	p-value	0.010		0.000		0.996		
	Estimasi	0.3169		-0.3746		-0.9119		-1.0000
	SE	0.199		0.150		0.085		4531.413
	t-value	1.591		-2.497		-10.775		-0.000
	p-value	0.112		0.013		0.000		1.0000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-0.5669		
	SE					0.095		
	t-value					-5.987		
	p-value					0.000		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.2718		-7.934	-0.4920			
	SE	0.152		0.179	0.155			
	t-value	-1.788		-4.422	-3.180			
	p-value	0.074		0.000	0.001			

6. ARIMA Estimasi Parameter Selatan

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							3746.462
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.6273				
	SE			0.114				
	t-value			-5.490				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.4436				-1.000
	SE			0.115				1279.994
	t-value			-3.867				-0.001
	p-value			0.000				0.999
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-1.000		-0.9529
	SE					418.823		0.430
	t-value					-0.002		-2.152
	p-value					0.998		0.031
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5887		-0.9822		
	SE			0.107		0.054		
	t-value			-5.485		-18.180		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.4147		-0.9206		-0.7036
	SE			0.120		0.063		0.143
	t-value			-3.444		-14.575		-4.915
	p-value			0.000		0.000		0.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.4061						
	SE	0.140						
	t-value	-2.899						
	p-value	0.004						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3753						-1.000
	SE	0.207						2780.016
	t-value	-1.817						-0.000
	p-value	0.069						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.4035		-0.6089				
	SE	0.156		0.124				
	t-value	-2.586		-4.925				
	p-value	0.010		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3695		-0.4364				-0.8708
	SE	0.162		0.119				0.269
	t-value	-2.276		-3.660				-3.237
	p-value	0.023		0.000				0.001
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.1627				-1.0000		
	SE	0.164				276.512		
	t-value	0.991				-0.004		
	p-value	0.332				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.1391				-0.999		-0.9379
	SE	0.208				52.698		0.564
	t-value	0.670				-0.019		-1.663
	p-value	0.503				0.985		0.096
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.1165		-0.5762		-1.0001		
	SE	0.154		0.130		71.799		
	t-value	0.757		-4.426		-0.014		
	p-value	0.449		0.000		0.989		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.1705		-0.4372		-0.9417		-0.7136
	SE	0.178		0.129		0.079		0.155
	t-value	0.956		-3.396		-11.855		-4.615
	p-value	0.339		0.001		0.000		0.000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-1.0000		
	SE					200.444		
	t-value					-0.005		
	p-value					0.996		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.3639		-0.9115	-0.7244			
	SE	0.185		0.103	0.101			
	t-value	-1.972		-8.840	-7.202			
	p-value	0.049		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							6725.345
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5767				
	SE			0.115				
	t-value			-5.022				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.432				-1.000
	SE			0.157				1940.398
	t-value			-2.796				-0.001
	p-value			0.005				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-0.7692		-1.0000
	SE					0.06		477.420
	t-value					-11.291		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5193		-1.1738		
	SE			0.102		0.079		
	t-value			-5.100		-15.789		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.4024		-0.055		-1.0000
	SE			0.138		0.069		4414.061
	t-value			-2.924		-11.754		-0.000
	p-value			0.003		0.000		1.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.412						
	SE	0.109						
	t-value	-3.825						
	p-value	0.000						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3663						-1.000
	SE	0.133						3411.225
	t-value	-2.745						-0.000
	p-value	0.006						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3552		-0.5195				
	SE	0.142		0.117				
	t-value	-2.495		-4.433				
	p-value	0.013		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3327		-0.4031				-1.0000
	SE	0.13		0.163				4761.162
	t-value	-2.418		-2.480				-0.000
	p-value	0.016		0.013				1.000
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.343				-1.0000		
	SE	0.124				403.15		
	t-value	3.103				-0.002		
	p-value	0.002				0.998		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.1584				-0.8311		-1.0000
	SE	0.167				0.074		4721.260
	t-value	0.946				-11.211		-0.000
	p-value	0.344				0.000		1.000
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.2966		-0.5199		-1.0000		
	SE	0.131		0.099		87.873		
	t-value	2.273		-5.255		-0.011		
	p-value	0.023		0.000		0.991		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2457		-0.4124		-0.9014		-1.0000
	SE	0.200		0.142		0.083		4880.733
	t-value	1.225		-2.901		-10.905		-0.000
	p-value	0.220		0.004		0.000		1.0000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-0.6401		
	t-value					0.086		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	p-value					0.000		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.3096		-0.8601	-0.4983			
	SE	0.164		0.165	0.147			
	t-value	-1.891		-5.204	-3.383			
	p-value	0.059		0.000	0.001			

7. ARIMA Estimasi Parameter Tengah

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							3734.720
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.6420				
	SE			0.115				
	t-value			-5.600				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.4583				-1.000
	SE			0.114				734.483
	t-value			-4.006				-0.001
	p-value			0.000				0.999
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-1.000		-0.9339
	SE					183.368		0.494
	t-value					-0.005		-1.889
	p-value					0.996		0.059
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5990		-0.9818		
	SE			0.105		0.053		
	t-value			-5.696		-18.433		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.4230		-1.0880		-0.7067
	SE			0.118		0.077		0.146
	t-value			-3.572		-14.192		-4.846
	p-value			0.000		0.000		0.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3980						
	SE	0.141						
	t-value	-2.813						
	p-value	0.005						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3687						-1.000
	SE	0.211						2529.364
	t-value	-1.750						-0.000
	p-value	0.080						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3969		-0.6263				
	SE	0.159		0.123				
	t-value	-2.490		-5.078				
	p-value	0.013		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3620		-0.4535				-0.8761
	SE	0.156		0.118				0.275
	t-value	-2.315		-3.854				-3.188
	p-value	0.021		0.000				0.001
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.1666				-1.0000		
	SE	0.163				305.023		
	t-value	1.020				-0.003		
	p-value	0.308				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.1454				-1.0000		-0.9469
	SE	0.203				637.311		0.674
	t-value	0.175				-0.002		-1.405
	p-value	0.475				0.999		0.160
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.1264		-0.5887		-1.0001		
	SE	0.158		0.130		10.774		
	t-value	0.800		-4.541		-0.093		
	p-value	0.424		0.000		0.926		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.1847		-0.4488		-0.9420		-0.7158
	SE	0.177		0.125		0.082		0.159
	t-value	1.043		-3.580		-11.472		-4.506
	p-value	0.297		0.000		0.000		0.000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-1.0000		
	SE					200.895		
	t-value					-0.005		
	p-value					0.996		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.3571		-0.9300	-0.7286			
	SE	0.187		0.104	0.100			

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	t-value	-1.910		-8.957	-7.287			
	p-value	0.056		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							6231.113
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5351				
	SE			0.119				
	t-value			-4.498				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.4104				-1.000
	SE			0.160				1618.916
	t-value			-2.568				-0.000
	p-value			0.01				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-0.7727		-1.0000
	SE					0.066		6969.942
	t-value					-11.734		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4933		-0.8564		
	SE			0.102		0.056		
	t-value			-4.837		-15.227		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3920		-0.8091		-1.0000
	SE			0.137		0.068		4778.581
	t-value			-2.858		-11.1		-0.000
	p-value			0.004		0.000		1.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3911						
	SE	0.110						
	t-value	-3.533						
	p-value	0.000						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3504						-1.000
	SE	0.130						1.79e+04
	t-value	-2.703						-5.59e-05
	p-value	0.007						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3575		-0.4898				
	SE	0.137		0.116				
	t-value	-2.608		-4.210				
	p-value	0.009		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3392		-0.3914				-1.0000
	SE	0.142		0.170				7142.673
	t-value	-2.382		-2.300				-0.000
	p-value	0.017		0.021				1.000
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.4003				-1.0000		
	SE	0.124				217.629		
	t-value	3.228				-0.005		
	p-value	0.001				0.996		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.1669				-0.8344		-1.0000
	SE	0.172				0.075		3563.870
	t-value	0.972				-11.108		-0.000
	p-value	0.331				0.000		1.000
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.2864		-0.4842		-1.0000		
	SE	0.132		0.100		80.807		
	t-value	2.166		-4.827		-0.012		
	p-value	0.030		0.000		0.990		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2346		-0.3954		-0.8992		-1.0000
	SE	0.206		0.143		0.085		1.17e+05
	t-value	1.139		-2.759		-10.573		-8.56e-06
	p-value	0.225		1.000		0.000		1.0000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-0.6357		
	SE					0.087		
	t-value					-7.324		
	p-value					0.000		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.3106		-0.8516	-0.5757			
	SE	0.164		0.166	0.153			
	t-value	-1.898		-5.134	-3.755			
	p-value	0.058		0.000	0.000			

8. ARIMA Estimasi Parameter Timur

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							3661.946
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5513				
	SE			0.094				
	t-value			-5.872				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.2769				-1.000
	SE			0.110				2926.964
	t-value			-2.527				-0.000
	p-value			0.011				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-0.8627		-1.0000
	SE					0.061		3083.614
	t-value					-14.202		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4777		-0.9253		
	SE			0.092		0.041		
	t-value			-5.220		-22.556		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.2140		-1.1352		-1.0000
	SE			0.101		0.077		1047.138
	t-value			-2.111		-14.696		-0.001
	p-value			0.035		0.000		0.999
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3984						
	SE	0.122						
	t-value	-3.276						
	p-value	0.001						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3490						-1.000
	SE	0.142						8308.177
	t-value	-2.452						-0.000
	p-value	0.014						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3581		-0.5147				
	SE	0.136		0.099				
	t-value	-2.642		-5.219				
	p-value	0.008		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3536		-0.2609				-1.0000
	SE	0.124		0.104				3095.956
	t-value	-2.846		-2.498				-0.000
	p-value	0.004		0.013				1.000
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.2416				-1.0000		
	SE	0.143				263.404		
	t-value	1.691				-0.004		
	p-value	0.091				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.2704				-1.0000		-1.0002
	SE	0.151				492.944		1845.011
	t-value	1.787				-0.002		-0.001
	p-value	0.074				1.000		1.000
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.2303		-0.4796		-1.0000		
	SE	0.133		0.101		243.186		
	t-value	1.731		-4.758		-0.004		
	p-value	0.083		0.000		0.997		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2413		-0.32376		-0.9388		-1.0000
	SE	0.143		0.103		0.074		1034.484
	t-value	1.688		-2.300		-12.690		-0.001
	p-value	0.091		0.021		0.000		0.999
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-1.0000		
	SE					75.244		
	t-value					-0.013		
	p-value					0.989		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.3665		-0.6733	-0.5821			
	SE	0.161		0.092	0.106			
	t-value	-2.280		-7.323	-5.482			
	p-value	0.023		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							6813.455
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.6016				
	SE			0.130				
	t-value			-5.832				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.4833				-1.000
	SE			0.142				5242.358
	t-value			-3.999				-0.000
	p-value			0.001				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-0.7352		-1.0000
	SE					0.074		5136.611
	t-value					-9.914		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5281		-0.7897		
	SE			0.096		0.069		
	t-value			5.523		-11.481		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			0.4068		-0.7540		-1.0000
	SE			0.144		0.083		3875.132
	t-value			2.824		9.112		-0.000
	p-value			0.005		0.000		1.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.4077						
	SE	0.097						
	t-value	-0.34206						
	p-value	0.000						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3166						-1.000
	SE	0.125						6452.918
	t-value	-2.529						-0.000
	p-value	0.011						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.2901		-0.5585				
	SE	0.148		0.107				
	t-value	-1.965		-5.242				
	p-value	0.049		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.2606		-0.4466				-1.0000
	SE	0.136		0.156				4129.369
	t-value	1.918		-2.859				-0.000
	p-value	0.055		0.004				1.000
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.3888				-1.0000		
	SE	0.121				296.462		
	t-value	3.223				-0.003		
	p-value	0.001				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.2086				-0.8222		-1.0000
	SE	0.182				0.082		5693.316
	t-value	1.145				-9.982		-0.000
	p-value	0.252				0.000		1.000
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.3208		-0.5455		-0.9320		
	SE	0.141		0.091		0.056		
	t-value	2.267		-5.975		-16.600		
	p-value	0.023		0.000		0.000		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.3032		-0.4348		-0.8823		-1.0000
	SE	0.220		0.148		0.095		3289.639
	t-value	1.379		-2.931		-9.255		-0.000
	p-value	0.168		0.003		0.000		1.0000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-0.6521		
	SE					0.083		
	t-value					-7.882		
	p-value					0.000		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.2865		-0.8725	-0.4058			
	SE	0.158		0.178	0.156			
	t-value	-1.811		-4.903	-2.067			
	p-value	0.070		0.000	0.009			

9. ARIMA Estimasi Parameter Utara

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							2650.585

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	t-value							-0.000
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5941				
	SE			0.106				
	t-value			-5.629				
	p-value			0.000				
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3730				-1.000
	SE			0.112				2960.058
	t-value			-3.318				-0.000
	p-value			0.001				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-1.0426		-1.0000
	SE					0.081		3555.542
	t-value					-12.841		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5326		-0.9723		
	SE			0.106		0.041		
	t-value			-5.043		-23.588		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3230		-0.9053		-0.7419
	SE			0.127		0.063		0.159
	t-value			-2.551		-14.471		-4.660
	p-value			0.011		0.000		0.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3577						
	SE	0.138						
	t-value	-2.597						
	p-value	0.009						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.2971						-1.000
	SE	0.205						9.3e+04
	t-value	-1.451						-1.08e-05
	p-value	0.147						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3252		-0.5564				
	SE	0.157		0.117				
	t-value	-2.075		-4.760				
	p-value	0.038		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.3100		-0.3506				-1.0000
	SE	0.167		0.119				1219.234
	t-value	-1.861		-2.959				-0.001
	p-value	0.063		0.003				0.999
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.2310				-1.0000		
	SE	0.161				313.227		
	t-value	1.439				-0.003		
	p-value	0.150				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.2506				-1.0000		-1.0002
	SE	0.205				2707.534		225.164
	t-value	1.222				-0.0000		-0.004
	p-value	0.222				1.000		0.996
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.2086		-0.5256		-1.0000		
	SE	0.149		0.126		11.364		
	t-value	1.402		-4.174		-0.009		
	p-value	0.161		0.000		0.993		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2515		-0.3543		-0.9438		-0.7445
	SE	0.165		0.132		0.080		0.170
	t-value	1.521		-2.685		-11.850		-4.373
	p-value	0.128		0.007		0.000		0.000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-1.0000		
	SE					163.626		
	t-value					-0.006		
	p-value					0.995		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.2886		-0.8174	-0.6466			
	SE	0.180		0.105	0.089			
	t-value	-1.605		-7.804	-7.228			
	p-value	0.108		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 1, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.000
	SE							1.1e+04
	t-value							-9.13e-05
	p-value							1.000
$(0, 1, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5153				
	SE			0.118				
	t-value			-4.361				
	p-value			0.000				

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 1, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3874				-1.000
	SE			0.178				9791.651
	t-value			-2.178				-0.000
	p-value			0.029				1.000
$(0, 1, 1) \times (0, 1, 1)_{12}$	Estimasi					-0.7296		-1.0000
	SE					0.077		5120.166
	t-value					-9.511		-0.000
	p-value					0.000		1.000
$(0, 1, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4808		1.2301		
	SE			0.106		0.098		
	t-value			-4.532		-12.530		
	p-value			0.000		0.000		
$(0, 1, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3622		-0.7711		-1.0000
	SE			0.142		0.075		3846.865
	t-value			-2.547		-10.244		-0.000
	p-value			0.011		0.000		1.000
$(1, 1, 0) \times (0, 1, 0)_{12}$	Estimasi	-0.3653						
	SE	0.112						
	t-value	-0.3017						
	p-value	0.001						
$(1, 1, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.3653						-1.000
	SE	0.112						2.92e+04
	t-value	-0.3017						-3.43e-05
	p-value	0.001						1.000
$(1, 1, 0) \times (1, 1, 0)_{12}$	Estimasi	-0.3153		-0.4639				
	SE	0.136		0.122				
	t-value	-2.312		-3.799				
	p-value	0.021		0.000				
$(1, 1, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.2845		-0.3604				-1.0000
	SE	0.140		0.186				3120.954
	t-value	-2.029		-1.943				-0.000
	p-value	0.042		0.052				1.000
$(1, 1, 1) \times (0, 1, 0)_{12}$	Estimasi	0.4566				-1.0000		
	SE	0.123				241.395		
	t-value	3.727				-0.004		
	p-value	0.000				0.997		
$(1, 1, 1) \times (0, 1, 1)_{12}$	Estimasi	0.2524				-0.8407		-1.0000
	SE	0.175				0.078		4029.152
	t-value	1.444				-10.754		-0.000
	p-value	0.149				0.000		1.000
$(1, 1, 1) \times (1, 1, 0)_{12}$	Estimasi	0.3528		-0.4678		-1.0000		
	SE	0.140		0.105		179.254		
	t-value	2.526		-4.462		-0.006		
	p-value	0.012		0.000		0.996		
$(1, 1, 1) \times (1, 1, 1)_{12}$	Estimasi	0.3173		-0.3688		-0.9131		-1.0000
	SE	0.199		0.150		0.084		3084.778
	t-value	1.598		-2.457		-10.810		-0.000
	p-value	0.110		0.014		0.000		1.0000
$(0, 1, 1) \times (0, 1, 0)_{12}$	Estimasi					-0.5622		
	SE					0.097		
	t-value					-5.824		
	p-value					0.000		
$(1, 1, 0) \times (2, 1, 0)_{12}$	Estimasi	-0.2605		-0.7918				
	SE	0.154		0.178	0.158			
	t-value	-1.697		-4.437	-3.338			
	p-value	0.090		0.000	0.001			

10. Hasil Evaluasi ARIMA

a. Tanpa Transformasi

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 1, 0) \times (0, 1, 0)_{12}$	16.797	22.603	22.818	9.783	17.251
$(0, 1, 0) \times (0, 1, 1)_{12}$	14.682	19.036	19.123	7.683	14.938
$(0, 1, 0) \times (1, 1, 0)_{12}$	14.490	18.750	18.680	6.996	14.664
$(0, 1, 0) \times (1, 1, 1)_{12}$	14.459	18.084	18.057	7.442	14.589
$(0, 1, 1) \times (0, 1, 0)_{12}$	3.648	4.823	4.791	1.791	3.665
$(0, 1, 1) \times (0, 1, 1)_{12}$	2.046	2.390	2.457	1.863	2.122
$(0, 1, 1) \times (1, 1, 0)_{12}$	2.055	2.656	2.714	1.463	2.093

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 1, 1) \times (1, 1, 1)_{12}$	2.672	3.562	3.677	2.243	2.804
$(1, 1, 1) \times (0, 1, 0)_{12}$	11.208	14.580	14.800	5.206	11.559
$(1, 1, 0) \times (0, 1, 1)_{12}$	11.029	13.240	13.373	5.364	11.321
$(1, 1, 0) \times (1, 1, 0)_{12}$	9.702	11.563	11.620	3.904	9.945
$(1, 1, 0) \times (1, 1, 1)_{12}$	10.616	12.578	12.687	5.254	10.879
$(1, 1, 1) \times (0, 1, 0)_{12}$	3.879	4.985	4.985	1.988	3.942
$(1, 1, 1) \times (0, 1, 1)_{12}$	2.629	2.755	2.853	2.362	2.756
$(1, 1, 1) \times (1, 1, 0)_{12}$	2.207	2.690	2.779	1.836	2.302
$(1, 1, 1) \times (1, 1, 1)_{12}$	3.211	3.976	4.147	2.657	3.421
$(1, 1, 0) \times (2, 1, 0)_{12}$	8.146	9.676	9.866	3.035	8.469

b. Transformasi

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 1, 0) \times (0, 1, 0)_{12}$	5.156	11.843	12.783	4.618	5.957
$(0, 1, 0) \times (0, 1, 1)_{12}$	4.944	6.646	6.872	4.194	5.116
$(0, 1, 0) \times (1, 1, 0)_{12}$	6.224	10.046	9.891	5.085	6.403
$(0, 1, 0) \times (1, 1, 1)_{12}$	5.833	7.956	7.853	5.646	6.270
$(0, 1, 1) \times (0, 1, 0)_{12}$	7.046	7.110	7.158	6.146	7.066
$(0, 1, 1) \times (0, 1, 1)_{12}$	6.975	7.011	7.042	6.125	6.991
$(0, 1, 1) \times (1, 1, 0)_{12}$	6.948	6.998	7.051	6.048	6.974
$(0, 1, 1) \times (1, 1, 1)_{12}$	3.332	4.474	4.881	3.185	3.353
$(1, 1, 0) \times (0, 1, 0)_{12}$	5.112	5.021	5.018	4.860	5.060
$(1, 1, 0) \times (0, 1, 1)_{12}$	4.541	4.691	4.553	4.596	4.466
$(1, 1, 0) \times (1, 1, 0)_{12}$	5.929	6.342	6.364	5.562	5.951
$(1, 1, 0) \times (1, 1, 1)_{12}$	5.367	5.039	4.787	4.948	5.294
$(1, 1, 1) \times (0, 1, 0)_{12}$	6.908	7.018	6.592	6.063	6.915
$(1, 1, 1) \times (1, 1, 0)_{12}$	6.183	6.246	6.131	5.843	6.183
$(1, 1, 1) \times (1, 1, 1)_{12}$	6.581	6.736	6.514	5.835	6.604
$(0, 1, 1) \times (0, 1, 0)_{12}$	5.833	5.939	5.660	5.712	5.740
$(1, 1, 0) \times (2, 1, 0)_{12}$	5.946	5.990	6.062	5.626	5.925

11. STARIMA Estimasi Parameter Uniform

a. SLAG 0

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,1	Estimasi				0.4146		
	SE				0.0488		
	t-value				8.5		
	p-value				0.0000000000000000024		
0,1,2	Estimasi				0.4233	0.2529	
	SE					0.0567	0.0567
	t-value				7.46	4.4	
	p-value				0.000000000000000041	0.0000100433899	

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,3	Estimasi				0.3264	0.1254	0.3128
	SE				0.0782	0.0773	0.0809
	t-value				4.18	1.62	3.87
	p-value				0.000035	0.10545	0.00013
1,1,0	Estimasi	0.4812					
	SE	0.0435					
	t-value	11.1					
	p-value	0.00000000000000002					
1,1,1	Estimasi	0.5747			-0.1557		
	SE	0.0685			0.0853		
	t-value	8.39			-1.83		
	p-value	0.00000000000000056			0.069		
1,1,2	Estimasi	0.6760			-0.2765	-0.1313	
	SE	0.088			0.1082	0.076	
	t-value	7.62			-2.56	-1.71	
	p-value	0.000000000000014			0.011	0.087	
1,1,3	Estimasi	0.7062			-0.3879	-0.1225	0.1323
	SE	0.0710			0.0916	0.0655	0.0643
	t-value	9.95			-4.23	-1.87	2.06
	p-value	0.00000000000000002			0.00028	0.062	0.040
2,1,0	Estimasi	0.4263	0.1174				
	SE	0.0541	0.0543				
	t-value	7.88	2.16				
	p-value	0.000000000000022	0.031				
2,1,1	Estimasi	0.7667	-0.0833		-0.4249		
	SE	0.1323	0.0902		0.1496		
	t-value	5.80	-0.92		-2.84		
	p-value	0.000000012	0.3563		0.0047		
2,1,2	Estimasi	0.6827	0.0198		-0.3489	-0.0782	
	SE	0.1972	0.1885		0.2213	0.1605	
	t-value	3.46	0.11		-1.58	-0.49	
	p-value	0.00058	0.91628		0.11560	0.62644	
2,1,3	Estimasi	0.7405	-0.082		-0.4099	-0.0209	0.0613
	SE	0.2062	0.2061		0.2315	0.1660	0.0980
	t-value	3.59	-0.33		-1.77	-0.13	0.63
	p-value	0.00036	0.74103		0.07728	0.89991	0.53188
3,1,0	Estimasi	0.4068	0.0586	0.1400			
	SE	0.0643	0.0687	0.0669			
	t-value	6.33	0.85	2.09			
	p-value	0.000000000057	0.394	0.037			
3,1,1	Estimasi	0.6487	-0.0797	0.1132	-0.3160		
	SE	0.1401	0.0993	0.0690	0.1621		
	t-value	4.63	-0.80	1.64	-1.95		
	p-value	0.0000047	0.423	0.102	0.052		
3,1,2	Estimasi	0.7800	-0.2580	0.1440	-0.4770	0.7130	
	SE	0.2500	0.3060	0.1470	0.2870	0.2760	
	t-value	3.12	-0.84	0.98	-1.66	0.63	
	p-value	0.0019	0.3999	0.3271	0.0976	0.5308	
3,1,3	Estimasi	0.6254	-0.1727	0.2167	-0.2859	0.1348	-0.0926
	SE	0.2891	0.3642	0.2789	0.3324	0.3447	0.2353
	t-value	2.16	-0.47	0.77	-0.86	0.39	-0.39
	p-value	0.031	0.636	0.439	0.390	0.696	0.694

b. SLAG 1

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,1	Estimasi				0.4228		
	SE				0.0496		
	t-value				8.53		
	p-value				0.00000000000000002		
0,1,2	Estimasi				0.4526	0.2774	
	SE				0.0631	0.0631	
	t-value				7.17	4.40	
	p-value				0.00000000000029	0.0000134794595	
0,1,3	Estimasi				0.3487	0.1179	0.2965
	SE				0.0939	0.0930	0.0972
	t-value				3.71	1.27	3.05
	p-value				0.00023	0.20529	0.00242
1,1,0	Estimasi	0.4890					
	SE	0.0437					
	t-value	11.2					
	p-value	0.00000000000000002					
1,1,1	Estimasi	0.5711			-0.1392		
	SE	0.0681			0.0855		
	t-value	8.38			-1.63		
	p-value	0.00000000000000058			0.1		
1,1,2	Estimasi	0.679			-0.2783	-0.125	
	SE	0.114			0.143	0.102	
	t-value	5.94			-1.98	-1.23	
	p-value	0.0000000057			0.048	0.221	

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
1,1,3	Estimasi	0.6526			-0.3225	-0.0799	0.0969
	SE	0.0848			0.1127	0.0870	0.0879
	t-value	7.70			-2.86	-0.96	1.10
	p-value	0.000000000000008			0.0044	0.3586	0.2706
2,1,0	Estimasi	0.4349	0.1142				
	SE	0.0575	0.0575				
	t-value	7.58	1.98				
	p-value	0.000000000000018	0.048				
2,1,1	Estimasi	0.8340	-0.0833		-0.5239		
	SE	0.1285	0.0834		0.1480		
	t-value	6.49	-1.00		-3.54		
	p-value	0.0000000000022	0.31574		0.00044		
2,1,2	Estimasi	0.6223	0.0826		-0.2744	-0.1344	
	SE	0.1708	0.1690		0.1955	0.1437	
	t-value	3.46	0.51		-1.40	-0.94	
	p-value	0.0003	0.6079		0.1610	0.3502	
2,1,3	Estimasi	0.7738	-0.0275		-0.4735	-0.0429	0.0294
	SE	0.2181	0.2161		0.2499	0.2093	0.117
	t-value	3.55	-0.13		-1.89	-0.21	0.26
	p-value	0.00043	0.89894		0.05877	0.83765	0.79262
3,1,0	Estimasi	0.4151	0.052	0.1441			
	SE	0.0752	0.0806	0.0783			
	t-value	5.52	0.65	1.84			
	p-value	0.0000000056	0.514	0.066			
3,1,1	Estimasi	0.6573	-0.0793	0.1164	-0.3276		
	SE	0.1700	0.1201	0.0879	0.2007		
	t-value	0.3087	-0.66	1.32	-1.63		
	p-value	0.00013	0.50925	0.18588	0.0336		
3,1,2	Estimasi	0.744	-0.194	0.126	-0.439	0.123	
	SE	0.314	0.369	0.195	0.369	0.354	
	t-value	2.37	-0.53	0.64	-1.19	0.35	
	p-value	0.018	0.5999	0.519	0.234	0.728	
3,1,3	Estimasi	0.674	-0.230	0.243	-0.350	0.187	-0.130
	SE	0.408	0.526	0.401	0.487	0.521	0.358
	t-value	1.65	-0.44	0.61	-0.72	0.36	-0.36
	p-value	0.10	0.66	0.54	0.47	0.72	0.72

12. STARIMA Estimasi Parameter Inverse

a. SLAG 0

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,1	Estimasi				0.4146		
	SE				0.0488		
	t-value				8.5		
	p-value				0.00000000000000024		
0,1,2	Estimasi				0.4233	0.2529	
	SE				0.0567	0.0567	
	t-value				7.46	4.46	
	p-value				0.0000000000000041	0.0000100433899	
0,1,3	Estimasi				0.3264	0.1254	0.3128
	SE				0.0782	0.0773	0.0809
	t-value				4.18	1.62	3.87
	p-value				0.000035	0.10545	0.00013
1,1,0	Estimasi	0.4812					
	SE	0.0435					
	t-value	11.1					
	p-value	0.00000000000000002					
1,1,1	Estimasi	0.5747			-0.1557		
	SE	0.0685			0.0853		
	t-value	8.39			-1.83		
	p-value	0.00000000000000056			0.069		
1,1,2	Estimasi	0.6760			-0.2765	-0.1313	
	SE	0.088			0.1082	0.076	
	t-value	7.62			-2.56	-1.71	
	p-value	0.000000000000014	0.011	0.087			
1,1,3	Estimasi	0.7062			-0.3879	-0.1225	0.1323
	SE	0.0710			0.0916	0.0655	0.0643
	t-value	9.95			-4.23	-1.87	2.06
	p-value	0.00000000000000002			0.000028	0.062	0.040
2,1,0	Estimasi	0.4263	0.1174				
	SE	0.0541	0.0543				
	t-value	7.88	2.16				
	p-value	0.0000000000000022	0.031				
2,1,1	Estimasi	0.7667	-0.0833		-0.4249		
	SE	0.1323	0.0902		0.1496		
	t-value	5.80	-0.92		-2.84		
	p-value	0.000000012	0.3563		0.0047		

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
2,1,2	Estimasi	0.6827	0.0198		-0.3489	-0.0782	
	SE	0.1972	0.1885		0.2213	0.1605	
	t-value	3.46	0.11		-1.58	-0.49	
	p-value	0.00058	0.91628		0.11560	0.62644	
2,1,3	Estimasi	0.7405	-0.0682		-0.4099	-0.0209	0.0613
	SE	0.2062	0.2061		0.2315	0.1660	0.0980
	t-value	3.59	-0.33		-1.77	-0.13	0.63
	p-value	0.00036	0.74103		0.07728	0.89991	0.53188
3,1,0	Estimasi	0.4068	0.0586	0.1400			
	SE	0.0643	0.0687	0.0669			
	t-value	6.33	0.85	2.09			
	p-value	0.000000000057	0.394	0.037			
3,1,1	Estimasi	0.6487	-0.0797	0.1132	-0.3160		
	SE	0.1401	0.0993	0.0690	0.1621		
	t-value	4.63	-0.80	1.64	-1.95		
	p-value	0.0000047	0.423	0.102	0.052		
3,1,2	Estimasi	0.7800	-0.2580	0.1440	-0.4770	0.7130	
	SE	0.2500	0.3060	0.1470	0.2870	0.2760	
	t-value	3.12	-0.84	0.98	-1.66	0.63	
	p-value	0.0019	0.3999	0.3271	0.0976	0.5308	
3,1,3	Estimasi	0.6254	-0.1727	0.2167	-0.2859	0.1348	-0.0926
	SE	0.2891	0.3642	0.2789	0.3324	0.3447	0.2353
	t-value	2.16	-0.47	0.77	-0.86	0.39	-0.39
	p-value	0.031	0.636	0.439	0.390	0.696	0.694

b. SLAG 1

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,1	Estimasi				0.4166		
	SE				0.0496		
	t-value				8.4		
	p-value				0.00000000000000052		
0,1,2	Estimasi				0.4506	0.2804	
	SE				0.0624	0.0623	
	t-value				7.22	4.50	
	p-value				0.000000000000021	0.0000086299958	
0,1,3	Estimasi				0.3404	0.1139	0.2978
	SE				0.0922	0.0913	0.0954
	t-value				3.69	1.25	3.12
	p-value				0.00025	0.21312	0.00190
1,1,0	Estimasi	0.4849					
	SE	0.0436					
	t-value	11.1					
	p-value	0.00000000000000002					
1,1,1	Estimasi	0.5694			-0.1423		
	SE	0.0682			0.0855		
	t-value	8.34			-1.66		
	p-value	0.00000000000000078			0.097		
1,1,2	Estimasi	0.6760			-0.2792	-0.1297	
	SE	0.1114			0.1385	0.0983	
	t-value	6.07			-2.02	-1.32	
	p-value	0.00000000026			0.044	0.187	
1,1,3	Estimasi	0.6547			-0.3318	-0.0820	0.1011
	SE	0.0831			0.1107	0.0847	0.0853
	t-value	7.88			-3.00	-0.97	1.18
	p-value	0.000000000000022			0.0029	0.3336	0.2367
2,1,0	Estimasi	0.4300	0.1162				
	SE	0.0579	0.0581				
	t-value	7.42	2.00				
	p-value	0.000000000000054	0.046				
2,1,1	Estimasi	0.7621	-0.0700		-0.4224		
	SE	0.1342	0.0899		0.1533		
	t-value	5.68	-0.78		-2.76		
	p-value	0.000000024	0.4365		0.0061		
2,1,2	Estimasi	0.6274	0.0758		-0.2866	-0.1260	
	SE	0.1633	0.1538		0.1871	0.1380	
	t-value	3.84	0.49		-1.53	-0.91	
	p-value	0.00014	0.62220		0.12602	0.36156	
2,1,3	Estimasi	0.7749	-0.0347		-0.4794	-0.0329	0.0323
	SE	0.2187	0.2169		0.2505	0.2093	0.1114
	t-value	3.54	-0.16		-1.91	-0.16	0.29
	p-value	0.00043	0.87282		0.05629	0.87529	0.77271
3,1,0	Estimasi	0.4104	0.0560	0.1414			
	SE	0.0771	0.0825	0.0801			
	t-value	5.32	0.68	1.76			
	p-value	0.00000016	0.498	0.078			
3,1,1	Estimasi	0.6554	-0.0766	0.1144	-0.3313		
	SE	0.1748	0.1231	0.0900	0.2065		
	t-value	3.75	-0.62	1.27	-1.60		
	p-value	0.0002	0.5339	0.2045	0.1093		

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
3,1,2	Estimasi	0.7570	-0.2050	0.1220	-0.4610	0.1410	
	SE	0.3060	0.3570	0.1860	0.3600	0.3440	
	t-value	2.47	-0.58	0.66	-1.28	0.41	
	p-value	0.014	0.565	0.512	0.201	0.683	
3,1,3	Estimasi	0.6920	-0.2570	0.2510	-0.3800	0.2200	-0.0143
	SE	0.4140	0.5380	0.4080	0.4930	0.5360	0.3700
	t-value	1.67	-0.48	0.62	-0.77	0.41	-0.39
	p-value	0.095	0.634	0.538	0.442	0.682	0.700

13. STARIMA Estimasi Parameter Korelasi Silang

a. SLAG 0

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,1	Estimasi				0.4146		
	SE				0.0488		
	t-value				8.5		
	p-value				0.00000000000000024		
0,1,2	Estimasi				0.4233	0.2529	
	SE				0.0567	0.0567	
	t-value				7.46	4.4	
	p-value				0.00000000000041	0.0000100433899	
0,1,3	Estimasi				0.3264	0.1254	0.3128
	SE				0.0782	0.0773	0.0809
	t-value				4.18	1.62	3.87
	p-value				0.000035	0.10545	0.00013
1,1,0	Estimasi	0.4812					
	SE	0.0435					
	t-value	11.1					
	p-value	0.00000000000000002					
1,1,1	Estimasi	0.5747			-0.1557		
	SE	0.0685			0.0853		
	t-value	8.39			-1.83		
	p-value	0.000000000000000056			0.069		
1,1,2	Estimasi	0.6760			-0.2765	-0.1313	
	SE	0.088			0.1082	0.076	
	t-value	7.62			-2.56	-1.71	
	p-value	0.0000000000000014			0.011	0.087	
1,1,3	Estimasi	0.7062			-0.3879	-0.1225	0.1323
	SE	0.0710			0.0916	0.0655	0.0643
	t-value	9.95			-4.23	-1.87	2.06
	p-value	0.00000000000000002			0.00028	0.062	0.040
2,1,0	Estimasi	0.4263	0.1174				
	SE	0.0541	0.0543				
	t-value	7.88	2.16				
	p-value	0.0000000000000022	0.031				
2,1,1	Estimasi	0.7667	-0.0833		-0.4249		
	SE	0.1323	0.0902		0.1496		
	t-value	5.80	-0.92		-2.84		
	p-value	0.0000000012	0.3563		0.0047		
2,1,2	Estimasi	0.6827	0.0198		-0.3489	-0.0782	
	SE	0.1972	0.1885		0.2213	0.1605	
	t-value	3.46	0.11		-1.58	-0.49	
	p-value	0.00058	0.9162		0.11560	0.62644	
2,1,3	Estimasi	0.7405	-0.0820		-0.4099	-0.0209	0.0613
	SE	0.2062	0.2061		0.2315	0.1600	0.0980
	t-value	3.59	-0.33		-1.77	-0.13	0.63
	p-value	0.0003	0.74103		0.07728	0.89991	0.53188
3,1,0	Estimasi	0.4068	0.0586	0.1400			
	SE	0.0643	0.067	0.0696			
	t-value	6.33	0.85	2.09			
	p-value	0.00000000000057	0.394	0.037			
3,1,1	Estimasi	0.6487	-0.079	0.1132	-0.3160		
	SE	0.1401	0.0993	0.0696	0.1621		
	t-value	4.63	-0.80	1.64	-1.95		
	p-value	0.0000047	0.423	0.102	0.052		
3,1,2	Estimasi	0.780	-0.258	0.144	-0.477	0.713	
	SE	0.250	0.306	0.147	0.287	0.276	
	t-value	3.12	-0.84	0.98	-1.66	0.63	
	p-value	0.0019	0.3999	0.3271	0.0976	0.5308	
3,1,3	Estimasi	0.6254	-0.1727	0.2167	-0.2859	0.1348	-0.0926
	SE	0.2819	0.342	0.2789	0.3324	0.3447	0.2353
	t-value	2.16	-0.47	0.77	-0.86	0.39	-0.39
	p-value	0.031	0.636	0.439	0.390	0.696	0.694

b. SLAG 1

Model	Statistik	AR Parameter			MA Parameter		
		φ_{10}	Φ_{20}	Φ_{30}	θ_{10}	Θ_{20}	Θ_{30}
0,1,1	Estimasi				0.4226		
	SE				0.0496		
	t-value				8.52		
	p-value				0.00000000000000053		
0,1,2	Estimasi				0.4528	0.2777	
	SE				0.0632	0.0631	
	t-value				7.17	4.40	
	p-value				0.000000000000029	0.0000132701631	
0,1,3	Estimasi				0.3489	0.1182	0.2963
	SE				0.0939	0.0930	0.0972
	t-value				3.71	1.27	3.05
	p-value				0.00023	0.20438	0.00243
1,1,0	Estimasi	0.4890					
	SE	0.0437					
	t-value	11.2					
	p-value	0.0000000000000002					
1,1,1	Estimasi	0.5712			-0.1392		
	SE	0.0681			0.0855		
	t-value	8.39			-1.63		
	p-value	0.00000000000000057			0.1		
1,1,2	Estimasi	0.679			-0.283	-0.125	
	SE	0.1115			0.144	0.102	
	t-value	5.90			-1.97	-1.22	
	p-value	0.000000007			0.05	0.22	
1,1,3	Estimasi	0.6527			-0.3227	-0.0800	0.0970
	SE	0.0848			0.1128	0.0871	0.0879
	t-value	7.69			-2.86	-0.92	1.10
	p-value	0.000000000000083			0.0044	0.3590	0.2708
2,1,0	Estimasi	0.4349	0.1142				
	SE	0.0574	0.0575				
	t-value	7.58	1.99				
	p-value	0.00000000000018	0.048				
2,1,1	Estimasi	0.8346	-0.0840		-0.5247		
	SE	0.1290	0.0837		0.1485		
	t-value	6.47	-1.00		-3.53		
	p-value	0.000000024	0.31633		0.00045		
2,1,2	Estimasi	0.6222	0.0827		-0.2744	-0.1344	
	SE	0.1714	0.1615		0.1962	0.1442	
	t-value	3.63	0.51		-1.40	-0.93	
	p-value	0.00031	0.60899		0.16258	0.35167	
2,1,3	Estimasi	0.7741	-0.0283		-0.4738	-0.0423	0.0300
	SE	0.2182	0.2169		0.2500	0.2092	0.1118
	t-value	3.55	-0.13		-1.90	-0.20	0.27
	p-value	0.00043	0.89589		0.05870	0.84002	0.78826
3,1,0	Estimasi	0.4104	0.0560	0.1414			
	SE	0.0771	0.0825	0.0801			
	t-value	5.32	0.68	1.76			
	p-value	0.00000016	0.498	0.078			
3,1,1	Estimasi	0.6554	-0.0766	0.1144	-0.3313		
	SE	0.1748	0.1231	0.0900	0.2065		
	t-value	3.75	-0.62	1.27	-1.60		
	p-value	0.0002	0.5339	0.2045	0.1093		
3,1,2	Estimasi	0.7570	-0.2050	0.1220	-0.4610	0.1410	
	SE	0.3060	0.3570	0.1860	0.3600	0.3440	
	t-value	2.47	-0.58	0.66	-1.28	0.41	
	p-value	0.014	0.565	0.512	0.201	0.683	
3,1,3	Estimasi	0.6920	-0.2570	0.2510	-0.3800	0.2200	-0.0143
	SE	0.4140	0.5380	0.4080	0.4930	0.5360	0.3700
	t-value	1.67	-0.48	0.62	-0.77	0.41	-0.39
	p-value	0.095	0.634	0.538	0.442	0.682	0.700

14. Hasil Evaluasi RMSE Uniform

a. SLAG 0

Model	Barat	Selatan	Tengah	Timur	Utara
0,1,1	1.970	2.342	2.269	1.613	1.985
0,1,2	1.947	2.262	2.275	1.585	2.024
0,1,3	1.957	2.254	2.289	1.597	2.016
1,1,0	1.689	2.019	2.065	1.423	1.699
1,1,1	1.652	2.003	2.125	1.408	1.681
1,1,2	1.640	2.120	2.252	1.405	1.697
1,1,3	1.647	2.164	2.328	1.418	1.727
2,1,0	1.806	2.122	2.161	1.564	1.815
2,1,1	1.757	2.414	2.702	1.546	1.961
2,1,2	1.639	2.114	2.245	1.417	1.689
2,1,3	1.727	2.375	2.594	1.482	1.879
3,1,0	1.770	2.074	2.113	1.507	1.777
3,1,1	1.681	2.146	2.362	1.454	1.782
3,1,2	2.200	3.222	3.621	2.001	2.521
3,1,3	1.792	2.394	2.555	1.561	1.899

b. SLAG 1

Model	Barat	Selatan	Tengah	Timur	Utara
0,1,1	1.969	2.343	2.269	1.613	1.985
0,1,2	1.944	2.262	2.273	1.581	2.027
0,1,3	1.955	2.250	2.291	1.594	2.018
1,1,0	1.685	2.018	2.066	1.420	1.696
1,1,1	1.653	2.005	2.119	1.407	1.680
1,1,2	1.640	2.124	2.258	1.406	1.699
1,1,3	1.647	2.105	2.226	1.416	1.691
2,1,0	1.796	2.112	2.152	1.554	1.804
2,1,1	1.839	2.633	2.976	1.634	2.133
2,1,2	1.660	2.041	2.127	1.458	1.658
2,1,3	1.699	2.349	2.588	1.461	1.860
3,1,0	1.760	2.065	2.105	1.497	1.766
3,1,1	1.684	2.159	2.381	1.458	1.790
3,1,2	1.966	2.802	3.108	1.741	2.203
3,1,3	1.945	2.704	2.947	1.740	2.122

15. Hasil Evaluasi RMSE Inverse

a. SLAG 0

Model	Barat	Selatan	Tengah	Timur	Utara
0,1,1	1.968	2.341	2.269	1.612	1.981
0,1,2	1.945	2.261	2.275	1.584	2.022
0,1,3	1.955	2.253	2.289	1.596	2.014
1,1,0	1.688	2.020	2.067	1.420	1.698
1,1,1	1.652	2.005	2.127	1.407	1.681
1,1,2	1.641	2.122	2.253	1.404	1.701
1,1,3	1.648	2.167	2.329	1.418	1.732
2,1,0	1.804	2.123	2.163	1.561	1.810
2,1,1	1.760	2.415	2.700	1.553	1.974
2,1,2	1.639	2.117	2.246	1.415	1.692
2,1,3	1.730	2.378	2.592	1.486	1.889
3,1,0	1.769	2.075	2.115	1.504	1.773
3,1,1	1.683	2.148	2.363	1.456	1.789
3,1,2	2.206	3.222	3.614	2.015	2.541
3,1,3	1.794	2.396	2.553	1.566	1.908

b. SLAG 1

Model	Barat	Selatan	Tengah	Timur	Utara
0,1,1	1.968	2.341	2.269	1.612	1.981
0,1,2	1.943	2.262	2.272	1.580	2.024
0,1,3	1.954	2.249	2.291	1.594	2.015
1,1,0	1.686	2.020	2.067	1.419	1.696
1,1,1	1.653	2.005	2.121	1.407	1.681
1,1,2	1.641	2.122	2.253	1.404	1.701
1,1,3	1.648	2.110	2.232	1.416	1.696
2,1,0	1.800	2.118	2.159	1.557	1.806
2,1,1	1.736	2.361	2.642	1.525	1.935
2,1,2	1.655	2.046	2.135	1.448	1.656
2,1,3	1.713	2.373	2.614	1.472	1.888
3,1,0	1.764	2.071	2.111	1.499	1.769
3,1,1	1.683	2.151	2.373	1.457	1.792
3,1,2	2.019	2.892	3.219	1.802	2.289
3,1,3	2.039	2.867	3.147	1.854	2.259

16. Hasil Evaluasi RMSE Korelasi Silang

a. SLAG 0

Model	Barat	Selatan	Tengah	Timur	Utara
0,1,1	1.970	2.342	2.269	1.613	1.985
0,1,2	1.947	2.262	2.275	1.585	2.024
0,1,3	1.957	2.254	2.289	1.597	2.016
1,1,0	1.689	2.019	2.065	1.423	1.699
1,1,1	1.652	2.003	2.125	1.408	1.681
1,1,2	1.640	2.120	2.252	1.405	1.697
1,1,3	1.647	2.164	2.328	1.418	1.727
2,1,0	1.806	2.122	2.161	1.564	1.815
2,1,1	1.757	2.414	2.702	1.546	1.961
2,1,2	1.639	2.114	2.245	1.417	1.689
2,1,3	1.727	2.376	2.594	1.482	1.879
3,1,0	1.770	2.074	2.113	1.507	1.777
3,1,1	1.682	2.147	2.362	1.453	1.782
3,1,2	2.201	3.223	3.623	2.001	2.521
3,1,3	1.792	2.395	2.555	1.561	1.900

b. SLAG 1

Model	Barat	Selatan	Tengah	Timur	Utara
0,1,1	1.969	2.343	2.269	1.613	1.985
0,1,2	1.944	2.262	2.273	1.581	2.027
0,1,3	1.955	2.250	2.290	1.594	2.018
1,1,0	1.685	2.018	2.066	1.420	1.696
1,1,1	1.653	2.005	2.120	1.407	1.680
1,1,2	1.640	2.124	2.258	1.406	1.699
1,1,3	1.647	2.105	2.226	1.416	1.692
2,1,0	1.796	2.112	2.152	1.555	1.804
2,1,1	1.840	2.636	2.980	1.635	2.136
2,1,2	1.660	2.041	2.127	1.458	1.658
2,1,3	1.701	2.352	2.592	1.462	1.863
3,1,0	1.760	2.065	2.104	1.497	1.766
3,1,1	1.684	2.159	2.381	1.458	1.790
3,1,2	1.967	2.804	3.111	1.742	2.204
3,1,3	1.946	2.705	2.949	1.741	2.124