

**PERAMALAN CURAH HUJAN DENGAN
PEMBOBOTAN DERET WAKTU
BERBASIS SPATIO TEMPORAL**

***RAINFALL FORECASTING USING TIME
SERIES WEIGHTING BASED ON
SPATIAL TEMPORAL***

Tugas Akhir

Diajukan untuk memenuhi salah satu syarat memperoleh
gelar sarjana dari program studi Sarjana Sains Data
Direktorat Kampus Surabaya
Universitas Telkom

Disusun oleh:
CALISTA GHEA ARDHANI
NIM 1206220010



**PROGRAM STUDI SARJANA SAINS DATA
DIREKTORAT KAMPUS SURABAYA
UNIVERSITAS TELKOM
SURABAYA
2025**

LEMBAR PENGESAHAN

TUGAS AKHIR

PERAMALAN CURAH HUJAN DENGAN PEMBOBOTAN DERET WAKTU BERBASIS SPATIO TEMPORAL

Telah disetujui dan disahkan untuk memenuhi syarat memperoleh
gelar pada Program Studi Sarjana Sains Data
Direktorat Kampus Surabaya, Universitas Telkom

CALISTA GHEA ARDHANI

NIM: 1206220010

Surabaya, 1 Desember 2025

Menyetujui

Regita Putri Permata S.Stat., M.Stat.
NIP: 22960008

(Pembimbing 1)

Rifdatun Ni'mah S.Si., M.Si.
NIP: 22900008

(Pembimbing 2)

Dosen Penguji Satu
NIP: Dosen Penguji Satu

(Penguji 1)

Dosen Penguji Dua
NIP: Dosen Penguji Dua

(Penguji 2)

Ketua Program Studi Sarjana
Sains Data

Moh. Hamim Zajuli Al Faroby, S.Si., M.Mat.
NIP: 23950023

Lembar Pernyataan Orisinalitas



Nama : CALISTA GHEA ARDHANI
NIM : 1206220010
Alamat : Jl. Residen Sudirman No 68K
No. Telp : 081213770725
Email : calistaghea@student.telkomuniversity.ac.id

Menyatakan bahwa Tugas Akhir ini merupakan karya orisinal saya sendiri. Atas pernyataan ini, saya siap menanggung risiko atau sanksi yang dijatuhkan kepada saya apabila kemudian ditemukan adanya pelanggaran terhadap kejujuran akademik atau etika keilmuan dalam karya ini, atau ditemukan bukti yang menunjukkan ketidakaslian karya ini.

Surabaya, 1 Desember 2025

CALISTA GHEA ARDHANI

ABSTRAK

Curah hujan memiliki peran penting bagi berbagai sektor seperti pertanian, infrastruktur, dan pengelolaan risiko bencana, sehingga prediksi yang akurat menjadi kebutuhan utama terutama di kota besar seperti Surabaya yang rentan terhadap banjir dan genangan. Mengingat curah hujan dipengaruhi oleh variasi ruang dan waktu secara simultan, penelitian ini menerapkan model STARIMA untuk memprediksi curah hujan bulanan dengan mempertimbangkan keterkaitan dinamis antarwilayah. Data yang digunakan berasal dari citra satelit NASA POWER periode 2015 - 2024. Tahapan penelitian meliputi pra-pemrosesan data melalui transformasi Box-Cox dan differencing, analisis pola spasio-temporal, uji stasioneritas, penyusunan Spatial Weight Matrix menggunakan tiga skema bobot (seragam, invers jarak, dan korelasi silang), pembangunan model SARIMA sebagai model pembanding, serta evaluasi performa menggunakan RMSE. Hasil penelitian menunjukkan adanya pola musiman yang konsisten serta korelasi spasial yang kuat antarwilayah Surabaya, mencerminkan bahwa informasi ruang tidak dapat diabaikan dalam peramalan. Model terbaik diperoleh pada STARIMA(1,1,1) dengan lag spasial 1 dan bobot terbaiknya yaitu bobot seragam, yang menghasilkan RMSE rata-rata 1.728 lebih rendah dibandingkan model STARIMA lain maupun SARIMA. Misalnya di wilayah Timur, RMSE turun signifikan dari 4.596 (SARIMA) menjadi 1.407 (STARIMA). Temuan ini menegaskan bahwa integrasi aspek ruang dan waktu melalui STARIMA mampu meningkatkan akurasi prediksi curah hujan dan berpotensi mendukung sistem peringatan dini serta mitigasi bencana hidrometeorologi di Surabaya.

Kata Kunci: Prediksi Curah Hujan, Spatial Weight Matrix, STARIMA, Surabaya.

Abstract

Rainfall plays a vital role in sectors such as agriculture, infrastructure, and disaster risk management, making accurate forecasting a critical necessity, particularly in major urban areas like Surabaya that are vulnerable to flooding and surface inundation. Given that rainfall is simultaneously influenced by spatial and temporal variations, this study applies the STARIMA model to forecast monthly rainfall while accounting for the dynamic interconnections among regions. The dataset employed is derived from NASA POWER satellite imagery covering the period 2015 - 2024. The research workflow includes data preprocessing using Box-Cox transformation and differencing, spatio-temporal pattern analysis, stationarity testing, construction of Spatial Weight Matrices with three weighting schemes (uniform, inverse-distance, and cross-correlation), development of SARIMA models as benchmarks, and performance evaluation using RMSE. The findings indicate consistent seasonal patterns and strong spatial correlations across Surabaya's regions, highlighting the essential role of spatial information in rainfall forecasting. The best-performing model is STARIMA(1,1,1) with a spatial lag of 1 and its optimal configuration—uniform weighting—yielding an average RMSE of 1.728, outperforming both other STARIMA variants and SARIMA. In the East region, for example, RMSE decreases significantly from 4.596 (SARIMA) to 1.407 (STARIMA). These results affirm that integrating spatial and temporal dimensions through the STARIMA framework substantially enhances rainfall forecasting accuracy and has the potential to support early warning systems and hydrometeorological disaster mitigation initiatives in Surabaya.

Keywords: Rainfall Prediction, Spatial Weight Matrix, STARIMA, Surabaya.

Kata Pengantar

Puji syukur saya panjatkan kepada Tuhan Yang Maha Esa atas segala rahmat-Nya sehingga skripsi berjudul "Peramalan Curah Hujan dengan Pembobotan Deret Waktu Berbasis Spasio-Temporal" ini dapat diselesaikan dengan baik. Skripsi ini disusun sebagai salah satu syarat kelulusan pada Program Studi Sains Data Universitas Telkom Kampus Surabaya.

Penelitian ini bertujuan untuk memprediksi curah hujan secara lebih akurat menggunakan model STARMA berbasis spasio-temporal. Diharapkan hasilnya dapat bermanfaat bagi sistem peringatan dini dan kebijakan mitigasi bencana.

Saya mengucapkan terima kasih kepada dosen pembimbing, seluruh pengajar, keluarga, serta teman-teman yang telah memberikan dukungan dan bantuan selama proses penyusunan skripsi ini. Kritik dan saran sangat saya harapkan demi penyempurnaan di masa mendatang.

Surabaya, 1 Desember 2025
CALISTA GHEA ARDHANI

Daftar Isi

Lembar Persetujuan	i
Lembar Pernyataan Orisinalitas	ii
Abstrak	iii
<i>Abstract</i>	iv
Kata Pengantar	v
Daftar Isi	vi
Daftar Tabel	viii
Daftar Gambar	ix
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	4
1.3 Tujuan Penelitian	5
1.4 Batasan dan Asumsi Penelitian	5
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	6
II Landasan Teori	8
2.1 Penelitian Terkait	8
2.2 Peramalan	12
2.3 Menguji Kestasioneran Data	13
2.4 ARIMA Model	15
2.5 Model STARMA (<i>Space-Time Autoregressive Moving Average</i>)	17
2.6 Spatial Weight Matrix (SWM)	21
2.6.1 Konsep Dasar Spatial Weight Matrix	21

2.6.2	Bentuk Umum Matriks SWM	22
2.6.3	Jenis-jenis Pembobotan	22
2.6.4	Peran SWM dalam Model STARMA	24
III	Metodologi Penelitian	25
3.1	Metode Penelitian	25
3.2	Sumber Data	26
3.2.1	Data Sekunder	26
3.3	Pra-pemrosesan Data	27
3.4	Analisis Eksploratif Pola Spasio-Temporal Curah Hujan	28
3.5	Pengecekan Kestasioneran Data	28
3.6	Pembentukan <i>Spatial Weight Matrix</i>	28
3.7	Pembangunan Model SARIMA	28
3.8	Pembangunan Model STARMA	29
3.9	Evaluasi	29
3.10	Harapan Hasil Peramalan	29
IV	Hasil dan Pembahasan	30
4.1	Eksplorasi Data	30
4.1.1	Statistika Deskriptif	30
4.1.2	Pola Curah Hujan Kelima Wilayah di Surabaya	31
4.1.3	Karakteristik dengan BoxPlot	34
4.1.4	Analisis Temporal Curah Hujan	35
4.1.5	Analisis Korelasi Spatio Temporal	36
4.2	ARIMA	36
4.2.1	Stasioner Data	36
4.2.2	Estimasi Parameter	41
4.2.3	Model Fitting	42
4.2.4	Hasil Forecasting SARIMA	43
4.3	STARIMA	46
4.3.1	Stasioner Data	46
4.3.2	Bobot Seragam	49
4.3.3	Bobot Invers Jarak	56
4.3.4	Bobot Lokasi Normalisasi Korelasi Silang	64
4.4	Hasil Peramalan	72
V	Kesimpulan dan Saran	74
5.1	Kesimpulan	74
5.2	Saran	74
	Daftar Pustaka	76
	Lampiran	79

Daftar Tabel

2.1	Nilai λ dan Bentuk Transformasi Box-Cox	14
3.1	Data Curah Hujan Bulanan Berdasarkan Wilayah	26
4.1	Statistika Deskriptif	30
4.2	Tabel Korelasi Setiap Wilayah	36
4.3	Nilai Lambda Semua Wilayah	37
4.4	Hasil Uji ADF	38
4.5	Perbandingan RMSE Tanpa Transformasi dan Dengan Tran- sformasi Box-Cox	40
4.6	Estimasi Parameter SARIMA	41
4.7	Hasil Model Fitting SARIMA	42
4.8	Nilai Lambda Semua Wilayah	47
4.9	Hasil Uji ADF	48
4.10	Estimasi Parameter Model STARIMA Uniform	51
4.11	Hasil Model Fitting STARIMA Uniform	51
4.12	Estimasi Parameter Model STARIMA Inverse	58
4.13	Hasil Model Fitting Inverse	59
4.14	Estimasi Parameter Model STARIMA Cross	66
4.15	Hasil Model Fitting Cross	67
4.16	Perbandingan RMSE SARIMA dan STARIMA per Wilayah . .	73

Daftar Gambar

3.1	Diagram Alur Metodologi Penelitian	25
3.2	Data NASA Wilayah Surabaya	26
4.1	Pola Curah Hujan Wilayah Barat	31
4.2	Pola Curah Hujan Wilayah Selatan	32
4.3	Pola Curah Hujan Wilayah Tengah	32
4.4	Pola Curah Hujan Wilayah Timur	33
4.5	Pola Curah Hujan Wilayah Utara	33
4.6	Boxplot Kelima Wilayah di Surabaya	34
4.7	Seasonal Decompose Semua Wilayah	35
4.8	Plot ACF dan PACF Wilayah Barat (Sebelum)	39
4.9	Plot ACF dan PACF Wilayah Barat (Sesudah)	39
4.10	Hasil Forecasting Wilayah Barat	43
4.11	Hasil Forecasting Wilayah Selatan	44
4.12	Hasil Forecasting Wilayah Tengah	44
4.13	Hasil Forecasting Wilayah Timur	45
4.14	Hasil Forecasting Wilayah Utara	46
4.15	Hasil Grafik Curah Hujan Setelah Transformasi dan Differencing	48
4.16	STACF dan STPACF SLAG 0	49
4.17	STACF dan STPACF SLAG 1	50
4.18	Hasil Peramalan Wilayah Barat	52
4.19	Hasil Peramalan Wilayah Selatan	53
4.20	Hasil Peramalan Wilayah Tengah	54
4.21	Hasil Peramalan Wilayah Timur	55
4.22	Hasil Peramalan Wilayah Utara	56
4.23	STACF dan STPACF SLAG 0	57
4.24	STACF dan STPACF SLAG 1	58
4.25	Hasil Peramalan Wilayah Barat	60
4.26	Hasil Peramalan Wilayah Selatan	61
4.27	Hasil Peramalan Wilayah Tengah	62
4.28	Hasil Peramalan Wilayah Timur	63
4.29	Hasil Peramalan Wilayah Utara	64

4.30 STACF dan STPACF SLAG 0	65
4.31 STACF dan STPACF SLAG 1	65
4.32 Hasil Peramalan Wilayah Barat	68
4.33 Hasil Peramalan Wilayah Selatan	69
4.34 Hasil Peramalan Wilayah Tengah	70
4.35 Hasil Peramalan Wilayah Timur	71
4.36 Hasil Peramalan Wilayah Utara	72

Bab I

Pendahuluan

1.1 Latar Belakang

Surabaya merupakan salah satu kota metropolitan di Indonesia yang memiliki kepadatan aktivitas ekonomi, sosial, dan infrastruktur yang tinggi. (Sesarin 2020). Terletak di wilayah timur Pulau Jawa, Surabaya berada pada zona iklim tropis basah yang ditandai dengan adanya dua musim, yaitu musim penghujan dan musim kemarau. Kondisi iklim ini menjadikan curah hujan sebagai salah satu elemen penting dalam tata kelola perkotaan. Tingginya intensitas curah hujan dalam waktu singkat di Surabaya dapat menyebabkan genangan atau banjir yang berpotensi mengganggu aktivitas masyarakat dan merusak infrastruktur. (Febriana 2019)

Curah hujan sendiri merupakan salah satu parameter meteorologi yang paling krusial dalam berbagai sektor, seperti pertanian, pengelolaan sumber daya air, mitigasi bencana, serta perencanaan pembangunan wilayah. Curah hujan menunjukkan banyaknya air hujan yang turun dalam suatu wilayah selama periode waktu tertentu. Dalam konteks kota seperti Surabaya, pemahaman terhadap curah hujan sangat penting untuk menunjang kebijakan adaptif dan strategi mitigasi terhadap dampak bencana hidrometeorologi. (Azka et al. 2018)

Dalam beberapa tahun terakhir terjadi ketidakpastian musim yang dipengaruhi oleh perubahan iklim global, termasuk pergeseran waktu dan intensitas musim penghujan maupun kemarau. Hal ini menjadikan upaya untuk memahami karakteristik curah hujan sebagai langkah penting dalam menghadapi tantangan perubahan iklim (Sofia et al. 2018). Salah satu karakteristik penting curah hujan adalah variabilitasnya, baik secara temporal (waktu) maupun spasial (lokasi geografis), yang mencerminkan fluktuasi jumlah serta distribusi hujan.

Untuk mendukung perencanaan dan pengambilan kebijakan yang adaptif, diperlukan model prediksi curah hujan yang akurat. Pemodelan ini bertujuan untuk melihat dan menganalisis pola hujan yang akan terjadi di masa mendatang. Penelitian ini menggunakan data curah hujan berbasis satelit dari NASA

untuk menganalisis dinamika curah hujan dan meramalkan pola curah hujan di wilayah Surabaya. Diharapkan hasil dari peramalan ini dapat digunakan sebagai dasar perencanaan kebijakan perkotaan yang tanggap terhadap risiko bencana dan perubahan iklim.

Forecasting atau peramalan adalah proses membuat prediksi mengenai kejadian di masa depan dengan menggunakan data historis dan pengetahuan saat ini. Tujuannya adalah memberikan dasar yang kuat bagi pengambilan keputusan dalam berbagai bidang. Peramalan tidak selalu harus menghasilkan satu nilai pasti, dalam praktiknya dapat berupa nilai tunggal *point forecast*, interval prediksi, distribusi probabilitas atau kemungkinan terjadinya sesuatu. Proses peramalan melibatkan pengamatan pola masa lampau seperti tren, musiman, atau siklus, yang kemudian dianalisis menggunakan berbagai metode statistik atau teknik pembelajaran mesin (Petrooulos et al. 2021). Terdapat dua jenis metode peramalan yang terdiri dari kualitatif dan kuantitatif. Metode kualitatif mengandalkan pendapat ahli dan bersifat subjektif, biasanya digunakan saat data historis sulit diperoleh. Sebaliknya, metode kuantitatif menggunakan prinsip statistik, lebih objektif, dan mencakup berbagai pendekatan salah satunya yaitu *time series* yang menganalisis pola data berurutan berdasarkan waktu untuk menghasilkan prediksi masa depan (Ruchjana 2019).

Namun, metode peramalan konvensional *time series* murni hanya mempertimbangkan aspek temporal tanpa mengikutsertakan faktor spasial, sehingga kurang optimal dalam menganalisis fenomena seperti curah hujan yang dipengaruhi oleh kondisi geografis wilayah. Itu dibuktikan dalam penelitian yang berjudul "*Enhanced Spatio Temporal Modeling for Rainfall Forecasting: A High Resolution Grid Analysis*" yang menjelaskan bahwa model konvensional seperti ARIMA hanya menangkap aspek temporal dan linier. Tanpa mempertimbangkan korelasi spasial antar lokasi, model model tersebut sering kali gagal memberikan prediksi curah hujan yang akurat terutama ketika diterapkan pada wilayah dengan variasi geografis yang kompleks. Sebaliknya, pendekatan spatio temporal berbasis grid resolusi tinggi merupakan salah satu pendekatan yang relevan dalam konteks iklim dan meteorologi (Alam et al. 2024).

Model spasio-temporal merupakan suatu pendekatan yang menggambarkan fenomena alam dengan mempertimbangkan aspek lokasi (spasial) dan waktu (temporal) (Utami 2017). Dalam proses analisisnya, model ini memperhitungkan adanya ketergantungan antar lokasi pengamatan serta hubungan korelatif yang mungkin muncul dari keterlambatan waktu (lag). Data yang diamati berdasarkan waktu biasanya tidak bersifat independen, melainkan saling berkorelasi dan membentuk pola deret waktu. Model spasio-temporal pertama kali dikembangkan oleh Bilonick dan Nicholas pada tahun 1983, melalui penelitian curah hujan menggunakan tiga pendekatan. Pendekatan pertama berfokus pada aspek temporal dengan mengabaikan pengaruh spasial, yang kedua menekankan pengaruh spasial tanpa mempertimbangkan aspek waktu,

dan yang ketiga menggabungkan keduanya dalam satu analisis (Islami et al. 2021).

Pendekatan spasio-temporal memungkinkan identifikasi kemiripan pola curah hujan antar wilayah dengan memperhatikan hubungan geografis antar lokasi, baik yang berdekatan maupun berjauhan. Salah satu alat penting dalam pendekatan ini adalah *Spatial Weight Matrix*. *Spatial Weight Matrix* merupakan matriks yang merepresentasikan kekuatan hubungan spasial antara suatu lokasi dengan lokasi lainnya (Mukhaiyar et al. 2024). Nilai dalam matriks ini menunjukkan seberapa besar pengaruh satu lokasi terhadap lokasi lain berdasarkan kedekatan geografis, jarak, atau karakteristik spasial tertentu.

Dalam pengembangannya, *Spatial Weight Matrix* dapat dibentuk dalam dua dimensi (menggunakan koordinat horizontal) maupun tiga dimensi (menggabungkan perbedaan ketinggian). Pendekatan tiga dimensi ini menjadi penting ketika fenomena yang diteliti, seperti curah hujan atau muka air tanah, dipengaruhi oleh topografi atau elevasi wilayah. Matrix ini bisa dibentuk dengan berbagai metode seperti bobot berbasis inverse distance, bobot seragam, hingga yang dimodifikasi untuk memasukkan faktor ketinggian (Mukhaiyar et al. 2024).

Dengan menggunakan *Spatial Weight Matrix* yang tepat, model spatio-temporal seperti STARMA (*Space Time Autoregressive Moving Average*) mampu menangkap keterikatan spasial dan temporal secara simultan (Sharma et al. 2025). Model ini mengakomodasi efek pengaruh wilayah sekitar terhadap suatu lokasi, serta mempertimbangkan dinamika temporal yang mempengaruhi dari waktu ke waktu. STARMA menggunakan bobot dan mengintegrasikannya dengan temporal lag untuk menghasilkan prediksi yang lebih akurat terhadap fenomena spasio-temporal seperti curah hujan.

Penggunaan pendekatan spasio-temporal seperti STARMA menjadi semakin relevan di tengah kondisi perubahan iklim yang menyebabkan curah hujan menjadi lebih ekstrem, tidak teratur, dan tidak menentu di berbagai wilayah Indonesia. Oleh karena itu, perancangan model prediksi curah hujan berbasis spasio-temporal tidak hanya memiliki kontribusi dalam pengembangan ilmu, tetapi juga sangat krusial untuk mendukung sistem peringatan dini, kebijakan mitigasi bencana, dan pengelolaan sumber daya air secara berkelanjutan.

Dalam mendukung kebutuhan tersebut, model spasio-temporal seperti STARMA telah dikembangkan dan digunakan untuk menangani fenomena yang melibatkan keterkaitan ruang dan waktu secara simultan. Konsep dasar dari model ini berakar pada penelitian awal oleh Cliff dan Ord pada tahun 1975 melalui pengembangan model STAR (*Space-Time Autoregressive*) serta model lanjutannya, yaitu STARMA (*Space-Time Autoregressive Moving Average*) (Laily 2020). Model STARMA menggabungkan pengaruh lag waktu sebelumnya baik dalam komponen autoregresif maupun *moving average*, yang berlaku tidak hanya secara temporal tetapi juga secara spasial. Model ini digunakan

untuk memodelkan data yang menunjukkan adanya autokorelasi spasial, yaitu keterkaitan antara nilai-nilai di lokasi yang berbeda dalam suatu sistem spasio-temporal (Rathod et al. 2018).

Berbagai pendekatan telah digunakan dalam peramalan curah hujan, mulai dari model *time series* konvensional seperti ARIMA yang menangani pola linier, hingga metode pembelajaran mesin seperti ANN, SVR, dan LSTM untuk menangani pola non-linier. Model *hybrid machine learning* menjadi alternatif menjanjikan karena mampu meningkatkan akurasi prediksi melalui kombinasi teknik dekomposisi sinyal dan algoritma optimasi, meskipun keberhasilannya sangat bergantung pada arsitektur dan pemrosesan data yang tepat (Latif et al. 2022).

Penelitian di Andhra Pradesh menggabungkan ARIMA, LSTM, XGBoost, dan Prophet dalam model ensemble menggunakan weighted averaging, menghasilkan prediksi yang lebih akurat dibandingkan model individu, dengan kontribusi besar dari ARIMA dan LSTM (Kumar et al. 2023). Di Indonesia, penelitian menggunakan algoritma *clustering* berbasis DTW menunjukkan bahwa klasifikasi iklim tidak hanya berdasarkan rata-rata, tetapi juga mempertimbangkan pola spasio-temporal (Suryana et al. 2023). Penelitian lain membandingkan beberapa algoritma *machine learning* dan menemukan bahwa *Random Forest Regressor* paling akurat dalam memprediksi curah hujan berdasarkan atribut suhu, kelembapan, dan tekanan udara (Jagtap & Karande 2019).

Namun, model konvensional dan *machine learning* sering kurang efektif untuk data spasio-temporal karena kompleksitas polanya. Untuk itu, model STARMA dirancang khusus menangani data tersebut dan terbukti efektif dalam berbagai studi klimatologis. Contohnya, model hibrida STARMA-ANN-SVM digunakan untuk memprediksi curah hujan tahunan di Bengal Barat (Saha et al. 2020). Di Indonesia, model GSTAR juga telah diterapkan pada data curah hujan di Jawa Tengah dengan hasil yang menunjukkan pengaruh spasial yang signifikan. Sementara itu, pengembangan model STARMA II yang menggabungkan STARMA dan TDNN berhasil meningkatkan akurasi prediksi hasil panen padi dengan menggunakan matriks spasial berbasis KNN dan korelasi Pearson untuk menggambarkan *Spatio Temporal Similarity* antar wilayah (Badu-Apraku et al. 2021).

Dengan melihat studi-studi terdahulu terbukti bahwa penggunaan model STARMA dan variannya mampu memberikan hasil prediksi yang lebih akurat pada data yang memiliki ketergantungan ruang dan waktu, khususnya dalam dominan meteorologi dan iklim.

1.2 Perumusan Masalah

Berikut rumusan masalah yang pada penelitian ini yaitu:

1. Bagaimana pola curah hujan di wilayah Surabaya dalam dimensi spasial temporal?

2. Bagaimana efektifitas pembobotan spatio temporal dalam memprediksi model curah hujan?
3. Bagaimana hasil peramalan berdasarkan pembobotan spasio temporal dalam memprediksi curah hujan?

1.3 Tujuan Penelitian

Berikut adalah tujuan yang ingin dicapai pada penulisan proposal/TA.

1. Untuk menganalisis pola penyebaran curah hujan di Surabaya dari waktu ke waktu dan antar lokasi dalam wilayah tersebut.
2. Untuk mendapatkan model curah hujan yang efektif dalam menangkap keterkaitan spatial dan temporal dalam data curah hujan Surabaya.
3. Untuk membandingkan hasil Peramalan curah hujan dengan pembobotan spasio temporal dan tanpa pembobotan.

1.4 Batasan dan Asumsi Penelitian

Hipotesis dari tulisan ini adalah

1. Data penelitian ini diambil dari data NASA yang dianggap sudah melalui proses validasi dan tidak mengandung kesalahan pencatatan yang signifikan ada di wilayah Surabaya
2. Data curah hujan yang digunakan adalah data bulanan selama 2015 sampai 2024
3. Model Spasio temporal yang digunakan adalah STARMA yang dianggap mampu merepresentasikan spatial dan temporal dalam curah hujan tanpa penggabungan model hybrid atau *machine learning*
4. Data NASA berupa tangkapan satelit di wilayah Surabaya didasarkan pada koordinat geografis (longitude dan latitude).

1.5 Manfaat Penelitian

Kontribusi dari tulisan ini adalah

1. Memberikan kontribusi dalam pengembangan ilmu statistik dan klimatologi, khususnya dalam pemodelan *spasio-temporal* data cuaca menggunakan metode STARMA.
2. Menambah referensi penelitian yang mengintegrasikan pendekatan statistik spasial dan deret waktu dalam konteks prediksi cuaca di Surabaya.
3. Menyediakan informasi komparatif mengenai hasil peramalan dari berbagai skema pembobotan, seperti bobot seragam, inverse jarak, korelasi silang untuk meningkatkan akurasi model STARMA.

1.6 Sistematika Penulisan

Berikut adalah gambaran singkat mengenai uraian secara singkat lingkup isi dari setiap Bab yang ada di dalam Buku Tugas Akhir ini:

1. Pendahuluan

Bab ini menjelaskan latar belakang pentingnya peramalan curah hujan di Surabaya sebagai kota metropolitan yang rawan banjir dan dipengaruhi dinamika iklim tropis basah. Bab ini menyoroti kompleksitas curah hujan yang dipengaruhi oleh factor spasial dan temporal, sehingga model time series biasas seperti ARIMA kurang memadai. Dijelaskan juga perkembangan model spasio-temporal seperti STARMA yang dapat menangkap ketergantungan antar lokasi dan antar waktu. Berdasarkan fenomena dan studi terdahulu, dirumuskan tiga masalah utama pola spasio temporal curah hujan, efektif pembobotan SWM, serta hasil peramalan. Bab ini juga memuat tujuan penelitian, batasan data NASA (2015 hingga 2024), asumsi, manfaat penelitian, serta rencana dan jadwal kegiatan penelitian.

2. Kajian Pustaka

Bab ini berisi teori dan penelitian terdahulu yang relevan dengan pemodelan curah hujan spasio temporal. Disajikan berbagai studi menggunakan ARIMA, STARMA, model hibrida, fuzzy STARMA, dan pembobotan spasial adaptif. Bab ini menjelaskan konsep dasar peramalan, jenis metode, RMSE sebagai evaluasi, serta kestasioneran data dengan uji ADF. Selanjutnya dibahas teori ARIMA, identifikasi orde dengan ACF/PACF, estimasi parameter, dan diagnostik model. Bagian inti menjelaskan model STARMA: struktur matematisnya, STACF/STPACF untuk identifikasi orde spasial-temporal, estimasi parameter AR dan MA, uji signifikansi, serta peran penting Spatial Weight Matrix. Jenis pembobotan SWM (seragam, invers jarak, korelasi silang) dijelaskan lengkap sebagai dasar model utama.

3. Metodologi

Bab ini menyajikan langkah-langkah penelitian secara sistematis. Dimulai dengan alur metode penelitian, kemudian dijelaskan sumber data curah hujan satelit NASA POWER untuk lima wilayah Surabaya tahun 2015–2024. Tahapan pra-pemrosesan mencakup pembersihan data, transformasi Box-Cox, dan differencing. Analisis eksploratif mencakup visualisasi pola spasial dan temporal. Setelah itu dilakukan uji kestasioneran, pembentukan tiga jenis Spatial Weight Matrix, serta pembangunan model baseline SARIMA. Setelah SARIMA, dibangun model STARIMA dengan tiga jenis bobot: seragam, invers jarak, dan korelasi silang. Bab

ini ditutup dengan penjelasan teknik evaluasi menggunakan RMSE serta tujuan akhir peramalan.

4. Hasil dan Pembahasan

Bab ini menyajikan hasil implementasi seluruh langkah penelitian. Pertama dilakukan eksplorasi data curah hujan untuk lima wilayah Surabaya, termasuk statistik deskriptif, pola musiman, dan korelasi antar wilayah. Selanjutnya hasil SARIMA ditampilkan: uji stasioner, estimasi parameter, fitting model, dan grafik peramalan untuk tiap wilayah. Bagian terbesar membahas STARIMA. Setiap jenis bobot (seragam, invers jarak, korelasi silang) dianalisis dari:

- a. Hasil Stationeritas
- b. Hasil STACF dan STPACF
- c. Estimasi parameter
- d. Fitting model
- e. Grafik hasil peramalan tiap wilayah

Setiap bobot dibandingkan performanya. Bab ini menunjukkan bahwa pembobotan tertentu memberikan RMSE paling rendah dan model STARIMA lebih unggul dibanding SARIMA.

5. Kesimpulan dan Saran

Bab ini merangkum temuan utama penelitian:

- a. Pola curah hujan di Surabaya memiliki variasi spasio-temporal kuat.
- b. Pembobotan spasial memengaruhi performa STARIMA secara signifikan.
- c. Model STARIMA tertentu menghasilkan prediksi terbaik berdasarkan RMSE.

Saran diberikan untuk pengembangan selanjutnya, seperti penggunaan resolusi data lebih tinggi, model hybrid, atau pembobotan spasial adaptif untuk meningkatkan akurasi.

Bab II

Landasan Teori

Pada bab ini, dipaparkan mengenai penelitian-penelitian terdahulu yang berkaitan dengan topik penelitian. Selain itu, ditunjukkan beberapa teori-teori yang menjadi landasan penyelesaian masalah yang dikemukakan pada penelitian ini.

2.1 Penelitian Terkait

Pada sub bab ini, dipaparkan mengenai penelitian-penelitian yang berkaitan dengan topik penelitian.

1. Penelitian yang dilakukan oleh (Fuad et al. 2021) yaitu memodelkan dan memprediksi penyebaran kasus COVID-19 di tiga kota wilayah Mekkah yaitu Jeddah, Makkah dan Taif dengan memanfaatkan pendekatan statistik ARIMA dan STARIMA (Space Time ARIMA). Penelitian ini bertujuan untuk membandingkan performa kedua model tersebut serta menilai pengaruh hubungan spasial antar wilayah terhadap Akurasi Prediksi. Dalam studinya, penulis menggunakan data 31 Mei hingga 11 Oktober 2020. Analisis awal menunjukkan bahwa data belum stasioner sehingga dilakukan transformasi log dan diferensiasi pertama. Model ARIMA dibangun secara terpisah untuk setiap kota. Menggunakan pendekatan Box Jenkins, sedangkan model STARIMA dikembangkan secara simultan dengan mempertimbangkan hubungan spasial antar lokasi melalui spatial weight matrix, yang merepresentasikan keterhubungan antar kota.

Hasil penelitian menunjukkan bahwa model STARIMA mampu menangkap autokorelasi ruang waktu dengan lebih baik dibandingkan ARIMA univariat. Model terbaik yang diperoleh adalah STARIMA $(1_0, 1, 1_1)$ yang menunjukkan nilai MAE, MSE, dan RMSE lebih rendah dibandingkan model ARIMA diketioga kota. Temuan ini menegaskan bahwa mempertimbangkan hubungan spasial (misalnya kedekatan geografis atau mobilitas penduduk antar kota) dapat secara signifikan meningkatkan Akurasi Peramalan penyebaran COVID-19.

Penelitian ini menyimpulkan bahwa pendekatan spasial temporal seperti STARIMA lebih unggul dan direkomendasikan untuk data epidemiologi yang memiliki pola penyebaran antar wilayah. Studi ini juga membuka peluang untuk penggunaan model spasial temporal yang lebih kompleks seperti Bayesian spatial temporal models atau spatial panel models untuk analisis lanjutan.

2. Dalam penelitian yang berjudul “*Enhanced Spatio-Temporal Modeling for Rainfall Forecasting: A High-Resolution Grid Analysis*” Curah hujan sangat penting bagi pertanian, terutama di negara seperti India. Karena bersifat spasio-temporal, peramalan curah hujan menjadi kompleks dan tidak cocok jika hanya menggunakan model deret waktu atau machine learning konvensional. Diperlukan pendekatan yang mampu menangani pola *non-linear*, *non-stasioner*, dan *non-normal*. Model STARMA efektif dalam menangkap ketergantungan spasial dan temporal sekaligus, dibantu oleh Spatial Weight Matrix (SWM) untuk mengintegrasikan pengaruh lokasi sekitar. Studi ini menggunakan data curah hujan tahunan selama 50 tahun (1970–2019) dari 119 lokasi di West Bengal, India, yang dibagi menjadi data pelatihan dan pengujian. Hasilnya menunjukkan bahwa model STARMA mampu meningkatkan akurasi peramalan, yang bermanfaat untuk perencanaan dan pengelolaan pertanian di wilayah rentan terhadap perubahan iklim (Alam et al. 2024)
3. Dalam penelitian yang berjudul “*An improved Space-Time Autoregressive Moving Average (STARMA) model for Modelling and Forecasting of Spatio-Temporal time-series data*” menjelaskan bahwa Model *Box-Jenkins* univariat tidak mampu menangani ketergantungan spasial yang sering muncul dalam fenomena iklim. Untuk mengatasi hal ini, digunakan model STARMA (*Space-Time Autoregressive Moving Average*) yang memasukkan hubungan spasial dan temporal secara simultan melalui matriks bobot spasial. Dalam penelitian ini, digunakan matriks bobot spasial seragam orde dua dan bobot berdasarkan jarak terbalik yang dihitung menggunakan jarak lingkaran besar (*great circle distance*) dari koordinat lintang dan bujur. Metode ini diuji pada data simulasi dan data nyata berupa suhu maksimum bulanan di sembilan distrik Karnataka Utara. Hasilnya menunjukkan bahwa model STARMA yang diusulkan memberikan performa yang lebih baik dibandingkan ARIMA univariat dan STARMA orde spasial pertama dalam pemodelan dan peramalan deret waktu spasio-temporal (Rathod et al. 2018)
4. Penelitian ini berhasil mengembangkan dan menguji model prediksi hasil panen padi berbasis pendekatan two-stage yang dinamakan STARMA II (*Spatio-Temporal Autoregressive Moving Average with Time Delay Ne-*

ural Network). Model ini menggabungkan keunggulan model STARMA yang menangkap ketergantungan spasial dan temporal secara linear dengan kemampuan model *Time Delay Neural Network* (TDNN) dalam mempelajari hubungan non-linear dari data time series.

Dalam implementasinya, pengaruh spasial antar distrik dimodelkan menggunakan *Spatial Weight Matrix* (SWM) yang dibangun berdasarkan gabungan metode *K-Nearest Neighbors* (KNN) dan koefisien korelasi Pearson. Matriks ini berfungsi untuk merepresentasikan kemiripan spatio-temporal antar wilayah secara kuantitatif, yang kemudian digunakan dalam tahap pelatihan model untuk menangkap pola hubungan antar wilayah dalam konteks produksi padi.

Hasil evaluasi model menunjukkan bahwa STARMA II memberikan akurasi prediksi yang lebih tinggi dan konsisten dibandingkan dengan:

- Model ARIMA yang hanya mempertimbangkan aspek temporal (waktu), dan
- Model STARMA klasik yang hanya menangkap hubungan linier antar ruang dan waktu.

Kinerja model diukur melalui metrik evaluasi seperti *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan *Coefficient of Determination* (R^2), di mana STARMA II unggul secara signifikan dalam semua indikator.

Dengan demikian, pendekatan two-stage hybrid model seperti STARMA II terbukti lebih efektif dalam memodelkan dinamika kompleks produksi padi yang dipengaruhi oleh faktor spasial dan temporal, serta memiliki potensi besar untuk diterapkan dalam sistem peringatan dini, perencanaan pertanian, dan pengambilan kebijakan berbasis data (Badu-Apraku et al. 2021)

5. Penelitian yang dilakukan oleh Saha, Singh, Ray, Rathod, dan Dhyani (2022) bertujuan untuk meningkatkan akurasi peramalan suhu dengan mengembangkan model baru yang disebut *Fuzzy Rule-Based Weighted Space-Time Autoregressive Moving Average* (STARMA). Model ini merupakan pengembangan dari STARMA konvensional, dengan mengintegrasikan sistem inferensi fuzzy (FIS) untuk menghitung bobot spasial antar lokasi. Pendekatan ini dirancang untuk mengatasi keterbatasan dari matriks bobot spasial konvensional yang tidak mampu menangkap dinamika dan heterogenitas spasial secara optimal. Dalam penelitian ini, data suhu maksimum bulanan digunakan dari tujuh distrik di negara bagian West Bengal, India, untuk mengembangkan model, serta dari sembilan distrik di Karnataka untuk validasi. Hasil penelitian menunjukkan bahwa

model fuzzy STARMA memberikan hasil yang lebih akurat dibandingkan dengan model STARMA konvensional dan model ARIMA. Hal ini dibuktikan dengan nilai *Mean Absolute Percentage Error* (MAPE) yang lebih rendah, yaitu 1,78% untuk model fuzzy STARMA, dibandingkan dengan 2,09% untuk STARMA biasa, dan 4,39% untuk ARIMA. Dengan demikian, penelitian ini menyimpulkan bahwa penggunaan sistem inferensi fuzzy dalam peramalan spasial-temporal memberikan peningkatan performa yang signifikan. Model ini sangat berpotensi untuk digunakan dalam aplikasi yang berkaitan dengan perencanaan iklim dan sektor pertanian, khususnya di wilayah yang memiliki karakteristik spasial yang kompleks seperti India (Saha et al. 2022)

6. Penelitian yang dilakukan oleh Kumar, Sarkar, Dhakre, dan Bhattacharya (2023) bertujuan untuk meningkatkan akurasi peramalan suhu bulanan dengan mengembangkan pendekatan pemodelan hibrida yang menggabungkan model *Space-Time Autoregressive Moving Average* (STARMA) dan *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH). Studi ini difokuskan pada peramalan suhu maksimum bulanan dan rentang suhu di delapan lokasi di negara bagian Bihar, India. Model STARMA digunakan untuk menangkap pola spasial dan temporal dalam data, dengan matriks bobot spasial yang dikonstruksi berdasarkan jarak antar lokasi. Setelah penerapan STARMA, residual model dianalisis lebih lanjut menggunakan uji BDS dan ARCH-LM, yang menunjukkan adanya karakteristik nonlinier dan heteroskedastisitas. Untuk menangani fenomena ini, model GARCH diterapkan pada residual STARMA, membentuk pendekatan hibrida STARMA-GARCH. Hasil penelitian menunjukkan bahwa model STARMA-GARCH (khususnya konfigurasi STARMA(1,1,0,0)-GARCH(0,1)) memberikan performa yang lebih baik dibandingkan model STARMA murni, dengan nilai kesalahan prediksi (MAPE) yang lebih rendah di semua lokasi. Uji diagnostik tambahan seperti uji Ljung-Box Q juga menunjukkan bahwa residual dari model hibrida tidak memiliki autokorelasi, menandakan bahwa model tersebut telah dikalibrasi dengan baik. Kesimpulan dari penelitian ini adalah bahwa pendekatan pemodelan hibrida ini sangat efektif dalam menangkap dinamika kompleks suhu bulanan dan dapat menjadi alat yang andal untuk mendukung pengambilan keputusan di sektor-sektor yang sensitif terhadap iklim seperti pertanian dan pengelolaan sumber daya alam (Kumar et al. n.d.)

Berbagai penelitian sebelumnya telah banyak mengembangkan model peramalan spasio-temporal menggunakan pendekatan STARMA dan variannya dengan integrasi matriks bobot spasial. Meskipun model STARMA efektif dalam menangkap ketergantungan linier spasial dan temporal,

model ini masih memiliki keterbatasan dalam mengakomodasi pola non-linear dan heterogenitas spasial yang kompleks, terutama dalam konteks data curah hujan. Selain itu, konstruksi matriks bobot spasial yang digunakan sebagian besar masih bersifat statis dan umum, seperti berdasarkan jarak geografis atau metode *K-Nearest Neighbors*, sehingga kurang mampu menangkap dinamika hubungan spasial-temporal secara adaptif. Selanjutnya, belum banyak penelitian yang secara eksplisit memanfaatkan pembobotan deret waktu berbasis kemiripan spasio-temporal yang menggabungkan aspek spasial dan temporal secara simultan dan kuantitatif, khususnya untuk peramalan curah hujan dengan skala spasial dan temporal yang rinci. Selain itu, kompleksitas model yang tinggi pada beberapa pendekatan hibrida seperti *neural network* dan *fuzzy inference* juga menimbulkan tantangan terkait efisiensi komputasi pada data berukuran besar. Oleh karena itu, penelitian ini berupaya mengisi gap tersebut dengan mengembangkan model peramalan curah hujan yang menggunakan pembobotan seragam, pembobotan invers jarak, dan pembobotan korelasi silang yang adaptif. Pendekatan ini diharapkan dapat meningkatkan akurasi peramalan curah hujan sekaligus mendukung pengambilan keputusan di bidang pertanian dan mitigasi risiko bencana iklim.

2.2 Peramalan

Peramalan deret waktu (*time series forecasting*) merupakan komponen kunci yang digunakan dalam berbagai bidang untuk memprediksi kejadian di masa depan dan mengidentifikasi tren. Metode peramalan terbagi menjadi dua yaitu kualitatif (berbasis opini ahli) dan kuantitatif (berbasis analisis statistik dan matematis), dengan deret waktu sebagai salah satu pendekatan kuantitatif yang umum digunakan karena menganalisis data berurutan berdasarkan waktu (Petropoulos et al. 2021). Model-model peramalan telah berkembang secara bertahap seiring waktu. Pada awalnya, metode prediksi deret waktu mengandalkan prosedur statistik murni seperti analisis regresi dan metode ARIMA (Putra et al. 2019). Metode statistik ini bekerja dengan baik untuk data dengan hubungan linier. Untuk data non linier, model kecerdasan buatan terutama jaringan saraf telah digunakan (Marino et al. 2016). Baru baru ini, metode hibrida yang menggabungkan metode statistik dengan pendekatan deep learning telah dikembangkan untuk menghasilkan prediksi yang lebih akurat (Jagtap & Karande 2019). Bahkan model konvensional seperti ARIMA sering kali gagal memberikan prediksi curah hujan yang akurat ketika diterapkan pada wilayah dengan variasi geografis yang kompleks sehingga memerlukan model alternatif. Maka dari itu, dalam konteks penelitian ini menggunakan model yang efektif ketika berhadapan dengan data spatio temporal. Untuk mengetahui model itu efektif atau tidaknya dalam penelitian ini menggunakan

evaluasi RMSE. Berikut adalah rumus umum untuk menghitung RMSE.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (2.1)$$

Persamaan (2.1) menunjukkan rumus *Root Mean Square Error* (RMSE). Keterangan:

- y_t : nilai aktual pada waktu ke- t
- $\hat{y}_t$: nilai prediksi pada waktu ke- t
- n : jumlah total data atau observasi yang diprediksi

Nilai-nilai seperti RMSE merupakan ukuran tingkat kesalahan prediksi. Semakin rendah nilai-nilai ini, maka semakin akurat model dalam memprediksi data.

2.3 Menguji Kestasioneran Data

Kestasioneran dalam data deret waktu merupakan salah satu asumsi utama dalam analisis deret waktu. Suatu deret dianggap stasioner apabila nilai rata-rata dan variansinya tidak berubah seiring waktu (Ilmi et al. 2023). Artinya, data tersebut cenderung stabil dan berfluktuasi di sekitar nilai tengah yang tetap.

a. Stasioner terhadap varians

Data dikatakan stasioner terhadap ragam apabila variansnya relatif konstan dari waktu ke waktu dan tidak menunjukkan pola fluktuasi yang signifikan. Identifikasi kestasioneran terhadap ragam dapat dilakukan menggunakan nilai lambda (λ). Apabila nilai parameter transformasi (λ) bernilai sama atau mendekati satu, maka data dapat dianggap telah stasioner terhadap ragam. Sebaliknya, apabila nilai λ berbeda jauh dari satu, maka data belum stasioner terhadap ragam. Proses penstasioneran terhadap ragam dapat dilakukan dengan menerapkan transformasi Box-Cox yang dirumuskan sebagai berikut:

$$T(Z_t) = Z_t^{(\lambda)} = \frac{Z_t^\lambda - 1}{\lambda} \quad (2.2)$$

Keterangan:

- $T(Z_t)$ adalah data yang mengalami transformasi,
- λ adalah parameter transformasi.

Cara penduga parameter parameter λ dilakukan dengan menentukan nilai lambda pada rentang tertentu, nilai λ yang biasa digunakan yaitu mendekati 1. Setiap tingkatan nilai λ yang telah ditetapkan dilakukan perhitungan nilai maksimum loglikelihood ($l_{\max}$) seperti persamaan dibawah ini:

$$l_{\max}(\lambda) = -\frac{n}{2} \ln \hat{\sigma}_a^2(\lambda) + (\lambda - 1) \sum_{t=1}^n \ln Z_t \quad (2.3)$$

di mana $\hat{\sigma}_a^2$ merupakan nilai dugaan kuadrat tengah galat. Penduga parameter λ dikatakan sebagai penduga yang baik apabila nilai maksimum log-likelihood menghasilkan nilai maksimum diantara nilai λ yang lain. Nilai λ dan bentuk transformasi Boxcox yang sesuai disajikan dalam tabel berikut:

Tabel 2.1: Nilai λ dan Bentuk Transformasi Box-Cox

Nilai λ	-1.0	-0.5	0.0	0.5	1.0
Transformasi	$\frac{1}{Z_t}$	$\frac{1}{\sqrt{Z_t}}$	$\ln Z_t$	$\sqrt{Z_t}$	Z_t

b. Stasioner terhadap rata-rata

Untuk menilai apakah data stasioner dalam hal rata-rata, dapat dilakukan secara visual dengan membuat plot antara nilai observasi dan waktu. Jika grafik menunjukkan pola fluktuasi yang konsisten di sekitar garis lurus dengan penyebaran yang relatif seragam, maka data dapat dianggap stasioner. Selain pendekatan visual, pengujian kestasioneran rata-rata juga dapat dilakukan menggunakan metode statistik seperti uji *Augmented Dickey-Fuller* (ADF).

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t \quad (2.4)$$

Keterangan:

- Δy_t : Diferensiasi orde pertama, yaitu $y_t - y_{t-1}$, digunakan untuk mengubah data menjadi stasioner.
- α : Konstanta (intersep) dalam model regresi.
- βt : Tren waktu (opsional), mencerminkan arah pergerakan jangka panjang dalam data.
- γy_{t-1} : Komponen autoregresif (lag 1), digunakan untuk menguji keberadaan akar unit (unit root).

- $\sum_{i=1}^p \delta_i \Delta y_{t-i}$: Lag dari perubahan y hingga lag ke- p , untuk mengatasi autokorelasi serial dalam residual.
- ε_t : Error term (white noise), mewakili gangguan acak yang tidak berkorelasi satu sama lain.

2.4 ARIMA Model

Autoregressive Integrated Moving Average (ARIMA) merupakan salah satu model deret waktu konvensional yang banyak digunakan, terutama sejak diperkenalkan oleh Box dan Jenkins (1970). Model ini membentuk pola deret waktu berdasarkan nilai masa lalu (lag) dan error acak (white noise) (Rathod et al. 2017). ARIMA terdiri dari tiga komponen utama, yaitu: Autoregressive (AR), Integrated (I), dan Moving Average (MA). Komponen AR merepresentasikan pengaruh nilai sebelumnya, I berfungsi menjadikan data stasioner melalui proses differencing, sedangkan MA mencerminkan pengaruh kesalahan masa lalu. Secara umum, model ini dinotasikan sebagai ARIMA (p, d, q), di mana p adalah orde AR, d adalah tingkat differencing, dan q adalah orde MA.

Berikut ini adalah gambaran singkat mengenai model model dalam metode tersebut.

1. Model Autoregressive (AR)

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + u_t \quad (2.5)$$

Model ini disebut model *autoregressive* karena variabel X_t bergantung secara linear pada nilai nya sendiri pada periode sebelumnya ($X_{t-1}, X_{t-2}, \dots, X_{t-p}$). Dengan kata lain, observasi saat ini X_t dapat dinyatakan sebagai fungsi linear dari observasi sebelumnya beserta komponen error acak yang dilambangkan dengan U_t

2. Model Moving Average (MA)

$$X_t = u_t - \theta_1 u_{t-1} - \theta_2 u_{t-2} - \cdots - \theta_q u_{t-q} \quad (2.6)$$

Model ini disebut model *moving average* karena variabel X_t bergantung secara linear pada error acak periode sekarang dan periode sebelumnya ($U_t, U_{t-1}, U_{t-2}, \dots, U_{t-q}$)

3. Model Autoregressive Moving Average (ARMA)

$$X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} - \theta_1 u_{t-1} - \cdots - \theta_q u_{t-q} + u_t \quad (2.7)$$

Model ARMA menggabungkan kedua komponen yaitu ketergantungan terhadap nilai-nilai masa lalu ($X_{t-1}, X_{t-2}, \dots, X_{t-p}$) dan ketergantungan terhadap error sebelumnya ($U_t, U_{t-1}, \dots, U_{t-q}$).

4. Model Autoregressive Integrated Moving Average (ARIMA)

$$\Phi(B)(1 - B)^d W_t = \theta(B)U_t \quad (2.8)$$

dimana W_t adalah diferensiasi pertama dari X_t , i.e., $W_t = X_t - X_{t-1}$. Sebagian deret waktu bersifat tidak stasioner terhadap mean, sehingga diperlukan proses differensiasi untuk membuatnya stasioner. Setelah proses differencing, deret yang telah stasioner dapat dimodelkan menggunakan ARMA, tetapi diperlukan operator differencing sebagai bagian dari model. Ketika tingkat interasi pada sebuah proses menunjukkan berapa kali differencing dilakukan untuk mencapai kestasioneran, model tersebut dinamakan Autoregressive Integrated Moving Average (ARIMA) dengan bentuk umum ARIMA (p,d,q), dimana:

- p = orde autoregressive (AR)
- d = tingkat differencing
- q = orde moving average (MA)

Langkah langkah dalam membangun model ARIMA yaitu:

1. Estimasi Parameter Model:

Latih model ARIMA dengan orde (p, d, q) yang telah ditentukan menggunakan data pelatihan. Parameter-parameter model diestimasi menggunakan metode Maximum Likelihood Estimation (MLE).

2. Menghitung Residual:

Untuk memvalidasi model, residual dari persamaan yang diestimasi harus white noise. Berikut adalah rumus ACF Residual

$$ACF(k) = \frac{\sum_{t=1}^{T-k} (e_t - \bar{e})(e_{t+k} - \bar{e})}{\sum_{t=1}^{T-k} (e_t - \bar{e})^2} \quad (2.9)$$

Keterangan:

- ACF(k) = Korelasi antara residu pada lag ke-k
- k = Lag yang diinginkan
- e_t = Residu pada waktu ke-t
- $\bar{e}$ = Rata-rata dari semua residu
- T = Jumlah observasi dalam deret waktu

3. Diagnostik Model Analisis Residual Periksa residu model (kesalahan prediksi) untuk memastikan mereka mendekati white noise (tidak ada autokorelasi, rata-rata nol, varians konstan). Gunakan uji Ljung-Box dan plot ACF/PACF residu. Rumus Ljung-Box :

$$Q = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k} \quad (2.10)$$

Keterangan:

- Q: Statistik Uji Ljung-box
- n : Jumlah observasi (ukuran sampel) dalam deret waktu.
- h : Jumlah lag yang diuji (batas atas jumlah autokorelasi yang dihitung). Nilai h dapat ditentukan sesuai kebutuhan; secara umum digunakan nilai $h = 1, 2, 3$
- ρ_k : Estimasi koefisien autokorelasi dari residu pada lag ke-k

2.5 Model STARMA (*Space-Time Autoregressive Moving Average*)

1. Estimasi Parameter

Setelah orde (p, q, λ, μ) dan matriks bobot spasial ditentukan, parameter model STARMA diestimasi. Estimasi parameter STARMA menggunakan Maximum Likelihood Estimation Langkah-langkah estimasi Maximum Likelihood Estimation:

- a) Membangun model ST-AR (Spatiotemporal Autoregressive)
 - i) Rumus umum

$$\mathbf{Z}_t = \sum_{k=1}^p \sum_{l=0}^{\lambda_k} \phi_{kl} W^l \mathbf{Z}_{t-k} + \mathbf{e}_t \quad (2.11)$$

Keterangan:

- $\mathbf{Z}_t$: Vektor data variabel dependen di semua lokasi pada waktu t .
- p : Orde lag temporal (berapa periode waktu ke belakang data mempengaruhi).
- λ_k : Orde lag spasial untuk lag temporal k (seberapa jauh pengaruh tetangga).
- ϕ_{kl} : Koefisien (parameter) yang menunjukkan pengaruh variabel pada lag temporal k dan lag spasial l .

- W^l : Matriks bobot spasial orde l (W^0 adalah diri sendiri, W^1 tetangga terdekat, dst.).
- $\mathbf{Z}_{t-k}$: Vektor data variabel dependen di semua lokasi pada waktu $t - k$.
- $\mathbf{e}_t$: Vektor istilah gangguan (error term) pada waktu t .

Kemudian dilakukan penurunan terhadap semua parameter, selanjutnya dibentuk matriks dengan memilih

$$\hat{\phi} = \begin{bmatrix} \phi_{10} \\ \phi_{11} \\ \phi_{12} \\ \vdots \\ \phi_{p\lambda} \end{bmatrix} \quad \text{dan} \quad \mathbf{X} = [\mathbf{Z}_{t-1} \quad W\mathbf{Z}_{t-1} \quad W^2\mathbf{Z}_{t-1} \quad \cdots \quad W^\lambda\mathbf{Z}_{t-p}] \quad (2.12)$$

ii) Estimasi Parameter

$$\hat{\phi} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Z} \quad (2.13)$$

Keterangan:

- $\hat{\phi}$: Nilai-nilai koefisien (parameter) yang diestimasi oleh model.
- $\mathbf{X}$: Matriks yang berisi semua data variabel penjelas (independen).
- $\mathbf{X}'$: Transpose dari matriks $\mathbf{X}$.
- $(\mathbf{X}'\mathbf{X})^{-1}$: Kebalikan (invers) dari hasil perkalian matriks $\mathbf{X}'$ dengan $\mathbf{X}$.
- $\mathbf{Z}$: Vektor data variabel yang dijelaskan (dependen).

iii) Uji Signifikansi

Dalam uji signifikansi menggunakan uji t

$$t = \frac{(\hat{\phi}_2 + \hat{\phi}_3) - (\phi_2 + \phi_3)}{\text{se}(\hat{\phi}_2 + \hat{\phi}_3)} = \frac{(\hat{\phi}_2 + \hat{\phi}_3) - 1}{\sqrt{\text{var}(\hat{\phi}_2) + \text{var}(\hat{\phi}_3) + 2 \text{cov}(\hat{\phi}_2, \hat{\phi}_3)}} \quad (2.14)$$

Keterangan:

- t : Nilai statistik uji- t yang dihitung.
- $(\hat{\phi}_2 + \hat{\phi}_3)$: Penjumlahan dari estimasi koefisien untuk variabel kedua ($\hat{\phi}_2$) dan ketiga ($\hat{\phi}_3$) dari model regresi.
- $(\phi_2 + \phi_3)$: Nilai hipotesis dari penjumlahan koefisien yang sebenarnya. Dalam baris kedua rumus, nilai 1 menunjukkan bahwa hipotesis yang diuji adalah apakah $\phi_2 + \phi_3 = 1$.

- $se(\hat{\phi}_2 + \hat{\phi}_3)$: Standard error dari penjumlahan estimasi koefisien, yang mengukur presisi dari estimasi tersebut.
- $var(\hat{\phi}_2)$: Variansi dari estimasi koefisien $\hat{\phi}_2$.
- $var(\hat{\phi}_3)$: Variansi dari estimasi koefisien $\hat{\phi}_3$.
- $cov(\hat{\phi}_2, \hat{\phi}_3)$: Kovariansi antara estimasi koefisien $\hat{\phi}_2$ dan $\hat{\phi}_3$.

Hipotesa Parameter

$$H_0 : \phi_j = 0 \quad (\text{parameter tidak signifikan}) \quad (2.15)$$

$$H_1 : \phi_j \neq 0 \quad (\text{parameter signifikan}) \quad (2.16)$$

Pengambilan keputusan

- Jika p-value < 0.05 maka tolak H_0
- Jika p-value > 0.05 maka gagal tolak H_0

Melihat hasil uji dari output regresi yang ada python dimana disitu tercantum nilai p-value. Untuk melihat apakah residual model ST-AR masih menunjukkan pola autokorelatif maka dilakukan uji multivariat box pierce. Jika ternyata masih ada maka itu dianggap model belum selesai dan bisa dilanjutkan ke ST-MA

b) Membangun ST-MA (Spatiotemporal Moving Average)

i) Rumus umum

$$\mathbf{Z}_t = \mathbf{e}_t - \sum_{k=1}^q \sum_{l=0}^{\lambda_k} \theta_{kl} W^l \mathbf{e}_{t-k} \quad (2.17)$$

Keterangan:

- $\mathbf{Z}_t$: Vektor data variabel dependen di semua lokasi pada waktu t .
- $\mathbf{e}_t$: Vektor istilah gangguan (error term) pada waktu t . Ini adalah "kejutan" atau error pada waktu saat ini.
- $\sum_{k=1}^q$: Penjumlahan untuk orde temporal moving average, di mana q adalah orde MA temporal maksimum.
- $\sum_{l=0}^{\lambda_k}$: Penjumlahan untuk orde spasial moving average, di mana λ_k adalah orde spasial maksimum untuk lag temporal k .
- θ_{kl} : Koefisien (parameter) moving average spatio-temporal yang akan diestimasi.
- W^l : Matriks bobot spasial orde ke- l (W^0 adalah diri sendiri, W^1 tetangga terdekat, dan seterusnya).

- $\mathbf{e}_{t-k}$: Vektor istilah gangguan (error term) dari waktu $t-k$, yaitu "kejutan" masa lalu dari lokasi itu sendiri dan tetangganya.

Kemudian dilakukan penurunan terhadap semua parameter, selanjutnya dibentuk matriks dengan memilih

$$\hat{\boldsymbol{\theta}} = \begin{bmatrix} \theta_{10} \\ \theta_{11} \\ \theta_{12} \\ \vdots \\ \theta_{p\lambda} \end{bmatrix} \quad \text{dan} \quad \hat{\mathbf{e}} = [\mathbf{e}_{t-1} \quad W\mathbf{e}_{t-1} \quad W^2\mathbf{e}_{t-1} \quad \cdots \quad W^\lambda\mathbf{e}_{t-p}] \quad (2.18)$$

ii) Estimasi parameter

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{e} \quad (2.19)$$

Keterangan:

- $\hat{\boldsymbol{\theta}}$: Vektor koefisien yang diestimasi (hasil akhir yang ingin kita cari).
- $\mathbf{X}$: Matriks berisi data variabel penjelas (independen).
- $\mathbf{X}'$: Transpose dari matriks $\mathbf{X}$.
- $(\mathbf{X}'\mathbf{X})^{-1}$: Invers dari hasil perkalian $\mathbf{X}'$ dengan $\mathbf{X}$.
- $\mathbf{e}$: Vektor berisi data variabel yang dijelaskan (dependen).

iii) Uji signifikansi

Dalam uji signifikansi menggunakan uji t

$$t = \frac{(\hat{\theta}_2 + \hat{\theta}_3) - (\theta_2 + \theta_3)}{\text{se}(\hat{\theta}_2 + \hat{\theta}_3)} = \frac{(\hat{\theta}_2 + \hat{\theta}_3) - 1}{\sqrt{\text{var}(\hat{\theta}_2) + \text{var}(\hat{\theta}_3) + 2 \text{cov}(\hat{\theta}_2, \hat{\theta}_3)}} \quad (2.20)$$

Keterangan:

- t : Nilai statistik uji- t yang dihitung.
- $(\hat{\theta}_2 + \hat{\theta}_3)$: Penjumlahan dari estimasi koefisien untuk variabel kedua ($\hat{\theta}_2$) dan ketiga ($\hat{\theta}_3$) dari model regresi.
- $(\theta_2 + \theta_3)$: Nilai hipotesis dari penjumlahan koefisien yang sebenarnya. Dalam baris kedua rumus, nilai 1 menunjukkan bahwa hipotesis yang diuji adalah apakah $\theta_2 + \theta_3 = 1$.
- $\text{se}(\hat{\theta}_2 + \hat{\theta}_3)$: Standard error dari penjumlahan estimasi koefisien, yang mengukur presisi dari estimasi tersebut.
- $\text{var}(\hat{\theta}_2)$: Variansi dari estimasi koefisien $\hat{\theta}_2$.
- $\text{var}(\hat{\theta}_3)$: Variansi dari estimasi koefisien $\hat{\theta}_3$.

- $\text{cov}(\hat{\theta}_2, \hat{\theta}_3)$: Kovariansi antara estimasi koefisien $\hat{\theta}_2$ dan $\hat{\theta}_3$.
Dalam uji signifikansi menggunakan hipotesis

$$H_0 : \theta_j = 0 \quad (\text{parameter tidak signifikan}) \quad (2.21)$$

$$H_1 : \theta_j \neq 0 \quad (\text{parameter signifikan}) \quad (2.22)$$

Pengambilan keputusan

- Jika p-value < 0.05 maka tolak H_0
- Jika p-value > 0.05 maka gagal tolak H_0

Melihat hasil uji dari output regresi yang ada python dimana disitu tercantum nilai p-value.

c) Model STARMA

Model STARMA secara umum dituliskan dalam bentuk matrix sebagai berikut:

$$Z(t) = \sum_{k=1}^p \sum_{l=0}^{L_k} \phi_{kl} W_l Z(t-k) + \sum_{k=1}^q \sum_{l=0}^{L_k} \theta_{kl} W_l \varepsilon(t-k) + \varepsilon(t) \quad (2.23)$$

Keterangan:

- $Z(t)$: vektor observasi pada waktu ke- t untuk semua lokasi
- p, q : orde *autoregressive* dan *moving average* dalam waktu
- L_k : orde spasial untuk lag waktu ke- k (misalnya tetangga orde ke-1, ke-2, dst.)
- ϕ_{kl}, θ_{kl} : parameter AR dan MA pada lag waktu ke- k dan lag spasial ke- l
- W_l : matriks bobot spasial orde ke- l
- $\varepsilon(t)$: vektor galat acak pada waktu ke- t , diasumsikan mengikuti distribusi normal identik dan independen (white noise)

2. Evaluasi Akurasi

Jika anda membagi data, evaluasi kinerja Peramalan model pada data pengujian menggunakan metrik akurasi seperti RMSE

Untuk menangkap hubungan antar lokasi, digunakan spatial weight matrix berukuran $N \times N$ yang menggambarkan sejauh mana keterkaitan antar lokasi.

2.6 Spatial Weight Matrix (SWM)

2.6.1 Konsep Dasar Spatial Weight Matrix

Matriks Bobot Spasial (SWM) merupakan matriks persegi berukuran $N \times N$, di mana N menyatakan jumlah total lokasi atau grid yang diamati. Setiap

elemen w_{ij} dalam matriks ini merepresentasikan besarnya pengaruh lokasi j terhadap lokasi i , dengan ketentuan sebagai berikut:

- $w_{ii} = 0$, yang berarti suatu lokasi tidak memberikan pengaruh terhadap dirinya sendiri.
- Jika terdapat keterkaitan spasial antara lokasi j dan i , maka $w_{ij} > 0$; jika tidak ada hubungan, maka $w_{ij} = 0$.

2.6.2 Bentuk Umum Matriks SWM

Secara umum, matriks bobot spasial dapat dituliskan dalam bentuk:

$$\mathbf{W} = \begin{bmatrix} 0 & w_{12} & w_{13} & \cdots & w_{1N} \\ w_{21} & 0 & w_{23} & \cdots & w_{2N} \\ w_{31} & w_{32} & 0 & \cdots & w_{3N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_{N1} & w_{N2} & w_{N3} & \cdots & 0 \end{bmatrix} \quad (2.24)$$

Dengan:

- w_{ij} menyatakan kekuatan hubungan dari lokasi j ke lokasi i
- Setiap baris menyatakan distribusi pengaruh dari semua lokasi terhadap satu lokasi tertentu.

2.6.3 Jenis-jenis Pembobotan

Berikut adalah beberapa metode populer dalam membentuk nilai w_{ij} dalam SWM:

- a) Bobot Lokasi Seragam (*Uniform Weight*) Mengasumsikan bahwa semua lokasi tetangga memiliki pengaruh yang sama besar terhadap lokasi target:

$$w_{ij} = \begin{cases} \frac{1}{n}, & i \neq j \\ 0, & i = j \end{cases} \quad (2.25)$$

dengan $n = N - 1$ sebagai jumlah lokasi tetangga. Bobot ini sederhana dan tidak memperhitungkan jarak geografis, namun tetap dapat menghasilkan model yang baik dalam kondisi tertentu.

- b) Bobot Inverse Jarak (*Inverse Distance Weight*) Menggunakan jarak antar lokasi sebagai dasar pembobotan. Lokasi yang lebih dekat memiliki bobot lebih besar:

$$d_{ij} = d_{ji} = ([x_i(u_i) - x_j(u_j)]^2 + [x_i(v_i) - x_j(v_j)]^2)^{1/2} \quad (2.26)$$

$$w_{ij} = w_{ji} = \frac{1}{d_{ij}} = \frac{1}{d_{ji}} \quad (2.27)$$

dan normalisasi bobot lokasi invers jarak dapat dihitung menggunakan rumus berikut:

$$w_{ij} = \begin{cases} \frac{w_{ij}}{\sum_{j=1}^m w_{ij}}, & i \neq j \\ 0, & i = j \end{cases} \quad (2.28)$$

Keterangan: x_i = lambang lokasi ke- i dengan $i = 1, 2, \dots, N$ u = koordinat lintang lokasi v = koordinat bujur lokasi d_{ij} = jarak antar lokasi ke- i terhadap lokasi lainnya (lokasi ke- j).

- c) Bobot Korelasi Silang (*Cross-Correlation Weight*) Didasarkan pada kemiripan pola waktu antar lokasi, dihitung dari korelasi silang pada lag tertentu:

$$\rho_{ij}(k) = \frac{\gamma_{ij}(k)}{\sigma_i \sigma_j} \quad (2.29)$$

Keterangan:

- $\rho_{ij}(k)$: korelasi silang antara lokasi ke- i dan ke- j pada lag waktu ke- k
- $\gamma_{ij}(k)$: kovarians silang antara lokasi ke- i dan ke- j pada lag waktu ke- k
- σ_i, σ_j : simpangan baku dari lokasi ke- i dan ke- j

di mana $\gamma_{ij}(k)$ merupakan kovarians silang antara pengamatan pada lokasi ke- i dan ke- j pada lag waktu k . σ_i dan σ_j merupakan simpangan baku dari pengamatan lokasi ke- i dan ke- j

$$r_{ij}(k) = \frac{\sum_{t=k+1}^n [z_i(t) - \bar{z}_i][z_j(t-k) - \bar{z}_j]}{(\sum_{t=1}^n [z_i(t) - \bar{z}_i]^2) (\sum_{t=1}^n [z_j(t) - \bar{z}_j]^2)} \quad (2.30)$$

Keterangan:

- $r_{ij}(k)$: penduga korelasi silang antara lokasi ke- i dan ke- j pada lag waktu ke- k
- $z_i(t)$: nilai pengamatan pada lokasi ke- i di waktu t
- $\bar{z}_i$: rata-rata nilai pengamatan pada lokasi ke- i
- n : banyaknya data

Untuk penentuan pembobot korelasi silang antar lokasi diperoleh sebagai berikut:

$$w_{ij} = \frac{r_{ij}(k)}{\sum_{j \neq i} |r_{ij}(k)|} \quad (2.31)$$

Keterangan:

- w_{ij} : bobot korelasi silang dari lokasi ke- j terhadap lokasi ke- i
- $r_{ij}(k)$: penduga korelasi silang seperti dijelaskan di atas

dan memenuhi $\sum_{i \neq j} |w_{ij}| = 1$. Pembobot korelasi silang ini tidak memerlukan aturan tertentu, seperti ketergantungan jarak dari lokasi.

2.6.4 Peran SWM dalam Model STARMA

Dalam model STARMA, SWM digunakan untuk mengintegrasikan pengaruh spasial antar lokasi ke dalam proses prediksi curah hujan. Setiap variasi bobot akan dimasukkan ke dalam model, lalu hasil peramalannya dibandingkan untuk menentukan pembobotan mana yang paling efektif dalam merepresentasikan hubungan spasio-temporal.


Bab III

Metodologi Penelitian

Pada bab ini, dijelaskan tentang tahapan-tahapan penelitian yang dilakukan untuk menyelesaikan masalah yang telah dikemukakan pada rumusan masalah. Ditunjukkan pula jadwal penelitian untuk masing-masing tahapan penelitian tersebut.

3.1 Metode Penelitian

Metode penelitian dapat dilihat pada Gambar 3.1.




Gambar 3.1: Diagram Alur Metodologi Penelitian

3.2 Sumber Data

Penelitian ini dilakukan menggunakan data sekunder secara daring tanpa melakukan pengambilan data di lapangan. Seluruh proses analisis dan pengolahan data dilakukan secara komputasi di lingkungan pengolahan data statistik.

Data utama yang digunakan dalam penelitian ini adalah data curah hujan bulanan berbasis satelit yang diperoleh dari NASA (*National Aeronautics and Space Administration*) melalui platform *POWER Data Access Viewer*. Data ini mencakup informasi spasial (koordinat grid wilayah) dan temporal (periode waktu pengamatan) yang diperlukan dalam pemodelan spasio temporal menggunakan STARMA.

Selain itu, informasi koordinat geografis yang merepresentasikan lokasi grid atau titik observasi juga digunakan untuk membangun *spatial weight matrix* yang merepresentasikan kedekatan spasial antar wilayah. Data pendukung ini diambil langsung dari metadata bawaan dataset NASA yang digunakan. Berikut merupakan gambar sumber data yang digunakan dalam penelitian ini:



Gambar 3.2: Data NASA Wilayah Surabaya

3.2.1 Data Sekunder

Tabel 3.1: Data Curah Hujan Bulanan Berdasarkan Wilayah

Wilayah	Latitude	Longitude	Date	Precipitation
Utara	-7.2	112.73	1/31/2015	13.89
Utara	-7.2	112.73	2/28/2015	11.93
Utara	-7.2	112.73	3/31/2015	9.38
⋮	⋮	⋮	⋮	⋮
Utara	-7.2	112.73	10/31/2024	1.12

Wilayah	Latitude	Longitude	Date	Precipitation
Utara	-7.2	112.73	11/30/2024	6.53
Utara	-7.2	112.73	12/31/2024	13.60
Barat	-7.24	112.61	1/31/2015	13.92
Barat	-7.24	112.61	2/28/2015	11.87
Barat	-7.24	112.61	3/31/2015	9.44
⋮	⋮	⋮	⋮	⋮
Barat	-7.24	112.61	10/31/2024	1.46
Barat	-7.24	112.61	11/30/2024	6.29
Barat	-7.24	112.61	12/31/2024	13.62
Timur	-7.31	112.84	1/31/2015	12.24
Timur	-7.31	112.84	2/28/2015	10.29
Timur	-7.31	112.84	3/31/2015	8.84
⋮	⋮	⋮	⋮	⋮
Timur	-7.31	112.84	10/31/2024	1.22
Timur	-7.31	112.84	11/30/2024	5.63
Timur	-7.31	112.84	12/31/2024	12.31
Selatan	-7.35	112.73	1/31/2015	14.30
Selatan	-7.35	112.73	2/28/2015	12.15
Selatan	-7.35	112.73	3/31/2015	11.21
⋮	⋮	⋮	⋮	⋮
Selatan	-7.35	112.73	10/31/2024	1.24
Selatan	-7.35	112.73	11/30/2024	6.63
Selatan	-7.35	112.73	12/31/2024	13.51
Tengah	-7.26	112.74	1/31/2015	14.25
Tengah	-7.26	112.74	2/28/2015	12.17
Tengah	-7.26	112.74	3/31/2015	11.19
⋮	⋮	⋮	⋮	⋮
Tengah	-7.26	112.74	10/31/2024	0.83
Tengah	-7.26	112.74	11/30/2024	6.66
Tengah	-7.26	112.74	12/31/2024	13.59

3.3 Pra-pemrosesan Data

Sebelum dilakukan pemodelan, data yang digunakan harus melalui tahapan pra-pemrosesan agar bersih, konsisten, dan siap untuk dianalisis secara spasio-temporal. Proses ini dimulai dengan pembersihan data dari nilai-nilai ekstrem atau tidak logis akibat gangguan akuisisi satelit. Jika terdapat nilai hilang, maka akan dilakukan *handling missing value*, atau penghapusan jika jumlahnya signifikan. Selanjutnya, dilakukan perhitungan statistika deskriptif.

3.4 Analisis Eksploratif Pola Spasio-Temporal Curah Hujan

Sebelum membentuk matriks pembobotan, dilakukan analisis eksploratif terhadap pola curah hujan di wilayah Surabaya. Analisis ini mencakup visualisasi boxplot setiap wilayah guna mengidentifikasi distribusi curah hujan bulanan secara spasial, visualisasi seasonal decompose untuk melihat tren, musiman dan residual dan melakukan pengecekan korelasi antar wilayah. Tujuan dari analisis ini adalah untuk memahami dinamika dan variabilitas intensitas hujan serta mengidentifikasi grid yang memiliki pola hujan serupa.

3.5 Pengecekan Kestasioneran Data

Data yang ada di cek stasioneritasnya menggunakan uji *Augmented Dickey-Fuller* (ADF). Jika data tersebut tidak stasioner maka akan dilakukan differencing, namun apabila data nya sudah stasioner maka akan dilakukan perhitungan selanjutnya.

3.6 Pembentukan *Spatial Weight Matrix*

Berdasarkan matriks *similarity* yang telah diperoleh, kemudian disusun *Spatial Weight Matrix* (SWM) seperti pada matriks 2.24 sebagai komponen penting dalam model STARMA. SWM menunjukkan kekuatan pengaruh antar grid, dan tidak hanya mempertimbangkan kedekatan geografis, tetapi juga kemiripan spasio-temporal. Dalam penelitian ini, dibangun tiga variasi bobot sebagai pembanding, yaitu bobot seragam yang memberikan bobot sama untuk seluruh tetangga yang dapat dilihat pada persamaan 2.25, bobot invers jarak yang menggunakan jarak antar lokasi sebagai dasar pembobotan yang dapat dilihat pada persamaan 2.27, bobot berdasarkan korelasi silang antar grid yang dapat dilihat pada persamaan 2.29. Masing-masing variasi digunakan untuk mengukur efektivitas pembobotan spasial dalam meningkatkan performa prediksi model.

3.7 Pembangunan Model SARIMA

Setelah data stasioner, dilakukan identifikasi nilai parameter p dan q dengan mengamati pola ACF (untuk q) 2.6 dan PACF (untuk p) 2.5, atau dapat pula menggunakan metode otomatis seperti *auto_arima*. Model kemudian dibangun dan parameternya diestimasi menggunakan **Maximum Likelihood Estimation (MLE)**. Setelah model dibentuk, dilakukan **analisis residu** untuk memastikan bahwa kesalahan model bersifat acak (*white noise*). Hal ini dapat diperiksa melalui plot ACF/PACF dari residu serta uji *Ljung-Box* 2.10. Diagnostik ini penting untuk memastikan bahwa model tidak melewatkan pola yang masih ada dalam data. Bila tersedia data uji, model dievaluasi menggunakan metrik prediksi seperti **RMSE**.

3.8 Pembangunan Model STARMA

Model STARMA digunakan untuk menganalisis data yang memiliki ketergantungan spasial dan temporal secara simulta. Identifikasi orde model melibatkan empat parameter utama: p dan q (lag temporal AR dan MA) serta λ dan μ (lag spasial AR dan MA). Orde ini ditentukan menggunakan fungsi STACF 2.17 dan STPACF 2.11, yang merupakan perluasan dari ACF dan PACF dalam konteks spasial-temporal. Setelah orde ditentukan, parameter model diestimasi menggunakan **Maximum Likelihood Estimation (MLE)**. Diagnostik dilakukan melalui analisis residu untuk memastikan tidak ada autokorelasi spasial-temporal yang tersisa, serta evaluasi akurasi dilakukan dengan metrik seperti RMSE

3.9 Evaluasi

Model-model yang dibangun kemudian divalidasi dengan menggunakan data testing untuk mengukur performanya. Validasi dilakukan dengan membandingkan hasil prediksi dengan data aktual menggunakan metrik evaluasi *Root Mean Square Error* (RMSE) pada persamaan 2.1. Selain itu, dilakukan perbandingan performa antara model STARMA dengan dan tanpa pembobotan spasio-temporal untuk mengetahui sejauh mana pembobotan tersebut meningkatkan akurasi model.

3.10 Harapan Hasil Peramalan

Hasil akhir dari proses pemodelan STARMA divisualisasikan dalam bentuk grafik yang membandingkan nilai prediksi dengan data aktual curah hujan. Visualisasi dilakukan pada lima titik observasi yang mewakili bagian-bagian wilayah Surabaya, yaitu Surabaya Barat, Timur, Utara, Selatan, dan Pusat. Hasil prediksi ini menjadi dasar untuk mengevaluasi sejauh mana model mampu merepresentasikan dinamika spasio-temporal curah hujan di Surabaya secara akurat.

Bab IV

Hasil dan Pembahasan

4.1 Eksplorasi Data

4.1.1 Statistika Deskriptif

Sebelum melakukan proses pemodelan dengan metode SARIMA dan STARIMA, langkah pertama yang dilakukan adalah melakukan eksplorasi data yaitu dengan statistika deskriptif. Tujuannya untuk memahami karakteristik dasar data seperti tren, musiman, serta variabilitas yang terjadi. Melalui analisa deskriptif, diperoleh gambaran umum mengenai perilaku data yang akan dimodelkan.

Tabel 4.1: Statistika Deskriptif

Statistik	Barat	Selatan	Tengah	Timur	Utara
Count	3653.000000	3653.000000	3653.000000	3653.000000	3653.000000
Mean	5.843041	5.920063	5.919724	5.206096	5.842067
Min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.090000	0.000000	0.020000	0.000000	0.120000
50%	1.650000	0.780000	1.370000	0.600000	2.010000
75%	7.520000	6.560000	7.630000	6.400000	8.030000
Max	308.380000	366.490000	318.680000	195.030000	249.460000
Std	11.013619	13.287137	11.868456	10.058238	10.116447

Tabel 4.1 menyajikan hasil analisis statistika deskriptif curah hujan pada lima wilayah Kota Surabaya, yaitu Barat, Selatan, Tengah, Timur, dan Utara. Berdasarkan tabel tersebut, jumlah data pengamatan pada masing-masing wilayah adalah 120 observasi, yang menunjukkan bahwa seluruh wilayah memiliki panjang deret waktu yang sama sepanjang periode penelitian.

Secara umum, nilai rata-rata (mean) curah hujan di kelima wilayah berkisar antara 5,20 hingga 5,92 mm, yang menunjukkan bahwa intensitas curah hujan harian di Kota Surabaya relatif seragam antar wilayah. Wilayah Tengah (5,92 mm) memiliki rata-rata curah hujan tertinggi, diikuti oleh Selatan (5,92 mm) dan Barat (5,84 mm), sedangkan wilayah Timur (5,21 mm) mencatat rata-rata

terendah.

Nilai minimum pada seluruh wilayah adalah 0 mm, yang menandakan adanya hari-hari tanpa hujan selama periode pengamatan. Sementara itu, nilai maksimum menunjukkan variasi yang cukup tinggi, di mana curah hujan ekstrem tertinggi tercatat di wilayah Selatan (366,49 mm), diikuti oleh Tengah (318,68 mm) dan Barat (308,38 mm). Hal ini menunjukkan bahwa wilayah bagian selatan Surabaya cenderung mengalami intensitas hujan ekstrem lebih besar dibandingkan wilayah lainnya.


Berdasarkan nilai median (50%), sebagian besar wilayah memiliki nilai tengah curah hujan antara 0,6 hingga 2,0 mm, yang berarti sebagian besar hari dalam periode pengamatan memiliki curah hujan rendah hingga sedang. Nilai kuartil atas (75%) menunjukkan bahwa 75% data memiliki curah hujan di bawah 7–8 mm, sedangkan sisanya mewakili kejadian hujan intensitas tinggi.

Nilai simpangan baku (standar deviasi) berkisar antara 10,05 hingga 13,28, yang mengindikasikan adanya variasi curah hujan yang cukup besar antar waktu. Wilayah Selatan memiliki standar deviasi tertinggi (13,29), yang menandakan fluktuasi curah hujan paling tinggi, sedangkan wilayah Timur menunjukkan variasi paling rendah (10,06).

Secara keseluruhan, analisis deskriptif ini menunjukkan bahwa curah hujan di lima wilayah Kota Surabaya memiliki pola sebaran yang relatif serupa, namun dengan tingkat variabilitas dan intensitas ekstrem yang berbeda antar wilayah. Temuan ini mendukung perlunya analisis spasio-temporal lanjutan menggunakan model STARIMA untuk menangkap hubungan dinamis antar wilayah dan antar waktu.

4.1.2 Pola Curah Hujan Kelima Wilayah di Surabaya


Data yang digunakan adalah data curah hujan hasil dari pengamatan satelit NASA POWER pada lima titik wilayah di Kota Surabaya yaitu Utara, Selatan, Timur, Tengah dan Barat selama periode 1 Januari 2015 hingga 31 Desember 2024. Data curah hujan nya memiliki satuan mm/hari dan kemudian dilakukan agregasi menjadi rata-rata bulanan agar dapat menggambarkan tren musiman jangka panjang.



Gambar 4.1: Pola Curah Hujan Wilayah Barat


Curah hujan bulanan di Wilayah Barat selama periode 2015 - 2024 mem-

perlihatkan pola musiman yang sangat jelas, dengan peningkatan intensitas hujan yang konsisten terjadi pada bulan Desember hingga Maret serta kondisi curah hujan rendah hingga mendekati nol pada bulan Juni hingga September. Puncak hujan tahunan umumnya berada pada kisaran 12–18 mm/hari, disertai beberapa kejadian ekstrem yang mencapai lebih dari 20 mm/hari pada tahun-tahun seperti 2017, 2020, 2022, dan 2024. Dengan struktur musiman yang kuat dan variabilitas yang cukup signifikan, deret waktu pada wilayah ini sangat mendukung penerapan model STARIMA dalam mempelajari hubungan spasial-temporal serta memprediksi curah hujan dengan lebih akurat.



Gambar 4.2: Pola Curah Hujan Wilayah Selatan


Curah hujan bulanan di Wilayah Selatan selama periode 2015 - 2024 menunjukkan pola musiman yang sangat konsisten, ditandai dengan peningkatan intensitas hujan pada bulan Desember hingga Maret dan kondisi hampir tanpa hujan pada periode Juni hingga September. Puncak hujan tahunan umumnya berada pada kisaran 12–18 mm/hari, dengan beberapa kejadian ekstrem yang melebihi 20 mm/hari terutama pada awal 2016, 2021, dan 2024. Variabilitas intra-tahunan yang cukup tinggi serta fluktuasi intensitas yang tajam menggambarkan dinamika atmosfer yang aktif di wilayah ini, sekaligus menegaskan adanya komponen musiman yang kuat dan berulang. Pola temporal yang terstruktur ini mendukung penerapan model deret waktu spasial-temporal seperti STARIMA untuk memodelkan dan memprediksi curah hujan secara lebih akurat.



Gambar 4.3: Pola Curah Hujan Wilayah Tengah


Curah hujan bulanan di Wilayah Tengah selama periode 2015 - 2024 menunjukkan pola musiman yang sangat jelas, dengan intensitas hujan meningkat secara konsisten pada Desember hingga Maret dan menurun drastis pada Juni

hingga September. Variabilitas intra-tahunan tampak cukup tinggi, ditandai dengan fluktuasi tajam antara kondisi tanpa hujan hingga puncak 10–15 mm/hari, serta beberapa kejadian ekstrem seperti pada awal 2024 yang mencapai lebih dari 25 mm/hari. Pola yang stabil dan berulang ini mencerminkan dinamika monsun yang kuat serta pengaruh faktor atmosfer regional yang membentuk variasi hujan tahunan. Struktur temporal yang konsisten tersebut mendukung penerapan model STARIMA dalam memodelkan dan memprediksi curah hujan berbasis hubungan spasial-temporal antar wilayah di Surabaya.



Gambar 4.4: Pola Curah Hujan Wilayah Timur

Curah hujan bulanan di Wilayah Timur selama periode 2015 - 2024 memperlihatkan pola musiman yang konsisten, dengan intensitas hujan meningkat pada bulan Desember hingga Maret dan menurun drastis mendekati nol pada periode Juni hingga September. Puncak hujan tahunan berada pada kisaran 10–15 mm/hari, dengan beberapa kejadian ekstrem yang melampaui nilai tersebut, seperti pada awal tahun 2021, 2022, dan 2024. Fluktuasi intra-tahunan yang tajam dan variasi antar tahun menunjukkan dinamika atmosfer yang aktif di wilayah ini, dipengaruhi oleh siklus monsun dan fenomena cuaca regional. Pola temporal yang berulang dan stabil ini menunjukkan bahwa wilayah Timur memiliki struktur deret waktu yang kuat untuk dimodelkan melalui pendekatan STARIMA dalam analisis spasial-temporal curah hujan.




Gambar 4.5: Pola Curah Hujan Wilayah Utara

Curah hujan bulanan di Wilayah Utara selama periode 2015 - 2024 menunjukkan pola musiman yang sangat konsisten, dengan peningkatan intensitas pada bulan Desember hingga Maret dan curah hujan yang hampir nol pada periode Juni hingga September. Puncak hujan tahunan berada pada kisaran 10–15 mm/hari, disertai beberapa kejadian ekstrem yang melebihi 20

mm/hari, terutama pada awal tahun 2020, 2022, dan 2024. Fluktuasi yang tajam antar musim menggambarkan dinamika atmosfer regional yang aktif dan dipengaruhi oleh siklus monsun serta fenomena cuaca skala besar seperti MJO dan ENSO. Pola temporal yang stabil dan berulang ini menunjukkan bahwa Wilayah Utara memiliki struktur deret waktu yang kuat dan cocok dimodelkan menggunakan pendekatan STARIMA untuk analisis dan peramalan spasial-temporal curah hujan.

4.1.3 Karakteristik dengan BoxPlot

Sebelum masuk ke analisis lebih lanjut, diperlukan pemahaman mengenai pola dasar distribusi curah hujan di setiap wilayah. Oleh karena itu, boxplot digunakan untuk menampilkan gambaran awal mengenai sebaran dan karakteristik data curah hujan bulanan.




Gambar 4.6: Boxplot Kelima Wilayah di Surabaya

Gambar 4.6 menampilkan boxplot distribusi curah hujan bulanan untuk lima wilayah di Kota Surabaya, yaitu Timur, Barat, Selatan, Utara, dan Tengah. Secara umum, kelima wilayah menunjukkan pola distribusi yang relatif serupa dengan median curah hujan berada di rata-rata 5 mm/hari, menandakan bahwa sebagian besar nilai curah hujan bulanan terkonsentrasi pada tingkat menengah. Rentang interkuartil (IQR) di seluruh wilayah menunjukkan variasi yang moderat, menggambarkan tingkat sebaran data yang cukup stabil antarwilayah. Meskipun demikian, terlihat adanya beberapa outlier pada Wilayah Barat, Selatan, dan Tengah dengan nilai di atas 25 mm/hari yang

menandakan adanya kejadian hujan ekstrem pada periode tertentu. Sementara itu, nilai minimum di setiap wilayah mendekati nol, menunjukkan periode kering yang umum terjadi selama musim kemarau. Tidak terdapat perbedaan yang signifikan antarwilayah dalam hal median maupun rentang variasi, yang mengindikasikan bahwa pola distribusi curah hujan bulanan di Surabaya relatif homogen secara spasial, meskipun dengan sedikit perbedaan amplitudo akibat pengaruh lokal seperti topografi dan kedekatan terhadap kawasan pesisir.

4.1.4 Analisis Temporal Curah Hujan

Analisis temporal dilakukan untuk mengidentifikasi pola perubahan curah hujan dari waktu ke waktu. Berdasarkan grafik deret waktu bulanan yang dibuat untuk masing – masing wilayah terlihat bahwa pola curah hujan Surabaya cenderung musiman dan berulang setiap tahun.



Gambar 4.7: Seasonal Decompose Semua Wilayah

Berdasarkan hasil dekomposisi pada gambar 4.7 tersebut dapat dijelaskan bahwa:

a. Komponen Tren:

Pola tren menunjukkan adanya fluktuasi jangka panjang yang cenderung meningkat secara perlahan hingga pertengahan periode pengamatan, kemudian relatif stabil. Hal ini mengindikasikan bahwa selama 2015-2024, curah hujan di seluruh wilayah Surabaya mengalami kecenderungan peningkatan moderat yang mungkin dipengaruhi oleh faktor klimatologis regional.

b. Komponen Musiman:

Pola musiman menunjukkan fluktuasi yang berulang secara konsisten setiap tahun, dengan puncak curah hujan umumnya terjadi pada Desember

– Februari dan minimum pada Juli – September. Pola ini menggambarkan dengan jelas siklus tahunan curah hujan di semua wilayah Surabaya yang mengikuti pola iklim monsun tropis.

c. **Komponen Residual:**

Komponen residual menunjukkan penyebaran acak disekitar nol yang menandakan bahwa sebagian besar variasi curah hujan telah berhasil dijelaskan oleh komponen tren dan musiman. Tidak terlihat adanya pola sistematis yang menonjol pada residu, sehingga model dekomposisi dianggap cukup baik dalam memisahkan variasi utama pada data

4.1.5 Analisis Korelasi Spatio Temporal

Analisis korelasi spasio-temporal dilakukan untuk mengidentifikasi tingkat keterhubungan pola curah hujan antar wilayah Surabaya. Nilai korelasi yang ditampilkan pada tabel berikut memberikan gambaran mengenai seberapa kuat kesamaan pola hujan secara ruang dan waktu.

Tabel 4.2: Tabel Korelasi Setiap Wilayah

Wilayah	Barat	Selatan	Tengah	Timur	Utara
Barat	1.000000	0.994376	0.993769	0.983211	0.999738
Selatan	0.994376	1.000000	0.999631	0.975665	0.994562
Tengah	0.993769	0.999631	1.000000	0.975762	0.994531
Timur	0.983211	0.975665	0.975762	1.000000	0.983363
Utara	0.999738	0.994562	0.994531	0.983363	1.000000

Tabel 4.2 merupakan tabel yang menunjukkan bahwa kelima wilayah di Surabaya ini memiliki nilai korelasi yang besar antara 0.975 hingga 0.999. Korelasi ini menunjukkan hubungan positif yang sangat kuat artinya peningkatan curah hujan di satu wilayah cenderung diikuti oleh peningkatan di wilayah lain pada waktu yang sama. Hal ini menandakan bahwa curah hujan di Surabaya bersifat homogen secara spasial karena semua wilayah mengalami kondisi meteorologis yang hampir sama.

4.2 ARIMA

4.2.1 Stasioner Data

Setelah dilakukan analisis dekomposisi untuk mengidentifikasi pola tren dan musiman, langkah selanjutnya adalah menguji tingkat kestasioneran data pada masing - masing wilayah. Uji stasioneritas dilakukan untuk memastikan bahwa deret waktu curah hujan telah memenuhi asumsi dasar analisis time series, yaitu nilai rata - rata dan varians yang relatif konstan terhadap waktu. Data yang tidak stasioner dapat menyebabkan estimasi parameter model

menjadi bias dan tidak stabil, sehingga perlu dilakukan transformasi atau differencing sebelum proses pemodelan. Oleh karena itu, pada tahap ini dilakukan pengujian kestasioneran data curah hujan di kelima wilayah Kota Surabaya guna menentukan apakah proses differencing diperlukan untuk menjadikan data stasioner secara statistik.

- a. Kestasioneran terhadap varians Kesationeran data curah hujan terhadap varians dapat dilihat dari transformasi lambda (λ) yang dihasilkan dari plot BoxCox. Jika nilai (λ) mendekati satu maka dapat disimpulkan bahwa data telah stasioner dan sebaliknya. Untuk membuat plot BoxCox data yang digunakan harus bernilai positif.

Tabel 4.3: Nilai Lambda Semua Wilayah

Wilayah	Nilai Lambda
Barat	0.3779
Selatan	0.3476
Tengah	0.3461
Timur	0.3596
Utara	0.3783

Berdasarkan tabel 4.3 nilai λ untuk seluruh wilayah berada pada rentang 0.34 - 0.38, yang menunjukkan bahwa data belum stasioner terhadap varians. Karena itu, diperlukan transformasi Box-Cox agar varians data lebih stabil dan sesuai dengan asumsi pemodelan time series. Transformasi ini membantu meningkatkan kinerja model dengan mengurangi bias akibat varians yang tidak stabil. Setelah transformasi diterapkan, stasioneritas mean diperiksa kembali melalui uji ADF dan analisis ACF/PACF. Jika pola tren atau musiman masih terlihat, maka perlu dilakukan differencing agar data benar - benar stasioner sebelum proses pemodelan.

- b. Kestasioneran terhadap rata - rata

Setelah data stasioner terhadap varians, selanjutnya dilakukan pengujian kestasioneran terhadap rata - rata. Pengujian ini dapat dilakukan dengan Menggunakan *Augmented Dickey-Fuller Unit Root Test*, berikut adalah hipotesisnya:

H_0 : $\phi \geq 0$ (data tidak stasioner terhadap rata-rata)

H_1 : $\phi < 0$ (data stasioner terhadap rata-rata)

Hasil pengujian *Augmented Dickey-Fuller Unit Root* untuk masing-masing lokasi terangkum pada tabel di bawah ini.


Tabel 4.4: Hasil Uji ADF

Wilayah	t-statistik	Nilai-p
Barat	-3.287547	0.015444
Selatan	-3.280075	0.015793
Tengah	-3.254672	0.017030
Timur	-3.347334	0.012891
Utara	-3.270636	0.016243

Tabel 4.4 itu menunjukkan bahwa data curah hujan kelima wilayah Surabaya sudah stasioner sepenuhnya. Berdasarkan hasil tersebut, dapat dilihat bahwa semua wilayah memiliki nilai $p\text{-value} < 0.05$ yang artinya sudah memenuhi syarat untuk melakukan pemodelan SARIMA.


c. Plot ACF dan PACF

Setelah dilakukan transformasi Box-Cox untuk menstabilkan varians dan proses differencing orde pertama untuk menghilangkan tren serta menjadikan data stasioner dalam mean, tahap selanjutnya adalah melakukan analisis fungsi autokorelasi (ACF) dan fungsi autokorelasi parsial (PACF). Analisis ini bertujuan untuk mengidentifikasi struktur keterkaitan temporal antar-observasi dalam deret waktu dan menentukan orde awal model SARIMA, yaitu nilai p (autoregressive) dan q (moving average). Plot ACF digunakan untuk mengamati pola korelasi antar lag waktu guna memperkirakan komponen MA, sedangkan plot PACF digunakan untuk mendeteksi lag signifikan yang mewakili komponen AR. Melalui analisis visual terhadap kedua plot tersebut, dapat diperoleh indikasi awal mengenai bentuk model SARIMA yang paling sesuai dengan karakteristik data curah hujan setelah proses transformasi dan differencing dilakukan. Berikut merupakan hasil plot ACF dan PACF:



Gambar 4.8: Plot ACF dan PACF Wilayah Barat (Sebelum)

Berdasarkan Gambar 4.8 pada plot ACF sebelum transformasi pola autokorelasi menunjukkan penurunan yang lambat dan masih signifikan hingga lag yang tinggi. Hal ini mengindikasikan bahwa data belum stasioner secara temporal karena masih terdapat pengaruh tren dan musiman yang kuat. Nilai autokorelasi positif yang menurun secara perlahan pada ACF memperlihatkan adanya long-term persistence, sedangkan pola PACF yang juga menunjukkan beberapa lag signifikan mengonfirmasi keberadaan komponen autoregresif (AR) dan musiman yang belum tereliminasi sehingga perlu dilakukan differencing dan juga transformasi BoxCox.



Gambar 4.9: Plot ACF dan PACF Wilayah Barat (Sesudah)

Berdasarkan Gambar 4.9 setelah dilakukan transformasi BoxCox dan differencing musiman, pola ACF dan PACF mengalami perubahan signifikan. ACF menunjukkan penurunan cepat di sekitar lag ke-1 hingga lag ke-2 dan kemudian berfluktuasi di sekitar nol, sedangkan PACF menampilkan cut-off yang jelas setelah lag pertama. Kondisi ini menandakan bahwa proses transformasi dan differencing berhasil menghilangkan tren dan menjadikan data stasioner dalam mean dan varians. Untuk plot ACF dan PACF lainnya dapat dilihat di Lampiran 4

d. Transformasi vs Tanpa Transformasi

Untuk memastikan bahwa proses transformasi BoxCox memberikan dampak yang signifikan terhadap stabilitas data dan akurasi prediksi, dilakukan evaluasi komprehensif terhadap kinerja model SARIMA pada lima wilayah. Evaluasi dilakukan dengan membandingkan nilai Root Mean Squared Error (RMSE) antara model yang dibangun tanpa transformasi BoxCox dan model yang menerapkan transformasi tersebut. Perbandingan kuantitatif atas seluruh konfigurasi model disajikan pada tabel dibawah ini

Tabel 4.5: Perbandingan RMSE Tanpa Transformasi dan Dengan Transformasi Box-Cox

Wilayah	Model	Tanpa Transformasi	Transformasi
Barat	$(1,0,0) \times (0,1,0)_{12}$	3.662	5.082
Selatan	$(1,0,0) \times (0,1,0)_{12}$	4.788	4.680
Tengah	$(1,0,0) \times (0,1,0)_{12}$	4.769	4.434
Timur	$(1,0,0) \times (0,1,0)_{12}$	1.835	4.643
Utara	$(1,0,0) \times (0,1,0)_{12}$	3.703	5.016

Berdasarkan Tabel 4.5 hasil perbandingan model SARIMA dengan dan tanpa transformasi pada lima wilayah pengamatan, dapat disimpulkan bahwa penerapan transformasi tidak selalu memberikan peningkatan akurasi pemodelan. Pada wilayah Barat, Timur, dan Utara, model tanpa transformasi justru menghasilkan nilai error yang lebih rendah, menunjukkan bahwa varians data pada wilayah tersebut sudah relatif stabil sehingga transformasi tidak diperlukan. Pada wilayah Selatan, perbedaan performa antara kedua pendekatan sangat kecil sehingga pengaruh transformasi dapat dikatakan minimal. Sementara itu, wilayah Tengah menjadi satu-satunya wilayah di mana transformasi memberikan peningkatan akurasi yang lebih jelas, mengindikasikan adanya variabilitas data yang lebih tinggi sehingga stabilisasi varians melalui transformasi menjadi bermanfaat. Secara keseluruhan, hasil ini menunjukkan bahwa efektif-

vitasi transformasi sangat bergantung pada karakteristik statistik masing-masing wilayah, sehingga penerapannya tidak dapat digeneralisasi dan perlu disesuaikan dengan kondisi data.

4.2.2 Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi menggunakan metode Maximum Likelihood, disajikan dalam table dibawah ini, bersama dengan standar error, nilai t , dan nilai p masing - masing:

Tabel 4.6: Estimasi Parameter SARIMA

Wilayah	Model	Statistik	AR Parameter			MA Parameter		
			Non Seasonal	Seasonal		Non Seasonal	Seasonal	
			AR 1	AR 2	AR	MA 1	MA 2	MA
Barat	$(1,0,0) \times (0,1,0)_{12}$	Estimasi	0.4326					
		SE	0.089					
		t-value	4.880					
		p-value	0.000					
Selatan	$(1,0,0) \times (0,1,0)_{12}$	Estimasi	0.3739					
		SE	0.092					
		t-value	4.053					
		p-value	0.000					
Tengah	$(1,0,0) \times (0,1,0)_{12}$	Estimasi	0.3889					
		SE	0.091					
		t-value	4.276					
		p-value	0.000					
Timur	$(1,0,0) \times (0,1,0)_{12}$	Estimasi	0.3822					
		SE	0.090					
		t-value	4.255					
		p-value	0.000					
Utara	$(1,0,0) \times (0,1,0)_{12}$	Estimasi	0.4391					
		SE	0.088					
		t-value	5.017					
		p-value	0.000					

Berdasarkan Tabel 4.6 dapat dilihat bahwa model SARIMA terbaik yang digunakan pada seluruh wilayah adalah SARIMA $(1,0,0) \times (0,1,0)_{12}$, di mana parameter yang signifikan secara statistik hanyalah komponen AR non-musiman. Hal ini ditunjukkan oleh nilai p-value ≤ 0.05 pada seluruh wilayah, sehingga parameter AR(1) terbukti memberikan kontribusi nyata dalam menjelaskan pola curah hujan bulanan. Nilai koefisien yang positif pada setiap wilayah juga menegaskan adanya hubungan autoregresif yang kuat antara curah hujan bulan ini dan bulan sebelumnya. Selain itu, nilai standard error yang relatif kecil serta t-value yang tinggi pada seluruh wilayah menunjukkan bahwa estimasi parameter bersifat stabil dan dapat dipercaya. Hasil diagnostik juga menunjukkan bahwa residual model telah memenuhi karakteristik white noise, sehingga tidak terdapat autokorelasi yang tersisa dan pola dalam data telah berhasil ditangkap oleh model. Dengan demikian, model SARIMA yang diperoleh dapat dinyatakan layak dan valid untuk digunakan dalam proses peramalan curah hujan pada masing-masing wilayah.

4.2.3 Model Fitting

Berdasarkan hasil analisis ACF dan PACF pada kelima wilayah terlihat bahwa pola autokorelasi menurun secara bertahap setelah lag ke-1 dan PACF menunjukkan cut-off pada lag pertama, baik untuk komponen non musiman maupun musiman. Pola tersebut mengindikasikan keberadaan komponen agresif (AR) dan moving average (MA) pada lag pertama, serta adanya pengaruh musiman dengan periode tahunan (seasonal periode = 12). Oleh karena itu, model yang sesuai untuk menggambarkan karakteristik data curah hujan di seluruh wilayah Kota Surabaya adalah sebagai berikut:


Tabel 4.7: Hasil Model Fitting SARIMA

Wilayah	Model	RMSE
Barat	$(1, 0, 0) \times (0, 1, 0)_{12}$	5.082
Selatan	$(1, 0, 0) \times (0, 1, 0)_{12}$	4.680
Tengah	$(1, 0, 0) \times (0, 1, 0)_{12}$	4.434
Timur	$(1, 0, 0) \times (0, 1, 0)_{12}$	4.643
Utara	$(1, 0, 0) \times (0, 1, 0)_{12}$	5.016

Berdasarkan Tabel 4.7 hasil evaluasi model SARIMA $(1, 0, 0) \times (0, 1, 0)_{12}$ pada kelima wilayah, diperoleh nilai RMSE yang bervariasi, mencerminkan tingkat akurasi model dalam memprediksi curah hujan di setiap wilayah. Wilayah Tengah menunjukkan performa terbaik dengan nilai RMSE sebesar 4.434, yang mengindikasikan bahwa pola musiman pada wilayah ini relatif stabil dan dapat ditangkap dengan baik oleh model. Wilayah Selatan berada pada posisi berikutnya dengan RMSE 4.680, yang berarti model memiliki kemampuan prediksi yang cukup baik meskipun terdapat sedikit ketidakstabilan pola data. Wilayah Timur dan Barat memiliki nilai RMSE masing-masing 4.643 dan 5.082 hasil ini menunjukkan bahwa meskipun model dapat menangkap pola musiman, masih terdapat variasi data yang tidak sepenuhnya terakomodasi oleh struktur model yang digunakan. Sementara itu, Wilayah Utara memiliki nilai RMSE tertinggi sebesar 5.016, menandakan bahwa pola curah hujan di wilayah tersebut lebih fluktuatif sehingga model kurang optimal dalam melakukan prediksi. Secara keseluruhan, variasi nilai RMSE ini mengindikasikan bahwa tingkat keakuratan model sangat dipengaruhi oleh karakteristik pola hujan masing-masing wilayah, dan wilayah dengan pola musiman yang lebih teratur cenderung menghasilkan performa model yang lebih baik.


4.2.4 Hasil Forecasting SARIMA

Berikut merupakan hasil forecasting SARIMA menggunakan model yang ada pada Tabel 4.7:




Gambar 4.10: Hasil Forecasting Wilayah Barat

Berdasarkan Gambar 4.10 hasil peramalan curah hujan wilayah Barat menggunakan model SARIMA $(1, 0, 0) \times (0, 1, 0)_{12}$ menunjukkan bahwa model hanya mampu mengikuti pola musiman secara umum, namun belum akurat dalam memprediksi nilai curah hujan, yang ditunjukkan oleh RMSE sebesar 5.082. Model cenderung menghasilkan prediksi yang lebih rendah daripada nilai aktual, terutama pada periode puncak hujan seperti Februari, Maret, dan Desember 2024. Meskipun pola penurunan pada musim kemarau dapat ditangkap, prediksi tetap berada di bawah nilai aktual sehingga mengindikasikan adanya underestimation. Secara keseluruhan, model SARIMA masih kurang mampu menangkap variabilitas curah hujan ekstrem di wilayah Barat, sehingga diperlukan pendekatan pemodelan lain yang lebih mampu merepresentasikan fluktuasi intensitas curah hujan.



Gambar 4.11: Hasil Forecasting Wilayah Selatan


Berdasarkan Gambar 4.11 hasil peramalan curah hujan wilayah Selatan menunjukkan bahwa model SARIMA mampu mengikuti pola musiman secara umum, namun akurasi masih rendah, terlihat dari nilai RMSE sebesar 4.680. Model cenderung menghasilkan prediksi yang lebih rendah daripada nilai aktual, terutama pada bulan-bulan dengan curah hujan tinggi seperti Maret, Mei, dan Desember 2024, sehingga terjadi underestimation. Pada periode curah hujan rendah, model sedikit lebih stabil, tetapi tetap belum mampu menangkap variasi secara tepat. Secara keseluruhan, model dapat menggambarkan pola dasar musiman, namun belum optimal dalam memodelkan fluktuasi ekstrem, sehingga diperlukan pendekatan model lain yang lebih adaptif untuk meningkatkan kinerja peramalan.



Gambar 4.12: Hasil Forecasting Wilayah Tengah


Berdasarkan Gambar 4.12 model SARIMA pada wilayah Tengah mengha-

silkan nilai RMSE 4.434 , yang menunjukkan akurasi prediksi sangat rendah. Model cenderung menghasilkan prediksi yang jauh lebih rendah dari data aktual, terutama pada bulan-bulan dengan curah hujan tinggi seperti Februari, Maret, dan Mei 2024, sehingga menunjukkan underestimation yang kuat. Pada periode curah hujan rendah, performa model sedikit lebih baik, namun tetap tidak mampu menangkap variasi kecil karena prediksinya cenderung mendekati nilai konstan. Secara keseluruhan, model hanya mampu mengikuti pola musiman dasar tetapi tidak cukup sensitif terhadap fluktuasi curah hujan yang ekstrem dan non-linear. Hal ini menunjukkan bahwa model SARIMA kurang optimal untuk wilayah ini dan perlu ditingkatkan melalui pendekatan lain yang lebih adaptif yaitu STARIMA.



Gambar 4.13: Hasil Forecasting Wilayah Timur

Berdasarkan Gambar 4.13 model SARIMA pada wilayah Timur menghasilkan RMSE 4.643 , menunjukkan akurasi yang rendah. Meskipun model mampu mengikuti pola musiman secara umum, prediksi sering berada jauh di bawah nilai aktual, terutama pada bulan-bulan dengan curah hujan tinggi seperti Februari, Maret, dan Mei 2024. Hal ini menunjukkan adanya underestimation dan ketidakmampuan model menangkap fluktuasi curah hujan yang ekstrem. Pada periode curah hujan rendah, model tampil sedikit lebih baik, namun tetap belum konsisten dalam mengikuti variasi aktual. Secara keseluruhan, model hanya cukup untuk menggambarkan pola dasar, tetapi tidak efektif dalam memodelkan perubahan intensitas curah hujan yang tajam, sehingga perlu pendekatan lain yang lebih adaptif untuk meningkatkan akurasi peramalan.



Gambar 4.14: Hasil Forecasting Wilayah Utara

Berdasarkan Gambar 4.14 model SARIMA pada wilayah Utara menghasilkan nilai RMSE 5.016, yang menunjukkan akurasi prediksi sangat rendah. Model cenderung menghasilkan prediksi yang jauh lebih rendah dari data aktual, terutama pada bulan-bulan dengan curah hujan tinggi seperti Februari, Maret, dan Mei 2024, sehingga menunjukkan underestimation yang kuat. Pada periode curah hujan rendah, performa model sedikit lebih baik, namun tetap tidak mampu menangkap variasi kecil karena prediksinya cenderung mendekati nilai konstan. Secara keseluruhan, model hanya mampu mengikuti pola musiman dasar tetapi tidak cukup sensitif terhadap fluktuasi curah hujan yang ekstrem dan non-linear. Hal ini menunjukkan bahwa model SARIMA kurang optimal untuk wilayah ini dan perlu ditingkatkan melalui pendekatan lain yang lebih adaptif yaitu STARIMA.

4.3 STARIMA

4.3.1 Stasioner Data

Setelah dilakukan analisis dekomposisi untuk mengidentifikasi pola tren dan musiman, langkah selanjutnya adalah menguji tingkat kestasioneran data pada masing - masing wilayah. Uji stasioneritas dilakukan untuk memastikan bahwa deret waktu curah hujan telah memenuhi asumsi dasar analisis time series, yaitu nilai rata - rata dan varians yang relatif konstan terhadap waktu. Data yang tidak stasioner dapat menyebabkan estimasi parameter model menjadi bias dan tidak stabil, sehingga perlu dilakukan transformasi atau differencing sebelum proses pemodelan. Oleh karena itu, pada tahap ini dilakukan pengujian kestasioneran data curah hujan di kelima wilayah Kota Surabaya guna menentukan apakah proses differencing diperlukan untuk menjadikan data stasioner secara statistik.

A. Kestasioneran terhadap varians

Kestasioneran data curah hujan terhadap varians dapat dilihat dari transformasi lambda (λ) yang dihasilkan dari plot BoxCox. Jika nilai (λ) mendekati satu maka dapat disimpulkan bahwa data telah stasioner dan sebaliknya. Untuk membuat plot BoxCox data yang digunakan harus bernilai positif.

Tabel 4.8: Nilai Lambda Semua Wilayah

Wilayah	Lambda Sebelum	Lambda Sesudah
Barat	0.1962	1.119
Selatan	0.2009	1.140
Tengah	0.1847	1.146
Timur	0.1843	1.305
Utara	0.1894	1.127

Berdasarkan Tabel 4.8 itu nilai λ hasil transformasi BoxCox menunjukkan peningkatan yang signifikan pada seluruh wilayah setelah proses optimasi dilakukan. Kenaikan nilai λ yang mendekati 1 menandakan bahwa varians data curah hujan menjadi lebih stabil dan mendekati kondisi stasioner. Dengan demikian, transformasi BoxCox terbukti efektif sebagai langkah pra pemrosesan untuk menormalkan varians dan memastikan bahwa data memenuhi asumsi homoskedastisitas sebelum proses differencing dan pemodelan STARIMA dilakukan.

B. Kestasioneran terhadap rata - rata


Setelah data stasioner terhadap varians, selanjutnya dilakukan pengujian kestasioneran terhadap rata - rata. Pengujian ini dapat dilakukan dengan Menggunakan *Augmented Dickey-Fuller Unit Root Test*, berikut adalah hipotesisnya: $H_0 : \phi \geq 0$ (data tidak stasioner terhadap rata-rata) vs $H_1 : \phi < 0$ (data stasioner terhadap rata-rata) Hasil pengujian *Augmented Dickey-Fuller Unit Root* untuk masing-masing lokasi terangkum pada tabel dibawah ini:

Tabel 4.9: Hasil Uji ADF

Wilayah	<i>t-statistik</i>	Nilai-p
Barat	-8.314	0.01
Selatan	-8.111	0.01
Tengah	-8.107	0.01
Timur	-7.781	0.01
Utara	-8.313	0.01

Tabel 4.9 menunjukkan bahwa data curah hujan kelima wilayah Surabaya telah stasioner terhadap varians juga stasioner terhadap rata - rata sehingga tidak perlu di diferensiasi. Hal tersebut dapat diketahui dari nilai peluang yang dihasilkan oleh ke 5 wilayah Surabaya yaitu sebesar 0.01. Dengan tingkat kepercayaan 95% dapat disimpulkan bahwa kelima wilayah Surabaya telah stasioner terhadap varians juga stasioner terhadap rata-rata.

Berikut adalah grafik curah hujan kelima wilayah surabaya setelah dilakukan transformasi BoxCox dan differencing.



Gambar 4.15: Hasil Grafik Curah Hujan Setelah Transformasi dan Differencing

Berdasarkan Gambar 4.15 diatas pola curah hujan yang telah melalui proses differencing musiman, setelah transformasi BoxCox diterapkan.

Seluruh wilayah Barat, Selatan, Tengah, Timur, dan Utara menunjukkan fluktuasi yang lebih stabil serta tidak lagi memperlihatkan pola musiman yang berulang, menandakan bahwa komponen musiman berhasil dieliminasi. Pola residual yang berosilasi di sekitar nol mengindikasikan bahwa data telah berada dalam kondisi yang lebih mendekati stasioner, sehingga layak digunakan untuk pemodelan STARIMA pada tahap selanjutnya.


4.3.2 Bobot Seragam

Pada STARIMA ini setelah melakukan stasioner tes seperti pada poin 4.3.1 lalu membuat pembobotan yang mana disini menggunakan tiga pembobotan yaitu bobot lokasi seragam, bobot lokasi invers jarak, dan bobot lokasi normalisasi korelasi silang. Penggunaan ketiga bobot ini dilakukan untuk mendapatkan model STARIMA terbaik dengan bobot lokasi yang sesuai. Berikut merupakan matriks bobot lokasi seragam:

$$W = \begin{pmatrix} 0.00 & 0.25 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.00 & 0.25 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.00 & 0.25 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.00 & 0.25 \\ 0.25 & 0.25 & 0.25 & 0.25 & 0.00 \end{pmatrix} \quad (4.1)$$

A. Identifikasi


Setelah mendapatkan bobot, melakukan perhitungan STACF seperti pada Rumus 2.17 dan STPACF seperti pada Rumus 2.11. Perhitungan STACF dan STPACF ini digunakan untuk menentukan orde p , q nya karena data nya sudah di differencing. Berikut adalah plot STACF dan STPACF:



Gambar 4.16: STACF dan STPACF SLAG 0

Gambar 4.16 menunjukkan hasil analisis *Spatio-Temporal Autocorrelation Function* (STACF) dan *Spatio Temporal Partial Autocorrelation Function* (STPACF) menggunakan bobot seragam. Plot STACF pada

spatial lag 0 menunjukkan adanya autokorelasi signifikan pada beberapa lag awal yang meluruh secara bertahap tanpa cut-off yang jelas, mengindikasikan dominasi komponen autoregressive. Sementara itu, STPACF memperlihatkan spike signifikan yang kuat pada lag 1 dan tidak signifikan pada lag berikutnya, yang merupakan ciri khas proses AR orde rendah. Berdasarkan pola tersebut, model dengan komponen AR(1) tanpa komponen MA yang dominan dinilai paling sesuai untuk merepresentasikan struktur temporal data pada spatial lag 0 dengan pembobotan seragam.



Gambar 4.17: STACF dan STPACF SLAG 1

Gambar 4.17 menunjukkan hasil analisis *Spatio-Temporal Autocorrelation Function* (STACF) dan *Spatio Temporal Partial Autocorrelation Function* (STPACF) menggunakan bobot seragam. Plot STACF pada spatial lag 1 dengan pembobotan seragam menunjukkan adanya autokorelasi signifikan pada beberapa lag awal yang meluruh secara bertahap, mengindikasikan keberadaan ketergantungan spasio-temporal yang kuat. Hal ini menandakan bahwa nilai pengamatan pada suatu wilayah dipengaruhi oleh nilai rata-rata wilayah tetangga pada waktu sebelumnya. Sementara itu, STPACF memperlihatkan spike signifikan yang dominan pada lag 1 dan tidak signifikan pada lag berikutnya, yang merupakan ciri proses autoregressive orde satu. Berdasarkan pola tersebut, model STARIMA dengan komponen AR spasial orde satu dan tanpa komponen MA yang dominan dinilai paling sesuai untuk merepresentasikan struktur spasio-temporal data.

B. Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi yaitu STARIMA $(0, 0, 1) \times (1, 1, 1)_{12}$ dan STARIMA $(0, 0, 0) \times (0, 1, 1)_{12}$ menggunakan metode Maximum Likelihood, disajikan dalam Tabel 4.10, bersama dengan standar error, nilai t , dan nilai p masing-masing:

Tabel 4.10: Estimasi Parameter Model STARIMA Uniform

Spatial Order	Model	Statistik	AR Parameter				MA Parameter		
			Non Seasonal		Seasonal		Non Seasonal		Seasonal
			AR1	AR2	AR1	AR2	MA1	MA2	MA
Lag 0	$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			0.2414		0.3270		-0.8901
		SE			0.0771		0.0594		0.0988
		t-value			3.13		5.51		-9.01
		p-value			0.0018***		0.000***		0.000***
Lag 1	$(0, 0, 0) \times (0, 1, 1_0)_{12}$	Estimasi							-0.5559
		SE							0.0412
		t-value							-13.5
		p-value							0.000***

Berdasarkan Tabel 4.10 hasil estimasi parameter dari kedua model dari lag spasial 0 dan lag spasial 1 yang diestimasi menggunakan metode Maximum Likelihood. Masing masing parameter dilaporkan bersama standar error, nilai t , dan nilai p untuk menilai signifikansi statistik. Secara umum berdasarkan signifikansi, model STARIMA dengan spatial lag 1 merupakan model terbaik. Model ini mampu menangkap ketergantungan spasio-temporal curah hujan antarwilayah melalui komponen MA musiman spasial yang signifikan, dengan struktur yang lebih sederhana dibandingkan model tanpa komponen spasial. Oleh karena itu, model spatial lag 1 dipilih sebagai model final untuk proses peramalan.

C. Model terbaik

Untuk memilih model spasial terbaik dalam penelitian ini menggunakan evaluasi *Root Mean Squared Error* (RMSE) untuk membandingkan kinerja peramalan dari model-model STARIMA. Berdasarkan hasil pada Lampiran 14, berikut adalah tabel nya:

Tabel 4.11: Hasil Model Fitting STARIMA Uniform


Wilayah	STARIMA $(0, 0, 1) \times (1, 1, 1)_{12}$	STARIMA $(0, 0, 0) \times (0, 1, 1_0)_{12}$
Barat	2.824	2.962
Selatan	3.856	3.921
Tengah	3.971	4.092
Timur	1.277	1.331
Utara	2.881	2.992
Rata-Rata	2.952	2.7934

Berdasarkan Tabel 4.11, terlihat bahwa evaluasi nilai RMSE per wilayah, model STARIMA $(0, 0, 1) \times (1, 1, 1)_{12}$ menunjukkan kinerja yang

lebih baik pada sebagian besar wilayah secara individual. Namun, ditinjau dari nilai RMSE rata-rata, model STARIMA $(0, 0, 0) \times (0, 1, 1_0)_{12}$ menghasilkan error yang lebih kecil secara keseluruhan. Dengan mempertimbangkan prinsip parsimoni dan kestabilan kinerja global, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ dipilih sebagai model terbaik untuk peramalan curah hujan.


D. Hasil Forecasting STARIMA

Berikut adalah hasil peramalan curah hujan di berbagai wilayah menggunakan bobot seragam:




Gambar 4.18: Hasil Peramalan Wilayah Barat

Berdasarkan Gambar 4.18 hasil prediksi curah hujan di Wilayah Barat menunjukkan nilai error sebesar 2,962, yang mengindikasikan bahwa tingkat kesalahan prediksi relatif kecil hingga menengah, sehingga model memiliki kemampuan peramalan yang cukup baik. Model mampu menangkap pola kenaikan curah hujan musiman di awal tahun dengan baik. Pada periode Mei hingga Agustus, terjadi penurunan curah hujan, dan hasil prediksi model masih mengikuti arah perubahan tersebut meskipun pada beberapa periode nilai prediksi sedikit lebih tinggi dibandingkan data aktual. Selanjutnya, mulai September hingga Desember, tren peningkatan curah hujan kembali terdeteksi dengan cukup akurat. Hal ini menunjukkan bahwa model mampu mengikuti dinamika perubahan curah hujan secara temporal dengan baik.




Gambar 4.19: Hasil Peramalan Wilayah Selatan

Berdasarkan Gambar 4.19 grafik menunjukkan bahwa model peramalan mampu menangkap pola musiman umum curah hujan di Wilayah Selatan dengan cukup baik, ditunjukkan oleh kemampuan model mengikuti penurunan curah hujan dari awal hingga pertengahan tahun serta kenaikan kembali menjelang akhir tahun. Pada periode curah hujan rendah (Juni–Oktober 2024), hasil prediksi relatif mendekati data aktual, menandakan kinerja model yang stabil pada kondisi tersebut. Namun, pada periode curah hujan tinggi di awal dan akhir tahun, model cenderung melakukan overestimate yang signifikan, terutama menjelang Januari 2025, sehingga berkontribusi terhadap nilai RMSE sebesar 3,921 yang tergolong cukup tinggi. Hal ini menunjukkan bahwa meskipun model efektif dalam menangkap tren dan musim, akurasi masih terbatas dalam memprediksi lonjakan ekstrem curah hujan.




Gambar 4.20: Hasil Peramalan Wilayah Tengah

Berdasarkan Gambar 4.20 grafik menunjukkan bahwa model peramalan mampu mengikuti pola fluktuasi dan tren umum curah hujan di Wilayah Tengah dengan cukup baik, terutama pada periode awal hingga pertengahan tahun. Pada kondisi curah hujan rendah di pertengahan tahun, hasil prediksi relatif mendekati data aktual, menandakan kinerja model yang stabil. Namun, pada periode ekstrem di akhir tahun, khususnya menjelang Januari 2025, model cenderung melakukan overestimate, sehingga menurunkan akurasi prediksi. Nilai RMSE sebesar 4,092 menunjukkan tingkat kesalahan yang masih moderat, yang mengindikasikan bahwa model cukup baik dalam menangkap pola umum, tetapi masih memiliki keterbatasan dalam memprediksi lonjakan curah hujan ekstrem di Wilayah Tengah.



Gambar 4.21: Hasil Peramalan Wilayah Timur

Berdasarkan Gambar 4.21 Grafik menunjukkan bahwa model peramalan memiliki kinerja sangat baik di Wilayah Timur, dengan nilai RMSE sebesar 1,331 yang tergolong rendah. Hasil prediksi terlihat sangat berdekatan dengan data aktual pada hampir seluruh periode pengamatan, baik pada kondisi curah hujan tinggi, rendah, maupun saat terjadi peningkatan kembali di akhir tahun. Model juga menunjukkan stabilitas tinggi tanpa deviasi ekstrem, serta mampu memprediksi kondisi curah hujan minimum dengan sangat akurat. Secara keseluruhan, hasil ini mengindikasikan bahwa model paling akurat dan konsisten dalam merepresentasikan dinamika curah hujan di Wilayah Timur dibandingkan wilayah lainnya.



Gambar 4.22: Hasil Peramalan Wilayah Utara

Berdasarkan Gambar 4.22 grafik menunjukkan bahwa model peramalan mampu mengikuti pola fluktuasi umum curah hujan di Wilayah Utara dengan cukup baik, termasuk penurunan di pertengahan tahun dan peningkatan menjelang akhir periode. Pada kondisi curah hujan rendah hingga sedang, hasil prediksi relatif mendekati data aktual, menandakan kinerja model yang stabil. Namun, pada periode ekstrem di akhir tahun, model cenderung melakukan overestimate, sehingga menurunkan akurasi prediksi. Nilai RMSE sebesar 2,922 menunjukkan tingkat kesalahan menengah, dengan akurasi yang lebih baik dibandingkan Wilayah Tengah, tetapi masih di bawah Wilayah Timur.

4.3.3 Bobot Invers Jarak


Perhitungan bobot lokasi invers jarak menggunakan jarak sebenarnya antar lokasi, perhitungan bobot ini diperoleh dari hasil invers jarak sebenarnya yang kemudian dinormalisasi. Perhitungan jarak antar wilayah dapat dilakukan sesuai dengan Persamaan 2.27 yaitu dengan menggunakan posisi longitude dan latitude dari kedua wilayah yang akan dihitung jaraknya. Posisi longitude dan latitude yang digunakan berupa jarak terluar atau terjauh dari masing masing wilayah Surabaya. Bobot lokasi invers jarak memberikan nilai koefisien yang kecil untuk jarak yang lebih jauh dan sebaliknya. Berikut merupakan matriks

bobot lokasi invers jarak:

$$W = \begin{pmatrix} 0.00 & 0.2380 & 0.2946 & 0.1612 & 0.3063 \\ 0.1896 & 0.00 & 0.3409 & 0.2637 & 0.2058 \\ 0.1727 & 0.2508 & 0.00 & 0.2031 & 0.3734 \\ 0.1482 & 0.3403 & 0.3186 & 0.00 & 0.2290 \\ 0.2112 & 0.1781 & 0.4910 & 0.1717 & 0.00 \end{pmatrix} \quad (4.2)$$


A. Identifikasi

Setelah mendapatkan bobot, melakukan perhitungan STACF seperti pada Rumus 2.17 dan STPACF seperti pada Rumus 2.11. Perhitungan Perhitungan STACF dan STPACF ini digunakan untuk menentukan orde p , q nya karena data nya sudah di differencing. Berikut adalah plot STACF dan STPACF:



Gambar 4.23: STACF dan STPACF SLAG 0

Gambar 4.23 menunjukkan hasil analisis *Spatio-Temporal Autocorrelation Function* (STACF) dan *Spatio Temporal Partial Autocorrelation Function* (STPACF) menggunakan invers jarak. Plot STACF menunjukkan adanya korelasi temporal jangka pendek serta pola musiman yang kuat pada lag ke-12 dan kelipatannya, yang mengindikasikan keberadaan komponen musiman tahunan. Sementara itu, plot STPACF menampilkan spike signifikan pada lag pertama dan lag musiman, yang mengarah pada keberadaan komponen autoregressive baik pada bagian non-musiman maupun musiman. Berdasarkan pola tersebut, model STARIMA dengan orde rendah pada komponen AR dan MA serta satu komponen musiman tahunan dinilai sesuai untuk memodelkan data.



Gambar 4.24: STACF dan STPACF SLAG 1

Gambar 4.24 menunjukkan hasil analisis *Spatio Temporal Autocorrelation Function* (STACF) dan *Spatio Temporal Partial Autocorrelation* (STPACF) menggunakan invers jarak. Plot STACF dan STPACF pada pembobot inverse jarak dengan spatial lag 1 menunjukkan pola korelasi yang tidak stabil dan tidak memberikan indikasi orde AR maupun MA yang jelas. Meskipun pola musiman tahunan masih terlihat, penambahan spatial lag 1 cenderung mengaburkan struktur temporal data. Hal ini menyebabkan parameter model STARIMA pada SLAG 1 tidak signifikan secara statistik, sehingga model dengan spatial lag 0 lebih layak digunakan.

B. Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi yaitu STARIMA $(0, 0, 1)(1, 1, 1)_{12}$ dan STARIMA $(0, 0, 0)(0, 1, 1_0)_{12}$ menggunakan metode Maximum Likelihood, disajikan dalam Tabel 4.12, bersama dengan standar error, nilai t , dan nilai p masing-masing:

Tabel 4.12: Estimasi Parameter Model STARIMA Inverse

Spatial Order	Model	Statistik	AR Parameter				MA Parameter		
			Non Seasonal		Seasonal		Non Seasonal		Seasonal
			AR1	AR2	AR1	AR2	MA1	MA2	MA
Lag 0	$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			0.2414		0.3270		-0.8901
		SE			0.0771		0.0594		0.0988
		t-value			3.13		5.51		-9.01
		p-value			0.0018***		0.000***		0.000***
Lag 1	$(0, 0, 0) \times (0, 1, 1_0)_{12}$	Estimasi							-0.5559
		SE							0.0412
		t-value							-13.5
		p-value							0.000***

Berdasarkan Tabel 4.12 hasil estimasi parameter dari kedua model dari lag spasial 0 dan lag spasial 1 yang di estimasi menggunakan metode Maximum Likelihood. Masing-masing parameter dilaporkan bersama standar error, nilai t , dan nilai p untuk menilai signifikansi statistik. Secara umum berdasarkan signifikansi, model STARIMA dengan spatial lag 0

merupakan model terbaik. Model STARIMA $(0, 0, 1)x(1, 1, 1)_{12}$ dengan spatial lag 0 memiliki seluruh parameter yang signifikan dan mampu menangkap dinamika temporal jangka pendek serta pola musiman tahunan secara komprehensif. Sebaliknya, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ dengan spatial lag 1 hanya menangkap komponen musiman dan menunjukkan struktur yang terlalu sederhana. Oleh karena itu, model dengan spatial lag 0 dinilai lebih layak digunakan sebagai model akhir dalam penelitian ini.

C. Model Terbaik


Untuk memilih model spasial terbaik dalam penelitian ini menggunakan evaluasi *Root Mean Squared Error* (RMSE) untuk membandingkan kinerja peramalan dari model-model STARIMA. Berdasarkan hasil pada Lampiran 15, berikut adalah tabel nya:

Tabel 4.13: Hasil Model Fitting Inverse

Wilayah	STARIMA $(0, 0, 1) \times (1, 1, 1)_{12}$	STARIMA $(0, 0, 0) \times (0, 1, 1_0)_{12}$
Barat	2.753	2.807
Selatan	3.667	3.796
Tengah	3.662	3.780
Timur	1.297	1.386
Utara	2.796	2.841
Rata-Rata	2.8344	2.922


Berdasarkan Tabel 4.13, terlihat bahwa evaluasi nilai RMSE per wilayah, model STARIMA $(0, 0, 1)x(1, 1, 1)_{12}$ menunjukkan kinerja yang lebih baik pada sebagian besar wilayah secara individual. Namun, ditinjau dari nilai RMSE rata-rata, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ menghasilkan error yang lebih kecil secara keseluruhan. Dengan mempertimbangan prinsip parsimoni dan kestabilan kinerja global, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ dipilih sebagai model terbaik untuk peramalan curah hujan.

D. Hasil Forecasting STARIMA Berikut adalah hasil peramalan curah hujan di berbagai wilayah menggunakan bobot invers jarak:




Gambar 4.25: Hasil Peramalan Wilayah Barat

Berdasarkan Gambar 4.25 grafik menunjukkan bahwa model peramalan di Wilayah Barat memiliki kinerja cukup baik dengan nilai RMSE sebesar 2,753. Model mampu mengikuti pola naik-turun curah hujan secara umum, terutama pada awal periode dan saat curah hujan rendah di pertengahan tahun, di mana selisih antara nilai aktual dan ramalan relatif kecil. Namun, pada periode ekstrem di akhir tahun, model cenderung melakukan overestimate terhadap lonjakan curah hujan, sehingga akurasinya menurun. Secara keseluruhan, model layak digunakan untuk peramalan umum, tetapi masih memiliki keterbatasan dalam memprediksi kejadian curah hujan ekstrem.




Gambar 4.26: Hasil Peramalan Wilayah Selatan

Berdasarkan Gambar 4.26 grafik menunjukkan bahwa model peramalan di Wilayah Selatan mampu menangkap pola musiman umum curah hujan dengan cukup baik, terutama pada awal hingga pertengahan periode. Pada kondisi curah hujan rendah hingga sedang, hasil prediksi relatif mendekati data aktual, menandakan kinerja model yang cukup andal. Namun, pada periode ekstrem di akhir tahun, model cenderung melakukan overestimate terhadap lonjakan curah hujan, sehingga meningkatkan nilai kesalahan prediksi. Nilai RMSE sebesar 3,667 menunjukkan bahwa akurasi model di Wilayah Selatan lebih rendah dibandingkan Wilayah Barat, yang mengindikasikan variabilitas curah hujan yang lebih tinggi dan keterbatasan model dalam memprediksi perubahan ekstrem.




Gambar 4.27: Hasil Peramalan Wilayah Tengah

Berdasarkan Gambar 4.27 grafik menunjukkan bahwa model peramalan di Wilayah Tengah mampu merepresentasikan pola temporal dan tren umum curah hujan dengan cukup baik, terutama pada awal hingga pertengahan periode. Pada kondisi curah hujan rendah hingga menengah, hasil prediksi relatif mendekati data aktual, menandakan kinerja model yang cukup efektif. Namun, pada periode ekstrem di akhir tahun, model cenderung melakukan overestimate terhadap lonjakan curah hujan, sehingga meningkatkan nilai kesalahan prediksi. Nilai RMSE sebesar 3,662 menunjukkan bahwa meskipun model berhasil menangkap struktur umum data, akurasi masih terbatas pada kejadian curah hujan tinggi.



Gambar 4.28: Hasil Peramalan Wilayah Timur

Berdasarkan Gambar 4.28 grafik menunjukkan bahwa model peramalan di Wilayah Timur memiliki akurasi sangat tinggi, dengan nilai RMSE sebesar 1,294 yang merupakan paling rendah dibandingkan wilayah lainnya. Hasil peramalan sangat mendekati data aktual pada hampir seluruh periode, baik saat curah hujan tinggi maupun rendah. Meskipun terdapat sedikit overestimate pada lonjakan di akhir periode, deviasinya relatif kecil dan tidak memengaruhi pola umum. Secara keseluruhan, model di Wilayah Timur paling stabil dan representatif, sehingga sangat andal untuk peramalan dan analisis curah hujan.



Gambar 4.29: Hasil Peramalan Wilayah Utara

Berdasarkan Gambar 4.29 grafik menunjukkan bahwa model peramalan di Wilayah Utara mampu menangkap pola umum curah hujan dengan cukup baik, terutama pada awal hingga pertengahan periode. Pada kondisi curah hujan rendah, hasil prediksi relatif mendekati data aktual, menandakan kinerja model yang stabil. Namun, pada periode ekstrem di akhir tahun, model cenderung melakukan overestimate terhadap lonjakan curah hujan, sehingga menurunkan akurasi prediksi. Nilai RMSE sebesar 2,796 menunjukkan tingkat kesalahan menengah, dengan akurasi yang lebih baik dibandingkan Wilayah Selatan dan Tengah, tetapi masih di bawah Wilayah Timur.


4.3.4 Bobot Lokasi Normalisasi Korelasi Silang

Perhitungan bobot lokasi normalisasi korelasi silang dapat diselesaikan dengan menormalisasikan korelasi silang antar lokasi pada lag yang sesuai, penentuan lag berdasarkan orde struktur data deret waktu. Perhitungan bobot lokasi normalisasi korelasi silang sesuai dengan Persamaan 2.31. Berikut merupakan matriks bobot lokasi normalisasi korelasi silang:

$$W = \begin{pmatrix} 0.00 & 0.2504 & 0.2503 & 0.2476 & 0.2518 \\ 0.2508 & 0.00 & 0.2522 & 0.2461 & 0.2509 \\ 0.2507 & 0.2522 & 0.00 & 0.2462 & 0.2509 \\ 0.2509 & 0.2490 & 0.2490 & 0.00 & 0.2510 \\ 0.2517 & 0.2504 & 0.2504 & 0.2476 & 0.00 \end{pmatrix} \quad (4.3)$$


A. Identifikasi

Setelah mendapatkan bobot, melakukan perhitungan STACF seperti pada Rumus 2.17 dan STPACF seperti pada Rumus 2.11. Perhitungan Perhitungan STACF dan STPACF ini digunakan untuk menentukan orde p, q nya karena data nya sudah di differencing. Berikut adalah plot STACF dan STPACF:



Gambar 4.30: STACF dan STPACF SLAG 0

Gambar 4.30 menunjukkan hasil analisis *Spatio-Temporal Autocorrelation Function* (STACF) dan *Spatio Temporal Partial Autocorrelation Function* (STPACF) menggunakan bobot korelasi silang. Plot STACF pada spatial lag 0 menunjukkan adanya autokorelasi signifikan pada beberapa lag awal yang meluruh secara bertahap tanpa cut-off yang jelas, mengindikasikan dominasi komponen autoregressive. Sementara itu, STPACF memperlihatkan spike signifikan yang kuat pada lag 1 dan tidak signifikan pada lag berikutnya, yang merupakan ciri khas proses AR orde rendah. Berdasarkan pola tersebut, model dengan komponen AR(1) tanpa komponen MA yang dominan dinilai paling sesuai untuk merepresentasikan struktur temporal data pada spatial lag 0 dengan pembobotan korelasi silang.



Gambar 4.31: STACF dan STPACF SLAG 1

Gambar 4.31 hasil analisis *Spatio Temporal Autocorrelation Function*

(STACF) dan *Spatio Temporal Partial Autocorrelation* (STPACF) menggunakan bobot korelasi silang. Plot STACF pada spatial lag 1 dengan pembobotan korelasi silang menunjukkan adanya autokorelasi signifikan pada beberapa lag awal yang meluruh secara bertahap, mengindikasikan keberadaan ketergantungan spasio-temporal yang kuat. Hal ini menandakan bahwa nilai pengamatan pada suatu wilayah dipengaruhi oleh nilai rata-rata wilayah tetangga pada waktu sebelumnya. Sementara itu, STPACF memperlihatkan spike signifikan yang dominan pada lag 1 dan tidak signifikan pada lag berikutnya, yang merupakan ciri proses autoregressive orde satu. Berdasarkan pola tersebut, model STARIMA dengan komponen AR spasial orde satu dan tanpa komponen MA yang dominan dinilai paling sesuai untuk merepresentasikan struktur spasio-temporal data.

B. Estimasi Parameter

Parameter yang diestimasi dari model yang telah diidentifikasi yaitu STARIMA $(0, 0, 1)(0, 1, 1)_{12}$ dan STARIMA $(0, 0, 0)(0, 1, 1_0)_{12}$ menggunakan metode Maximum Likelihood, disajikan dalam Tabel 4.14, bersama dengan standar error, nilai t , dan nilai p masing-masing:

Tabel 4.14: Estimasi Parameter Model STARIMA Cross

Spatial Order	Model	Statistik	MA Parameter		
			Non Seasonal		Seasonal
			MA1	MA2	MA
Lag 0	$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.374		-0.580
		SE	0.144		0.212
		t-value	2.59		-2.73
		p-value	0.0110***		0.0074***
Lag 1	$(0, 0, 0) \times (0, 1, 1_0)_{12}$	Estimasi			-0.556
		SE			0.22
		t-value			-2.53
		p-value			0.0131***

Berdasarkan Tabel 4.14 hasil estimasi parameter dari kedua model dari lag spasial 0 dan lag spasial 1 yang diestimasi menggunakan metode Maximum Likelihood. Masing-masing parameter dilaporkan bersama standar error, nilai t , dan nilai p untuk menilai signifikansi statistik. Secara umum berdasarkan signifikansi, model STARIMA dengan spatial lag 1 merupakan model terbaik. Model ini mampu menangkap ketergantungan spasio-temporal curah hujan antarwilayah melalui komponen MA musiman spasial yang signifikan, dengan struktur yang lebih sederhana dibandingkan model tanpa komponen spasial. Oleh karena itu, model spatial lag 1 dipilih sebagai model final untuk proses peramalan.

C. Model Terbaik

Untuk memilih model spasial terbaik dalam penelitian ini menggunakan evaluasi *Root Mean Squared Error* (RMSE) untuk membandingkan kinerja peramalan dari model-model STARIMA. Berdasarkan hasil pada Lampiran 16, berikut adalah tabel nya:


Tabel 4.15: Hasil Model Fitting Cross

Wilayah	STARIMA $(0, 0, 1) \times (0, 1, 1)_{12}$	STARIMA $(0, 0, 0) \times (0, 1, 1_0)_{12}$
Barat	2.855	2.846
Selatan	3.835	3.827
Tengah	3.822	3.814
Timur	1.461	1.451
Utara	2.893	2.884
Rata-Rata	2.9732	2.9644

Berdasarkan Tabel 4.15 terlihat bahwa evaluasi nilai RMSE per wilayah, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ menunjukkan kinerja yang lebih baik pada sebagian besar wilayah secara individual. Namun, ditinjau dari nilai RMSE rata-rata, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ menghasilkan error yang lebih kecil secara keseluruhan. Dengan mempertimbangan prinsip parsimoni dan kestabilan kinerja global, model STARIMA $(0, 0, 0)x(0, 1, 1_0)_{12}$ dipilih sebagai model terbaik untuk peramalan curah hujan.


D. Hasil Forecasting

Berikut adalah hasil peramalan menggunakan bobot korelasi silang:




Gambar 4.32: Hasil Peramalan Wilayah Barat

Berdasarkan Gambar 4.32 grafik menunjukkan bahwa model peramalan memiliki kinerja cukup baik di Wilayah Barat dengan nilai RMSE sebesar 2,846, yang menandakan kesalahan prediksi relatif kecil. Model mampu mengikuti tren utama dan pola musiman curah hujan, terutama pada periode penurunan dari awal hingga pertengahan tahun serta kondisi curah hujan rendah di pertengahan tahun. Namun, pada periode dengan perubahan ekstrem, khususnya di awal dan akhir tahun, model cenderung melakukan overestimate, terutama menjelang Januari 2025. Secara keseluruhan, model cukup andal dalam menggambarkan pola umum curah hujan, tetapi akurasinya menurun pada lonjakan curah hujan yang tajam, sehingga perlu kehati-hatian dalam interpretasi pada kondisi ekstrem.




Gambar 4.33: Hasil Peramalan Wilayah Selatan

Berdasarkan Gambar 4.33 grafik menunjukkan bahwa kinerja model peramalan di Wilayah Selatan memiliki akurasi yang lebih rendah dibandingkan Wilayah Barat, dengan nilai RMSE sebesar 3,827. Model masih mampu mengikuti tren umum dan pola musiman curah hujan, terutama penurunan dari awal hingga pertengahan tahun serta kondisi curah hujan rendah yang relatif stabil. Namun, model cenderung kurang presisi dalam menangkap fluktuasi kecil dan melakukan overestimate yang signifikan pada periode ekstrem, khususnya menjelang Januari 2025. Deviasi ini menjadi penyumbang utama tingginya nilai RMSE. Secara keseluruhan, model cukup baik untuk analisis pola jangka panjang, tetapi masih memiliki keterbatasan dalam memprediksi lonjakan curah hujan ekstrem di Wilayah Selatan.




Gambar 4.34: Hasil Peramalan Wilayah Tengah

Berdasarkan Gambar 4.34 grafik menunjukkan bahwa model peramalan di Wilayah Tengah memiliki akurasi sedang, dengan nilai RMSE sebesar 3,814 yang sedikit lebih tinggi dibandingkan Wilayah Barat. Model mampu mengikuti pola musiman dan tren utama curah hujan, terutama penurunan dari awal hingga pertengahan tahun serta kondisi curah hujan rendah yang stabil pada musim kemarau. Namun, model cenderung melakukan overestimate, terutama pada awal dan akhir periode, dengan deviasi paling besar terjadi menjelang Januari 2025 akibat ketidakmampuan model menangkap lonjakan curah hujan ekstrem. Secara keseluruhan, model cukup andal untuk analisis pola dan tren jangka panjang, tetapi masih memerlukan pengembangan lebih lanjut untuk meningkatkan akurasi pada peristiwa hujan ekstrem di Wilayah Tengah.



Gambar 4.35: Hasil Peramalan Wilayah Timur

Berdasarkan Gambar 4.35 grafik menunjukkan bahwa model peramalan di Wilayah Timur memiliki akurasi sangat baik, dengan nilai RMSE sebesar 1,451 yang merupakan paling rendah dibandingkan wilayah lainnya. Model mampu mengikuti pola musiman dan dinamika curah hujan secara konsisten, mulai dari penurunan menuju musim kemarau hingga kenaikan kembali menjelang akhir tahun. Perbedaan antara nilai ramalan dan aktual relatif kecil di hampir seluruh periode, dengan hanya sedikit overestimate pada awal dan akhir periode yang tidak signifikan. Secara keseluruhan, model di Wilayah Timur paling stabil dan representatif, sehingga sangat layak digunakan untuk peramalan dan analisis curah hujan.



Gambar 4.36: Hasil Peramalan Wilayah Utara

Berdasarkan Gambar 4.36 Grafik menunjukkan bahwa model peramalan di Wilayah Utara memiliki akurasi sedang, dengan nilai RMSE sebesar 2,884, lebih baik dibandingkan Wilayah Selatan dan Tengah, namun masih di bawah Wilayah Timur. Model mampu mengikuti pola musiman dan tren utama curah hujan, terutama penurunan menuju musim kemarau dan kenaikan kembali di akhir tahun. Namun, model cenderung melakukan overestimate, khususnya pada awal dan akhir periode, serta kurang mampu menangkap fluktuasi kecil di pertengahan tahun. Secara keseluruhan, model cukup stabil dan layak untuk analisis pola dan peramalan umum, tetapi perlu kehati-hatian dalam memprediksi lonjakan curah hujan ekstrem di Wilayah Utara.

Penambahan unsur spasial terbukti membuat hasil Peramalan curah hujan menjadi lebih baik yaitu dengan hasil RMSE yang lebih rendah daripada SARIMA univariat.

4.4 Hasil Peramalan

Berdasarkan hasil peramalan yang telah dilakukan dengan ketiga pembo- botan itu diperoleh yang paling baik yaitu Bobot Seragam dengan model (1,1,1). Hasil yang diperoleh, dapat disimpulkan bahwa model STARIMA mengungguli model SARIMA univariat. Keunggulan model STARIMA dibanding- kan model SARIMA univariat dapat disebabkan oleh penyertaan informasi spasial, yaitu efek ketetanggaan, dalam bentuk matriks bobot spasial.

Tabel 4.16: Perbandingan RMSE SARIMA dan STARIMA per Wilayah

Wilayah	Model	RMSE
Barat	SARIMA(1, 0, 0) $\times$ (0, 1, 0) ₁₂	5.082
	STARIMA(0, 0, 0) $\times$ (0, 1, 1 ₀) ₁₂	2.962
Selatan	SARIMA(1, 0, 0) $\times$ (0, 1, 0) ₁₂	4.680
	STARIMA(0, 0, 0) $\times$ (0, 1, 1 ₀) ₁₂	3.921
Tengah	SARIMA(1, 0, 0) $\times$ (0, 1, 0) ₁₂	4.434
	STARIMA(0, 0, 0) $\times$ (0, 1, 1 ₀) ₁₂	4.092
Timur	SARIMA(1, 0, 0) $\times$ (0, 1, 0) ₁₂	4.643
	STARIMA(0, 0, 0) $\times$ (0, 1, 1 ₀) ₁₂	1.331
Utara	SARIMA(1, 0, 0) $\times$ (0, 1, 0) ₁₂	5.016
	STARIMA(0, 0, 0) $\times$ (0, 1, 1 ₀) ₁₂	2.992

Tabel 4.16 ini menunjukkan nilai RMSE dari model SARIMA univariat dan model STARIMA untuk masing - masing wilayah. Berdasarkan hasil peramalan, model STARIMA secara konsisten memberikan nilai kesalahan (RMSE) yang lebih rendah dibandingkan SARIMA. Hal ini mengindikasikan bahwa penyertaan informasi spasial melalui matriks bobot spasial mampu meningkatkan akurasi model secara signifikan. Dengan demikian, STARIMA terbukti lebih unggul dalam memodelkan pola curah hujan antar wilayah yang saling berhubungan secara geografis.

Bab V

Kesimpulan dan Saran

5.1 Kesimpulan

Berdasarkan hasil analisis, dapat disimpulkan bahwa kelima wilayah di Surabaya memiliki karakteristik curah hujan yang relatif serupa, baik dari nilai rata-rata maupun pola persebaran statistiknya. Curah hujan menunjukkan pola musiman yang kuat dengan puncak hujan pada bulan Desember hingga Februari, serta kondisi minimum pada bulan Juli hingga September. Kelima wilayah juga memiliki korelasi spasial yang sangat tinggi (0,975–0,999), sehingga dinamika hujan antarwilayah bergerak hampir serentak. Model SARIMA mampu menggambarkan pola musiman tahunan, namun kinerjanya kurang responsif terhadap fluktuasi hujan ekstrem, tercermin dari nilai RMSE yang lebih tinggi karena SARIMA hanya memanfaatkan informasi temporal tanpa mempertimbangkan interaksi spasial antarwilayah. Untuk mengatasi keterbatasan tersebut digunakan model STARIMA dengan tiga jenis pembobotan spasial, yaitu bobot seragam, bobot invers jarak, dan bobot korelasi silang. Hasil evaluasi RMSE menunjukkan adanya peningkatan akurasi yang signifikan dibandingkan SARIMA. Hasil peramalan secara konsisten memperlihatkan bahwa STARIMA lebih mampu menangkap puncak musiman, lebih stabil pada periode penurunan hujan, menghasilkan error lebih kecil, serta lebih responsif terhadap pola spasial-temporal. Dari seluruh model yang diuji, STARIMA(1,1,1) dengan bobot seragam merupakan model paling optimal karena memberikan error paling rendah dan performa paling konsisten di seluruh wilayah.

5.2 Saran

Untuk memperoleh gambaran spasial yang lebih detail pada penelitian selanjutnya, disarankan untuk menambah jumlah titik pengamatan serta menggunakan data curah hujan dari stasiun BMKG maupun radar cuaca agar akurasi meningkat. Selain itu, penelitian berikutnya dapat mempertimbangkan penggunaan model spasio-temporal modern berbasis machine learning seperti LSTM Spatio-Temporal atau Graph Neural Network. Pengembangan sistem

prediksi berbasis aplikasi untuk mendukung sistem peringatan dini berbasis STARIMA juga sangat direkomendasikan, termasuk pembuatan dashboard pemantauan curah hujan secara real-time. Saran-saran tersebut diharapkan dapat menjadi acuan dalam mengembangkan model prediksi curah hujan yang lebih akurat, responsif, dan aplikatif. Kombinasi antara pendekatan statistik klasik dan metode modern berbasis kecerdasan buatan berpotensi menghasilkan model spasio-temporal yang jauh lebih akurat dalam menggambarkan dinamika iklim pada kawasan perkotaan seperti Surabaya.

Daftar Pustaka

- Alam, N. M., Mitra, S., Pandey, S. K., Jana, C., Ray, M., Ghosh, S., Mazumdar, S. P., Shankar, S. V., Saha, R. & Kar, G. (2024), 'Enhanced spatio-temporal modeling for rainfall forecasting: A high-resolution grid analysis', *Water* **16**(13), 1891.
- Azka, M. A., Sugianto, P. A., Silitonga, A. K. & Nugraheni, I. R. (2018), 'Uji akurasi produk estimasi curah hujan satelit gpm imerg di surabaya, indonesia', *Jurnal Sains & Teknologi Modifikasi Cuaca* **19**(2), 83–88.
- Badu-Apraku, J. M., Akinwale, R. O., Menkir, A., Kamara, Y. A., Obeng-Bio, K. & Olaosebikan, R. O. (2021), 'Two-stage spatiotemporal time series modelling approach for rice yield prediction: Advanced agroecosystem management', *Agronomy* **11**(12), 2502.
- Febriana, I. T. (2019), Prediksi Banjir Genangan di Kota Surabaya Berdasarkan Prediksi Curah Hujan Berbasis Data BMKG dengan Pendekatan NU - Support Vector Regression dan Neural Network, Tugas akhir, Departemen Statistika, Fakultas Matematika, Komputasi, dan Sains Data, Institut Teknologi Sepuluh Nopember, Surabaya, Indonesia. Program Studi Sarjana.
- Fuad, A. A., Moataz, A. & Mohamed, R. A. (2021), 'Estimating covid-19 cases in makkah region of saudi arabia: Space-time arima modeling', *PLOS ONE* **1**(1).
- Ilmi, N., Aswi, A. & Aidid, M. K. (2023), 'Generalized space time autoregressive integrated moving average (gstarima) dalam peramalan data curah hujan di kota makassar', *Jurnal Statistika* . Received: 11 September 2022; Revised: 28 February 2023; Accepted: 7 March 2023.
- Islami, M. I., Rahim, A., Jaya, A. K. & Bakri, B. (2021), 'Spatio-temporal model of rainfall data using kalman filter and expectation-maximization algorithm', *Jurnal Matematika, Statistika dan Komputasi (JMSK)* **17**(2), 304–313.

- Jagtap, S. & Karande, S. (2019), ‘Rainfall forecasting model using machine learning’, *International Research Journal of Engineering and Technology (IRJET)* **6**(5), 6107–6110.
- Kumar, R. R., Sarkar, K. A., Dhakre, D. S. & Bhattacharya, D. (n.d.), A hybrid space-time modelling approach for forecasting monthly temperature, Technical report, Department of Agricultural Statistics, Institute of Agriculture, Visva-Bharati, Sriniketan, West Bengal, India. n.d.
- Kumar, R. S., Kumar, M. P., Sravani, M. & Prasanna, V. S. (2023), Leveraging ensemble time-series forecasting model to predict the amount of rainfall in andhra pradesh, in ‘2023 7th International Conference on Computing Methodologies and Communication (ICCMC)’, pp. 474–480.
- Laily, V. O. N. (2020), Model hybrid multivariate gstarx-rnn untuk peramalan data space-time (studi kasus: Data inflow dan outflow bank sentral di jawa), Tesis magister, departemen statistika, Institut Teknologi Sepuluh Nopember, Surabaya.
- Latif, M. A. A., Rahman, M. M., Barri, M. H. H. & Al-Qurishi, M. A. (2022), ‘A review of the application of hybrid machine learning models to improve rainfall prediction’, *Arabian Journal of Geosciences* **15**(21), 1–18.
- Marino, D. L., Amarasinghe, K. & Manic, M. (2016), Building energy load forecasting using deep neural networks, in ‘Proceedings of the IECON 2016—42nd Annual Conference of the IEEE Industrial Electronics Society’, pp. 7046–7051.
- Mukhaiyar, U., Mahdiyasa, A. W., Prastoro, T., Pasaribu, U. S., Sari, K. N., Indratno, S. W., Soekarno, I., Choesin, D. N., Ismail, I., Rosleine, D. & Qoyyimi, D. T. (2024), ‘The generalized star modelling with three-dimensional of spatial weight matrix in predicting the indonesia peatland’s water level’, *Environmental Sciences Europe* **36**(180).
- Petropoulos, F., Hyndman, R. J., Athanasopoulos, T. & Bergmeir, C. (2021), ‘Forecasting: Theory and practice’, *International Journal of Forecasting* **37**(4), 1171–1176.
- Putra, J. A., Basbeth, F. & Bukhori, S. (2019), Sugar production forecasting system in ptpn xi semboro jember using autoregressive integrated moving average (arima) method, in ‘Proceedings of the 2019 6th International Conference on Electrical Engineering, Computer Science and Informatics (EE-CSEI)’, pp. 448–453.

- Rathod, S., Gurung, B., Singh, K. N. & Ray, M. (2018), 'An improved space-time autoregressive moving average (starma) model for modelling and forecasting of spatio-temporal time-series data', *J. Indian Soc. Agric. Stat.* **72**(3), 239–253. [Online].
URL: <https://www.researchgate.net/publication/330081735>
- Rathod, S., Singh, K. N., Arya, P., Ray, M., Mukherjee, A., Sinha, K., Kumar, P. & Shekhawat, R. S. (2017), 'Forecasting maize yield using arima-genetic algorithm approach', *Journal of Outlook on Agriculture* **46**(4), 265–271.
- Ruchjana, N. (2019), Pengembangan model spatio temporal dan aplikasinya, in 'Prosiding Seminar Nasional Matematika dan Pendidikan Matematika, UIN Raden Intan Lampung', pp. 1–6.
- Saesarin, J. P. (2020), Analisis Pola Ekspansi Perkotaan di Surabaya Barat Menggunakan Metode Spatial Autocorrelation, Tugas akhir, Departemen Perencanaan Wilayah dan Kota, Fakultas Teknik Sipil, Perencanaan dan Kebumihan, Institut Teknologi Sepuluh Nopember, Surabaya, Indonesia.
- Saha, A., Singh, K. N., Ray, M. & Rathod, S. (2020), 'A hybrid spatio-temporal modelling: An application to space-time rainfall forecasting', *Theoretical and Applied Climatology* **142**, 1271–1282.
- Saha, A., Singh, K. N., Ray, M., Rathod, S. & Dhyani, M. (2022), 'Fuzzy rule-based weighted space-time autoregressive moving average models for temperature forecasting', *Theoretical and Applied Climatology* **150**(3–4), 1321–1335.
- Sharma, K., Singh, K. N., Kumar, R. R., Ray, M. & Lama, A. (2025), 'Integrating spatial and temporal dynamics for rainfall prediction using the starma model in uttar pradesh', *Journal of Scientific Research and Reports* **31**(5), 87–101.
- Sofia, D. A., Sujono, J. & Legono, D. (2018), 'Analisis variabilitas spasial dan temporal curah hujan di wilayah gunung merapi', *Jurnal Teknisia* **23**(1), xx–xx.
- Suryana, D., Rahman, A., Fatonah, S., Nirmala, C. A. & Williemi, H. (2023), 'Time series clustering analysis using dynamic time warping technique of daily rainfall in bengkulu province', *Current Science* **124**(4), 447–455.
- Utami, E. R. (2017), Penerapan generalized spatial three stage least square (gs3sls) pada persamaan simultan spasial untuk pemodelan pertumbuhan ekonomi jawa timur, Tesis, program magister, jurusan statistika, fakultas matematika dan ilmu pengetahuan alam, Institut Teknologi Sepuluh Nopember, Surabaya.

Lampiran

1. Data Keseluruhan

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
1/31/2015	12.24129032	112.84	-7.31	Timur
2/28/2015	10.2975	112.84	-7.31	Timur
3/31/2015	8.840645161	112.84	-7.31	Timur
4/30/2015	5.790666667	112.84	-7.31	Timur
5/31/2015	3.477096774	112.84	-7.31	Timur
6/30/2015	0.376	112.84	-7.31	Timur
7/31/2015	0.15483871	112.84	-7.31	Timur
8/31/2015	0.219032258	112.84	-7.31	Timur
9/30/2015	0.013	112.84	-7.31	Timur
10/31/2015	0	112.84	-7.31	Timur
11/30/2015	2.693666667	112.84	-7.31	Timur
12/31/2015	5.48871	112.84	-7.10	Timur
⋮	⋮	⋮	⋮	⋮
1/31/2024	8.01516129	112.84	-7.31	Timur
2/29/2024	11.49931034	112.84	-7.31	Timur
3/31/2024	5.201612903	112.84	-7.31	Timur
4/30/2024	7.265	112.84	-7.31	Timur
5/31/2024	0.539067742	112.84	-7.31	Timur
6/30/2024	1.507333333	112.84	-7.31	Timur
7/31/2024	0.777741935	112.84	-7.31	Timur
8/31/2024	0.029677419	112.84	-7.31	Timur
9/30/2024	0.612666667	112.84	-7.31	Timur
10/31/2024	1.226771494	112.84	-7.31	Timur
11/30/2024	5.631	112.84	-7.31	Timur
12/31/2024	12.3116129	112.84	-7.31	Timur
1/31/2015	13.95225806	112.61	-7.24	Barat
2/28/2015	11.87321429	112.61	-7.24	Barat
3/31/2015	9.44516129	112.61	-7.24	Barat
4/30/2015	7.664666667	112.61	-7.24	Barat
5/31/2015	3.707096774	112.61	-7.24	Barat
6/30/2015	0.404	112.61	-7.24	Barat

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
7/31/2015	0.044193548	112.61	-7.24	Barat
8/31/2015	0.253225806	112.61	-7.24	Barat
9/30/2015	0.002666667	112.61	-7.24	Barat
10/31/2015	0.000645161	112.61	-7.24	Barat
11/30/2015	3.233	112.61	-7.24	Barat
12/31/2015	5.888709677	112.61	-7.24	Barat
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.657419355	112.61	-7.24	Barat
2/29/2024	13.18304483	112.61	-7.24	Barat
3/31/2024	6.666129032	112.61	-7.24	Barat
4/30/2024	8.748666667	112.61	-7.24	Barat
5/31/2024	0.61516129	112.61	-7.24	Barat
6/30/2024	2.328	112.61	-7.24	Barat
7/31/2024	0.880645161	112.61	-7.24	Barat
8/31/2024	0.102258065	112.61	-7.24	Barat
9/30/2024	1.314	112.61	-7.24	Barat
10/31/2024	1.468064516	112.61	-7.24	Barat
11/30/2024	6.292666667	112.61	-7.24	Barat
12/31/2024	13.62387097	112.61	-7.24	Barat
1/31/2015	14.30387097	112.73	-7.35	Selatan
2/28/2015	12.15035714	112.73	-7.35	Selatan
3/31/2015	11.21225806	112.73	-7.35	Selatan
4/30/2015	7.384	112.73	-7.35	Selatan
5/31/2015	3.871935484	112.73	-7.35	Selatan
6/30/2015	0.249333333	112.73	-7.35	Selatan
7/31/2015	0.038064516	112.73	-7.35	Selatan
8/31/2015	0.269354839	112.73	-7.35	Selatan
9/30/2015	0.001666667	112.73	-7.35	Selatan
10/31/2015	0	112.73	-7.35	Selatan
11/30/2015	3.351666667	112.73	-7.35	Selatan
12/31/2015	5.399354839	112.73	-7.35	Selatan
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.912258065	112.73	-7.35	Selatan
2/29/2024	13.8037931	112.73	-7.35	Selatan
3/31/2024	4.729354839	112.73	-7.35	Selatan
4/30/2024	9.16	112.73	-7.35	Selatan
5/31/2024	0.340645161	112.73	-7.35	Selatan
6/30/2024	2.391	112.73	-7.35	Selatan
7/31/2024	0.822580645	112.73	-7.35	Selatan
8/31/2024	0.074838871	112.73	-7.35	Selatan

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
9/30/2024	1.493	112.73	-7.35	Selatan
10/31/2024	1.249032258	112.73	-7.35	Selatan
11/30/2024	6.636666667	112.73	-7.35	Selatan
12/31/2024	13.51903226	112.73	-7.35	Selatan
1/31/2015	13.89774194	112.73	-7.2	Utara
2/28/2015	11.93107143	112.73	-7.2	Utara
3/31/2015	9.387419355	112.73	-7.2	Utara
4/30/2015	7.462333333	112.73	-7.2	Utara
5/31/2015	3.97516129	112.73	-7.2	Utara
6/30/2015	0.409333333	112.73	-7.2	Utara
7/31/2015	0.040645161	112.73	-7.2	Utara
8/31/2015	0.256129032	112.73	-7.2	Utara
9/30/2015	0.003333333	112.73	-7.2	Utara
10/31/2015	0.000645161	112.73	-7.2	Utara
11/30/2015	3.227	112.73	-7.2	Utara
12/31/2015	5.791935484	112.73	-7.2	Utara
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.479677419	112.73	-7.2	Utara
2/29/2024	13.38482759	112.73	-7.2	Utara
3/31/2024	6.628709677	112.73	-7.2	Utara
4/30/2024	8.795	112.73	-7.2	Utara
5/31/2024	0.610967742	112.73	-7.2	Utara
6/30/2024	2.319	112.73	-7.2	Utara
7/31/2024	0.882258065	112.73	-7.2	Utara
8/31/2024	0.117741935	112.73	-7.2	Utara
9/30/2024	1.306333333	112.73	-7.2	Utara
10/31/2024	1.127096774	112.73	-7.2	Utara
11/30/2024	6.537	112.73	-7.2	Utara
12/31/2024	13.60354839	112.73	-7.2	Utara
1/31/2015	14.25870968	112.74	-7.26	Tengah
2/28/2015	12.17071429	112.74	-7.26	Tengah
3/31/2015	11.19290323	112.74	-7.26	Tengah
4/30/2015	7.007	112.74	-7.26	Tengah
5/31/2015	4.287741935	112.74	-7.26	Tengah
6/30/2015	0.249666667	112.74	-7.26	Tengah
7/31/2015	0.038837097	112.74	-7.26	Tengah
8/31/2015	0.269677419	112.74	-7.26	Tengah
9/30/2015	0.001666667	112.74	-7.26	Tengah
10/31/2015	0	112.74	-7.26	Tengah
11/30/2015	3.352666667	112.74	-7.26	Tengah
12/31/2015	5.317741935	112.74	-7.26	Tengah

Date	PRECTOTCORR	Longitude	Latitude	Wilayah
⋮	⋮	⋮	⋮	⋮
1/31/2024	9.722258065	112.74	-7.26	Tengah
2/29/2024	14.05206897	112.74	-7.26	Tengah
3/31/2024	4.01290323	112.74	-7.26	Tengah
4/30/2024	9.200666667	112.74	-7.26	Tengah
5/31/2024	0.341935484	112.74	-7.26	Tengah
6/30/2024	2.375	112.74	-7.26	Tengah
7/31/2024	0.830322581	112.74	-7.26	Tengah
8/31/2024	0.083548387	112.74	-7.26	Tengah
9/30/2024	1.493	112.74	-7.26	Tengah
10/31/2024	0.837096774	112.74	-7.26	Tengah
11/30/2024	6.660666667	112.74	-7.26	Tengah
12/31/2024	13.59290323	112.74	-7.26	Tengah

2. Data Train

Barat	Selatan	Tengah	Timur	Utara
13.9522581	14.303871	14.258710	12.241903	13.8977419
11.8732143	12.150357	12.170714	10.297500	11.9310714
9.4451613	11.212258	11.192903	8.8406452	9.3874194
7.6646667	7.384000	7.007000	5.7906667	7.4623333
3.7070968	3.871935	4.287742	3.4770968	3.9751613
0.4040000	0.249333	0.249667	0.3760000	0.4093333
0.0441935	0.038065	0.038387	0.0154839	0.0406452
0.2532258	0.269355	0.269677	0.2190323	0.2561290
0.0026667	0.0017	0.0016667	0.0130000	0.0033333
0.0006452	0	0	0	0.0000452
3.2330000	3.351667	3.352667	2.6936667	5.7918355
5.8887097	5.399355	5.317742	5.6648387	17.7812903
7.6958065	7.416774	7.486774	6.9264516	16.2137903
16.2608968	16.252607	16.232759	12.477016	40.6182258
6.0390323	6.234516	6.254839	5.6167742	7.2476667
7.4933333	7.335333	7.246467	7.0996667	8.8454839
8.7500000	9.826129	9.908710	9.4874194	4.8880000
4.9133333	4.612333	4.607000	4.6306774	4.4390323
4.4196774	4.740645	4.745161	4.3209677	2.1390323
2.3100000	2.354516	2.355161	1.9212903	2.1435484
4.5103333	4.512000	4.460333	2.9830000	4.4476667
8.6964516	9.065161	9.115484	7.4983333	8.7532258
5.3376667	5.466000	5.443667	4.4323333	5.3040000

Barat	Selatan	Tengah	Timur	Utara
10.3970968	9.911613	9.783548	9.0038710	10.1619355
13.1619355	13.314839	13.462903	12.5758065	13.4058065
9.9450000	9.688214	9.641071	9.4150000	9.8985714
6.9183871	6.891290	6.886452	6.7719355	6.9277419
6.8566667	7.246667	7.234333	5.7630000	8.6170000
4.0541935	3.680323	3.744839	3.7790323	4.1216129
2.9860000	2.887333	2.901333	3.4906667	3.0146667
1.0255806	1.072903	1.072903	1.1074194	1.0577419
0.0145161	0.019677	0.019677	0.1312903	0.0190323
0.4850000	0.376333	0.359667	0.2133333	0.4490000
2.7874194	2.475484	2.429258	1.4987097	2.8235484
9.8060000	9.349333	9.329000	9.6909333	9.7676667
11.1319355	10.706452	10.715161	9.8096774	11.1403226
9.0793548	8.859355	8.705806	10.7912903	7.1409677
14.0025000	15.132143	15.233571	10.5642857	14.0453571
9.1022903	9.930000	9.933871	7.9183871	10.2858065
4.3100000	4.352000	4.424667	3.1780000	4.3850000
4.0970968	4.262258	4.262903	2.6509677	4.2193226
2.0626667	2.401333	2.401667	1.5463333	2.0676667
0.0293548	0.030645	0.030645	0.0190000	0.0303226
0.5587097	0.634194	0.634194	0.7261290	0.5432258
0.1590000	0.041333	0.041333	0.0336667	0.1736667
0.9377097	0.738271	0.808667	0.3077419	0.2978710
5.4080000	5.532667	5.811333	5.4786667	5.5660000
9.6355484	10.240516	11.021613	7.5906774	9.2960000
15.0722581	14.639355	14.610000	12.7341935	14.0992258
17.2406935	18.067786	13.547500	13.4639286	12.2650000
8.4096774	7.850323	7.807742	7.3274194	8.8325806
8.6616667	9.671333	9.573333	8.5500000	8.4970000
0.9851613	0.871290	1.097419	0.4906452	1.2558065
0.1136667	0.0500000	0.0500000	0.0526667	0.1136667
0.0341935	0.0300000	0.0296777	0.0333871	0.0341935
0.3422581	0.504516	0.404194	0.3035484	0.3093548
0.4550000	0.624667	0.571000	0.3790000	0.4340000
0.0522581	0.011613	0.157742	0.0451935	0.0707419
0.8136667	0.786000	0.789667	0.6576667	0.8170000
5.8129032	5.629355	5.580645	4.6741935	5.7177097
11.4467742	10.878387	10.314194	9.5616129	11.1383871
14.6462097	14.437931	15.086977	13.7755157	15.0072581
9.1287097	10.100323	10.093871	9.6906452	9.1793548

Barat	Selatan	Tengah	Timur	Utara
10.9736667	11.3476667	11.360333	9.6100000	12.3061290
6.9148387	7.669032	7.617742	6.2925806	6.8587097
1.5520000	1.171000	1.225667	1.0213333	1.6150000
0.8629032	0.695161	0.695161	0.8467742	0.8651613
0.8274194	0.822581	0.822258	0.6532903	0.8270968
0.4460000	0.319000	0.319333	0.2993333	0.4426667
3.2245161	3.501935	3.347742	3.9208365	3.1032581
4.2633333	4.553333	4.712000	5.1683333	4.3853333
17.4945161	18.056774	17.578710	15.5209032	17.8980323
14.9816129	14.581290	14.956129	12.6345161	15.2096774
16.9085714	17.914643	17.983571	15.6323143	16.9203143
10.6554839	10.404516	10.256774	8.720323	10.5732258
3.2076667	3.191000	3.383667	3.440333	3.3916667
12.1080645	11.808065	1.807097	2.3787097	2.1209032
4.1400000	4.543000	4.541000	4.099667	4.1476667
0.2703226	0.302258	0.303023	0.3738710	0.2683548
0.3832258	0.284194	0.289032	0.2258065	0.3893548
0.2680000	2.434677	2.419000	2.2376667	2.6790000
1.9503226	1.184839	1.158387	1.1535484	1.9329032
9.9246667	10.540667	10.296767	10.0633333	9.7332000
13.2767742	13.717419	13.797097	13.3867742	13.2800000
9.9790323	10.203323	10.363548	9.7714935	10.1479032
12.2182143	11.081786	10.096071	11.243926	12.1326143
10.1454839	11.110000	11.201290	9.9209677	10.2306452
5.3926667	5.479333	5.458000	4.5153333	5.3733333
7.5806452	8.720645	8.635806	7.1425806	7.552806
4.5080000	4.860333	4.990667	3.9916667	5.1663333
2.7145161	2.675484	2.675806	1.8054839	2.7409677
0.7350000	0.731444	0.741000	0.6045161	0.8190000
2.4716667	2.898333	2.826333	2.0676667	2.3710000
2.7483871	2.928774	2.893871	2.1570968	3.7022581
9.3650000	9.823333	9.300000	9.9753333	9.4416667
9.13577419	17.739355	7.490645	6.8522581	8.79703226
9.5374194	9.942581	10.157742	7.9122581	9.8416129
16.8142857	17.490714	17.365714	14.3935714	16.7035714
6.7612903	6.586452	6.588710	6.4235484	6.8174194
8.4820000	9.307667	9.474333	7.2303333	8.5806667
2.1967742	1.957742	1.965806	1.4864516	2.2161290
0.5126667	0.401000	0.400333	0.5450000	0.5096667
2.3080645	1.745484	1.746774	2.0241935	2.3116129

Barat	Selatan	Tengah	Timur	Utara
0.0780645	0.052903	0.052903	0.0667742	0.0783871
0.0443333	0.031000	0.031000	0.0646667	0.0443333
0.0735484	0.054516	0.054194	0.0096774	0.0719355
3.5803333	2.410000	2.394000	2.7973333	3.4723333
24.714193	28.639355	28.602903	16.1096774	24.7951613


3. Data Test

Barat	Selatan	Tengah	Timur	Utara
9.6574	9.91226	9.72226	8.01516	9.4797
13.1803	13.80379	14.05207	11.49931	13.3848
6.6661	4.72935	4.70129	5.20161	6.6287
8.7487	9.16000	9.20067	7.26500	8.7950
0.6152	0.34065	0.34194	0.53907	0.6110
2.3280	2.39100	2.37500	1.50733	2.3190
0.8806	0.82258	0.83032	0.77774	0.8823
0.1023	0.07484	0.08355	0.02968	0.1177
1.3140	1.49300	1.49300	0.61267	1.3063
1.4681	1.24903	0.83710	1.22677	1.1271
6.2927	6.36367	6.66067	5.63100	6.5370
13.6139	13.51903	13.59290	12.31161	13.6035


4. SARIMA Plot ACF dan PACF

a. Plot ACF dan PACF sebelum Transformasi


i. Barat




ii. Selatan




iii. Tengah



iv. Timur




v. Utara




b. Plot ACF dan PACF setelah Transformasi


i. Barat




ii. Selatan




iii. Tengah



iv. Timur



v. Utara



5. SARIMA Estimasi Parameter Barat

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0001
	SE							720.067
	t-value							-0.001
	p-value							0.999
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4775				
	SE			0.128				
	t-value			-3.735				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.2223				-0.7755
	SE			0.146				0.236
	t-value			-1.522				-3.282
	p-value			0.128				0.001
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3287		-1.0000
	SE					0.211		683.267
	t-value					1.561		-0.001
	p-value					0.119		0.999
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4854		0.2454		
	SE			0.144		0.176		
	t-value			-3.382		1.397		
	p-value			0.001		0.162		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.2532		0.3068		-0.7806
	SE			0.186		0.183		0.253
	t-value			-1.363		1.678		-3.083
	p-value			0.173		0.093		0.002
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.1305						
	SE	0.119						
	t-value	1.097						
	p-value	0.272						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.2404						-1.000
	SE	0.187						1187.201
	t-value	1.287						-0.001
	p-value	0.198						0.999
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.1839		-0.4794				
	SE	0.158		0.145				
	t-value	1.166		-3.296				
	p-value	0.244		0.001				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.2330		-0.2824				-0.7728
	SE	0.166		0.170				0.239
	t-value	1.400		-1.658				-3.240
	p-value	0.161		0.097				0.001
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	-0.4356				0.6652		
	SE	0.389				0.322		
	t-value	-1.120				2.067		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	p-value	0.263				0.039		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	-0.3419				0.6365		-1.0001
	SE	0.448				0.356		565.752
	t-value	-0.763				1.785		-0.002
	p-value	0.445				0.074		0.999
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.4272		-0.4868		0.6750		
	SE	0.508		0.147		0.406		
	t-value	-0.841		-3.309		1.662		
	p-value	0.400		0.001		0.097		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.4286		-0.2521		0.7181		-0.7879
	SE	0.449		0.204		0.331		0.260
	t-value	-0.955		-1.237		2.168		-3.036
	p-value	0.339		0.216		0.030		0.002
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.2320		
	SE					0.140		
	t-value					1.652		
	p-value					0.099		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.2882		-0.7626	-0.5659			
	SE	0.176		0.163	0.107			
	t-value	1.639		-4.680	-5.313			
	p-value	0.101		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							4308.205
	t-value							-0.000
	p-value							1.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4577				
	SE			0.091				
	t-value			-5.036				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3598				-1.0000
	SE			0.109				1731.553
	t-value			-3.306				-0.001
	p-value			0.001				1.000
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3670		-1.0000
	SE					0.113		5015.431
	t-value					3.238		-0.000
	p-value					0.001		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5060		0.3615		
	SE			0.088		0.109		
	t-value			-5.748		3.321		
	p-value			0.000		0.001		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3928		0.4205		-1.0000
	SE			0.114		0.121		1833.246
	t-value			-3.445		3.469		-0.001
	p-value			0.001		0.001		1.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.4326						
	SE	0.089						
	t-value	4.880						
	p-value	0.000						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.3741						-1.000
	SE	0.118						6493.269
	t-value	3.157						-0.000
	p-value	0.002						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.3470		-0.4913				
	SE	0.109		0.092				
	t-value	3.182		-5.315				
	p-value	0.001		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.3840		-0.3915				-1.0000
	SE	0.129		0.118				2921.273
	t-value	2.977		-3.316				-0.000
	p-value	0.003		0.001				1.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.7032				-0.3265		
	SE	0.153				0.233		
	t-value	4.590				-1.401		
	p-value	0.000				0.161		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.3677				0.0128		-1.0000
	SE	0.273				0.296		7076.731
	t-value	1.347				0.043		-0.000
	p-value	0.178				0.966		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	0.2193		-0.4961		0.1461		
	SE	0.331		0.092		0.337		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(1, 0, 1) \times (1, 1, 1)_{12}$	t-value	0.663		-5.387		0.434		
	p-value	0.508		0.000		0.665		
	Estimasi	0.1768		-0.3859		0.2462		-1.0000
	SE	0.277		0.118		0.268		2022.150
	t-value	0.638		-3.258		0.920		-0.000
	p-value	0.524		0.001		0.358		1.0000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.3715		
	SE					0.109		
	t-value					3.406		
	p-value					0.001		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.4773		-0.8211	-0.4020			
	SE	0.127		0.167	0.147			
	t-value	3.761		-4.919	-2.738			
	p-value	0.000		0.000	0.006			

6. SARIMA Estimasi Parameter Selatan

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							1363.139
	t-value							-0.001
	p-value							0.999
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5601				
	SE			0.128				
	t-value			-4.389				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3285				-0.7504
	SE			0.141				0.224
	t-value			-2.334				-3.352
	p-value			0.020				0.001
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.1999		-1.0000
	SE					0.229		1700.248
	t-value					0.875		-0.001
	p-value					0.382		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5672		0.1131		
	SE			0.149		0.185		
	t-value			-3.804		0.612		
	p-value			0.000		0.540		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3480		0.2071		-0.7746
	SE			0.1740		0.190		0.250
	t-value			-2.005		1.088		-3.093
	p-value			0.045		0.276		0.002
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.669						
	SE	0.125						
	t-value	0.536						
	p-value	0.592						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.1504						-1.0000
	SE	0.203						1248.809
	t-value	0.741						-0.001
	p-value	0.459						0.999
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.0928		-0.5609				
	SE	0.172		0.149				
	t-value	0.541		-3.774				
	p-value	0.589		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.1742		-0.3768				-0.7615
	SE	0.176		0.163				0.232
	t-value	0.990		-2.318				-3.280
	p-value	0.322		0.020				0.001
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	-0.4540				0.5948		
	SE	0.653				0.5962		
	t-value	-0.696				0.998		
	p-value	0.487				0.318		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	-0.3716				0.5557		-1.0000
	SE	0.726				0.674		1652.656
	t-value	-0.512				0.825		-0.001
	p-value	0.609				0.410		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.5225		-0.5712		0.6614		
	SE	0.837		0.156		0.739		
	t-value	-0.625		-3.671		0.894		
	p-value	0.532		0.000		0.371		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.4681		-0.3482		0.6729		-0.7780
	SE	0.619		0.188		0.512		0.255
	t-value	-0.757		-1.848		1.315		-3.047
	p-value	0.449		0.065		0.188		0.002
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.1276		
	SE					0.143		
	t-value					0.894		
	p-value					0.371		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.2410		-0.8984	-0.6420			
	SE	0.168		0.141	0.112			
	t-value	1.439		-6.357	-5.728			
	p-value	0.150		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							9121.468
	t-value							-0.000
	p-value							1.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4906				
	SE			0.087				
	t-value			-5.658				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3953				-1.000
	SE			0.104				3243.976
	t-value			-3.797				-0.000
	p-value			0.000				1.000
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.2885		-1.0000
	SE					0.117		2.39e+04
	t-value					2.471		-4.19e-05
	p-value					0.013		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5328		0.2858		
	SE			0.086		0.111		
	t-value			-6.187		2.586		
	p-value			0.000		0.010		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.4215		0.3383		-1.0000
	SE			0.109		0.134		1907.989
	t-value			-3.877		2.526		-0.001
	p-value			0.000		0.012		1.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.3739						
	SE	0.092						
	t-value	4.053						
	p-value	0.000						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.3068						-1.000
	SE	0.112						4894.193
	t-value	2.728						-0.000
	p-value	0.006						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.2882		-0.5254				
	SE	0.107		0.089				
	t-value	2.693		-5.880				
	p-value	0.007		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.3285		-0.4249				-1.0000
	SE	0.128		0.111				3160.155
	t-value	2.574		-3.835				-0.000
	p-value	0.010		0.000				1.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.6981				-0.3735		
	SE	0.172				0.243		
	t-value	4.058				-1.534		
	p-value	0.000				0.125		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.4137				-0.1153		-1.0000
	SE	0.322				0.375		5.11e+05
	t-value	1.284				-0.308		-1.96e-06
	p-value	0.199				-0.758		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	0.2318		-0.5268		0.0624		
	SE	0.406		0.089		0.428		
	t-value	0.571		-5.915		0.146		
	p-value	0.0568		0.000		0.884		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2399		-0.4160		0.1046		-1.0000
	SE	0.331		0.113		0.361		4733.994
	t-value	0.725		-3.693		0.289		-0.000
	p-value	0.469		0.000		0.772		1.0000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.3024		
	t-value					2.751		

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	p-value					0.006		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.4099		-0.8824	-0.4082			
	SE	0.125		0.156	0.138			
	t-value	3.279		-5.669	-2.948			
	p-value	0.001		0.000	0.003			

7. SARIMA Estimasi Parameter Tengah

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							1433.210
	t-value							-0.001
	p-value							0.999
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.5720				
	SE			0.124				
	t-value			-4.596				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3385				-0.7565
	SE			0.138				0.234
	t-value			-2.452				-3.237
	p-value			0.014				0.001
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.2176		-1.0000
	SE					0.227		1098.050
	t-value					0.961		-0.001
	p-value					0.337		0.999
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5809		0.1279		
	SE			0.149		0.190		
	t-value			-3.892		0.673		
	p-value			0.000		0.501		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3635		0.2308		-0.7849
	SE			0.169		0.187		0.266
	t-value			-2.156		1.231		-2.950
	p-value			0.031		0.218		0.003
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.0722						
	SE	0.124						
	t-value	0.583						
	p-value	0.560						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.1617						-1.0000
	SE	0.200						1444.310
	t-value	0.808						-0.001
	p-value	0.419						0.999
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.1046		-0.5738				
	SE	0.177		0.149				
	t-value	0.592		-3.861				
	p-value	0.554		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.1965		-0.3963				-0.7716
	SE	0.176		0.159				0.245
	t-value	1.113		-2.499				-3.150
	p-value	0.266		0.012				0.002
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	-0.4551				0.6118		
	SE	0.599				0.543		
	t-value	-0.760				1.128		
	p-value	0.447				0.259		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	-0.3533				0.5535		-1.0000
	SE	0.696				0.645		1810.836
	t-value	-0.507				0.858		-0.001
	p-value	0.612				0.391		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.4996		-0.5807		0.6492		
	SE	0.833		0.156		0.736		
	t-value	-0.600		-3.733		0.881		
	p-value	0.548		0.000		0.378		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.4128		-0.3570		0.6363		-0.7872
	SE	0.629		0.185		0.527		0.272
	t-value	-0.656		-1.925		1.207		-2.896
	p-value	0.512		0.054		0.227		0.004
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.1412		
	SE					0.143		
	t-value					0.990		
	p-value					0.322		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.2568		-0.9200	-0.6440			
	SE	0.163		0.137	0.113			

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	t-value	1.577		-6.718	-5.688			
	p-value	0.115		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							1601.479
	t-value							-0.001
	p-value							1.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4653				
	SE			0.086				
	t-value			-5.429				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3862				-1.000
	SE			0.104				2989.853
	t-value			-3.720				-0.000
	p-value			0.000				1.000
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3068		-1.0000
	SE					0.114		3754.304
	t-value					2.694		-0.000
	p-value					0.007		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4979		0.2809		
	SE			0.086		0.108		
	t-value			-5.769		2.600		
	p-value			0.000		0.009		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3994		0.3337		-1.0000
	SE			0.112		0.135		1766.312
	t-value			-3.558		2.468		-0.001
	p-value			0.000		0.014		1.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.3889						
	SE	0.091						
	t-value	4.276						
	p-value	0.000						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.3105						-1.000
	SE	0.111						3858.451
	t-value	2.808						-0.000
	p-value	0.005						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.2767		-0.4908				
	SE	0.105		0.089				
	t-value	2.631		-5.503				
	p-value	0.009		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.3204		-0.4078				-1.0000
	SE	0.127		0.114				3610.869
	t-value	2.518		-3.582				-0.000
	p-value	0.012		0.000				1.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.6795				-0.3401		
	SE	0.178				0.260		
	t-value	3.815				-1.308		
	p-value	0.000				0.191		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.3100				0.0070		-1.0000
	SE	0.334				0.365		1.76e+04
	t-value	0.929				0.019		-5.7e-05
	p-value	0.353				0.985		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	0.1887		-0.4920		0.0960		
	SE	0.428		0.089		0.444		
	t-value	0.441		-5.515		0.216		
	p-value	0.659		0.000		0.829		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	0.2540		-0.3959		0.0806		-1.0000
	SE	0.337		0.116		0.377		4262.632
	t-value	0.753		-3.409		0.214		-0.000
	p-value	0.451		0.001		0.831		1.0000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.3323		
	SE					0.110		
	t-value					3.019		
	p-value					0.003		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.4438		-0.8717	-0.4828			
	SE	0.122		0.156	0.151			
	t-value	3.642		-5.584	-3.192			
	p-value	0.000		0.000	0.001			

8. SARIMA Estimasi Parameter Timur

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							2708.317
	t-value							-0.000
	p-value							1.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4072				
	SE			0.105				
	t-value			-3.871				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.1556				-1.0001
	SE			0.108				963.221
	t-value			-1.444				-0.001
	p-value			0.149				0.999
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3015		-1.0000
	SE					0.140		2497.145
	t-value					2.162		-0.000
	p-value					0.031		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4256		0.2711		
	SE			0.114		0.148		
	t-value			-3.732		1.826		
	p-value			0.000		0.068		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.2007		0.2677		-1.0001
	SE			0.120		0.134		380.423
	t-value			-1.677		1.995		-0.003
	p-value			0.094		0.046		0.998
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.1479						
	SE	0.096						
	t-value	1.537						
	p-value	0.124						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.2835						-1.0000
	SE	0.126						3518.174
	t-value	2.249						-0.000
	p-value	0.024						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.2370		-0.4266				
	SE	0.128		0.113				
	t-value	1.845		-3.790				
	p-value	0.065		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.2499		-0.2127				-1.0001
	SE	0.131		0.119				374.919
	t-value	-1.908		-1.787				-0.003
	p-value	0.056		0.074				0.998
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	-0.4344				0.6304		
	SE	0.425				0.384		
	t-value	-1.022				1.640		
	p-value	0.307				0.101		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	-0.3007				0.5801		-1.0000
	SE	0.398				0.357		5046.194
	t-value	-0.755				1.623		-0.000
	p-value	0.450				0.105		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.3447		-0.4284		0.6090		
	SE	0.454		0.116		0.389		
	t-value	-0.759		-3.689		1.565		
	p-value	0.448		0.000		0.118		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.2718		-0.1929		0.5303		-1.0001
	SE	0.472		0.132		0.403		560.759
	t-value	-0.576		-1.459		1.315		-0.002
	p-value	0.565		-0.452		0.189		0.999
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.2047		
	SE					0.118		
	t-value					1.732		
	p-value					0.083		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.2945		-0.6657	-0.4762			
	SE	0.138		0.120	0.100			
	t-value	2.131		-5.571	-4.758			
	p-value	0.033		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							4409.547
	t-value							-0.000
	p-value							1.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4754				
	SE			0.085				
	t-value			-5.607				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3677				-1.0000
	SE			0.113				3444.686
	t-value			-3.268				-0.000
	p-value			0.001				1.000
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3757		-1.0000
	SE					0.129		4169.989
	t-value					2.903		-0.000
	p-value					0.004		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5613		0.4197		
	SE			0.080		0.115		
	t-value			-7.022		3.635		
	p-value			0.000		0.000		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.4551		0.4774		-1.0000
	SE			0.116		0.125		2855.887
	t-value			-3.919		3.825		-0.000
	p-value			0.000		0.000		1.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.3822						
	SE	0.090						
	t-value	4.255						
	p-value	0.000						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.3797						-1.0000
	SE	0.127						6342.783
	t-value	3.000						-0.000
	p-value	0.003						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.3761		-0.5439				
	SE	0.112		0.081				
	t-value	3.364		-6.689				
	p-value	0.001		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.4163		-0.4400				-1.0000
	SE	0.151		0.116				3076.504
	t-value	2.764		-3.781				-0.000
	p-value	0.006		0.000				1.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.7288				-0.4088		
	SE	0.170				0.249		
	t-value	4.279				-1.642		
	p-value	0.000				0.101		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.3845				-0.0066		-1.0000
	SE	0.288				0.317		1583.677
	t-value	1.337				-0.021		-0.001
	p-value	0.181				0.983		0.999
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.2965		-0.5834		0.7107		
	SE	0.234		0.085		0.188		
	t-value	-1.268		-6.896		3.778		
	p-value	0.205		0.000		0.000		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.2020		-0.4674		0.6726		-1.0000
	SE	0.300		0.115		0.188		2314.164
	t-value	-0.674		-4.054		3.583		-0.000
	p-value	0.500		0.000		0.000		1.0000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.3334		
	SE					0.108		
	t-value					3.096		
	p-value					0.002		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.4341		-0.8649	-0.3188			
	SE	0.138		0.170	0.153			
	t-value	3.137		-5.074	-2.085			
	p-value	0.002		0.000	0.037			

9. SARIMA Estimasi Parameter Utara

a. Tanpa Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal	Seasonal	
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							1302.960

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
	t-value							-0.001
	p-value							0.999
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4900				
	SE			0.124				
	t-value			-3.938				
	p-value			0.000				
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.2348				-0.7852
	SE			0.143				0.252
	t-value			-1.645				-3.113
	p-value			0.100				0.002
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3517		-1.0000
	SE					0.215		1259.476
	t-value					1.636		-0.001
	p-value					0.102		0.999
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.5003		0.2634		
	SE			0.143		0.180		
	t-value			-3.492		1.460		
	p-value			0.000		0.144		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.2752		0.3400		-0.7953
	SE			0.181		0.183		0.274
	t-value			-1.516		1.859		-2.897
	p-value			0.129		0.063		0.004
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.1330						
	SE	0.118						
	t-value	1.122						
	p-value	0.262						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.2524						-1.0000
	SE	0.187						1.24e+04
	t-value	1.347						-8.07e-05
	p-value	0.178						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.1940		-0.4937				
	SE	0.162		0.145				
	t-value	1.198		-3.408				
	p-value	0.231		0.001				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.2564		-0.3069				-0.7869
	SE	0.167		0.166				0.256
	t-value	1.538		-1.843				-3.069
	p-value	0.124		0.065				0.002
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	-0.4265				0.6689		
	SE	0.379				0.315		
	t-value	-1.127				2.122		
	p-value	0.260				0.034		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	-0.3105				0.6246		-1.0001
	SE	0.441				0.350		493.351
	t-value	-0.704				1.785		-0.002
	p-value	0.482				0.074		0.998
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.4027		-0.4978		0.6650		
	SE	0.510		0.148		0.409		
	t-value	-0.790		-3.364		1.626		
	p-value	0.430		0.001		0.104		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.3804		-0.2686		0.6969		-0.8025
	SE	0.444		0.204		0.327		0.284
	t-value	-0.856		-1.318		2.133		-2.831
	p-value	0.392		0.187		0.033		0.005
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.2467		
	SE					0.141		
	t-value					1.754		
	p-value					0.079		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.3093		-0.7918	-0.5803			
	SE	0.170		0.157	0.106			
	t-value	1.816		-5.033	-5.457			
	p-value	0.069		0.000	0.000			

b. Transformasi

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi							
	SE							
	t-value							
	p-value							
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi							-1.0000
	SE							4443.846
	t-value							-0.000
	p-value							1.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.4487				
	SE			0.090				
	t-value			-4.963				
	p-value			0.000				

Model	Statistik	AR Parameter				MA Parameter		
		Non Seasonal		Seasonal		Non Seasonal		Seasonal
		AR1	AR2	AR12	AR24	MA1	MA2	MA
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			-0.3574				-1.0000
	SE			0.108				2727.662
	t-value			-3.321				-0.000
	p-value			0.001				1.000
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi					0.3792		-1.0000
	SE					0.112		5532.394
	t-value					3.400		-0.000
	p-value					0.001		1.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4912		0.3613		
	SE			0.089		0.108		
	t-value			-5.549		3.342		
	p-value			0.000		0.001		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.3846		0.4254		-1.0000
	SE			0.115		0.123		1970.551
	t-value			-3.335		3.471		-0.001
	p-value			0.001		0.001		1.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.4391						
	SE	0.088						
	t-value	5.017						
	p-value	0.000						
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.3753						-1.0000
	SE	0.116						9700.163
	t-value	3.226						-0.000
	p-value	0.001						1.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.3419		-0.4767				
	SE	0.108		0.092				
	t-value	3.164		-5.174				
	p-value	0.002		0.000				
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.3821		-0.3862				-1.0000
	SE	0.127		0.118				3840.943
	t-value	3.003		-3.268				-0.000
	p-value	0.003		0.001				1.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.6932				-0.3087		
	SE	0.155				0.239		
	t-value	4.465				-1.289		
	p-value	0.000				0.197		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.3105				0.0823		-1.0000
	SE	0.276				0.289		5078.294
	t-value	1.125				0.285		-0.000
	p-value	0.260				0.775		1.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	0.1677		-0.4820		0.1967		
	SE	0.340		0.093		0.340		
	t-value	0.494		-5.209		0.579		
	p-value	0.621		0.000		0.563		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	0.1215		-0.3801		0.3056		-1.0000
	SE	0.278		0.119		0.261		2036.492
	t-value	0.437		-3.200		1.171		-0.000
	p-value	0.662		0.001		0.241		1.0000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi					0.3874		
	SE					0.109		
	t-value					3.569		
	p-value					0.000		
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.4967		-0.8193	-0.4393			
	SE	0.123		0.163	0.150			
	t-value	4.039		-5.015	-2.929			
	p-value	0.000		0.000	0.003			

10. Hasil Evaluasi SARIMA

a. Tanpa Transformasi

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	3.597	4.764	4.730	1.768	3.611
$(0, 0, 0) \times (0, 1, 1)_{12}$	1.559	1.905	1.971	1.746	1.641
$(0, 0, 0) \times (1, 1, 0)_{12}$	1.971	2.534	2.575	1.529	1.986
$(0, 0, 0) \times (1, 1, 1)_{12}$	1.837	2.631	2.749	1.924	1.962
$(0, 0, 1) \times (0, 1, 0)_{12}$	3.754	4.832	4.837	1.862	3.843
$(0, 0, 1) \times (0, 1, 1)_{12}$	2.446	2.432	2.582	2.094	2.646
$(0, 0, 1) \times (1, 1, 0)_{12}$	2.243	2.621	2.715	1.768	2.366

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 1) \times (1, 1, 1)_{12}$	2.617	3.133	3.351	2.285	2.887
$(1, 0, 0) \times (0, 1, 0)_{12}$	3.662	4.788	4.769	1.835	3.703
$(1, 0, 0) \times (0, 1, 1)_{12}$	2.201	2.278	2.392	2.095	2.342
$(1, 0, 0) \times (1, 1, 0)_{12}$	2.143	2.590	2.664	1.735	2.216
$(1, 0, 0) \times (1, 1, 1)_{12}$	2.491	3.141	3.365	2.284	2.731
$(1, 0, 1) \times (0, 1, 0)_{12}$	3.670	4.814	4.841	1.795	3.769
$(1, 0, 1) \times (0, 1, 1)_{12}$	2.403	2.524	2.666	2.098	2.585
$(1, 0, 1) \times (1, 1, 0)_{12}$	2.358	2.992	3.026	1.814	2.494
$(1, 0, 1) \times (1, 1, 1)_{12}$	2.726	3.388	3.527	2.292	2.946
$(1, 0, 0) \times (2, 1, 0)_{12}$	2.734	3.272	3.408	2.067	2.894

b. Transformasi

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	5.613	5.311	5.140	4.975	5.598
$(0, 0, 0) \times (0, 1, 1)_{12}$	6.380	6.416	6.461	5.458	6.407
$(0, 0, 0) \times (1, 1, 0)_{12}$	6.328	6.353	6.204	5.562	6.342
$(0, 0, 0) \times (1, 1, 1)_{12}$	6.566	6.673	6.528	5.606	6.600
$(0, 0, 1) \times (0, 1, 0)_{12}$	5.400	5.039	4.829	4.829	5.361
$(0, 0, 1) \times (0, 1, 1)_{12}$	6.252	6.276	6.307	5.370	6.269
$(0, 0, 1) \times (1, 1, 0)_{12}$	6.209	6.236	6.121	5.470	6.215
$(0, 0, 1) \times (1, 1, 1)_{12}$	6.418	6.525	6.366	5.568	6.447
$(1, 0, 0) \times (0, 1, 0)_{12}$	5.082	4.680	4.434	4.643	5.016
$(1, 0, 0) \times (0, 1, 1)_{12}$	6.132	6.180	6.225	5.285	6.149
$(1, 0, 0) \times (1, 1, 0)_{12}$	6.124	6.175	6.074	5.419	6.129
$(1, 0, 0) \times (1, 1, 1)_{12}$	6.396	6.523	6.405	5.556	6.427
$(1, 0, 1) \times (0, 1, 0)_{12}$	5.224	4.894	4.632	4.879	5.144
$(1, 0, 1) \times (0, 1, 1)_{12}$	6.171	6.221	6.252	5.320	6.189
$(1, 0, 1) \times (1, 1, 0)_{12}$	6.139	6.178	6.078	5.545	6.155
$(1, 0, 1) \times (1, 1, 1)_{12}$	6.386	6.502	6.384	5.614	6.423
$(1, 0, 0) \times (2, 1, 0)_{12}$	6.314	6.411	6.286	5.572	6.303

11. STARIMA Estimasi Parameter Uniform

a. SLAG 0

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal	Seasonal		Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi					
	SE					
	t-value					
	p-value					

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal	Seasonal		Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi					-0.5559
	SE					0.0412
	t-value					-13.5
	p-value					0.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi		-0.3674			
	SE		0.0409			
	t-value		-8.98			
	p-value		0.000			
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi		0.1387			-0.6216
	SE		0.0866			0.0943
	t-value		1.60			-6.59
	p-value		0.11			0.000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi				0.4146	
	SE				0.0488	
	t-value				8.50	
	p-value				0.000	
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi				0.3739	-0.5799
	SE				0.0517	0.0448
	t-value				7.23	-12.94
	p-value				0.000	0.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi		-0.3602		0.3877	
	SE		0.0396		0.0533	
	t-value		-9.09		7.28	
	p-value		0.000		0.000	
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi		0.2414		0.3270	-0.8901
	SE		0.0771		0.0594	0.0988
	t-value		3.13		5.51	-9.01
	p-value		0.0018		0.000	0.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.4812				
	SE	0.0435				
	t-value	11.1				
	p-value	0.000				
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.2280				-0.5591
	SE	0.0443				0.0486
	t-value	5.15				-11.51
	p-value	0.000				0.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.2867	-0.3046			
	SE	0.0476	0.0427			
	t-value	6.02	-7.13			
	p-value	0.000	0.000			
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.2178	0.3718			-0.9762
	SE	0.0470	0.0867			0.1098
	t-value	4.63	4.29			-8.89
	p-value	0.000	0.000			0.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.5747			-0.1557	
	SE	0.0685			0.0853	
	t-value	8.39			-1.83	
	p-value	0.000			0.069	
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.0483			0.3323	-0.6054
	SE	0.0840			0.1109	0.0514
	t-value	0.57			3.00	-11.78
	p-value	0.5658			0.0029	0.000
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.0304	-0.3671		0.4284	
	SE	0.1028	0.0463		0.1231	
	t-value	-0.30	-7.93		3.48	
	p-value	0.76745	0.000		0.000	
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	0.0934	0.2416		0.2349	-0.8592
	SE	0.0882	0.0851		0.1198	0.1082
	t-value	1.06	2.84		1.96	-7.94
	p-value	0.2902	0.0047		0.0505	0.000
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.2693	-0.4535	-0.2729		

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal	Seasonal		Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
	SE	0.0540	0.0634	0.0502		
	t-value	4.98	-7.15	-5.44		
	p-value	0.000	0.000	0.000		

b. SLAG 1

Model	Statistik	AR Parameter					MA Parameter			
		Non Seasonal		Seasonal			Non Seasonal		Seasonal	
		AR1 ₀	AR1 ₁	AR1 ₀	AR1 ₁	AR2 ₀	MA1 ₀	MA1 ₁	MA1 ₀	MA1 ₁
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi								-0.667	0.112
	SE								0.273	0.273
	t-value								-2.44	0.41
	p-value								0.41	0.683
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi			-0.485	0.120					
	SE			0.249	0.251					
	t-value			-1.94	0.48					
	p-value			0.052	0.633					
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi			0.0004	0.1344				-0.6422	0.0287
	SE			0.5670	0.5710				0.6900	0.6939
	t-value			0.00	0.24				-0.93	0.04
	p-value			1.00	0.81				0.35	0.97
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi						0.0637	0.3595		
	SE						0.2834	0.2860		
	t-value						0.22	1.26		
	p-value						0.82	0.21		
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi						0.0033	0.3808	-0.6682	0.0929
	SE						0.2722	0.2754	0.2696	0.2720
	t-value						0.01	1.38	-2.48	0.34
	p-value						0.990	0.167	0.014	0.733
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi			-0.4873	0.1265		0.0555	0.3430		
	SE			0.2432	0.2452		0.2858	0.2889		
	t-value			-1.99	0.52		0.19	1.19		
	p-value			0.047	0.606		0.846	0.236		
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi			-0.1463	0.3738		-0.0027	0.3445	-0.4954	-0.3761
	SE			0.4559	0.4601		0.3046	0.3084	0.5635	0.5691
	t-value			-0.32	0.81		-0.01	1.12	-0.88	-0.66
	p-value			0.75	0.42		0.99	0.26	0.38	0.51
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.0751	0.4143							
	SE	0.2757	0.2778							
	t-value	0.27	1.49							
	p-value	0.79	0.14							
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	-0.029	0.266						-0.669	0.111
	SE	0.237	0.240						0.292	0.295
	t-value	-0.12	1.11						-2.29	0.38
	p-value	0.903	0.269						0.023	0.707
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.0311	0.2646	-0.4714	0.1726					
	SE	0.2537	0.2566	0.2594	0.2617					
	t-value	0.12	1.03	-1.82	0.66					
	p-value	0.90	0.30	0.07	0.51					
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	-0.0184	0.2458	-0.1135	0.4959				-0.5203	-0.4710
	SE	0.2628	0.2657	0.4988	0.5039				0.6191	0.6257
	t-value	-0.07	0.93	-0.23	0.98				-0.84	-0.75
	p-value	0.94	0.36	0.82	0.33				0.40	0.45
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.1091	0.4616				-0.0457	-0.0923		
	SE	2.1273	2.1279				2.1523	2.1534		
	t-value	0.05	0.22				-0.02	-0.04		
	p-value	0.96	0.83				0.98	0.97		
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	-0.178	0.241				0.217	0.116	-0.704	0.104
	SE	0.517	0.522				0.656	0.663	0.328	0.331
	t-value	-0.34	0.46				0.33	0.17	-2.15	0.31
	p-value	0.730	0.645				0.741	0.861	0.032	0.754
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.0527	0.0411	-0.4832	0.1230		0.1149	0.3024		
	SE	0.5203	0.5272	0.2666	0.2693		0.6340	0.6421		
	t-value	-0.10	0.08	-1.81	0.46		0.18	0.47		
	p-value	0.919	0.938	0.071	0.648		0.856	0.638		
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	-0.1275	0.2415	-0.003	0.2157		0.1360	0.0880	-0.7168	-0.0970
	SE	0.5197	0.5231	0.5433	0.5483		0.6622	0.6703	0.6985	0.7047
	t-value	-0.25	0.46	0.00	0.39		0.21	0.13	-1.03	-0.14
	p-value	0.81	0.65	1.00	0.69		0.84	0.90	0.31	0.89
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.0354	0.2421	-0.6326	0.1870	-0.2724				
	SE	0.2778	0.2809	0.2820	0.2845	0.0502				
	t-value	0.13	0.86	-2.24	0.66	-5.43				
	p-value	0.899	0.389	0.025	0.511	0.000				

12. STARIMA Estimasi Parameter Inverse

a. SLAG 0

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal	Seasonal		Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi					
	SE					
	t-value					
	p-value					
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi					-0.5559
	SE					0.0412
	t-value					-13.5
	p-value					0.000
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi		-0.3674			
	SE		0.0409			
	t-value		-8.98			
	p-value		0.000			
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi		0.1387			-0.6216
	SE		0.0866			0.0943
	t-value		1.60			-6.59
	p-value		0.11			0.000
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi				0.4146	
	SE				0.0488	
	t-value				8.50	
	p-value				0.000	
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi				0.3739	-0.5799
	SE				0.0517	0.0448
	t-value				7.23	-12.94
	p-value				0.000	0.000
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi		-0.3602		0.3877	
	SE		0.0396		0.0533	
	t-value		-9.09		7.28	
	p-value		0.000		0.000	
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi		0.2414		0.3270	-0.8901
	SE		0.0771		0.0594	0.0988
	t-value		3.13		5.51	-9.01
	p-value		0.0018		0.000	0.000
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi	0.4812				
	SE	0.0435				
	t-value	11.1				
	p-value	0.000				
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi	0.2280				-0.5591
	SE	0.0443				0.0486
	t-value	5.15				-11.51
	p-value	0.000				0.000
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi	0.2867	-0.3046			
	SE	0.0476	0.0427			
	t-value	6.02	-7.13			
	p-value	0.000	0.000			
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.2178	0.3718			-0.9762
	SE	0.0470	0.0867			0.1098
	t-value	4.63	4.29			-8.89
	p-value	0.000	0.000			0.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.5747			-0.1557	
	SE	0.0685			0.0853	
	t-value	8.39			-1.83	
	p-value	0.000			0.069	
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.0483			0.3323	-0.6054
	SE	0.0840			0.1109	0.0514
	t-value	0.57			3.00	-11.78
	p-value	0.5658			0.0029	0.000

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal		Seasonal	Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.0304	-0.3671		0.4284	
	SE	0.1028	0.0463		0.1231	
	t-value	-0.30	-7.93		3.48	
	p-value	0.76745	0.000		0.00055	
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	0.0934	0.2416		0.2349	-0.8592
	SE	0.0882	0.0851		0.1198	0.1082
	t-value	1.06	2.84		1.96	-7.94
	p-value	0.2902	0.0047		0.0505	0.000
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.2693	-0.4535	-0.2729		
	SE	0.0540	0.0634	0.0502		
	t-value	4.98	-7.15	-5.44		
	p-value	0.000	0.000	0.000		

b. SLAG 1

Model	Statistik	AR Parameter					MA Parameter			
		Non Seasonal		Seasonal			Non Seasonal		Seasonal	
		AR1 ₀	AR1 ₁	AR1 ₀	AR1 ₁	AR2 ₀	MA1 ₀	MA1 ₁	MA1 ₀	MA1 ₁
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi									
	SE									

Model	Statistik	AR Parameter					MA Parameter			
		Non Seasonal		Seasonal			Non Seasonal		Seasonal	
		AR1 ₀	AR1 ₁	AR1 ₀	AR1 ₁	AR2 ₀	MA1 ₀	MA1 ₁	MA1 ₀	MA1 ₁
$(1, 0, 1) \times (1, 1, 1)_{12}$	t-value									
	p-value									
	Estimasi									
	SE									
	t-value									
$(1, 0, 0) \times (2, 1, 0)_{12}$	p-value									
	Estimasi									
	SE									
	t-value									
	p-value									

13. STARIMA Estimasi Parameter Korelasi Silang

a. SLAG 0

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal	Seasonal		Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
(0, 0, 0) × (0, 1, 0) ₁₂	Estimasi					
	SE					
	t-value					
	p-value					
(0, 0, 0) × (0, 1, 1) ₁₂	Estimasi					-0.556
	SE					0.220
	t-value					-2.53
	p-value					0.0131
(0, 0, 0) × (1, 1, 0) ₁₂	Estimasi		-0.367			
	SE		0.205			
	t-value		-1.79			
	p-value		0.0761			
(0, 0, 0) × (1, 1, 1) ₁₂	Estimasi		0.139			-0.622
	SE		0.188			0.231
	t-value		0.737			-2.694
	p-value		0.4631			0.008
(0, 0, 1) × (0, 1, 0) ₁₂	Estimasi				0.415	
	SE				0.164	
	t-value				2.52	
	p-value				0.0134	
(0, 0, 1) × (0, 1, 1) ₁₂	Estimasi				0.374	-0.580
	SE				0.144	0.212
	t-value				2.59	-2.73
	p-value				0.0110	0.0074
(0, 0, 1) × (1, 1, 0) ₁₂	Estimasi		-0.360		0.388	
	SE		0.183		0.160	
	t-value		-1.97		2.42	
	p-value		0.0521		0.0174	
(0, 0, 1) × (1, 1, 1) ₁₂	Estimasi		0.241		0.327	-0.890
	SE		0.221		0.193	0.284
	t-value		1.09		1.69	-3.14
	p-value		0.2777		0.0943	0.0022
(1, 0, 0) × (0, 1, 0) ₁₂	Estimasi	0.481				
	SE	0.159				
	t-value	3.02				
	p-value	0.0032				
(1, 0, 0) × (0, 1, 1) ₁₂	Estimasi	0.228				-0.559
	SE	0.143				0.210
	t-value	1.59				-2.66
	p-value	0.1146				0.0092
(1, 0, 0) × (1, 1, 0) ₁₂	Estimasi	0.287	-0.305			
	SE	0.155	0.195			
	t-value	1.85	-1.56			
	p-value	0.0676	0.1223			

Model	Statistik	AR Parameter			MA Parameter	
		Non Seasonal		Seasonal	Non Seasonal	Seasonal
		AR1 ₀	AR1 ₀	AR2 ₀	MA1 ₀	MA1 ₀
$(1, 0, 0) \times (1, 1, 1)_{12}$	Estimasi	0.218	0.372			-0.976
	SE	0.146	0.184			0.225
	t-value	1.49	2.02			-4.34
	p-value	0.1394	0.0462			0.000
$(1, 0, 1) \times (0, 1, 0)_{12}$	Estimasi	0.575			-0.156	
	SE	0.158			0.166	
	t-value	3.628			-0.936	
	p-value	0.000			0.3515	
$(1, 0, 1) \times (0, 1, 1)_{12}$	Estimasi	0.0483			0.3323	-0.6054
	SE	0.143			0.150	0.220
	t-value	0.338			2.215	-2.751
	p-value	0.7363			0.0292	0.0071
$(1, 0, 1) \times (1, 1, 0)_{12}$	Estimasi	-0.0304	-0.3671		0.4284	
	SE	0.152	0.192		0.168	
	t-value	-0.199	-1.911		2.554	
	p-value	0.8423	0.0591		0.0123	
$(1, 0, 1) \times (1, 1, 1)_{12}$	Estimasi	0.0934	0.2416		0.2349	-0.8592
	SE	0.151	0.190		0.166	0.243
	t-value	0.618	1.270		1.414	-3.533
	p-value	0.5378	0.2073		0.1608	0.000
$(1, 0, 0) \times (2, 1, 0)_{12}$	Estimasi	0.269	-0.453	-0.273		
	SE	0.151	0.190	0.166		
	t-value	1.79	-2.39	-1.65		
	p-value	0.0768	0.0188	0.1027		

b. SLAG 1

Model	Statistik	AR Parameter					MA Parameter			
		Non Seasonal		Seasonal			Non Seasonal		Seasonal	
		AR1 ₀	AR1 ₁	AR1 ₀	AR1 ₁	AR2 ₀	MA1 ₀	MA1 ₁	MA1 ₀	MA1 ₁
$(0, 0, 0) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (1, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 0) \times (1, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (1, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(0, 0, 1) \times (1, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (0, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (0, 1, 1)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									
$(1, 0, 0) \times (1, 1, 0)_{12}$	Estimasi									
	SE									
	t-value									
	p-value									

$(1, 0, 0) \times (1, 1, 0)_{12}$

Model	Statistik	AR Parameter					MA Parameter			
		Non Seasonal		Seasonal			Non Seasonal		Seasonal	
		AR1 ₀	AR1 ₁	AR1 ₀	AR1 ₁	AR2 ₀	MA1 ₀	MA1 ₁	MA1 ₀	MA1 ₁
	SE									
	t-value									
	p-value									
	Estimasi									
$(1, 0, 0) \times (1, 1, 1)_{12}$	SE									
	t-value									
	p-value									
	Estimasi									
$(1, 0, 1) \times (0, 1, 0)_{12}$	SE									
	t-value									
	p-value									
	Estimasi									
$(1, 0, 1) \times (0, 1, 1)_{12}$	SE									
	t-value									
	p-value									
	Estimasi									
$(1, 0, 1) \times (1, 1, 0)_{12}$	SE									
	t-value									
	p-value									
	Estimasi									
$(1, 0, 1) \times (1, 1, 1)_{12}$	SE									
	t-value									
	p-value									
	Estimasi									
$(1, 0, 0) \times (2, 1, 0)_{12}$	SE									
	t-value									
	p-value									
	Estimasi									

14. Hasil Evaluasi RMSE Uniform

a. SLAG 0

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	2.910	4.013	3.964	1.297	2.834
$(0, 0, 0) \times (0, 1, 1)_{12}$	2.962	3.921	4.092	1.331	2.992
$(0, 0, 0) \times (1, 1, 0)_{12}$	2.834	3.928	4.157	1.262	2.848
$(0, 0, 0) \times (1, 1, 1)_{12}$	2.766	3.893	3.782	1.231	2.992
$(0, 0, 1) \times (0, 1, 0)_{12}$	2.771	4.110	4.134	1.224	2.974
$(0, 0, 1) \times (0, 1, 1)_{12}$	2.783	3.807	3.875	1.317	2.943
$(0, 0, 1) \times (1, 1, 0)_{12}$	2.790	3.976	3.861	1.314	2.926
$(0, 0, 1) \times (1, 1, 1)_{12}$	2.824	3.856	3.971	1.277	2.882
$(1, 0, 0) \times (0, 1, 0)_{12}$	3.085	3.886	3.989	1.246	2.919
$(1, 0, 0) \times (0, 1, 1)_{12}$	2.890	4.035	4.118	1.291	2.883
$(1, 0, 0) \times (1, 1, 0)_{12}$	2.916	3.914	3.992	1.293	3.008
$(1, 0, 0) \times (1, 1, 1)_{12}$	2.953	4.011	3.864	1.278	2.964
$(1, 0, 1) \times (0, 1, 0)_{12}$	2.921	4.117	4.042	1.339	2.964
$(1, 0, 1) \times (0, 1, 1)_{12}$	2.868	4.155	4.126	1.318	3.005
$(1, 0, 1) \times (1, 1, 0)_{12}$	2.914	4.153	4.063	1.301	2.986
$(1, 0, 1) \times (1, 1, 1)_{12}$	2.927	3.933	3.872	1.341	2.940
$(1, 0, 0) \times (2, 1, 0)_{12}$	2.941	4.043	3.890	1.292	2.972

b. SLAG 1

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	3.010	4.010	3.981	1.434	3.022
$(0, 0, 0) \times (0, 1, 1)_{12}$	3.056	4.059	4.037	1.491	3.081
$(0, 0, 0) \times (1, 1, 0)_{12}$	3.319	4.411	4.371	2.573	3.310
$(0, 0, 0) \times (1, 1, 1)_{12}$	2.783	3.776	3.757	1.345	2.808
$(0, 0, 1) \times (0, 1, 0)_{12}$	3.045	4.048	4.026	1.466	3.070
$(0, 0, 1) \times (0, 1, 1)_{12}$	3.056	4.059	4.037	1.491	3.081
$(0, 0, 1) \times (1, 1, 0)_{12}$	3.317	4.409	4.369	2.568	3.309
$(0, 0, 1) \times (1, 1, 1)_{12}$	2.886	3.925	3.900	1.569	2.907
$(1, 0, 0) \times (0, 1, 0)_{12}$	2.802	3.798	3.788	1.373	2.839
$(1, 0, 0) \times (0, 1, 1)_{12}$	2.781	3.774	3.752	1.339	2.802
$(1, 0, 0) \times (1, 1, 0)_{12}$	3.307	4.402	4.366	2.535	3.304
$(1, 0, 0) \times (1, 1, 1)_{12}$	2.853	3.881	3.855	1.501	2.872
$(1, 0, 1) \times (0, 1, 0)_{12}$	2.818	3.817	3.813	1.392	2.860
$(1, 0, 1) \times (0, 1, 1)_{12}$	2.803	3.809	3.776	1.348	2.811
$(1, 0, 1) \times (1, 1, 0)_{12}$	3.308	4.402	4.358	2.544	3.296
$(1, 0, 1) \times (1, 1, 1)_{12}$	2.789	3.791	3.760	1.339	2.801
$(1, 0, 0) \times (2, 1, 0)_{12}$	3.697	4.354	4.296	2.853	3.640

15. Hasil Evaluasi RMSE Inverse

a. SLAG 0

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	3.091	4.088	4.070	1.523	3.123
$(0, 0, 0) \times (0, 1, 1)_{12}$	2.807	3.796	3.780	1.386	2.841
$(0, 0, 0) \times (1, 1, 0)_{12}$	3.236	4.338	4.306	2.240	3.250
$(0, 0, 0) \times (1, 1, 1)_{12}$	2.776	3.726	3.716	1.295	2.815
$(0, 0, 1) \times (0, 1, 0)_{12}$	2.806	3.795	3.779	1.385	2.840
$(0, 0, 1) \times (0, 1, 1)_{12}$	2.811	3.801	3.785	1.390	2.845
$(0, 0, 1) \times (1, 1, 0)_{12}$	3.230	4.331	4.300	2.222	3.245
$(0, 0, 1) \times (1, 1, 1)_{12}$	2.753	3.667	3.662	1.294	2.796
$(1, 0, 0) \times (0, 1, 0)_{12}$	3.5441	4.772	4.870	2.117	3.713
$(1, 0, 0) \times (0, 1, 1)_{12}$	3.020	4.044	4.066	1.639	3.105
$(1, 0, 0) \times (1, 1, 0)_{12}$	3.464	4.610	4.628	2.406	3.543
$(1, 0, 0) \times (1, 1, 1)_{12}$	2.792	3.655	3.703	1.462	2.896
$(1, 0, 1) \times (0, 1, 0)_{12}$	3.840	5.212	5.346	2.365	4.053
$(1, 0, 1) \times (0, 1, 1)_{12}$	2.843	3.832	3.822	1.433	2.866
$(1, 0, 1) \times (1, 1, 0)_{12}$	3.236	4.341	4.307	2.232	3.247
$(1, 0, 1) \times (1, 1, 1)_{12}$	2.808	3.726	3.734	1.348	2.870
$(1, 0, 0) \times (2, 1, 0)_{12}$	4.111	5.359	5.384	2.890	4.203

b. SLAG 1

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	1.870	2.171	2.195	1.519	1.839
$(0, 0, 0) \times (0, 1, 1)_{12}$	1.846	2.143	2.164	1.483	1.790
$(0, 0, 0) \times (1, 1, 0)_{12}$	2.283	2.451	2.413	1.836	1.895
$(0, 0, 0) \times (1, 1, 1)_{12}$	1.851	2.162	2.178	1.470	1.781
$(0, 0, 1) \times (0, 1, 0)_{12}$	1.851	2.149	2.172	1.495	1.804
$(0, 0, 1) \times (0, 1, 1)_{12}$	1.840	2.129	2.148	1.469	1.767
$(0, 0, 1) \times (1, 1, 0)_{12}$	2.309	2.469	2.416	1.839	1.909
$(0, 0, 1) \times (1, 1, 1)_{12}$	1.828	2.081	2.096	1.458	1.730
$(1, 0, 0) \times (0, 1, 0)_{12}$	1.754	2.064	2.097	1.418	1.705
$(1, 0, 0) \times (0, 1, 1)_{12}$	1.780	2.079	2.106	1.430	1.717
$(1, 0, 0) \times (1, 1, 0)_{12}$	1.983	2.058	2.026	1.778	2.177
$(1, 0, 0) \times (1, 1, 1)_{12}$	1.806	2.108	2.133	1.464	1.754
$(1, 0, 1) \times (0, 1, 0)_{12}$	1.759	2.225	2.270	1.537	1.914
$(1, 0, 1) \times (0, 1, 1)_{12}$	1.826	2.112	2.129	1.454	1.742
$(1, 0, 1) \times (1, 1, 0)_{12}$	2.525	2.780	2.755	2.128	2.142
$(1, 0, 1) \times (1, 1, 1)_{12}$	1.900	1.999	1.993	1.550	1.629
$(1, 0, 0) \times (2, 1, 0)_{12}$	2.091	2.119	2.129	2.369	3.090

16. Hasil Evaluasi RMSE Korelasi Silang

a. SLAG 0

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$					
$(0, 0, 0) \times (0, 1, 1)_{12}$	2.846	3.827	3.814	1.451	2.884
$(0, 0, 0) \times (1, 1, 0)_{12}$	3.337	4.440	4.413	2.354	3.355
$(0, 0, 0) \times (1, 1, 1)_{12}$	2.809	3.748	3.741	1.349	2.853
$(0, 0, 1) \times (0, 1, 0)_{12}$	2.845	3.826	3.813	1.450	2.883
$(0, 0, 1) \times (0, 1, 1)_{12}$	2.855	3.835	3.822	1.461	2.893
$(0, 0, 1) \times (1, 1, 0)_{12}$	3.337	4.439	4.412	2.345	3.356
$(0, 0, 1) \times (1, 1, 1)_{12}$	2.773	3.671	3.670	1.337	2.821
$(1, 0, 0) \times (0, 1, 0)_{12}$	3.753	4.984	5.094	2.349	3.919
$(1, 0, 0) \times (0, 1, 1)_{12}$	3.144	4.157	4.187	1.799	3.230
$(1, 0, 0) \times (1, 1, 0)_{12}$	3.664	4.808	4.834	2.626	3.740
$(1, 0, 0) \times (1, 1, 1)_{12}$	2.853	3.691	3.748	1.561	2.962
$(1, 0, 1) \times (0, 1, 0)_{12}$	4.107	5.484	5.632	2.644	4.311
$(1, 0, 1) \times (0, 1, 1)_{12}$	2.907	3.885	3.880	1.532	2.954
$(1, 0, 1) \times (1, 1, 0)_{12}$	3.345	4.451	4.422	2.355	3.360

Model	Barat	Selatan	Tengah	Timur	Utara
$(1, 0, 1) \times (1, 1, 1)_{12}$	2.862	3.762	3.776	1.432	2.929
$(1, 0, 0) \times (2, 1, 0)_{12}$					

b. SLAG 1

Model	Barat	Selatan	Tengah	Timur	Utara
$(0, 0, 0) \times (0, 1, 0)_{12}$	1.873	2.170	2.191	1.523	1.843
$(0, 0, 0) \times (0, 1, 1)_{12}$	1.848	2.139	2.157	1.486	1.792
$(0, 0, 0) \times (1, 1, 0)_{12}$	2.194	2.308	2.263	1.764	1.792
$(0, 0, 0) \times (1, 1, 1)_{12}$	1.840	2.121	2.136	1.469	1.761
$(0, 0, 1) \times (0, 1, 0)_{12}$	1.855	2.148	2.156	1.500	1.809
$(0, 0, 1) \times (0, 1, 1)_{12}$	1.841	2.123	2.139	1.471	1.766
$(0, 0, 1) \times (1, 1, 0)_{12}$	2.1284	2.277	2.213	1.722	1.735
$(0, 0, 1) \times (1, 1, 1)_{12}$	1.816	1.914	1.913	1.443	1.577
$(1, 0, 0) \times (0, 1, 0)_{12}$	1.812	2.103	2.125	1.460	1.759
$(1, 0, 0) \times (0, 1, 1)_{12}$	1.857	2.147	2.163	1.488	1.749
$(1, 0, 0) \times (1, 1, 0)_{12}$	2.111	2.183	2.120	1.643	1.679
$(1, 0, 0) \times (1, 1, 1)_{12}$	1.817	1.952	1.959	1.464	1.628
$(1, 0, 1) \times (0, 1, 0)_{12}$	1.766	2.067	2.092	1.422	1.707
$(1, 0, 1) \times (0, 1, 1)_{12}$	1.933	2.242	2.259	1.566	1.894
$(1, 0, 1) \times (1, 1, 0)_{12}$	2.268	2.390	2.330	1.831	1.804
$(1, 0, 1) \times (1, 1, 1)_{12}$	1.897	2.182	2.191	1.512	1.814
$(1, 0, 0) \times (2, 1, 0)_{12}$	2.157	2.128	2.008	1.602	1.810